

Cambridge
Elements

Quantitative
Finance

Machine Learning for Asset Managers

Marcos M.
López de Prado

Cambridge Elements

Các yếu tố trong Tài chính định lượng được

biên tập bởi

Riccardo Rebonato

Trưởng Kinh doanh EDHEC

HỌC MÁY CHO

QUẢN LÝ TÀI SẢN

Đại học Marcos M. López
de Prado Cornell



CAMBRIDGE
UNIVERSITY PRESS

CAMBRIDGE UNIVERSITY PRESS

Nhà in Đại học, Cambridge CB2 8BS, Vương quốc Anh

One Liberty Plaza, Tầng 20, New York, NY 10006, Hoa Kỳ

477 Williamstown Road, Cảng Melbourne, VIC 3207, Úc

314-321, Tầng 3, Khu 3, Diễn đàn Splendor, Trung tâm Quận Jasola,
New Delhi - 110025, Ấn Độ

79 Đường Anson, #06-04/06, Singapore 079906

Nhà xuất bản Đại học Cambridge là một phần của Đại học Cambridge.

Nó thúc đẩy sứ mệnh của trường đại học bằng cách phổ biến kiến thức trong việc theo đuổi
giáo dục, học tập và nghiên cứu ở cấp độ xuất sắc quốc tế cao nhất.

www.cambridge.org Thông

tin về tiêu đề này: www.cambridge.org/9781108792899 Mã số:
[10.1017/9781108883658](https://doi.org/10.1017/9781108883658)

© Công nghệ True Positive, LP 2020

Ấn phẩm này có bản quyền. Tùy thuộc vào ngoại lệ theo luật định và các
điều khoản của thỏa thuận cấp phép tập thể có liên quan, không được sao
chép bất kỳ phần nào mà không có sự cho phép bằng văn bản của Cambridge
University Press.

Xuất bản lần đầu năm 2020

Hồ sơ danh mục cho ấn phẩm này có sẵn tại Thư viện Anh.

ISBN 978-1-108-79289-9 Bìa mềm ISSN

2631-8571 (trực tuyến)

ISSN 2631-8563 (bản in)

Nhà xuất bản Đại học Cambridge không chịu trách nhiệm về tính bền vững hoặc tính chính xác của
các URL cho các trang web internet bên ngoài hoặc của bên thứ ba được đề cập trong ấn phẩm
này và không đảm bảo rằng bất kỳ nội dung nào trên các trang web đó là chính xác hoặc
phù hợp.

Học máy cho các nhà quản lý tài sản

Các yếu tố trong tài chính định lượng

DOI: 10.1017/9781108883658 Lần đầu

tiền xuất bản trực tuyến: Tháng 4 năm 2020

Đại học Marcos M. López de
Prado Cornell

Tác giả liên hệ: ml863@cornell.edu

Tóm tắt: Các chiến lược đầu tư thành công là những triển khai cụ thể của các lý thuyết chung. Một chiến lược đầu tư thiếu cơ sở lý thuyết có khả năng là sai. Do đó, một nhà quản lý tài sản nên tập trung nỗ lực vào việc phát triển một lý thuyết thay vì kiểm tra ngược các quy tắc giao dịch tiềm năng. Mục đích của Yếu tố này là giới thiệu các công cụ học máy (ML) có thể giúp các nhà quản lý tài sản khám phá các lý thuyết kinh tế và tài chính. ML không phải là hộp đen và không nhất thiết phải phù hợp quá mức. Các công cụ ML bổ sung chứ không thay thế các phương pháp thống kê cổ điển. Một số điểm mạnh của ML bao gồm: (1) tập trung vào khả năng dự đoán ngoài mẫu thay vì phân định phương sai trong mẫu; (2) sử dụng các phương pháp tính toán để tránh dựa vào các giả định (có khả năng không thực tế); (3) khả năng "học" các thông số kỹ thuật phức tạp, bao gồm các hiệu ứng tương tác phi tuyến tính, phân cấp và không liên tục trong không gian có nhiều chiều; và (4) khả năng tách biệt tìm kiếm biến khỏi tìm kiếm thông số kỹ thuật, theo cách mạnh mẽ đối với đa cộng tuyến và các hiệu ứng thay thế khác.

Từ khóa: học máy, học không giám sát, học có giám sát, phân cụm, phân loại, dán nhãn, xây dựng danh mục đầu tư

Phân loại JEL: G0, G1, G2, G15, G24, E44

Phân loại AMS: 91G10, 91G60, 91G70, 62C, 60E

© Công nghệ True Positive, LP 2020

ISBN: 9781108792899 (PB), 9781108883658 (OC)

ISSN: 2631-8571 (trực tuyến), 2631-8563 (in)

Nội dung

1 Giới thiệu	1
2. Khử nhiễu và kích nổ	24
3 Khoảng cách đo lường	38
4 Phân cụm tối ưu	52
5 Nhãn tài chính	65
6 Phân tích tầm quan trọng của tính năng	74
7 Xây dựng danh mục đầu tư	92
8 Kiểm tra tập hợp quá mức	105
Phụ lục A: Kiểm tra trên dữ liệu tổng hợp	125
Phụ lục B: Chứng minh Định lý “Chiến lược sai”	128
Tài liệu tham khảo	130
Tài liệu tham khảo	136

1 Giới thiệu

1.1 Động lực

Ở mức độ lớn hơn so với các ngành toán học khác, thống kê là sản phẩm của thời đại. Nếu Francis Galton, Karl Pearson, Ronald Fisher và Jerzy Neyman có thể tiếp cận máy tính, họ có thể đã tạo ra một lĩnh vực hoàn toàn khác. Thống kê cổ điển dựa trên các giả định đơn giản (tuyến tính, độc lập), phân tích trong mẫu, các giải pháp phân tích và các tính chất tiệm cận một phần vì những người sáng lập ra nó có quyền truy cập vào sức mạnh tính toán hạn chế. Ngày nay, nhiều phương pháp kế thừa này vẫn tiếp tục được giảng dạy tại các khóa học đại học và trong các chương trình cấp chứng chỉ chuyên nghiệp, mặc dù các phương pháp tính toán, chẳng hạn như xác thực chéo, ước lượng tổng thể, chính quy hóa, khởi động và Monte Carlo, cung cấp các giải pháp tốt hơn rõ ràng. Theo lời của [Efron và Hastie \(2016, 53\)](#),

hai từ giải thích sở thích cổ điển đối với các mô hình tham số: tính dễ xử lý toán học. Trong thế giới của các thanh trượt và số học cơ học chậm, công thức toán học, theo sự cần thiết, trở thành công cụ tính toán được lựa chọn. Môi trường tính toán phong phú mới của chúng ta đã giải quyết được nút thắt cổ chai toán học, mang đến cho chúng ta một khối lượng kỹ thuật thống kê thực tế hơn, linh hoạt hơn và có phạm vi rộng hơn.

Các vấn đề tài chính đặt ra một thách thức đặc biệt đối với các phương pháp kế thừa đó, vì các hệ thống kinh tế thể hiện mức độ phức tạp vượt quá khả năng nắm bắt của các công cụ thống kê cổ điển ([López de Prado 2019b](#)). Do đó, máy học (ML) đóng vai trò ngày càng quan trọng trong tài chính. Chỉ vài năm trước, rất hiếm khi tìm thấy các ứng dụng ML ngoài dự đoán giá ngắn hạn, thực hiện giao dịch và thiết lập xếp hạng tín dụng. Ngày nay, rất khó để tìm thấy một trường hợp sử dụng mà ML không được triển khai dưới một hình thức nào đó. Xu hướng này khó có thể thay đổi, vì các tập dữ liệu lớn hơn, sức mạnh tính toán lớn hơn và các thuật toán hiệu quả hơn đều hợp sức để mở ra thời kỳ hoàng kim của ML tài chính. Cuộc cách mạng ML tạo ra cơ hội cho các công ty năng động và thách thức cho các nhà quản lý tài sản lỗi thời. Các công ty chống lại cuộc cách mạng này có thể sẽ chia sẻ số phận của Kodak. Một động lực của Yếu tố này là chứng minh cách hiện đại

các công cụ thống kê giúp giải quyết nhiều thiếu sót của các kỹ thuật cổ điển trong bối cảnh quản lý tài sản.

Hầu hết các thuật toán ML ban đầu được thiết kế cho các tập dữ liệu cắt ngang. Điều này hạn chế khả năng ứng dụng trực tiếp của chúng vào các vấn đề tài chính, trong đó việc mô hình hóa các thuộc tính chuỗi thời gian của các tập dữ liệu là điều cần thiết. Cuốn sách trước đây của tôi, *Advances in Financial Machine Learning* (AFML; [López de Prado 2018a](#)), đã giải quyết thách thức trong việc mô hình hóa các thuộc tính chuỗi thời gian của các tập dữ liệu tài chính bằng các thuật toán ML, theo quan điểm của một học giả đồng thời cũng là một người hành nghề.

Học máy dành cho Quản lý tài sản liên quan đến việc trả lời một thách thức khác: làm thế nào chúng ta có thể sử dụng ML để xây dựng các lý thuyết tài chính tốt hơn? Đây không phải là một câu hỏi triết học hay tu từ. Bất kỳ lợi thế nào mà bạn mong muốn đạt được trong tài chính, nó chỉ có thể được biện minh khi người khác mắc phải một sai lầm có hệ thống mà bạn được hưởng lợi.¹ Nếu không có một lý thuyết có thể kiểm chứng giải thích về lợi thế của bạn, thì khả năng là bạn không có lợi thế nào cả. Mô phỏng lịch sử về hiệu suất của một chiến lược đầu tư (kiểm tra ngược) không phải là một lý thuyết; đó là mô phỏng (có khả năng không thực tế) về một quá khứ chưa từng xảy ra (bạn đã không triển khai chiến lược đó cách đây nhiều năm; đó là lý do tại sao bạn đang kiểm tra ngược!). Chỉ có một lý thuyết mới có thể xác định được cơ chế nhân quả rõ ràng cho phép bạn trích xuất lợi nhuận từ trí tuệ tập thể của đám đông - một lý thuyết có thể kiểm chứng giải thích bằng chứng thực tế cũng như các trường hợp phản thực tế (x ngụ ý y và việc không có y ngụ ý việc không có x). Các nhà quản lý tài sản nên tập trung nỗ lực của mình vào việc nghiên cứu các lý thuyết, chứ không phải kiểm tra ngược các quy tắc giao dịch. ML là một công cụ mạnh mẽ để xây dựng các lý thuyết tài chính và mục tiêu chính của Phần này là giới thiệu cho bạn những kỹ thuật thiết yếu mà bạn sẽ cần trong nỗ lực của mình.

1.2 Vấn đề lý thuyết

Thiên nga đen thường được định nghĩa là một sự kiện cực đoan chưa từng được quan sát trước đây. Có người từng nói với tôi rằng các chiến lược đầu tư định lượng là vô ích. Bối rối, tôi hỏi tại sao. Ông ấy trả lời, "Bởi vì tương lai đầy rẫy thiên nga đen, và vì theo định nghĩa, các tập dữ liệu lịch sử không thể chứa các sự kiện chưa từng thấy trước đây, nên các thuật toán ML không thể được đào tạo để dự đoán chúng." Tôi phản biện rằng, trong nhiều trường hợp, thiên nga đen đã được dự đoán.

Hãy để tôi giải thích nghịch lý rõ ràng này bằng một giai thoại. Quay trở lại năm 2010, tôi là người đứng đầu bộ phận tương lai tần suất cao tại một quỹ đầu cơ lớn của Hoa Kỳ. Vào ngày 6 tháng 5, chúng tôi đang chạy các thuật toán cung cấp thanh khoản như thường lệ, thì vào khoảng 12:30 ET, nhiều thuật toán trong số chúng bắt đầu tự động san phẳng các vị thế của chúng. Chúng tôi không can thiệp hoặc ghi đè lên các hệ thống, vì vậy chỉ trong vài phút, mức độ tiếp xúc với thị trường của chúng tôi trở nên rất nhỏ. Hành vi hệ thống này chưa bao giờ xảy ra với chúng tôi trước đây. Nhóm của tôi và tôi đang tiến hành phân tích pháp y về nguyên nhân khiến hệ thống tự đóng cửa thì vào khoảng 14:30 ET, chúng tôi thấy S&P 500 lao dốc, trong vòng vài phút, gần 10% so với giá mở cửa. Ngay sau đó, các hệ thống bắt đầu mua mạnh, hưởng lợi từ đợt tăng giá 5% khi thị trường đóng cửa. Báo chí gọi sự kiện thiên nga đen này là "sự cố chớp nhoáng". Chúng tôi đã hai lần ngạc nhiên trước sự việc này: đầu tiên, chúng tôi không hiểu được cách hệ thống của mình

¹ Điều này cũng đúng trong bối cảnh đầu tư theo yếu tố, khi mà sai lầm có hệ thống có thể được giải thích theo khuôn hướng hành vi, thời hạn đầu tư không phù hợp, khả năng chịu rủi ro, ràng buộc về mặt pháp lý và các biến số khác ảnh hưởng đến quyết định của nhà đầu tư.

dự đoán một sự kiện mà chúng tôi, những nhà phát triển, không lường trước được; thứ hai, chúng tôi không hiểu tại sao hệ thống của chúng tôi bắt đầu mua ngay sau khi thị trường chạm đáy.

Khoảng năm tháng sau, một cuộc điều tra chính thức phát hiện ra rằng vụ sụp đổ có khả năng là do lệnh bán 75.000 hợp đồng tương lai E-mini S&P 500 với tỷ lệ tham gia cao (CFTC 2010). Lệnh lớn đó đã góp phần gây mất cân bằng dai dẳng trong luồng lệnh, khiến các nhà tạo lập thị trường rất khó có thể lật ngược hàng tồn kho của mình mà không phải chịu lỗ. Luồng lệnh độc hại này đã kích hoạt giới hạn dừng giao dịch trên các nhà tạo lập thị trường, những người đã ngừng cung cấp thanh khoản. Các nhà tạo lập thị trường trở thành những người tiếp nhận thanh khoản hung hăng và khi không còn ai ở lại trong lệnh mua, thị trường chắc chắn sẽ sụp đổ (Easley và cộng sự 2011).

Chúng ta không thể dự đoán được sự sụp đổ chớp nhoáng bằng cách xem CNBC hoặc đọc Tạp chí Phố Wall. Đối với hầu hết những người quan sát, sự sụp đổ chớp nhoáng thực sự là một con thiên nga đen không thể đoán trước. Tuy nhiên, nguyên nhân cơ bản của sự sụp đổ chớp nhoáng rất phổ biến. Dòng lệnh hầu như không bao giờ cân bằng hoàn hảo. Trên thực tế, dòng lệnh mất cân bằng là chuẩn mực, với nhiều mức độ dai dẳng khác nhau (ví dụ, được đo bằng tương quan nối tiếp). Hệ thống của chúng tôi đã được đào tạo để giảm vị thế trong điều kiện cực đoan của mất cân bằng dòng lệnh. Khi làm như vậy, chúng tôi được đào tạo để tránh các điều kiện mà ngay sau đó gây ra thiên nga đen. Khi thị trường sụp đổ, hệ thống của chúng tôi nhận ra rằng cơ hội mua với mức chiết khấu 10% bù đắp cho mỗi quan tâm trước đó từ tình trạng mất cân bằng dòng lệnh cực độ và chúng tôi giữ các vị thế mua cho đến khi đóng cửa. Kinh nghiệm này minh họa cho hai bài học quan trọng nhất có trong Yếu tố này.

1.2.1 Bài 1: Bạn cần một lý thuyết

Trái với niềm tin phổ biến, backtesting không phải là một công cụ nghiên cứu. Backtests không bao giờ có thể chứng minh rằng một chiến lược là một kết quả dương tính thực sự và chúng chỉ có thể cung cấp bằng chứng rằng một chiến lược là một kết quả dương tính giả. Không bao giờ phát triển một chiến lược chỉ thông qua backtests. Các chiến lược phải được hỗ trợ bởi lý thuyết, không phải mô phỏng lịch sử. Các lý thuyết của bạn phải đủ tổng quát để giải thích các trường hợp cụ thể, ngay cả khi các trường hợp đó là thiên nga đen. Sự tồn tại của hồ đen đã được dự đoán bởi thuyết tương đối rộng hơn năm thập kỷ trước khi hồ đen đầu tiên được quan sát. Trong câu chuyện trên, lý thuyết vi mô thị trường của chúng tôi (sau này được gọi là lý thuyết VPIN; xem Easley và cộng sự 2011b) đã giúp chúng tôi dự đoán và kiếm lợi nhuận từ thiên nga đen. Không chỉ vậy, công trình lý thuyết của chúng tôi cũng góp phần vào sự phục hồi của thị trường (các đồng nghiệp của tôi thường nói đùa rằng chúng tôi đã giúp đưa "tia chớp" vào "sự sụp đổ chớp nhoáng"). Yếu tố này chứa một số công cụ bạn cần để khám phá ra các lý thuyết của riêng mình.

1.2.2 Bài 2: ML giúp khám phá các lý thuyết

Hãy xem xét cách tiếp cận sau đây để khám phá các lý thuyết tài chính mới. Đầu tiên, bạn áp dụng các công cụ ML để khám phá các biến ẩn liên quan đến một

hiện tượng. Đây là những thành phần mà lý thuyết phải kết hợp để đưa ra dự báo thành công. Các công cụ ML đã xác định những

thành phần; tuy nhiên, chúng không trực tiếp thông báo cho bạn về phương trình chính xác liên kết các thành phần với nhau. Thứ hai, chúng tôi xây dựng một lý thuyết kết nối các thành phần này thông qua một câu lệnh cấu trúc. Câu lệnh cấu trúc này về cơ bản là một hệ phương trình đưa ra giả thuyết về một cơ chế nhân quả cụ thể. Thứ ba, lý thuyết có nhiều hàm ý có thể kiểm chứng vượt ra ngoài các quan sát được các công cụ ML dự đoán trong bước đầu tiên.² Một lý thuyết thành công sẽ dự đoán các sự kiện ngoài mẫu.

Hơn nữa, nó sẽ giải thích không chỉ những điều tích cực (x gây ra y) mà còn cả những điều tiêu cực (sự vắng mặt của y là do sự vắng mặt của x).

Trong quá trình khám phá ở trên, ML đóng vai trò chính trong việc tách rời quá trình tìm kiếm biến khỏi quá trình tìm kiếm thông số kỹ thuật. Các lý thuyết kinh tế thường bị chỉ trích vì dựa trên “các sự kiện có giá trị chân lý chưa biết” (Romer 2016) và các giả định “nói chung là giả mạo” (Solow 2010). Xem xét tính phức tạp của các hệ thống tài chính hiện đại, không có khả năng một nhà nghiên cứu có thể khám phá ra các thành phần của một lý thuyết bằng cách kiểm tra trực quan dữ liệu hoặc bằng cách chạy một vài phép hồi quy. Các phương pháp thống kê cổ điển không cho phép tách rời hai quá trình tìm kiếm này.

Sau khi lý thuyết đã được kiểm tra, nó tự đứng vững. Theo cách này, lý thuyết, chứ không phải thuật toán ML, đưa ra dự đoán. Trong giai đoạn trên, lý thuyết, chứ không phải dự báo trực tuyến do thuật toán ML tự động tạo ra, đã đóng vai trò. Dự báo có cơ sở lý thuyết và không dựa trên một số mô hình không xác định. Đúng là lý thuyết không thể được khám phá nếu không có sự trợ giúp của các kỹ thuật ML, nhưng sau khi lý thuyết được khám phá, thuật toán ML không đóng vai trò gì trong quyết định đóng các vị thế hai giờ trước khi xảy ra sự cố flash crash. Ứng dụng sâu sắc nhất của ML trong tài chính là để khám phá các lý thuyết. Bạn có thể sử dụng ML thành công để đưa ra dự báo tài chính; tuy nhiên, đó không nhất thiết là cách sử dụng khoa học tốt nhất của công nghệ này (đặc biệt nếu mục tiêu của bạn là phát triển các chiến lược đầu tư có năng lực cao).

1.3 Các nhà khoa học sử dụng ML như thế nào

Thuật toán ML học các mẫu phức tạp trong không gian nhiều chiều với ít sự hướng dẫn của con người về việc chỉ định mô hình. Việc các mô hình ML không cần phải được nhà nghiên cứu chỉ định đã khiến nhiều người kết luận sai lầm rằng ML phải

²

Một lý thuyết có thể được kiểm tra bằng các công cụ mạnh hơn là kiểm tra ngược. Ví dụ, chúng ta có thể điều tra xem nhà tạo lập thị trường nào đã mất tiền trong vụ sụp đổ chớp nhoáng. Họ có theo dõi tình trạng mất cân bằng dòng lệnh không? Các nhà tạo lập thị trường theo dõi tình trạng mất cân bằng dòng lệnh có hoạt động tốt hơn không? Chúng ta có thể tìm thấy bằng chứng về sự thoái lui trước đó của họ trong các thông điệp FIX của ngày hôm đó không? Một mô phỏng lịch sử về một quy tắc giao dịch không thể cung cấp cho chúng ta mức độ hiểu biết này.

là một hộp đen. Theo quan điểm đó, ML chỉ là một “nhà tiên tri”,³ một cỗ máy dự đoán mà không thể trích xuất bất kỳ hiểu biết nào. Quan điểm hộp đen về ML là một quan niệm sai lầm. Nó được thúc đẩy bởi các ứng dụng công nghiệp phổ biến của ML, nơi mà việc tìm kiếm các dự đoán tốt hơn quan trọng hơn nhu cầu hiểu biết về mặt lý thuyết. Một đánh giá về những đột phá khoa học gần đây cho thấy những ứng dụng hoàn toàn khác biệt của ML trong khoa học, bao gồm:

- 1 Sự tồn tại: ML đã được triển khai để đánh giá tính hợp lý của một lý thuyết trên tất cả các lĩnh vực khoa học, thậm chí vượt ra ngoài các ngành khoa học thực nghiệm. Đáng chú ý, các thuật toán ML đã giúp tạo ra các khám phá toán học. Các thuật toán ML không thể chứng minh một định lý, tuy nhiên chúng có thể chỉ ra sự tồn tại của một định lý chưa được khám phá, sau đó có thể được suy đoán và cuối cùng là chứng minh. Nói cách khác, nếu có thể dự đoán được điều gì đó thì hy vọng rằng cơ chế đó có thể được phát hiện (*Gryak và cộng sự, sắp xuất bản*).
- 2 Tầm quan trọng: Thuật toán ML có thể xác định nội dung thông tin tương đối của các biến giải thích (các tính năng, theo cách nói của ML) cho mục đích giải thích và/hoặc dự đoán (*Liu 2004*). Ví dụ, phương pháp độ chính xác giảm trung bình (MDA) tuân theo các bước sau: (1) Phù hợp với thuật toán ML trên một tập dữ liệu cụ thể; (2) suy ra độ chính xác được xác thực chéo ngoài mẫu; (3) lặp lại bước (2) sau khi xáo trộn chuỗi thời gian của các tính năng riêng lẻ hoặc các kết hợp tính năng; (4) tính toán sự suy giảm độ chính xác giữa (2) và (3). Việc xáo trộn chuỗi thời gian của một tính năng quan trọng sẽ khiến độ chính xác suy giảm đáng kể. Do đó, mặc dù MDA không khám phá ra cơ chế cơ bản, nhưng nó khám phá ra các biến cần phải là một phần của lý thuyết.
3. Nguyên nhân: Thuật toán ML thường được sử dụng để đánh giá suy luận nhân quả theo các bước sau: (1) Phù hợp với thuật toán ML trên dữ liệu lịch sử để dự đoán kết quả, không có hiệu ứng. Mô hình này không mang tính lý thuyết và hoàn toàn được thúc đẩy bởi dữ liệu (giống như một nhà tiên tri); (2) thu thập các quan sát về kết quả khi có hiệu ứng; (3) sử dụng thuật toán ML phù hợp trong (1) để dự đoán quan sát được thu thập trong (2). Lỗi dự đoán phần lớn có thể được quy cho hiệu ứng và có thể đề xuất một lý thuyết về nhân quả (*Varian 2014; Athey 2015*).
- 4 Người theo chủ nghĩa giản lược: Các kỹ thuật ML rất cần thiết cho việc trực quan hóa các tập dữ liệu lớn, đa chiều và phức tạp. Ví dụ, các thuật toán học tập đa dạng có thể nhóm một số lượng lớn các quan sát thành một tập hợp con thu gọn của các nhóm ngang hàng, sau đó có thể phân tích các đặc tính khác biệt của chúng (*Schlecht và cộng sự, 2008*).

³ Ở đây chúng tôi sử dụng định nghĩa chung về oracle trong lý thuyết phức tạp: một hộp đen có khả năng đưa ra giải pháp cho bất kỳ trường hợp nào của một vấn đề tính toán nhất định.

5 Retriever: ML được sử dụng để quét qua dữ liệu lớn để tìm kiếm các mẫu mà con người không nhận ra. Ví dụ, mỗi đêm, các thuật toán ML được cung cấp hàng triệu hình ảnh để tìm kiếm siêu tân tinh. Khi chúng tìm thấy một hình ảnh có xác suất cao chứa siêu tân tinh, các kính thiên văn đất liền có thể được hướng đến một khu vực cụ thể trong vũ trụ, nơi con người sẽ xem xét kỹ lưỡng dữ liệu (Lochner và cộng sự, 2016). Một ví dụ thứ hai là phát hiện giá trị ngoại lệ. Việc tìm ra giá trị ngoại lệ là một vấn đề dự đoán chứ không phải là vấn đề giải thích. Thuật toán ML có thể phát hiện ra một quan sát bất thường, dựa trên cấu trúc phức tạp mà nó tìm thấy trong dữ liệu, ngay cả khi cấu trúc đó không được giải thích cho chúng ta (Hodge và Austin, 2004).

Thay vì thay thế các lý thuyết, ML đóng vai trò quan trọng trong việc giúp các nhà khoa học hình thành các lý thuyết dựa trên bằng chứng thực nghiệm phong phú. Tương tự như vậy, ML mở ra cơ hội cho các nhà kinh tế áp dụng các công cụ khoa học dữ liệu mạnh mẽ để phát triển các lý thuyết hợp lý.


1.4 Hai loại quá khớp

Mặt tối của tính linh hoạt của ML là, trong tay những người thiếu kinh nghiệm, các thuật toán này có thể dễ dàng quá khớp dữ liệu. Triệu chứng chính của quá khớp là sự khác biệt giữa hiệu suất trong mẫu và ngoài mẫu của mô hình (được gọi là lỗi tổng quát hóa). Chúng ta có thể phân biệt giữa hai loại quá khớp: quá khớp xảy ra trên tập huấn luyện và quá khớp xảy ra trên tập kiểm tra. Hình 1.1 tóm tắt cách ML xử lý cả hai loại quá khớp.

1.4.1 Quá trình lắp ráp bộ huấn luyện

Quá trình lắp ráp quá mức của bộ huấn luyện là kết quả của việc chọn một thông số kỹ thuật linh hoạt đến mức nó giải thích không chỉ tín hiệu mà còn cả nhiễu. Vấn đề với việc nhầm lẫn tín hiệu với nhiễu là nhiễu, theo định nghĩa, là không thể đoán trước. Một mô hình quá mức sẽ đưa ra những dự đoán sai với độ tin cậy không có cơ sở, điều này sẽ dẫn đến hiệu suất kém ngoài mẫu (hoặc thậm chí trong một mẫu giả ngoài mẫu, như trong một thử nghiệm ngược).

Các nhà nghiên cứu ML nhận thức sâu sắc về vấn đề này, họ giải quyết theo ba cách bổ sung cho nhau. Cách tiếp cận đầu tiên để sửa lỗi quá khớp tập huấn luyện là đánh giá lỗi tổng quát hóa, thông qua các kỹ thuật lấy mẫu lại (như xác thực chéo) và các phương pháp Monte Carlo. Phụ lục A mô tả các kỹ thuật và phương pháp này chi tiết hơn. Cách tiếp cận thứ hai để giảm quá khớp tập huấn luyện là các phương pháp chính quy hóa, giúp ngăn ngừa độ phức tạp của mô hình trừ khi có thể biện minh theo sức mạnh giải thích lớn hơn. Mô hình



Hình 1.1 Giải pháp cho hai loại quá khớp.

Tính tiết kiệm có thể được thực thi bằng cách giới hạn số lượng tham số (ví dụ: LASSO) hoặc hạn chế cấu trúc của mô hình (ví dụ: dừng sớm). Cách tiếp cận thứ ba để giải quyết tình trạng quá khớp tập hợp là các kỹ thuật tổng hợp, giúp giảm phương sai của lỗi bằng cách kết hợp các dự báo của một tập hợp các ước lượng. Ví dụ, chúng ta có thể kiểm soát rủi ro quá khớp một khu rừng ngẫu nhiên trên một tập hợp tập hợp theo ít nhất ba cách: (1) xác thực chéo các dự báo; (2) giới hạn độ sâu của mỗi cây; và (3) thêm nhiều cây hơn.

Tóm lại, một backtest có thể gợi ý về sự xuất hiện của quá khớp tập huấn luyện, có thể được khắc phục bằng cách sử dụng các phương pháp trên. Thật không may, backtest không có tác dụng đối với loại quá khớp thứ hai, như được giải thích tiếp theo.

1.4.2 Kiểm tra quá khớp tập

Hãy tưởng tượng rằng một người bạn tuyên bố rằng anh ta có một kỹ thuật để dự đoán vé trúng thưởng trong kỳ xổ số tiếp theo. Kỹ thuật của anh ta không chính xác, vì vậy anh ta phải mua nhiều hơn một vé. Tất nhiên, nếu anh ta mua tất cả các vé, thì không có gì ngạc nhiên khi anh ta sẽ trúng thưởng. Bạn sẽ cho phép anh ta mua bao nhiêu vé trước khi kết luận rằng phương pháp của anh ta vô dụng? Để đánh giá độ chính xác của kỹ thuật của anh ta, bạn nên điều chỉnh theo thực tế là anh ta đã mua nhiều vé. Tương tự như vậy, các nhà nghiên cứu chạy nhiều bài kiểm tra thống kê trên cùng một tập dữ liệu có nhiều khả năng đưa ra khám phá sai. Bằng cách áp dụng cùng một bài kiểm tra trên cùng một tập dữ liệu nhiều lần, chắc chắn rằng cuối cùng một nhà nghiên cứu sẽ đưa ra khám phá sai. Sai lệch lựa chọn này xuất phát từ việc điều chỉnh mô hình để hoạt động tốt trên tập kiểm tra, chứ không phải tập huấn luyện.

Một ví dụ khác về việc quá khớp bộ kiểm tra xảy ra khi một nhà nghiên cứu kiểm tra ngược một chiến lược và cố ý điều chỉnh nó cho đến khi đầu ra đạt được hiệu suất mục tiêu. Chu kỳ kiểm tra ngược-điều chỉnh-kiểm tra ngược đó là một bài tập vô ích mà chắc chắn sẽ kết thúc bằng một chiến lược quá khớp (một kết quả dương tính giả). Thay vào đó, nhà nghiên cứu nên dành thời gian để điều tra cách thức quá trình nghiên cứu đã khiến cô ấy hiểu sai về việc kiểm tra ngược một chiến lược sai. Nói cách khác, một kiểm tra ngược hoạt động kém là một cơ hội để sửa chữa quá trình nghiên cứu, chứ không phải là một cơ hội để sửa chữa một chiến lược đầu tư cụ thể.

Hầu hết các khám phá được công bố trong lĩnh vực tài chính có khả năng là sai, do bộ kiểm tra quá phù hợp. ML không gây ra cuộc khủng hoảng hiện tại trong nghiên cứu tài chính (Harvey et al. 2016). Cuộc khủng hoảng đó là do việc sử dụng sai rộng rãi các phương pháp thống kê cổ điển trong tài chính, và đặc biệt là p-hacking. ML có thể giúp giải quyết vấn đề về việc lấp quá mức bộ kiểm tra, theo ba cách. Đầu tiên, chúng ta có thể theo dõi số lượng các bài kiểm tra độc lập mà một nhà nghiên cứu đã chạy, để đánh giá khả năng rằng ít nhất một trong các kết quả là một khám phá sai (được gọi là tỷ lệ lỗi theo gia đình, hay FWER). Tỷ lệ Sharpe giảm phát (Bailey và López de Prado 2014) như sau

một cách tiếp cận tương tự trong bối cảnh kiểm tra ngược, như đã giải thích trong [Phần 8](#). Nó tương đương với việc kiểm soát số lượng vé số mà bạn của bạn đã mua. Thứ hai, trong khi dễ dàng để phù hợp quá mức một mô hình với một tập kiểm tra, thì khó có thể phù hợp quá mức một mô hình với hàng nghìn tập kiểm tra cho mỗi chứng khoán. Hàng nghìn tập kiểm tra đó có thể được tạo ra bằng cách lấy mẫu lại các phân tách kết hợp của các tập huấn luyện và tập kiểm tra. Đây là cách tiếp cận tiếp theo là phương pháp xác thực chéo đã thanh lọc kết hợp hoặc CPCV (AFML, chương 12). Thứ ba, chúng ta có thể sử dụng các chuỗi lịch sử để ước tính quy trình tạo dữ liệu cơ bản và lấy mẫu các tập dữ liệu tổng hợp khớp với các thuộc tính thống kê được quan sát thấy trong lịch sử. Các phương pháp Monte Carlo đặc biệt mạnh mẽ trong việc tạo ra các tập dữ liệu tổng hợp khớp với các thuộc tính thống kê của một chuỗi lịch sử. Các kết luận từ các thử nghiệm này phụ thuộc vào tính đại diện của quy trình tạo dữ liệu ước tính (AFML, chương 13). Ưu điểm chính của cách tiếp cận này là những kết luận đó không liên quan đến một hiện thực cụ thể (được quan sát) của quá trình tạo dữ liệu mà liên quan đến toàn bộ sự phân phối các hiện thực ngẫu nhiên. Theo ví dụ của chúng tôi, điều này tương đương với việc sao chép trò chơi xổ số và lặp lại nhiều lần, để chúng ta có thể loại trừ yếu tố may rủi.

Tóm lại, có nhiều giải pháp thực tế cho vấn đề quá khớp tập huấn luyện và tập kiểm tra. Các giải pháp này không phải là không thể sai cũng không phải là không tương thích, và lời khuyên của tôi là bạn nên áp dụng tất cả các giải pháp đó. Đồng thời, tôi phải nhấn mạnh rằng không có kiểm tra ngược nào có thể thay thế một lý thuyết, vì ít nhất hai lý do: (1) kiểm tra ngược không thể mô phỏng thiên nga đen - chỉ có các lý thuyết mới có đủ chiều rộng và chiều sâu cần thiết để xem xét các sự kiện chưa từng thấy trước đây; (2) kiểm tra ngược có thể ám chỉ rằng một chiến lược có lợi nhuận, nhưng chúng không cho chúng ta biết lý do tại sao. Chúng không phải là một thí nghiệm được kiểm soát. Chỉ có một lý thuyết mới có thể nêu cơ chế nhân quả và xây dựng một loạt các dự đoán và hàm ý có thể được kiểm tra độc lập về các sự kiện và phản sự kiện. Một số hàm ý này thậm chí có thể được kiểm tra bên ngoài phạm vi đầu tư. Ví dụ, lý thuyết VPIN dự đoán rằng các nhà tạo lập thị trường sẽ phải chịu tình trạng dừng lỗ do mất cân bằng dòng lệnh liên tục. Ngoài việc kiểm tra xem mất cân bằng dòng lệnh có gây ra tình trạng giảm thanh khoản hay không, các nhà nghiên cứu cũng có thể kiểm tra xem các nhà tạo lập thị trường có bị lỗ trong cuộc khủng hoảng chớp nhoáng hay không (gợi ý: họ đã bị lỗ). Bài kiểm tra sau này có thể được thực hiện bằng cách xem xét các báo cáo tài chính, độc lập với bằng chứng có trong hồ sơ giá cả và báo giá của sàn giao dịch.

1.5 Phác thảo

Phần tử này cung cấp cho các nhà quản lý tài sản hướng dẫn từng bước để xây dựng các lý thuyết tài chính với sự trợ giúp của các phương pháp ML. Để đạt được mục tiêu đó, mỗi phần đều sử dụng những gì chúng ta đã học được trong các phần trước. Mỗi phần (trừ phần giới thiệu này)

chứa một phân tích thực nghiệm, trong đó các phương pháp được giải thích được đưa vào thử nghiệm trong các thí nghiệm Monte Carlo.

Bước đầu tiên trong việc xây dựng một lý thuyết là thu thập dữ liệu minh họa cách một số biến liên quan đến nhau. Trong các thiết lập tài chính, những dữ liệu đó thường có dạng ma trận hiệp phương sai. Chúng tôi sử dụng ma trận hiệp phương sai để chạy hồi quy, tối ưu hóa danh mục đầu tư, quản lý rủi ro, tìm kiếm mối liên kết, v.v. Tuy nhiên, ma trận hiệp phương sai tài chính nổi tiếng là nhiễu. Một tỷ lệ tương đối nhỏ thông tin mà chúng chứa là tín hiệu, bị các lực lượng chèn lệch giá trị tiêu một cách có hệ thống. [Phần 2](#) giải thích cách khử nhiễu ma trận hiệp phương sai mà không từ bỏ tín hiệu nhỏ mà nó chứa. Hầu hết các cuộc thảo luận tập trung vào lý thuyết ma trận ngẫu nhiên, nhưng cốt lõi của giải pháp nằm ở một kỹ thuật ML: ước tính mật độ hạt nhân.

Nhiều câu hỏi nghiên cứu liên quan đến khái niệm tương đồng hoặc khoảng cách. Ví dụ, chúng ta có thể quan tâm đến việc hiểu mức độ liên quan chặt chẽ giữa hai biến. Ma trận hiệp phương sai khử nhiễu có thể rất hữu ích để suy ra số liệu khoảng cách từ các mối quan hệ tuyến tính. Mô hình hóa các mối quan hệ phi tuyến tính đòi hỏi các khái niệm nâng cao hơn. [Phần 3](#) cung cấp một khuôn khổ lý thuyết thông tin để trích xuất các tín hiệu phức tạp từ dữ liệu nhiễu.

Đặc biệt, nó cho phép chúng ta xác định các số liệu khoảng cách với các giả định tối thiểu liên quan đến các biến cơ bản đặc trưng cho không gian số liệu. Các số liệu khoảng cách này có thể được coi là một khái quát phi tuyến tính của khái niệm tương quan.

Một trong những ứng dụng của ma trận khoảng cách là nghiên cứu xem một số biến có liên quan chặt chẽ hơn với nhau so với các biến còn lại hay không, do đó tạo thành các cụm. Phân cụm có nhiều ứng dụng trong tài chính, như trong phân loại nhóm tài sản, xây dựng danh mục đầu tư, giảm chiều hoặc mô hình hóa mạng lưới các tác nhân. Một vấn đề chung trong phân cụm là tìm số lượng cụm tối ưu. [Phần 4](#) giới thiệu thuật toán ONC, cung cấp giải pháp chung cho vấn đề này. Nhiều trường hợp sử dụng khác nhau cho thuật toán này được trình bày trong suốt Phần tử này.

Phân cụm là một vấn đề học tập không giám sát. Trước khi chúng ta có thể đi sâu vào các vấn đề học tập có giám sát, chúng ta cần đánh giá các cách dán nhãn dữ liệu tài chính. Hiệu quả của thuật toán ML có giám sát phụ thuộc rất nhiều vào loại vấn đề mà chúng ta cố gắng giải quyết. Ví dụ, có thể khó dự báo lợi nhuận S&P 500 của ngày mai hơn là dấu hiệu của động thái 5% tiếp theo của nó. Các tính năng khác nhau phù hợp với các loại nhãn khác nhau. Các nhà nghiên cứu nên cân nhắc cẩn thận phương pháp dán nhãn mà họ áp dụng cho dữ liệu của mình. [Phần 5](#) thảo luận về ưu điểm của các phương án thay thế khác nhau.

AFML cảnh báo độc giả rằng backtesting không phải là một công cụ nghiên cứu. Tầm quan trọng của tính năng là. Backtest không thể giúp chúng ta phát triển một lý thuyết kinh tế hoặc tài chính.

Để làm được điều đó, chúng ta cần hiểu sâu hơn về các biến liên quan đến một hiện tượng.

Phần 6 nghiên cứu các công cụ ML để đánh giá tầm quan trọng của các biến giải thích và giải thích cách các công cụ này vượt qua nhiều cảnh báo của các phương pháp cổ điển, chẳng hạn như giá trị p . Một mối quan tâm đặc biệt là làm thế nào để khắc phục tình trạng thiếu độ tin cậy của giá trị p trong điều kiện đa cộng tuyến. Để giải quyết vấn đề này, chúng ta phải áp dụng những gì đã học được trong tất cả các phần trước, bao gồm khử nhiễu (Phần 2), số liệu khoảng cách (Phần 3), phân cụm (Phần 4) và dán nhãn (Phần 5).

Khi bạn đã có lý thuyết tài chính, bạn có thể sử dụng khám phá của mình để phát triển chiến lược đầu tư. Việc thiết kế chiến lược đó sẽ đòi hỏi phải đưa ra một số quyết định đầu tư trong điều kiện không chắc chắn. Với mục đích đó, các phương pháp tối ưu hóa danh mục đầu tư trung bình-phương sai được biết đến và sử dụng rộng rãi, mặc dù chúng nổi tiếng là không ổn định. Theo truyền thống, sự bất ổn này đã được giải quyết theo một số cách, chẳng hạn như đưa ra các ràng buộc mạnh, thêm các tiên nghiệm, thu hẹp ma trận hiệp phương sai và các kỹ thuật tối ưu hóa mạnh mẽ khác. Nhiều nhà quản lý tài sản quen thuộc với sự bất ổn do nhiễu trong ma trận hiệp phương sai gây ra.

Ít nhà quản lý tài sản nhận ra rằng một số cấu trúc dữ liệu nhất định (các loại tín hiệu) cũng là nguồn bất ổn đối với các giải pháp trung bình-phương sai. **Phần 7** giải thích lý do tại sao tín hiệu có thể là nguồn bất ổn và cách các phương pháp ML có thể giúp sửa lỗi.

Cuối cùng, một cuốn sách về ML tài chính sẽ không hoàn chỉnh nếu không có phần giải quyết chi tiết về cách đánh giá khả năng khám phá của bạn là sai, do kết quả của việc khớp quá mức bộ kiểm tra. **Phần 8** giải thích các mối nguy hiểm của việc khớp quá mức kiểm tra ngược và cung cấp một số giải pháp thực tế cho vấn đề sai lệch lựa chọn trong quá trình kiểm tra nhiều lần.

1.6 Đối tượng

Nếu, giống như hầu hết các nhà quản lý tài sản, bạn thường xuyên tính toán ma trận hiệp phương sai, sử dụng tương quan, tìm kiếm các biểu diễn chiều thấp của không gian chiều cao, xây dựng các mô hình dự đoán, tính toán các giá trị p , giải các tối ưu hóa phương sai trung bình hoặc áp dụng cùng một bài kiểm tra nhiều lần trên một tập dữ liệu nhất định, bạn cần phải đọc Phần tử này. Trong đó, bạn sẽ tìm hiểu rằng các ma trận hiệp phương sai tài chính có nhiễu và chúng cần được làm sạch trước khi chạy hồi quy hoặc tính toán danh mục đầu tư tối ưu (**Phần 2**). Bạn sẽ tìm hiểu rằng các tương quan đo lường một định nghĩa rất hẹp về sự phụ thuộc lẫn nhau và rằng nhiều số liệu lý thuyết thông tin có hiểu biết sâu sắc hơn (**Phần 3**). Bạn sẽ tìm hiểu các cách trực quan để giảm chiều của một không gian, không liên quan đến việc thay đổi cơ sở.

Không giống như PCA, các phương pháp giảm chiều dựa trên ML cung cấp kết quả trực quan (**Phần 4**). Thay vì hướng đến các dự đoán chân trời cố định không hợp lý, bạn sẽ học các cách thay thế để đặt ra các vấn đề dự đoán tài chính có thể được giải quyết với độ chính xác cao hơn (**Phần 5**). Bạn sẽ học các phương pháp hiện đại

các giải pháp thay thế cho các giá trị p cổ điển (Phần 6). Bạn sẽ học cách giải quyết vấn đề bất ổn gây ảnh hưởng đến danh mục đầu tư trung bình-phương sai (Phần 7). Và bạn sẽ học cách đánh giá xác suất khám phá của bạn là sai do kết quả của nhiều lần thử nghiệm (Phần 8). Nếu bạn làm việc trong ngành quản lý tài sản hoặc tài chính học thuật, thì Element này dành cho bạn.

1.7 Năm quan niệm sai lầm phổ biến về ML tài chính

Financial ML là một công nghệ mới. Như thường lệ với các công nghệ mới, sự ra đời của nó đã tạo ra một số quan niệm sai lầm. Dưới đây là một số quan niệm sai lầm phổ biến nhất.

1.7.1 ML là Chén Thánh so với ML là Vô dụng

Lượng cường điệu và phản cường điệu xung quanh ML thách thức logic. Sự cường điệu tạo ra một loạt kỳ vọng có thể không được đáp ứng trong tương lai gần.

Counterhype cố gắng thuyết phục khán giả rằng ML không có gì đặc biệt và các phương pháp thống kê cổ điển đã tạo ra kết quả mà những người đam mê ML tuyên bố.

Những người chỉ trích ML đôi khi lập luận rằng "cảnh báo X trong hồi quy tuyến tính không phải là vấn đề lớn", trong đó X có thể có nghĩa là mô hình không đúng, đa cộng tuyến, thiếu hồi quy, hiệu ứng tương tác phi tuyến tính, v.v. Trên thực tế, bất kỳ vi phạm nào trong số các giả định cổ điển này sẽ dẫn đến việc chấp nhận các biến không có thông tin (một kết quả dương tính giả) và/hoặc từ chối các biến có thông tin (một kết quả âm tính giả). Để biết ví dụ, hãy xem Phần 6.

Một lỗi phổ biến khác là tin rằng định lý giới hạn trung tâm đôi khi cách biện minh cho việc sử dụng các mô hình hồi quy tuyến tính ở mọi nơi. Lập luận như sau: với đủ số quan sát, Chuẩn tắc sẽ thắng thế và các mô hình tuyến tính cung cấp sự phù hợp tốt với cấu trúc tương quan tiềm ẩn. "CLT Hail Mary pass" này là một tưởng tượng của sinh viên đại học: đúng vậy, giá trị trung bình mẫu hội tụ trong phân phối theo Gauss, nhưng không phải bản thân mẫu! Và sự hội tụ đó chỉ xảy ra nếu các quan sát độc lập và phân phối giống hệt nhau. Chỉ cần một vài dòng mã để chứng minh rằng hồi quy không xác định đúng sẽ hoạt động kém, cho dù chúng ta cung cấp cho nó hàng nghìn hay hàng tỷ quan sát.

Cả hai thái cực (thối phồng và phản thối phồng) đều ngăn cản các nhà đầu tư nhận ra giá trị thực và khác biệt mà ML mang lại ngày nay. ML là thống kê hiện đại và nó giúp khắc phục nhiều cảnh báo của các kỹ thuật cổ điển đã làm các nhà quản lý tài sản bận tâm trong nhiều thập kỷ. Xem López de Prado (2019c) để biết nhiều ví dụ về các ứng dụng hiện tại của ML trong tài chính.

1.7.2 ML là một hộp đen

Đây có lẽ là huyền thoại phổ biến nhất xung quanh ML. Mọi phòng thí nghiệm nghiên cứu trên thế giới đều sử dụng ML ở một mức độ nào đó, vì vậy rõ ràng ML tương thích với phương pháp khoa học. ML không chỉ không phải là hộp đen mà như [Mục 6](#) giải thích, các công cụ nghiên cứu dựa trên ML có thể sâu sắc hơn các phương pháp thống kê truyền thống (bao gồm cả kinh tế lượng). Các mô hình ML có thể được diễn giải thông qua một số quy trình, chẳng hạn như PDP, ICE, ALE, Friedman's H-stat, MDI, MDA, giá trị thay thế toàn cục, LIME và giá trị Shapley, cùng nhiều quy trình khác. Xem [Molnar \(2019\)](#) để biết cách xử lý chi tiết về khả năng diễn giải ML.

Việc ai đó áp dụng ML như một hộp đen hay hộp trắng là vấn đề lựa chọn cá nhân. Điều tương tự cũng đúng với nhiều chủ đề kỹ thuật khác. Cá nhân tôi không quan tâm nhiều đến cách chiếc xe của tôi hoạt động, và tôi phải thú nhận rằng tôi chưa bao giờ mở nắp capo để xem động cơ (tôi thích toán học, không phải cơ học).

Vì vậy, đối với tôi, xe của tôi vẫn là một hộp đen. Tôi không đổ lỗi cho các kỹ sư thiết kế xe của tôi vì sự thiếu tò mò của tôi, và tôi biết rằng những người thợ máy làm việc tại gara của tôi coi xe của tôi là một hộp trắng. Tương tự như vậy, lời khẳng định rằng ML là một hộp đen cho thấy một số người đã chọn áp dụng ML, và đó không phải là sự thật phổ quát.

1.7.3 Tài chính không đủ dữ liệu cho ML

Đúng là một số thuật toán ML, đặc biệt là trong bối cảnh dự đoán giá, đòi hỏi rất nhiều dữ liệu. Đó là lý do tại sao một nhà nghiên cứu phải chọn đúng thuật toán cho một công việc cụ thể. Mặt khác, những người chỉ trích ML đưa ra lập luận này dường như bỏ qua thực tế là nhiều ứng dụng ML trong tài chính không yêu cầu bất kỳ dữ liệu lịch sử nào. Các ví dụ bao gồm phân tích rủi ro, xây dựng danh mục đầu tư, phát hiện giá trị ngoại lai, tầm quan trọng của tính năng và phương pháp định cỡ cược. Mỗi phần trong Phần tử này trình bày các tính chất toán học của ML mà không dựa vào bất kỳ chuỗi lịch sử nào. Ví dụ, [Phần 7](#) đánh giá độ chính xác của thuật toán xây dựng danh mục đầu tư dựa trên ML thông qua các thí nghiệm Monte Carlo.

Kết luận rút ra từ hàng triệu mô phỏng Monte Carlo dạy cho chúng ta một số điều-

điều về các tính chất toán học chung của một cách tiếp cận cụ thể. Bằng chứng giai thoại có được từ một số ít các mô phỏng lịch sử không khớp

để đánh giá nhiều tình huống khác nhau.

Các ứng dụng ML tài chính khác, như phân tích tình cảm, phòng ngừa sâu, xếp hạng tín dụng, thực hiện và các tập dữ liệu thương mại tư nhân, có rất nhiều dữ liệu. Cuối cùng, trong một số bối cảnh, các nhà nghiên cứu có thể tiến hành các thí nghiệm có kiểm soát ngẫu nhiên, trong đó họ có thể tạo ra dữ liệu của riêng mình và thiết lập các cơ chế nhân quả chính xác. Ví dụ, chúng ta có thể diễn đạt lại một bài báo và so sánh việc trích xuất tình cảm của ML với kết luận của con người, kiểm soát

nhiều thay đổi khác nhau. Tương tự như vậy, chúng ta có thể thử nghiệm phản ứng của thị trường đối với các triển khai thay thế của thuật toán thực thi trong các điều kiện tương đương.

1.7.4 Tỷ lệ tín hiệu trên nhiễu quá thấp trong tài chính

Không có nghi ngờ gì rằng các tập dữ liệu tài chính thể hiện tỷ lệ tín hiệu trên nhiễu thấp hơn so với các tập được sử dụng bởi các ứng dụng ML khác (một điểm mà chúng tôi sẽ chứng minh trong [Phần 2](#)). Vì tỷ lệ tín hiệu trên nhiễu rất thấp trong tài chính, nên dữ liệu riêng lẻ không đủ tốt để dựa vào các dự đoán hộp đen. Điều đó không có nghĩa là ML không thể được sử dụng trong tài chính. Điều đó có nghĩa là chúng ta phải sử dụng ML theo cách khác, do đó có khái niệm ML tài chính là một chủ đề nghiên cứu riêng biệt. ML tài chính không chỉ là ứng dụng đơn thuần của ML chuẩn vào các tập dữ liệu tài chính. ML tài chính bao gồm các kỹ thuật ML được thiết kế đặc biệt để giải quyết các thách thức cụ thể mà các nhà nghiên cứu tài chính phải đối mặt, giống như kinh tế lượng không chỉ đơn thuần là ứng dụng các kỹ thuật thống kê chuẩn vào các tập dữ liệu kinh tế.

Mục tiêu của ML tài chính phải là hỗ trợ các nhà nghiên cứu trong việc khám phá ra các lý thuyết kinh tế mới. Các lý thuyết được khám phá ra, chứ không phải các thuật toán ML, sẽ tạo ra các dự báo. Điều này không khác gì cách các nhà khoa học sử dụng ML trong mọi lĩnh vực nghiên cứu.

1.7.5 Rủi ro của việc quá phù hợp là quá cao trong tài chính

[Phần 1.4](#) đã vạch trần huyền thoại này. Trong tay những người hiểu biết, thuật toán ML ít phù hợp hơn các phương pháp cổ điển. Tuy nhiên, tôi thừa nhận rằng trong tay những người không chuyên, thuật toán ML có thể gây hại nhiều hơn là có lợi.

1.8 Tương lai của nghiên cứu tài chính

International Data Corporation ước tính rằng 80% trong số tất cả dữ liệu có sẵn là dữ liệu phi cấu trúc ([IDC 2014](#)). Nhiều tập dữ liệu mới có sẵn cho các nhà nghiên cứu là dữ liệu đa chiều, thưa thớt hoặc không phải dạng số. Do tính phức tạp của các tập dữ liệu mới này, nên có giới hạn về lượng dữ liệu mà các nhà nghiên cứu có thể tìm hiểu bằng cách sử dụng các mô hình hồi quy và các phương pháp tiếp cận đại số tuyến tính hoặc hình học khác. Ngay cả với các tập dữ liệu cũ hơn, các kỹ thuật định lượng truyền thống vẫn có thể không nắm bắt được các mối liên kết phức tạp tiềm ẩn (ví dụ: phi tuyến tính và tương tác) giữa các biến và các kỹ thuật này cực kỳ nhạy cảm với vấn đề đa cộng tuyến phổ biến trong các tập dữ liệu tài chính ([López de Prado 2019b](#)).

Kinh tế và tài chính có nhiều lợi ích từ việc áp dụng các phương pháp ML. Tính đến ngày 26 tháng 11 năm 2018, Web of Science⁴ liệt kê 13.772 tạp chí

⁴ www.webofknowledge.com.

các bài viết về các chủ đề nằm trong giao điểm của "Kinh tế học" và "Thống kê & Xác suất". Trong số các ấn phẩm đó, chỉ có tám mươi chín bài viết (0,65%) chứa bất kỳ thuật ngữ nào sau đây: phân loại, phân cụm, mạng nơ-ron hoặc học máy. Để đưa ra quan điểm, trong số 40.283 bài viết nằm trong giao điểm của "Sinh học" và "Thống kê & Xác suất", tổng cộng 4.049 bài (10,05%) chứa bất kỳ thuật ngữ nào trong số đó và trong số 4.994 bài viết nằm trong giao điểm của "Hóa học, Phân tích" và "Thống kê & Xác suất", tổng cộng 766 bài (15,34%) chứa bất kỳ thuật ngữ nào trong số đó.

Kinh tế lượng chuẩn mực có từ trước khi máy tính kỹ thuật số ra đời. Hầu hết các mô hình kinh tế lượng được thiết kế để ước tính bằng tay và là sản phẩm của thời đại đó. Theo lời của Robert Tibshirani, "mọi người sử dụng một số phương pháp nhất định vì đó là cách mọi thứ bắt đầu và đó là những gì họ đã quen. Thật khó để thay đổi nó". Thế kỷ 21⁵ Học sinh trong không nên tiếp xúc quá nhiều với các công nghệ cũ. Hơn nữa, các công ty đầu tư định lượng thành công nhất trong lịch sử chủ yếu dựa vào ML, không phải kinh tế lượng, và sự thống trị hiện tại của kinh tế lượng trong các nghiên cứu sau đại học giúp sinh viên chuẩn bị cho sự nghiệp học thuật, không phải cho công việc trong ngành.

Điều này không có nghĩa là kinh tế lượng đã lỗi thời. Các nhà nghiên cứu được yêu cầu quyết định giữa kinh tế lượng và ML được đưa ra một lựa chọn sai lầm. ML và kinh tế lượng bổ sung cho nhau, vì chúng có những điểm mạnh khác nhau. Ví dụ, ML có thể đặc biệt hữu ích trong việc gợi ý cho các nhà nghiên cứu các thành phần của một lý thuyết (xem Phần 6) và kinh tế lượng có thể hữu ích trong việc kiểm tra một lý thuyết có cơ sở vững chắc trên quan sát thực nghiệm. Trên thực tế, đôi khi chúng ta có thể muốn áp dụng cả hai mô hình cùng một lúc, như trong các phương pháp bán tham số. Ví dụ, hồi quy có thể kết hợp các biến giải thích có thể quan sát được với các biến kiểm soát được đóng góp bởi thuật toán ML (Mullainathan và Spiess 2017). Cách tiếp cận như vậy sẽ giải quyết được sự thiên vị liên quan đến các hồi quy bị bỏ sót (Clarke 2005).

1.9 Những câu hỏi thường gặp

Trong vài năm qua, những người tham dự hội thảo đã hỏi tôi đủ loại câu hỏi thú vị. Trong phần này, tôi đã cố gắng cung cấp câu trả lời ngắn gọn cho một số câu hỏi phổ biến nhất. Tôi cũng đã thêm một vài câu hỏi mà tôi vẫn hy vọng rằng một ngày nào đó sẽ có người hỏi.

Nói một cách đơn giản, ML là gì?

Nói một cách rộng rãi, ML đề cập đến tập hợp các thuật toán học các mẫu phức tạp trong không gian nhiều chiều mà không cần chỉ đạo cụ thể. Chúng ta hãy phá vỡ

⁵ <https://qz.com/1206229/this-is-the-best-book-for-learning-modern-statistics-its-free/>.

định nghĩa đó thành ba thành phần của nó. Đầu tiên, ML học mà không cần chỉ đạo cụ thể, vì các nhà nghiên cứu áp đặt rất ít cấu trúc vào dữ liệu.

Thay vào đó, thuật toán lấy cấu trúc đó từ dữ liệu. Thứ hai, ML học các mẫu phức tạp, vì cấu trúc được xác định bởi thuật toán có thể không thể biểu diễn được dưới dạng một tập hợp hữu hạn các phương trình. Thứ ba, ML học trong không gian nhiều chiều, vì các giải pháp thường liên quan đến một số lượng lớn các biến và các tương tác giữa chúng.

Ví dụ, chúng ta có thể huấn luyện một thuật toán ML để nhận dạng khuôn mặt người bằng cách cho nó xem các ví dụ. Chúng ta không định nghĩa khuôn mặt là gì, do đó thuật toán học mà không cần sự chỉ đạo của chúng ta. Vấn đề không bao giờ được đặt ra dưới dạng các phương trình và trên thực tế, vấn đề có thể không thể diễn đạt được dưới dạng các phương trình. Và thuật toán sử dụng một số lượng biến cực lớn để thực hiện nhiệm vụ này, bao gồm các pixel riêng lẻ và tương tác giữa các pixel.

Trong những năm gần đây, ML đã trở thành một công cụ nghiên cứu ngày càng hữu ích trong mọi lĩnh vực nghiên cứu khoa học. Ví dụ bao gồm phát triển thuốc, nghiên cứu bộ gen, vật liệu mới và vật lý năng lượng cao. Các sản phẩm tiêu dùng và dịch vụ công nghiệp đã nhanh chóng kết hợp các công nghệ này và một số công ty có giá trị nhất trên thế giới sản xuất các sản phẩm và dịch vụ dựa trên ML.

ML khác với hồi quy kinh tế lượng như thế nào?

Các nhà nghiên cứu sử dụng hồi quy truyền thống để phù hợp với một dạng hàm được xác định trước với một tập hợp các biến. Hồi quy cực kỳ hữu ích khi chúng ta có mức độ tin tưởng cao về dạng hàm đó và tất cả các hiệu ứng tương tác liên kết các biến với nhau. Quay trở lại thế kỷ thứ mười tám, các nhà toán học đã phát triển các công cụ phù hợp với các dạng hàm đó bằng cách sử dụng các ước lượng có các thuộc tính mong muốn, tùy thuộc vào một số giả định về dữ liệu.

Bắt đầu từ những năm 1950, các nhà nghiên cứu nhận ra rằng có một cách khác để tiến hành phân tích thực nghiệm, với sự trợ giúp của máy tính. Thay vì áp đặt một dạng hàm, đặc biệt là khi dạng đó chưa được biết trước, họ sẽ cho phép các thuật toán tìm ra các phụ thuộc biến từ dữ liệu. Và thay vì đưa ra các giả định mạnh mẽ về dữ liệu, các thuật toán sẽ tiến hành các thí nghiệm đánh giá các đặc tính toán học của các dự đoán ngoài mẫu. Sự nổi lên này về dạng hàm và các giả định dữ liệu, kết hợp với việc sử dụng các máy tính mạnh, đã mở ra cánh cửa để phân tích các tập dữ liệu phức tạp, bao gồm các hiệu ứng tương tác phi tuyến tính, phân cấp và không liên tục.

Hãy xem xét ví dụ sau: một nhà nghiên cứu muốn ước tính xác suất sống sót của một hành khách trên tàu Titanic, dựa trên một số biến số, chẳng hạn như

như giới tính, hạng vé và độ tuổi. Một phương pháp hồi quy điển hình sẽ là điều chỉnh mô hình logit cho một biến nhị phân, trong đó 1 có nghĩa là người sống sót và 0 có nghĩa là người đã chết, sử dụng giới tính, hạng vé và độ tuổi làm hồi quy. Hóa ra, mặc dù các hồi quy này là đúng, nhưng mô hình logit (hoặc probit) không đưa ra được dự đoán tốt. Lý do là các mô hình logit không nhận ra rằng tập dữ liệu này không phải là một cấu trúc phân cấp (giống cây), với các tương tác phức tạp. Ví dụ, nam giới trưởng thành ở hạng hai tử vong với tỷ lệ cao hơn nhiều so với từng thuộc tính này khi xét riêng lẻ. Ngược lại, một thuật toán "cây phân loại" đơn giản thực hiện tốt hơn đáng kể, vì chúng ta cho phép thuật toán tìm ra cấu trúc phân cấp đó (và các tương tác phức tạp liên quan) cho chúng ta.

Hóa ra, các cấu trúc phân cấp có mặt ở khắp mọi nơi trong kinh tế và tài chính (Simon 1962). Hãy nghĩ đến các phân loại ngành, xếp hạng tín dụng, các loại tài sản, các mối liên kết kinh tế, mạng lưới thương mại, các cụm kinh tế khu vực, v.v. Khi đối mặt với những loại vấn đề này, các công cụ ML có thể bổ sung và khắc phục các hạn chế của kinh tế lượng hoặc thống kê truyền thống tương tự phương pháp.

ML khác với Big Data như thế nào?

Thuật ngữ dữ liệu lớn đề cập đến các tập dữ liệu quá lớn và/hoặc phức tạp đến mức các kỹ thuật thống kê truyền thống không thể trích xuất và mô hình hóa thông tin chứa trong chúng. Người ta ước tính rằng 90% tất cả dữ liệu được ghi lại đã được

được tạo ra trong hai năm qua và 80% dữ liệu là dữ liệu phi cấu trúc (tức là không thể áp dụng trực tiếp các kỹ thuật thống kê truyền thống).

Trong những năm gần đây, số lượng và mức độ chi tiết của dữ liệu kinh tế đã được cải thiện đáng kể. Tin tốt là sự bùng nổ đột ngột của các tập dữ liệu hành chính, khu vực tư nhân và cấp độ vi mô cung cấp cái nhìn sâu sắc vô song về hoạt động bên trong của nền kinh tế. Tin xấu là các tập dữ liệu này đặt ra nhiều thách thức đối với việc nghiên cứu kinh tế. (1) Một số tập dữ liệu thú vị nhất là không có cấu trúc. Chúng cũng có thể không phải là số và không phải là danh mục, như bài báo, bản ghi âm giọng nói hoặc hình ảnh vệ tinh.

(2) Các tập dữ liệu này có chiều cao (ví dụ: giao dịch thẻ tín dụng.)

Số lượng biến liên quan thường vượt quá số lượng quan sát, khiến việc áp dụng các giải pháp đại số tuyến tính trở nên rất khó khăn. (3) Nhiều tập dữ liệu này cực kỳ thưa thớt. Ví dụ, các mẫu có thể chứa một tỷ lệ lớn các số không, trong khi các khái niệm chuẩn như tương quan không hoạt động tốt. (4) Nhưng trong các tập dữ liệu này là thông tin quan trọng liên quan đến mạng lưới các tác nhân, động cơ và hành vi tổng hợp của các nhóm người.

Các kỹ thuật ML được thiết kế để phân tích dữ liệu lớn, đó là lý do tại sao chúng thường được trích dẫn cùng nhau.

Ngành quản lý tài sản đang sử dụng ML như thế nào?

Có lẽ ứng dụng phổ biến nhất của ML trong quản lý tài sản là dự đoán giá. Nhưng có rất nhiều ứng dụng quan trọng không kém, như phòng ngừa rủi ro, xây dựng danh mục đầu tư, phát hiện các giá trị ngoại lệ và phá vỡ cấu trúc, xếp hạng tín dụng, phân tích tâm lý, tạo lập thị trường, định cỡ cược, phân loại chứng khoán và nhiều ứng dụng khác. Đây là những ứng dụng thực tế vượt qua sự cường điệu thường gắn liền với kỳ vọng về dự đoán giá.

Ví dụ, các công ty đầu tư theo yếu tố sử dụng ML để định nghĩa lại giá trị. Vài năm trước, tỷ lệ giá trên thu nhập có thể cung cấp thứ hạng tốt cho giá trị, nhưng hiện nay thì không phải vậy. Ngày nay, khái niệm giá trị phức tạp hơn nhiều. Các nhà quản lý tài sản hiện đại sử dụng ML để xác định các đặc điểm của giá trị và cách các đặc điểm đó tương tác với động lực, chất lượng, quy mô, v.v. Siêu nhân (Phần 5.5) là một chủ đề nóng khác có thể giúp các nhà quản lý tài sản định cỡ và thời điểm đặt cược theo yếu tố của họ.

Các công ty giao dịch tần suất cao đã sử dụng ML trong nhiều năm để phân tích nguồn cấp dữ liệu trao đổi theo thời gian thực, nhằm tìm kiếm dấu vết do các nhà giao dịch có hiểu biết để lại. Họ có thể sử dụng thông tin này để đưa ra dự đoán giá ngắn hạn hoặc đưa ra quyết định về mức độ tích cực hay thụ động trong việc thực hiện lệnh.

Các công ty xếp hạng tín dụng cũng là những đơn vị áp dụng mạnh mẽ ML, vì các thuật toán này đã chứng minh được khả năng sao chép các xếp hạng do các nhà phân tích tín dụng tạo ra. Phát hiện giá trị ngoại lệ là một ứng dụng quan trọng khác, vì các mô hình tài chính có thể rất nhạy cảm với sự hiện diện của ngay cả một số lượng nhỏ các giá trị ngoại lệ. Các mô hình ML có thể giúp cải thiện hiệu suất đầu tư bằng cách tìm ra quy mô phù hợp của một vị thế, để lại quyết định mua hay bán cho các mô hình truyền thống hoặc cơ bản.

Và cụ thể là các nhà đầu tư định lượng thì sao?

Tất cả các ứng dụng trên và nhiều ứng dụng khác nữa đều liên quan đến các nhà đầu tư định lượng. Đây là thời điểm tuyệt vời để trở thành một nhà định lượng. Dữ liệu phong phú hơn bao giờ hết và máy tính cuối cùng cũng cung cấp sức mạnh cần thiết để sử dụng hiệu quả ML. Tôi đặc biệt hào hứng với dự đoán thống kê kinh tế vĩ mô theo thời gian thực, theo ví dụ của Dự án Tỷ giá của MIT (Cavallo và Rigobon 2016). ML có thể đặc biệt hữu ích trong việc khám phá các mối quan hệ cho đến nay vẫn còn ẩn giấu, ngay cả trong các tập dữ liệu truyền thống. Ví dụ, các mối quan hệ kinh tế giữa các công ty có thể không được mô tả hiệu quả bằng các phân loại theo ngành-nhóm- ngành truyền thống, chẳng hạn như GICS.⁶ Một phương pháp tiếp cận mạng lưới, trong đó các công ty có mối quan hệ với nhau theo nhiều yếu tố khác nhau, có khả năng

⁶ www.msci.com/gics.

để cung cấp thông tin phong phú và chính xác hơn về động lực, điểm mạnh và điểm yếu của các phân khúc cụ thể trên thị trường chứng khoán hoặc tín dụng (Cohen và Frazzini 2008).

Một số cách nào ML có thể được áp dụng vào danh mục đầu tư của nhà đầu tư?

Xây dựng danh mục đầu tư là một lĩnh vực cực kỳ hứa hẹn đối với ML (Phần 7). Trong nhiều thập kỷ, ngành quản lý tài sản đã dựa vào các biến thể và tính chính của biên giới hiệu quả của Markowitz để xây dựng danh mục đầu tư. Người ta biết rằng nhiều giải pháp trong số này là tối ưu trong mẫu, tuy nhiên, chúng có thể hoạt động kém ngoài mẫu do sự bất ổn về mặt tính toán liên quan đến tối ưu hóa lỗi. Nhiều phương pháp tiếp cận cổ điển đã cố gắng, với thành công khác nhau, để giải quyết những sự bất ổn về mặt tính toán này. Các thuật toán ML đã cho thấy tiềm năng tạo ra các danh mục đầu tư mạnh mẽ hoạt động tốt ngoài mẫu, nhờ khả năng nhận dạng các mối quan hệ phân cấp thừa thớt mà các phương pháp truyền thống bỏ qua (López de Prado 2016).

Rủi ro là gì? Có điều gì mà nhà đầu tư cần lưu ý hoặc cảnh giác không?

Tài chính không phải là chủ đề cấm và chạy khi liên quan đến ML. Việc lập mô hình chuỗi tài chính khó hơn lái xe ô tô hoặc nhận diện khuôn mặt. Lý do là tỷ lệ tín hiệu trên nhiễu trong dữ liệu tài chính cực kỳ thấp, do các lực lượng chênh lệch giá và các hệ thống không tính tại. Sức mạnh tính toán và tính linh hoạt về mặt chức năng của ML đảm bảo rằng nó sẽ luôn tìm thấy một mô hình trong dữ liệu, ngay cả khi mô hình đó là một sự may rủi chứ không phải là kết quả của một hiện tượng dai dẳng. Một cách tiếp cận "oracle" đối với ML tài chính, trong đó các thuật toán được phát triển để hình thành các dự đoán tách biệt khỏi mọi lý thuyết kinh tế, có khả năng tạo ra những khám phá sai lầm. Tôi chưa bao giờ nghe một nhà khoa học nào nói rằng "Quên lý thuyết đi, tôi có một oracle có thể trả lời bất cứ điều gì, vì vậy chúng ta hãy ngừng suy nghĩ và hãy tin một cách mù quáng bất cứ điều gì xuất hiện".

Điều quan trọng là các nhà đầu tư phải nhận ra rằng ML không phải là sự thay thế cho lý thuyết kinh tế, mà là một công cụ mạnh mẽ để xây dựng các lý thuyết kinh tế hiện đại. Chúng ta cần ML để phát triển các lý thuyết tài chính tốt hơn và chúng ta cần các lý thuyết tài chính để hạn chế xu hướng quá phù hợp của ML. Nếu không có sự tương tác giữa lý thuyết và ML này, các nhà đầu tư sẽ đặt niềm tin vào tử vi công nghệ cao.

Bạn mong đợi ML sẽ tác động thế nào đến ngành quản lý tài sản trong thập kỷ tới?

Ngày nay, số lượng ML được nông dân sử dụng là rất lớn: máy kéo tự lái, máy bay không người lái quét các mảnh đất không bằng phẳng, cảm biến cho gia súc ăn và

cung cấp chất dinh dưỡng khi cần thiết, cây trồng biến đổi gen, hình ảnh vệ tinh để ước tính năng suất, v.v. Tương tự như vậy, tôi nghĩ rằng trong mười năm nữa chúng ta sẽ nhìn lại và ML sẽ là một khía cạnh quan trọng của quản lý tài sản. Và giống như trong ngành nông nghiệp, mặc dù sự chuyển đổi này có thể không diễn ra trong một sớm một chiều, nhưng rõ ràng là chỉ có một hướng đi về phía trước.

Các tập dữ liệu kinh tế sẽ chỉ ngày càng lớn hơn và máy tính sẽ ngày càng mạnh hơn. Hầu hết các nhà quản lý tài sản sẽ thất bại hoặc là không phát triển hoặc là vội vã lao vào điều chưa biết mà không nhận thức đầy đủ những nguy hiểm liên quan đến cách tiếp cận "oracle". Chỉ một số ít nhà quản lý tài sản sẽ thành công bằng cách phát triển theo cách chu đáo và có trách nhiệm.

Bạn mong đợi ML sẽ tác động thế nào đến học thuật tài chính trong thập kỷ tới?

Hãy tưởng tượng nếu các nhà vật lý phải đưa ra các lý thuyết trong một vũ trụ mà các định luật cơ bản của tự nhiên liên tục thay đổi; nơi các ẩn phẩm có tác động đến chính hiện tượng đang được nghiên cứu; nơi mà việc thử nghiệm gần như không thể thực hiện được; nơi mà dữ liệu thì tốn kém, tín hiệu thì mờ nhạt và hệ thống đang được nghiên cứu thì vô cùng phức tạp... Tôi cảm thấy vô cùng ngưỡng mộ những gì mà các học giả tài chính đã đạt được trước nghịch cảnh to lớn.

ML có nhiều thứ để cung cấp cho nghề học thuật. Đầu tiên, ML cung cấp sức mạnh và tính linh hoạt cần thiết để tìm ra những tín hiệu mờ nhạt trong biển tiếng ồn do các lực lượng chênh lệch giá gây ra. Thứ hai, ML cho phép các học giả tách quá trình nghiên cứu thành hai giai đoạn: (1) tìm kiếm các biến quan trọng bất kể dạng chức năng và (2) tìm kiếm dạng chức năng liên kết các biến đó. López de Prado (2019b) chứng minh rằng ngay cả những lỗi thống số kỹ thuật nhỏ cũng khiến các nhà nghiên cứu hiểu lầm khi từ chối các biến quan trọng. Thật khó để cường điệu hóa tính liên quan của việc tách tìm kiếm thống số kỹ thuật khỏi tìm kiếm biến. Thứ ba, ML cung cấp khả năng thực hiện mô phỏng trên dữ liệu tổng hợp. Đây là cách tài chính gần nhất có thể đạt được với thử nghiệm, khi không có phòng thí nghiệm. Chúng ta đang sống trong thời đại thú vị để thực hiện nghiên cứu học thuật về các hệ thống tài chính và tôi mong đợi những đột phá to lớn khi ngày càng nhiều nhà nghiên cứu tài chính áp dụng ML.

Có phải ML tài chính chỉ là dự đoán giá cả không?

Một trong những hiểu lầm lớn nhất mà tôi nhận thấy khi đọc báo chí là quan niệm cho rằng mục tiêu chính (nếu không muốn nói là duy nhất) của ML là dự đoán giá. Định giá tài sản chắc chắn là một nỗ lực rất đáng giá, tuy nhiên tầm quan trọng của nó thường bị cường điệu hóa. Có lợi thế trong dự đoán giá chỉ là một điều cần thiết, tuy nhiên hoàn toàn

không đủ điều kiện để thành công trong thị trường cạnh tranh cao hiện nay.

Những lĩnh vực khác cũng quan trọng không kém là xử lý dữ liệu, xây dựng danh mục đầu tư, quản lý rủi ro, theo dõi sự cố cấu trúc, định mức cược và phát hiện chiến lược đầu tư sai lầm, v.v.

Hãy xem xét những người chơi tại World Series of Poker. Các lá bài được xáo trộn và phân phối ngẫu nhiên. Những người chơi này rõ ràng không thể dự đoán những lá bài nào sẽ được chia cho người chơi với bất kỳ độ chính xác có ý nghĩa nào. Tuy nhiên, cùng một nhóm người chơi lại kết thúc ở vị trí cao nhất năm này qua năm khác. Một lý do là, quy mô cược quan trọng hơn dự đoán bài. Khi một người chơi nhận được một ván bài tốt, anh ta đánh giá khả năng một người chơi khác cũng có thể có một ván bài mạnh và đặt cược một cách chiến lược. Tương tự như vậy, các nhà đầu tư có thể không thể dự đoán giá, tuy nhiên họ có thể nhận ra khi nào một mức giá bất thường được in ra và đặt cược cho phù hợp. Tôi không nói rằng quy mô cược là chìa khóa để đầu tư thành công. Tôi chỉ nêu rằng quy mô cược ít nhất cũng quan trọng như dự đoán giá và việc xây dựng danh mục đầu tư có thể thậm chí còn quan trọng hơn.

Tại sao bạn không thảo luận về nhiều thuật toán ML?

Mục đích của Element này không phải là giới thiệu cho người đọc về số lượng lớn các thuật toán ML được sử dụng trong tài chính hiện nay. Có hai lý do cho điều đó. Đầu tiên, có những sách giáo khoa dài dành riêng cho việc trình bày có hệ thống các thuật toán đó, và một cuốn khác hầu như không cần thiết. Các tài liệu tham khảo tuyệt vời bao gồm [James et al. \(2013\)](#), [Hastie et al. \(2016\)](#) và [Efron và Hastie \(2016\)](#). Thứ hai, các tập dữ liệu tài chính có những phiên toái cụ thể và sự thành công hay thất bại của một dự án phụ thuộc vào việc hiểu chúng. Sau khi chúng ta đã thiết kế các tính năng và đặt vấn đề đúng cách, việc lựa chọn một thuật toán đóng vai trò tương đối thứ yếu.

Cho phép tôi minh họa điểm thứ hai bằng một ví dụ. So sánh một thuật toán dự báo thay đổi là 1, nhưng nhận được thay đổi thực tế là 3, với một thuật toán khác dự báo thay đổi là -1, nhưng nhận được thay đổi thực tế là 1. Trong cả hai trường hợp, lỗi dự báo là 2. Trong nhiều ứng dụng công nghiệp, chúng ta sẽ không phân biệt giữa cả hai lỗi. Trường hợp này không đúng trong tài chính. Trong trường hợp đầu tiên, nhà đầu tư kiếm được một phần ba lợi nhuận dự đoán, trong khi trong trường hợp thứ hai, nhà đầu tư chịu tổn thất bằng với lợi nhuận dự đoán. Không dự đoán được quy mô là mất cơ hội, nhưng không dự đoán được dấu hiệu là mất thực tế. Các nhà đầu tư phạt các khoản lỗ thực tế nhiều hơn nhiều so với các khoản lỗ cơ hội. Dự đoán dấu hiệu của một kết quả thường quan trọng hơn dự đoán quy mô của nó và là lý do để ưu tiên các bộ phân loại hơn các phương pháp hồi quy trong tài chính. Ngoài ra, trong tài chính, người ta thường thấy rằng dấu hiệu và quy mô của một kết quả phụ thuộc vào các tính năng khác nhau, do đó

dự báo dấu hiệu và quy mô của một kết quả với một tập hợp các tính năng độc đáo có thể dẫn đến kết quả kém.⁷ Các chuyên gia ML chuyển sang tài chính từ các lĩnh vực khác thường mắc phải những sai lầm cơ bản, như đặt vấn đề không đúng cách, như đã giải thích trong López de Prado (2018b). ML tài chính là một chủ đề riêng biệt và việc thảo luận về các thuật toán ML chung không phải là trọng tâm của vấn đề.

Tại sao bạn không thảo luận về một chiến lược đầu tư cụ thể như nhiều cuốn sách khác?

Có rất nhiều sách trên thị trường cung cấp công thức để thực hiện chiến lược đầu tư của người khác. Những cuốn sách dạy nấu ăn đó chỉ cho chúng ta cách làm bánh của người khác. Element này thì khác.

Tôi muốn chỉ cho bạn cách bạn có thể sử dụng ML để khám phá các lý thuyết kinh tế và tài chính mới có liên quan đến bạn, trên đó bạn có thể dựa vào các chiến lược đầu tư độc quyền của mình. Các chiến lược đầu tư của bạn chỉ là sự triển khai cụ thể của các lý thuyết mà trước tiên bạn phải tự mình khám phá. Bạn không thể nướng bánh cho người khác và mong đợi giữ lại cho mình.

1.10 Kết luận

Mục đích của Element này là giới thiệu các công cụ ML hữu ích cho việc khám phá các lý thuyết kinh tế và tài chính. Các chiến lược đầu tư thành công là các triển khai cụ thể của các lý thuyết chung. Một chiến lược đầu tư thiếu cơ sở lý thuyết có khả năng là sai. Do đó, một nhà nghiên cứu nên tập trung nỗ lực vào việc phát triển một lý thuyết, thay vì kiểm tra ngược các chiến lược tiềm năng.

ML không phải là hộp đen và không nhất thiết phải quá phù hợp. Các công cụ ML bổ sung chứ không phải thay thế các phương pháp thống kê cổ điển. Một số điểm mạnh của ML bao gồm (1) Tập trung vào khả năng dự đoán ngoài mẫu hơn là phân đoán phương sai; (2) sử dụng các phương pháp tính toán để tránh dựa vào các giả định (có khả năng không thực tế); (3) khả năng "học" các thông số kỹ thuật phức tạp, bao gồm các hiệu ứng tương tác phi tuyến tính, phân cấp và không liên tục trong không gian có nhiều chiều; và (4) khả năng tách biệt tìm kiếm biến khỏi tìm kiếm thông số kỹ thuật, theo cách mạnh mẽ đối với đa cộng tuyến và các hiệu ứng thay thế khác.

⁷

Xem López de Prado (2018a) để thảo luận về các thuật toán gần nhân siêu dữ liệu, trong đó quyết định về dấu hiệu và kích thước được đưa ra bởi các thuật toán độc lập.

1.11 Bài tập

- 1 Có thể sử dụng các phương pháp định lượng để dự đoán các sự kiện chưa bao giờ xảy ra không?
trước đây? Làm thế nào các phương pháp định lượng có thể dự đoán được một con thiên nga đen?
- 2 Tại sao lý thuyết lại đặc biệt quan trọng trong tài chính và kinh tế?
cách sử dụng ML tốt nhất trong tài chính?
- 3 Những quan niệm sai lầm phổ biến về ML tài chính là gì? Bộ dữ liệu tài chính có đủ lớn cho các ứng dụng ML không?
- 4 ML kiểm soát tình trạng quá khớp như thế nào? Tỷ lệ tín hiệu trên nhiễu trong tài chính có quá thấp để cho phép sử dụng ML không?
- 5 Mô tả một phương pháp định lượng trong tài chính kết hợp các phương pháp cổ điển và ML. ML khác với hồi quy lớn như thế nào? Mô tả năm ứng dụng của ML tài chính.

2. Khử nhiễu và kích nổ

2.1 Động lực

Ma trận hiệp phương sai có mặt ở khắp mọi nơi trong tài chính. Chúng tôi sử dụng chúng để chạy hồi quy, ước tính rủi ro, tối ưu hóa danh mục đầu tư, mô phỏng các kịch bản thông qua Monte Carlo, tìm cụm, giảm chiều của không gian vectơ, v.v. Ma trận hiệp phương sai thực nghiệm được tính toán trên chuỗi quan sát từ một vectơ ngẫu nhiên, để ước tính sự đồng chuyển động tuyến tính giữa các biến ngẫu nhiên cấu thành vectơ ngẫu nhiên. Với bản chất hữu hạn và không xác định của

những quan sát này, ước tính của ma trận hiệp phương sai bao gồm một lượng nhiễu nhất định. Ma trận hiệp phương sai thực nghiệm có nguồn gốc từ các yếu tố ước tính cũng có điều kiện số không tốt, vì các yếu tố đó cũng được ước tính từ dữ liệu sai lệch. Nếu chúng ta không xử lý nhiễu này, nó sẽ ảnh hưởng đến các phép tính mà chúng ta thực hiện với ma trận hiệp phương sai, đôi khi đến mức khiến cho việc phân tích trở nên vô ích.

Mục tiêu của phần này là giải thích một quy trình để giảm nhiễu và tăng cường tín hiệu có trong ma trận hiệp phương sai thực nghiệm. Trong suốt Phần tử này, chúng tôi giả định rằng các ma trận hiệp phương sai thực nghiệm và tương quan đã được áp dụng quy trình này.

2.2 Định lý Marenko-Pastur

Hãy xem xét một ma trận các quan sát ngẫu nhiên độc lập và phân phối giống hệt nhau X , có kích thước $T \times N$, trong đó quá trình cơ bản tạo ra các quan sát có giá trị trung bình bằng không và phương sai σ^2 . Ma trận $C = \frac{1}{T} X X^T$ có các giá trị hội tụ tiệm cận (khi $N \rightarrow \infty$ và $T \rightarrow \infty$ với $1 < \frac{T}{N} \rightarrow \lambda < \infty$) đến Hàm mật độ xác suất Marcenko-Pastur (PDF),

$$f(\lambda) = \frac{\sqrt{4\lambda - \lambda^2}}{4\pi\sigma^2} \quad \text{nếu } \lambda \in [2^{-1/2}\sigma^2, 2^{1/2}\sigma^2];$$

$$0 \quad \text{nếu } \lambda < 2^{-1/2}\sigma^2 \text{ hoặc } \lambda > 2^{1/2}\sigma^2;$$

trong đó giá trị riêng mong đợi lớn nhất là $2^{1/2}\sigma^2$ và $N = T$ và

giá trị riêng mong đợi tối thiểu là $2^{-1/2}\sigma^2$. Khi $\sigma^2 = 1$, thì C

là ma trận tương quan liên quan đến X . [Đoạn mã 2.1](#) triển khai Marcenko-Pastur PDF bằng python.

Các giá trị riêng $\lambda \in [2^{-1/2}\sigma^2, 2^{1/2}\sigma^2]$ phù hợp với hành vi ngẫu nhiên và các giá trị riêng $\lambda < 2^{-1/2}\sigma^2$ hoặc $\lambda > 2^{1/2}\sigma^2$ phù hợp với hành vi không ngẫu nhiên. Cụ thể, chúng tôi liên kết các giá trị riêng $\lambda < 2^{-1/2}\sigma^2$ với nhiễu. [Hình 2.1](#) và [Đoạn mã 2.2](#) chứng minh phân phối Marcenko-Pastur giải thích chặt chẽ như thế nào các giá trị riêng của ma trận ngẫu nhiên X .

ĐOẠN TRÍCH 2.1 PDF MARCENKO -PASTUR

```

nhập numpy dưới dạng np, pandas dưới dạng pd
#- - - - -
định nghĩa mpPDF(var,q,pts):
    # Marcenko-Pastur pdf # q=T/N

    eMin,eMax=var*(1-(1./q)**.5)**2,var*(1+(1./q)**.5)**2
    eVal=np.linspace(eMin,eMax,pts)
    pdf=q/(2*np.pi*var*eVal)*((eMax-eVal)*(eVal-eMin))**.5
    pdf=pd.Series(pdf,index=eVal)
    trả lại pdf

```


ĐOẠN TRÍCH 2.2 KIỂM TRA ĐỊNH LÝ MARCENKO-PASTUR

```

từ sklearn.neighbors.kde nhập KernelDensity
#- - - - -
def getPCA(ma trận):
    # Lấy eVal,eVec từ ma trận Hermitian
    eVal,eVec=np.linalg.eigh(matrix) chỉ
    số=eVal.argsort()[::-1] # đổi số để sắp xếp eVal desc
    eVal,eVec=eVal[chỉ số],eVec[:,chỉ số]

    eVal=np.diagflat(eVal)
    trả về eVal,eVec
#- - - - -
def fitKDE(obs,bWidth=.25,kernel='gaussian',x=Không có):
    # Phù hợp hạt nhân với một loạt các obs và suy ra xác suất của các obs
    # x là mảng các giá trị mà KDE sẽ đánh giá độ phù hợp nếu
    len(obs.shape)==1:obs=obs.reshape(-1,1)
    kde=KernelDensity(kernel=kernel,bandwidth=bWidth).fit(obs) nếu x là
    None:x=np.unique(obs).reshape(-1,1) nếu
    len(x.shape)==1:x=x.reshape(-1,1)
    logProb=kde.score_samples(x) # log(density)
    pdf=pd.Series(np.exp(logProb),index=x.flatten()) return pdf
#- - - - -
x=np.random.normal(size=(10000,1000))
eVal0,eVec0=getPCA(np.corrcoef(x,rowvar=0))
pdf0=mpPDF(1.,q=x.shape[0]/float(x.shape[1]),pts=1000)
pdf1=fitKDE(np.diag(eVal0),bWidth=.01) # pdf thực nghiệm

```



Hình 2.1 Hình ảnh trực quan của định lý Marcenko-Pastur.

2.3 Ma trận ngẫu nhiên có tín hiệu

Trong một ma trận tương quan thực nghiệm, không phải tất cả các vectơ riêng đều có thể là ngẫu nhiên. [Đoạn mã 2.3](#) xây dựng một ma trận hiệp phương sai không hoàn toàn ngẫu nhiên và do đó các giá trị riêng của nó sẽ chỉ tuân theo PDF Marcenko-Pastur một cách gần đúng. Trong số các biến ngẫu nhiên $n \times n$ tạo thành ma trận hiệp phương sai do `getRndCov` tạo ra, chỉ có `nFact` chứa một số tín hiệu. Để pha loãng tín hiệu hơn nữa, chúng tôi thêm ma trận hiệp phương sai đó vào một ma trận hoàn toàn ngẫu nhiên, với trọng số α . Xem [Lewandowski và cộng sự \(2009\)](#) để biết các cách thay thế để xây dựng ma trận hiệp phương sai ngẫu nhiên.

2.4 Phù hợp với phân bố Marcenko-Pastur

Trong phần này, chúng ta sẽ làm theo cách tiếp cận được giới thiệu bởi [Laloux và cộng sự \(2000\)](#). Vì chỉ một phần của phương sai là do các vectơ riêng ngẫu nhiên gây ra, nên chúng ta có thể điều chỉnh σ^2 cho phù hợp trong các phương trình trên. Ví dụ, nếu chúng ta giả sử rằng vectơ riêng liên kết với giá trị riêng cao nhất không phải là ngẫu nhiên, thì chúng ta nên thay thế σ^2 bằng $\sigma^2 + 1/\lambda_p = N$ trong các phương trình trên. Trên thực tế, chúng ta có thể điều chỉnh hàm $f(\lambda) = \frac{1}{2}\lambda$ theo phân phối thực nghiệm của các giá trị riêng để suy ra σ^2 ngụ ý. Điều đó sẽ cung cấp cho chúng ta phương sai được giải thích bởi các vectơ riêng ngẫu nhiên có trong ma trận tương quan và nó sẽ xác định mức cắt λ_p , được điều chỉnh cho sự hiện diện của các vectơ riêng không ngẫu nhiên.

[Đoạn mã 2.4](#) khớp PDF Marcenko-Pastur với ma trận hiệp phương sai ngẫu nhiên có chứa tín hiệu. Mục tiêu của phép khớp là tìm giá trị σ^2 để giảm thiểu tổng các bình phương sai số giữa PDF phân tích và

ĐOẠN TRÍCH 2.3 THÊM TÍN HIỆU VÀO MA TRẬN PHƯƠNG PHÁP NGẪU NHIÊN

```
def getRndCov(nCols,nFacts):
    w=np.random.normal(size=(nCols,nFacts)) cov=np.dot(w,wT) # ma
    trận cov ngẫu nhiên, tuy nhiên không phải là cov hạng đầy
    đủ+=np.diag(np.random.uniform(size=nCols)) # cov hạng đầy đủ
    trở về cov

#- - - - -
định nghĩa cov2corr(cov):
    # Lấy ma trận tương quan từ ma trận hiệp phương sai
    std=np.sqrt(np.diag(cov))
    corr=cov/np.outer(std,std)
    corr[corr<-1],corr[corr>1]=-1,1 # lỗi số
    trả lại corr

#- - - - -
alpha, nCols, nFact, q=.995,1000,100,10
cov=np.cov(np.random.normal(size=(nCols*q,nCols)),rowvar=0) cov=alpha*cov+(1-
alpha)*getRndCov(nCols,nFact) # noise+signal
corr0=cov2corr(cov)
eVal0,eVec0=getPCA(corr0)
```

ĐOẠN TRÍCH 2.4 PHÙ HỢP VỚI PDF MARCENKO-PASTUR

```
từ scipy.optimize nhập khẩu thu nhỏ


#- - - - -
định nghĩa errPDFs(var,eVal,q,bWidth,pts=1000):
    # Lỗi vừa vặn
    pdf0=mpPDF(var,q,pts) # pdf lý thuyết
    pdf1=fitKDE(eVal,bWidth,x=pdf0.index.values) # pdf thực nghiệm sse=np.sum((pdf1-pdf0)**2)

    trả lại sse

#- - - - -
def findMaxEval(eVal,q,bWidth):
    # Tìm eVal ngẫu nhiên tối đa bằng cách lặp dist của Marcenko
    out=minimize(lambda *x:errPDFs(*x),.5,args=(eVal,q,bWidth),
        giới hạn=((1E-5,1-1E-5),))
    nếu out['success']:var=out['x'][0]
    khác:var=1

    eMax=var*(1+(1./q)**.5)**2
    trả về eMax,var

#- - - - -
eMax0,var0=findMaxEval(np.diag(eVal0),q,bWidth=.01)
nFacts0=eVal0.shape[0]-np.diag(eVal0)[::-1].searchsorted(eMax0)
```



Hình 2.2 Phù hợp PDF Marcenko-Pastur trên ma trận hiệp phương sai nhiễu.

ước tính mật độ hạt nhân (KDE) của các giá trị riêng quan sát được (để tham khảo về KDE, hãy xem [Rosenblatt 1956](#); [Parzen 1962](#)). Giá trị λ được báo cáo là $eMax0$, giá trị σ^2 được lưu trữ là $var0$ và số lượng các yếu tố được phục hồi là $nFacts0$.

Hình 2.2 vẽ biểu đồ histogram của các giá trị riêng và PDF của phân phối Marcenko-Pastur được lắp ghép. Các giá trị riêng ở bên phải của phân phối Marcenko-Pastur được lắp ghép không thể liên kết với nhiễu, do đó chúng liên quan đến tín hiệu. Mã trả về giá trị 100 cho $nFacts0$, cùng số lượng các yếu tố mà chúng tôi đã đưa vào ma trận hiệp phương sai. Mặc dù tín hiệu mờ hiện diện trong ma trận hiệp phương sai, quy trình này đã có thể tách các giá trị riêng liên kết với nhiễu khỏi các giá trị riêng liên kết với tín hiệu. Phân phối được điều chỉnh ngụ ý rằng $\sigma^2 \approx :6768$, cho thấy chỉ có khoảng 32,32% phương sai có thể được quy cho tín hiệu. Đây là một cách đo tỷ lệ tín hiệu trên nhiễu trong các tập dữ liệu tài chính, được biết là thấp do các lực chênh lệch giá.

2.5 Giảm nhiễu

Trong các ứng dụng tài chính, việc thu nhỏ ma trận hiệp phương sai có điều kiện số không tốt là điều thường thấy ([Ledoit và Wolf 2004](#)). Bằng cách làm cho ma trận hiệp phương sai gần với đường chéo hơn, sự thu nhỏ làm giảm số điều kiện của nó. Tuy nhiên, shrink-age thực hiện điều đó mà không phân biệt giữa nhiễu và tín hiệu. Do đó, sự thu nhỏ có thể loại bỏ thêm một tín hiệu vốn đã yếu.

Trong phần trước, chúng ta đã học cách phân biệt giữa các giá trị riêng liên quan đến thành phần nhiễu và các giá trị riêng liên quan đến thành phần tín hiệu. Trong phần này, chúng ta thảo luận về cách sử dụng thông tin này để khử nhiễu ma trận tương quan.

2.5.1 Phương pháp trị riêng dư hằng số

Cách tiếp cận này bao gồm việc thiết lập một giá trị riêng hằng số cho tất cả các vectơ riêng ngẫu nhiên. Cho $\lambda_1, \dots, \lambda_N$ là tập hợp tất cả các giá trị riêng, được sắp xếp giảm dần, và i là vị trí của giá trị riêng sao cho $\lambda_i > \lambda_p$ và $\lambda_{i+1} \leq \lambda_p$. Sau đó, chúng ta thiết lập $\lambda_k, j = i+1; \dots; N$, do đó bảo tồn dấu vết của $\lambda_j = \delta_{ij}$ Ma trận tương quan P_N . Với phép phân tích vectơ riêng $V = \frac{1}{\sqrt{N}} W \Lambda$, chúng ta tạo ma trận tương quan khử nhiễu C_1 như

$$C_1 = \frac{1}{N} W \Lambda W^T$$

$$C_1 = \frac{1}{N} C_1 \text{ diag}(C_1) \text{ hi} \quad \text{diag}(C_1) \text{ xin chào} \quad \#1;$$

trong đó Λ_e là ma trận đường chéo chứa các giá trị riêng đã hiệu chỉnh, dấu nhảy đơn (') chuyển vị một ma trận và $\text{diag}[\cdot]$ làm cho tất cả các phần tử không nằm trên đường chéo của một ma trận bình phương bằng 0. Lý do cho phép biến đổi thứ hai là để định lại tỷ lệ ma trận C_1 , sao cho đường chéo chính của C_1 là một mảng gồm 1. [Đoạn mã 2.5](#) triển khai phương pháp này. [Hình 2.3](#) so sánh logarit của các giá trị riêng trước và sau khi khử nhiễu bằng phương pháp này.

ĐOẠN TRÍCH 2.5 KHỬ NHỊN BẰNG GIÁ TRỊ RIÊNG DƯ HẰNG SỐ


```
def denoisedCorr(eVal,eVec,nFacts):
    # Loại bỏ nhiễu khỏi corr bằng cách sửa các giá trị riêng ngẫu nhiên
    eVal=np.diag(eVal).copy()
    eVal[nFacts:]=eVal[nFacts:].sum()/float(eVal_.shape[0]-nFacts) eVal=np.diag(eVal_)

    corr1=np.dot(eVec,eVal_).dot(eVec.T)
    corr1=cov2corr(corr1)
    trả về corr1

#-----
corr1=Corr khử nhiễu(eVal0,eVec0,nFacts0)
eVal1,eVec1=getPCA(corr1)
```

2.5.2 Co ngót mục tiêu

Phương pháp số được mô tả trước đó được ưa chuộng hơn phương pháp thu hẹp, vì nó loại bỏ tiếng ồn trong khi vẫn giữ nguyên tín hiệu. Ngoài ra, chúng ta có thể nhắm mục tiêu



Hình 2.3 So sánh các giá trị riêng trước và sau khi áp dụng phần dư phương pháp giá trị riêng.


ứng dụng của sự co ngót nghiêm ngặt đối với các vectơ riêng ngẫu nhiên. Hãy xem xét ma trận tương quan C1

$$C1 = \frac{1}{4} \begin{bmatrix} WL & AL & WL \\ \alpha WR & AR & WR \\ \beta \delta \text{Diagonal} & WR & AR \end{bmatrix};$$

trong đó WR và AR là các vectơ riêng và giá trị riêng liên quan đến $n \times n$ λ_{pgf} , WL và AL là các vectơ riêng và giá trị riêng liên quan đến $n \times n$ λ_{pgf} và α điều chỉnh lượng co rút giữa các vectơ riêng và các giá trị riêng liên quan đến nhiễu ($\alpha = 0$ đối với tổng độ co ngót). Đoạn mã 2.6 triển khai phương pháp này. Hình 2.4 so sánh logarit của các giá trị riêng trước và sau khi khử nhiễu bằng phương pháp này.

2.6 NỔ

Ma trận tương quan tài chính thường kết hợp một thành phần thị trường. thành phần thị trường được đặc trưng bởi vectơ riêng đầu tiên, với tải trọng $w_{n;1} \approx N1 \sqrt{2}, n = 1; \dots; N$. Theo đó, một thành phần thị trường ảnh hưởng đến mọi mục của ma trận hiệp phương sai. Trong bối cảnh của các ứng dụng cụm, nó là hữu ích để loại bỏ thành phần thị trường, nếu nó tồn tại (một giả thuyết có thể được (đã được kiểm tra về mặt thống kê)). Lý do là, việc phân cụm mối tương quan khó khăn hơn



Hình 2.4 So sánh các giá trị riêng trước và sau khi áp dụng phương pháp co ngót mục tiêu.

ĐOẠN TRÍCH 2.6 GIẢM NHIỄU BẰNG SỰ THU HÚT CÓ MỤC TIÊU

```
def denoisedCorr2(eVal,eVec,nFacts,alpha=0):
    # Loại bỏ tiếng ồn từ corr thông qua sự co ngót mục tiêu
    eValL,eVecL=eVal[:nSự kiện,:nSự kiện],eVec[:, :nSự kiện]
    eValR,eVecR=eVal[nSự kiện:,nSự kiện:],eVec[:,nSự kiện:]
    corr0=np.dot(eVecL,eValL).dot(eVecL.T)
    corr1=np.dot(eVecR,eValR).dot(eVecR.T)
    corr2=corr0+alpha*corr1+(1-alpha)*np.diag(np.diag(corr1))
    trả về corr2
#-----
corr1=giảm nhiễuCorr2(eVal0,eVec0,nFacts0,alpha=.5)
eVal1,eVec1=getPCA(corr1)
```

ma trận với thành phần thị trường mạnh, vì thuật toán sẽ gặp khó khăn khi tìm ra sự khác biệt giữa các cụm. Bằng cách loại bỏ thành phần thị trường, chúng ta cho phép phần lớn hơn của mỗi tương quan được giải thích bằng các thành phần ảnh hưởng đến các tập hợp con cụ thể của chứng khoán. Tương tự như việc loại bỏ một âm thanh lớn khiến chúng ta không nghe thấy những âm thanh khác. Detoning là phép phân tích thành phần chính tương tự như tính toán lợi nhuận đã điều chỉnh beta (hoặc điều chỉnh thị trường) trong phân tích hồi quy.

C₂ $\frac{1}{4}$ Ce₂ diaq Ce₂ hi chẩn đoán Ce₂ hi ;

Trong phần này, chúng tôi tính toán các lỗi liên quan đến việc ước tính danh mục phương sai tối thiểu có và không có khử nhiễu. **Đoạn mã 2.7** tạo thành một vectơ giá trị trung bình và một ma trận hiệp phương sai từ mười khối có kích thước năm mươi, trong đó các phần tử ngoài đường chéo trong mỗi khối có tương quan là 0,5. Ma trận hiệp phương sai này là một biểu diễn cách điệu của ma trận tương quan detonated thực (không theo kinh nghiệm) của S&P 500, trong đó mỗi khối được liên kết với một lĩnh vực kinh tế. Không mất tính tổng quát, các phương sai được rút ra từ một phân phối đồng đều

ĐOẠN TRÍCH 2.7 TẠO MA TRẬN PHƯƠNG PHÁP ĐOẠN CHÉO KHỐI VÀ MỘT VECTOR CỦA CÓ NGHĨA

```
def formBlockMatrix(nBlocks,bSize,bCorr):
    khối=np.ones((bSize,bSize))*bCorr khối[phạm
    vi(bSize),phạm vi(bSize)]=1
    corr=block_diag*([khối]*nKhối))
    trả lại corr

#- - - - -
def định nghĩa formTrueMatrix(nBlocks,bSize,bCorr):
    corr0=formBlockMatrix(nBlocks,bSize,bCorr)
    corr0=pd.DataFrame(corr0)
    cột = corr0. cột. danh sách()
    np.random.shuffle(cột)
    corr0=corr0[cột].loc[cột].copy(sâu=Đúng)
    std0=np.random.uniform(.05,.2,corr0.shape[0])
    cov0=corr2cov(corr0,std0)
    mu0=np.random.normal(std0,std0,cov0.shape[0]).reshape(-1,1)
    trả về mu0,cov0

#- - - - -
từ scipy.linalg nhập block_diag từ
sklearn.covariance nhập LedoitWolf
nKhối,bKích thước,bCorr=10,50,.5
np.random.seed(0)
mu0,cov0=formTrueMatrix(nBlock,bSize,bCorr)
```

giới hạn giữa 5% và 20%, và vectơ trung bình được rút ra từ phân phối chuẩn với trung bình và độ lệch chuẩn bằng độ lệch chuẩn từ ma trận hiệp phương sai. Điều này phù hợp với khái niệm rằng trong một

thị trường tất cả các chứng khoán đều có cùng tỷ lệ Sharpe dự kiến. Chúng tôi cố định một hạt giống để tạo điều kiện so sánh kết quả giữa các lần chạy với các tham số khác nhau.

Đoạn mã 2.8 sử dụng ma trận hiệp phương sai thực (không theo kinh nghiệm) để vẽ một ma trận ngẫu nhiên X có kích thước $T \times N$ và nó suy ra ma trận hiệp phương sai kinh nghiệm và vectơ trung bình liên quan. Hàm `simCovMu` nhận đối số `nObs`,

ĐOẠN TRÍCH 2.8 TẠO MA TRẬN PHƯƠNG PHÁP KINH NGHIỆM

```
def simCovMu(mu0,cov0,nObs,shrink=False):
    x=np.random.multivariate_normal(mu0.flatten(),cov0,size=nObs) mu1=x.mean(axis=0).reshape(-1,1)
    nếu thu nhỏ:cov1=LedoitWolf().fit(x).covariance_
    nếu không:cov1=np.cov(x,rowvar=0)

    trả về mu1,cov1
```

thiết lập giá trị của T . Khi $\text{shrink}=\text{True}$, hàm thực hiện thu nhỏ Ledoit-Wolf của ma trận hiệp phương sai thực nghiệm.

Đoạn mã 2.9 áp dụng các phương pháp được giải thích trong phần này để khử nhiễu ma trận hiệp phương sai thực nghiệm. Trong thí nghiệm cụ thể này, chúng tôi khử nhiễu thông qua phương pháp giá trị riêng dư không đổi.

ĐOẠN TRÍCH 2.9 GIẢM NHIỆT CỦA MA TRẬN PHƯƠNG PHÁP KINH NGHIỆM

```
def corr2cov(corr,std):
    cov=corr*np.outer(std,std)
    trở về cov

#- - - - -

def deNoiseCov(cov0,q,bWidth):
    corr=corr2cov(cov0)
    eVal0,eVec0=getPCA(corr0)
    eMax0,var0=findMaxEval(np.diag(eVal0),q,bWidth) nFacts0=eVal0.shape[0]-
    np.diag(eVal0)[-1].searchsorted(eMax0)
    corr1=Corr khử nhiễu(eVal0,eVec0,nFacts0)
    cov1=corr2cov(corr1,np.diag(cov0)**.5)
    trở lại cov1
```

Đoạn mã 2.10 chạy thử nghiệm Monte Carlo sau với 1.000 lần lặp: (1) vẽ một ma trận hiệp phương sai kinh nghiệm ngẫu nhiên (tùy chọn thu hẹp) với $T = 1; 000$; (2) khử nhiễu ma trận hiệp phương sai kinh nghiệm (tùy chọn); (3)

ĐOẠN TRÍCH 2.10 GIẢM NHIỆT CỦA MA TRẬN PHƯƠNG PHÁP KINH NGHIỆM

```
def optPort(cov,mu=None):
    inv=np.linalg.inv(cov)
    ones=np.ones(hình dạng=(inv.shape[0],1))
    nếu mu là None:mu=ones
    w=np.dot(inv,mu)
    w/=np.dot(ones.T,w)
    trở lại w

#- - - - -

nObs, nTrials, bWidth, thu nhỏ, minVarPortf=1000,1000,.01, False, True
w1=pd.DataFrame(columns=xrange(cov0.shape[0]),
                  chỉ số = xrange(nThử nghiệm),dtype = float)

w1_d=w1.copy(deep=True)
np.random.seed(0) cho i
trong phạm vi(nThử nghiệm):
    mu1,cov1=simCovMu(mu0,cov0,nObs,shrink=thu nhỏ)
    nếu minVarPortf:mu1=None
    cov1_d=deNoiseCov(cov1,nObs*1./cov1.shape[1],bWidth)
    w1.loc[i]=optPort(cov1,mu1).flatten()
    w1_d.loc[i]=optPort(cov1_d,mu1).flatten()
```


lấy danh mục phương sai tối thiểu, sử dụng hàm `optPort`. Khi chúng ta truyền đối số `shrink=True` cho hàm `simCovMu`, ma trận hiệp phương sai là thu nhỏ. Khi tham số `bWidth>0`, ma trận hiệp phương sai được khử nhiễu trước ước tính danh mục đầu tư có phương sai tối thiểu.⁸ Một hạt giống ngẫu nhiên được thiết lập tùy ý, do đó rằng chúng ta có thể chạy thử nghiệm Monte Carlo này trên cùng một ma trận hiệp phương sai, có và không có khử nhiễu.

Đoạn mã 2.11 tính toán danh mục phương sai tối thiểu thực sự, được lấy từ từ ma trận hiệp phương sai thực. Sử dụng các phân bố đó làm chuẩn mực, sau đó tính toán các lỗi bình phương trung bình căn bậc hai (RMSE) trên tất cả các trọng số, với và không cần khử nhiễu. Chúng ta có thể chạy [Code Snippet 2.11](#) có và không có sự co lại, do đó thu được bốn kết hợp được hiển thị trong [Hình 2.5](#). Giảm nhiễu nhiều hơn hiệu quả hơn sự co lại: danh mục đầu tư phương sai tối thiểu được khử nhiễu phải chịu chỉ 40,15% RMSE phát sinh do danh mục phương sai tối thiểu mà không có khử nhiễu. Đó là mức giảm 59,85% trong RMSE chỉ từ việc khử nhiễu, so với mức giảm 30,22% khi sử dụng phương pháp co ngót Ledoit-Wolf. Co ngót thêm ít lợi ích vượt xa những gì khử nhiễu mang lại. Việc giảm RMSE từ kết hợp khử nhiễu với co ngót là 65,63%, không tốt hơn nhiều so với kết quả chỉ sử dụng khử nhiễu.

Snippet 2.11 Lỗi bình phương trung bình gốc

```
w0=optPort(cov0, Không nếu minVarPortf nếu không thì mu0)
w0=np.repeat(w0.T,w1.shape[0],axis=0)
rmsd=np.mean((w1-w0).values.flatten())**2)**.5 # RMSE
rmsd_d=np.mean((w1_d-w0).values.flatten())**2)**.5 # RMSE
in rmsd,rmsd_d
```

	Không khử nhiễu	Đã khử nhiễu
Không bị co lại	4.95E-03	1.99E-03
Thu nhỏ	3.45E-03	1.70E-03

Hình 2.5 RMSE cho các kết hợp giữa khử nhiễu và co ngót (danh mục phương sai tối thiểu).

2.7.2 Danh mục đầu tư tỷ lệ Sharpe tối đa

Chúng ta có thể lặp lại thí nghiệm trước đó, trong đó lần này chúng ta nhắm mục tiêu vào ước tính danh mục đầu tư tỷ lệ Sharpe tối đa. Để làm được điều đó, chúng ta cần

⁸ Như một bài tập, chúng ta sẽ thực hiện ước tính thông qua xác thực chéo giá trị tối ưu của `bWidth`.

để đặt `minVarPortf=True` trong [Đoạn mã 2.10](#). [Hình 2.6](#) cho thấy rằng, một khi một lần nữa, việc khử nhiễu hiệu quả hơn nhiều so với việc co lại: mức khử nhiễu tối đa Danh mục tỷ lệ Sharpe chỉ chịu 0,04% RMSE do danh mục tỷ lệ Sharpe tối đa chịu mà không cần khử nhiễu. Đó là mức giảm 94,44% RMSE từ việc khử nhiễu đơn thuần, so với mức giảm 70,77% khi sử dụng Ledoit-Sự co ngót của Wolf. Trong khi sự co ngót có phần hữu ích khi không có sự khử nhiễu, nó không mang lại lợi ích gì khi kết hợp với việc khử nhiễu. Điều này là do sự co ngót làm loãng tiếng ồn nhưng cũng làm loãng một số tín hiệu.

	Không khử nhiễu	Đã khử nhiễu
Không bị co lại	9.48E-01	5.27E-02
Thu nhỏ	2.77E-01	5.17E-02

Hình 2.6 RMSE cho các kết hợp khử nhiễu và sự co lại (danh mục đầu tư có tỷ lệ Sharpe tối đa).

2.8 Kết luận

Trong tài chính, ma trận hiệp phương sai thực nghiệm thường có điều kiện số không tốt, như một kết quả của số lượng nhỏ các quan sát độc lập được sử dụng để ước tính một lượng lớn số lượng tham số. Làm việc trực tiếp với các ma trận đó, không cần xử lý, là không được khuyến khích. Ngay cả khi ma trận hiệp phương sai không kỳ dị, và do đó không thể đảo ngược, định thức nhỏ gần như đảm bảo rằng lỗi ước tính sẽ là được khuếch đại rất nhiều bởi quá trình đảo ngược. Những lỗi ước tính này gây ra sự phân bố sai tài sản và chi phí giao dịch đáng kể do việc tái cân bằng không cần thiết.

Định lý Marcenko-Pastur cung cấp cho chúng ta sự phân bố của các giá trị riêng liên quan đến một ma trận ngẫu nhiên. Bằng cách phù hợp với phân phối này, chúng ta có thể phân biệt giữa các giá trị riêng liên quan đến tín hiệu và các giá trị riêng liên quan đến nhiễu. Cái sau có thể được điều chỉnh để sửa chữa tình trạng xấu của ma trận mà không làm loãng tín hiệu. Cách tiếp cận lý thuyết ma trận ngẫu nhiên này thường được ưa chuộng hơn (1) phương pháp ngưỡng ([Jolliffe 2002](#), 113), trong đó chọn một số thành phần cùng nhau giải thích một lượng phương sai cố định, bất kể lượng phương sai thực sự là bao nhiêu do tiếng ồn gây ra; và (2) phương pháp co ngót ([Ledoit và Wolf 2004](#)), có thể loại bỏ một số tiếng ồn nhưng phải đánh đổi bằng việc làm loãng phần lớn tín hiệu.

Nhớ lại rằng số điều kiện của ma trận tương quan là tỷ lệ giữa giá trị riêng cực đại và cực tiểu (theo moduli). Việc khử nhiễu làm giảm số điều kiện bằng cách tăng giá trị riêng thấp nhất. Chúng ta có thể giảm thêm số điều kiện bằng cách giảm giá trị riêng cao nhất. Điều này làm cho toán học giác quan, và cũng là giác quan trực quan. Loại bỏ các thành phần thị trường có trong

ma trận tương quan củng cố các tín hiệu tinh tế hơn ẩn dưới "giọng điệu" của thị trường. Ví dụ, nếu chúng ta đang cố gắng nhóm một ma trận tương quan của lợi nhuận cổ phiếu, việc làm nổi bật ma trận đó có thể sẽ giúp khuếch đại các tín hiệu liên quan đến các mức độ tiếp xúc khác, chẳng hạn như lĩnh vực, ngành hoặc quy mô.

Chúng tôi đã chứng minh tính hữu ích của việc khử nhiễu trong bối cảnh tối ưu hóa danh mục đầu tư, tuy nhiên ứng dụng của nó mở rộng sang bất kỳ cách sử dụng nào của ma trận hiệp phương sai. Ví dụ, việc khử nhiễu ma trận $X \times X$ trước khi đảo ngược nó sẽ giúp giảm phương sai của ước tính hồi quy và cải thiện sức mạnh của các thử nghiệm thống kê về giả thuyết. Vì lý do tương tự, các ma trận hiệp phương sai có nguồn gốc từ các yếu tố hồi quy (còn được gọi là ma trận hiệp phương sai dựa trên yếu tố) cũng yêu cầu khử nhiễu và không nên sử dụng mà không có xử lý số.

2.9 Bài tập

1 Triển khai phương pháp nổi được mô tả trong [Phần 2.6 bằng Python](#).

2 Sử dụng một loạt ma trận lợi nhuận cổ phiếu: a

Tính toán ma trận hiệp phương sai. Số điều kiện của ma trận tương quan?

b Tính một trăm biên giới hiệu quả bằng cách vẽ một trăm vectơ bản địa thay thế của lợi nhuận dự kiến từ phân phối chuẩn với trung bình 10% và độ lệch chuẩn 10%.

c Tính toán phương sai của các lỗi so với đường biên hiệu quả trung bình.

3 Lập lại Bài tập 2, lần này bạn khử nhiễu ma trận hiệp phương sai trước

tính toán một trăm biên giới hiệu quả. a Giá trị của

σ^2 được ngụ ý bởi phân phối Marcenko-Pastur là bao nhiêu? b Có bao nhiêu giá trị riêng được liên kết với các thành phần ngẫu nhiên? c Phương sai của các lỗi cao hơn hay thấp hơn đáng kể? Tại sao?

4 Lập lại Bài tập 2, lần này bạn áp dụng phương pháp thu nhỏ Ledoit-Wolf (thay vì khử nhiễu) trên ma trận hiệp phương sai trước khi tính toán một trăm biên giới hiệu quả. Phương sai của các lỗi cao hơn hay thấp hơn đáng kể? Tại sao?

5 Lập lại Bài tập 3, lần này bạn cũng loại bỏ ma trận hiệp phương sai trước khi tính toán một trăm biên giới hiệu quả. Phương sai của các lỗi cao hơn hay thấp hơn đáng kể? Tại sao?

6 Điều gì xảy ra nếu bạn loại bỏ các thành phần có giá trị riêng giảm xuống dưới ngưỡng nhất định? Bạn vẫn có thể tính toán được các biên giới hiệu quả không? Bằng cách nào?

7 Mở rộng hàm fitKDE trong Code Snippet 2.2, để nó ước tính thông qua xác thực chéo giá trị tối ưu của $bWidth$.

3 Khoảng cách đo lường

3.1 Động lực

Trong [Phần 2](#), chúng tôi đã nghiên cứu các tính chất số quan trọng của ma trận tương quan thực nghiệm (và theo nghĩa mở rộng là hiệp phương sai). Bất chấp tất cả các ưu điểm của nó, tương quan vẫn phải chịu một số hạn chế quan trọng như một thước đo của sự phụ thuộc lẫn nhau. Trong phần này, chúng tôi khắc phục những hạn chế đó bằng cách xem xét các khái niệm lý thuyết thông tin làm nền tảng cho nhiều điều kỳ diệu hiện đại, chẳng hạn như internet, điện thoại di động, nén tệp, phát trực tuyến video hoặc mã hóa. Không một phát minh nào trong số này có thể thành hiện thực nếu các nhà nghiên cứu không nhìn xa hơn các mối tương quan để hiểu về sự phụ thuộc lẫn nhau.

Hóa ra, lý thuyết thông tin nói chung và khái niệm entropy của Shannon nói riêng cũng có những ứng dụng hữu ích trong tài chính. Ý tưởng chính đằng sau entropy là định lượng lượng bất định liên quan đến một biến ngẫu nhiên. Lý thuyết thông tin cũng rất cần thiết đối với ML, vì mục tiêu chính của nhiều thuật toán ML là giảm lượng bất định liên quan đến giải pháp cho một vấn đề. Trong phần này, chúng tôi xem xét các khái niệm được sử dụng trong ML trong nhiều bối cảnh khác nhau, bao gồm (1) xác định hàm mục tiêu trong học cây quyết định; (2) xác định hàm mất mát cho các vấn đề phân loại; (3) đánh giá khoảng cách giữa hai biến ngẫu nhiên; (4) so sánh các cụm; và (5) lựa chọn tính năng.

3.2 Một phép đo dựa trên tương quan

Tương quan là một phép đo hữu ích về sự phụ thuộc lẫn nhau tuyến tính. Khi ma trận tương quan đã được khử nhiễu và khử nhiễu, nó có thể tiết lộ thông tin cấu trúc quan trọng về một hệ thống. Ví dụ, chúng ta có thể sử dụng tương quan để xác định các cụm chứng khoán có mối quan hệ mật thiết cao. Nhưng trước khi có thể làm điều đó, chúng ta cần giải quyết một vấn đề kỹ thuật: tương quan không phải là một phép đo, vì nó không thỏa mãn các điều kiện bất đẳng thức tam giác và không âm. Các phép đo rất quan trọng vì chúng tạo ra một tô pô trực quan trên một tập hợp. Nếu không có tô pô trực quan đó, việc so sánh các phép đo không phải là phép đo về sự phụ thuộc lẫn nhau có thể dẫn đến những kết quả không nhất quán. Ví dụ, sự khác biệt giữa các tương quan $(0, 9, 1, 0)$ giống như $(0, 1, 0, 2)$, mặc dù phép đo trước liên quan đến sự khác biệt lớn hơn về mặt phụ thuộc lẫn nhau.

Xét hai vectơ ngẫu nhiên X, Y có kích thước T và ước lượng tương quan $\rho^{1/2}X; Y$, với yêu cầu duy nhất là $\sigma^{1/2}X; Y \sim \rho^{1/2}X; Y$; $Y \sim \sigma^{1/2}X \sigma^{1/2}Y$, trong đó $\sigma^{1/2}X; Y$ là hiệp phương sai giữa hai vectơ và $\sigma^{1/2}$ là độ lệch chuẩn. Tương quan Pearson là một trong số nhiều ước lượng tương quan

Để chứng minh tuyên bố đó, trước tiên hãy xem xét khoảng cách Euclid giữa hai vectơ là $d^2(x; y) = \frac{1}{2} \|x - y\|^2$. Thứ hai, chúng tôi chuẩn hóa n những các vectơ như $x = \frac{1}{\sqrt{n}} \sum_{i=1}^n x_i e_i$, $y = \frac{1}{\sqrt{n}} \sum_{i=1}^n y_i e_i$, trong đó x_i là giá trị trung bình của X_i , và y_i là giá trị trung bình của Y_i . Do đó, $d^2(x; y) = \frac{1}{2n} \sum_{i=1}^n (x_i - y_i)^2$. Thứ ba, chúng ta suy ra khoảng cách Euclidean $d(x; y)$ là

$$\begin{array}{c} \text{d}^{1/2}x; \text{ y }^{1/4} \\ \text{S} \end{array} \quad \begin{array}{c} \text{T} \\ \text{x} \quad \text{xt} \quad \text{yt} \quad \text{p}^2 \\ \text{t}^{1/4}1 \end{array} \quad \begin{array}{c} \text{T} \\ \text{x} \quad \text{x}^2 \quad \text{px} \quad \text{y}^2 \\ \text{vuut t}^{1/4}1 \end{array} \quad \begin{array}{c} \text{T} \\ 2 \quad \text{l} \text{ä} \text{n}^{\text{xtyt}} \quad \text{p} \quad \text{T} \quad \text{p} \quad \text{T} \quad 2\text{T}\sigma^{1/2}x; \text{ y} \\ \text{t}^{1/4}1 \end{array}$$

Tương tự như vậy, chúng ta có thể chứng minh rằng $d(p^{1/2}X; Y)$ giảm xuống một metric thực trên $Z=2Z$ thường. Để làm được điều đó, chúng ta định nghĩa lại $y^{1/4} \overline{\partial} Y = p \circ s^{1/2} Y \operatorname{sgn}^{1/2} p^{1/2} X$; Y , trong đó $\operatorname{sgn}^{1/2}$: là toán tử dấu, do đó $0 \leq p^{1/2}X$; $y^{1/4} j p^{1/2} X$; Y_j . Sau đó, theo cùng một lập luận được sử dụng trước đó,

$$d^{1/2}x; y^{1/4} \quad 2T \quad 01 \quad p^{1/2}x; y^{1/4} \quad 2T \quad p \quad dj p^{1/2}x; y:$$

$$B@ \quad 1/4 \quad j p^{1/2}x; y \quad j CA$$

3.3 Entropy biên và Entropy liên hợp

Khái niệm tương quan đưa ra ba cảnh báo quan trọng. Đầu tiên, nó định lượng sự phụ thuộc tuyến tính giữa hai biến ngẫu nhiên. Nó bỏ qua các mối quan hệ phi tuyến tính. Thứ hai, tương quan bị ảnh hưởng rất nhiều bởi các giá trị ngoại lai. Thứ ba, ứng dụng của nó ngoài trường hợp Chuẩn đa biến là đáng ngờ. Chúng ta có thể tính toán tương quan giữa bất kỳ hai biến thực nào, tuy nhiên tương quan đó thường vô nghĩa trừ khi hai biến tuân theo phân phối Chuẩn hai biến. Để khắc phục những cảnh báo này, chúng ta cần giới thiệu một số khái niệm lý thuyết thông tin.

Cho X là biến ngẫu nhiên rời rạc lấy giá trị x từ tập SX với xác suất $p^{1/2}x$. Entropy của X được định nghĩa là

$$H^{1/2}X^{1/4}X \quad p^{1/2}x \log^{1/2} p^{1/2}x;$$

$$x \in SX$$

Trong suốt phần này, chúng ta sẽ tuân theo quy ước rằng $0 \log^{1/2} 0^{1/4} 0$, vì $\lim_{p \rightarrow 0} p \log^{1/2} p^{1/4} 0$. Giá trị $1 = p^{1/2}x$ đo lường mức độ bất ngờ của một quan sát, vì các quan sát bất ngờ được đặc trưng bởi xác suất thấp của chúng. Entropy là giá trị kỳ vọng của những bất ngờ đó, trong đó hàm $\log^{1/2}$: ngăn ngừa việc $p^{1/2}x$ hủy bỏ $1 = p^{1/2}x$ và mang lại cho entropy các tính chất toán học mong muốn. Theo đó, entropy có thể được hiểu là lượng bất định liên quan đến X . Entropy bằng không khi toàn bộ xác suất tập trung vào một phần tử duy nhất của SX . Entropy đạt cực đại tại $\log^{1/2} SX$ khi X phân phối đều, $p^{1/2}x^{1/4} 1 = SX$; $8x \in SX$.

Cho Y là biến ngẫu nhiên rời rạc lấy giá trị y từ tập SY với xác suất $p^{1/2}y$. Biến ngẫu nhiên X và Y không cần được định nghĩa trên cùng một không gian xác suất. Entropy chung của X và Y là

$$H^{1/2}X; Y^{1/4}X \quad p^{1/2}x; y \log^{1/2} p^{1/2}x; y:$$

$$x; y \in SX \cup SY$$

Cụ thể, ta có $H^{1/2}X; Y^{1/4} H^{1/2}Y; X$, $H^{1/2}X; X^{1/4} H^{1/2}X$, $H^{1/2}X; Y \geq \max H^{1/2}X; H^{1/2}Y$, và $H^{1/2}X; Y \leq H^{1/2}X \cup H^{1/2}Y$.

Điều quan trọng là phải nhận ra rằng entropy của Shannon chỉ hữu hạn đối với các biến ngẫu nhiên rời rạc. Trong trường hợp liên tục, người ta nên sử dụng mật độ giới hạn của các điểm rời rạc (LDDP) hoặc rời rạc hóa biến ngẫu nhiên, như đã giải thích trong [Phần 3.9 \(Jaynes 2003\)](#).

3.4 Entropy có điều kiện

Entropy có điều kiện của X khi Y được xác định là

$$H^{1/2}X|Y = H^{1/2}X; Y = H^{1/2}Y^{1/4}X \quad p^{1/2}y \quad X \quad p^{1/2}x|y = \frac{1}{4} \quad y \log \frac{1}{2} p^{1/2}x|y = \frac{1}{4} \quad y; \\ y^{2SY} \quad x^{2SX}$$

trong đó $p^{1/2}x|y = \frac{1}{4} \quad y$ là xác suất X lấy giá trị x với điều kiện Y đã lấy giá trị y . Theo định nghĩa này, $H^{1/2}X|Y$ là độ không chắc chắn mà chúng ta mong đợi trong X nếu chúng ta được cho biết giá trị của Y . Theo đó, $H^{1/2}X|X = \frac{1}{4} \quad 0$ và $H^{1/2}X \geq H^{1/2}X|Y$.

3.5 Phân kỳ Kullback-Leibler

Cho p và q là hai phân phối xác suất rời rạc được xác định trên cùng một không gian xác suất. Độ phân kỳ Kullback-Leibler (hoặc KL) giữa p và q là

$$DKL^{1/2} \quad p \quad q^{1/4}X \quad \frac{q^{1/2}x}{x^{2SX}} \quad \frac{1}{p^{1/2}x \log \frac{1}{p^{1/2}x}} \quad \frac{1}{4}X \quad \frac{p^{1/2}x \log \frac{p^{1/2}x}{q^{1/2}x}}{x^{2SX}} ;$$

trong đó $q^{1/2}x = \frac{1}{4} \quad 0$) $p^{1/2}x = \frac{1}{4} \quad 0$. Theo trực giác, biểu thức này đo lường mức độ p phân kỳ so với phân phối tham chiếu q . Độ phân kỳ KL không phải là một phép đo: mặc dù nó luôn không âm ($DKL^{1/2} \quad p \quad q \geq 0$), nhưng nó vi phạm tính đối xứng ($DKL^{1/2} \quad p \quad q \neq DKL^{1/2} \quad q \quad p$) và các điều kiện bất đẳng thức tam giác. Lưu ý sự khác biệt với định nghĩa về entropy chung, trong đó hai biến ngẫu nhiên không nhất thiết phải tồn tại trong cùng một không gian xác suất. Độ phân kỳ KL được sử dụng rộng rãi trong suy luận biến phân.

3.6 Entropy chéo

Cho p và q là hai phân phối xác suất rời rạc được xác định trên cùng một không gian xác suất. Entropy chéo giữa p và q là

$$HC^{1/2} \quad p \quad q^{1/4}X \quad p^{1/2}x \log \frac{1}{2} q^{1/2}x = \frac{1}{4} \quad H^{1/2}X \quad p \quad DKL^{1/2} \quad p \quad q :$$

Cross-entropy có thể được hiểu là sự không chắc chắn liên quan đến X , trong đó chúng ta đánh giá nội dung thông tin của nó bằng cách sử dụng phân phối sai q thay vì phân phối thực p . Cross-entropy là một hàm tính điểm phổ biến trong các bài toán phân loại và đặc biệt có ý nghĩa trong các ứng dụng tài chính (López de Prado 2018, phần 9.4).

3.7 Thông tin chung

Thông tin tương hỗ được định nghĩa là sự giảm đi sự không chắc chắn (hoặc lợi ích thông tin) trong X có được do biết được giá trị của Y :

$$I^{1/2}X; Y = \frac{1}{4} H^{1/2}X - H^{1/2}X|Y = \frac{1}{4} H^{1/2}X - \frac{1}{4} H^{1/2}Y - H^{1/2}X; Y = \frac{1}{4} p^{1/2}x; y$$

$$\begin{aligned} I^{1/2}X; Y &= \frac{1}{4} X \log \frac{X}{x_{2S} x_{2Y}} - \frac{1}{4} p^{1/2}x; y \log \frac{p^{1/2}x; y}{p^{1/2}x p^{1/2}y} \\ &= \frac{1}{4} DKL \frac{1}{2} p^{1/2}x; y - \frac{1}{4} X \log \frac{X}{x_{2S} x_{2Y}} - \frac{1}{4} p^{1/2}y \log \frac{p^{1/2}y}{p^{1/2}x} \\ &= \frac{1}{4} EY - \frac{1}{4} DKL \frac{1}{2} p^{1/2}x; y - \frac{1}{4} X \log \frac{X}{x_{2S} x_{2Y}} - \frac{1}{4} p^{1/2}y \log \frac{p^{1/2}y}{p^{1/2}x} \\ &= \frac{1}{4} EX - \frac{1}{4} DKL \frac{1}{2} p^{1/2}y; x - \frac{1}{4} p^{1/2}y; \end{aligned}$$

Từ trên ta thấy rằng $I^{1/2}X; Y \geq 0$, $I^{1/2}X; Y = \frac{1}{4} I^{1/2}Y; X$ và $I^{1/2}X; X = \frac{1}{4} H^{1/2}X$. Khi X và Y độc lập, $p^{1/2}x; y = \frac{1}{4} p^{1/2}x p^{1/2}y$, do đó $I^{1/2}X; Y = \frac{1}{4} 0$. Giới hạn trên được đưa ra bởi $I^{1/2}X; Y \leq \min H^{1/2}X; H^{1/2}Y$. Tuy nhiên, thông tin tương hỗ không phải là một phép đo, vì nó không thỏa mãn bất đẳng thức tam giác: $I^{1/2}X; Z \leq I^{1/2}X; Y + I^{1/2}Y; Z$. Một thuộc tính quan trọng của thông tin tương hỗ là tính chất nhóm của nó,

$$I^{1/2}X; Y; Z = \frac{1}{4} I^{1/2}X; Y + \frac{1}{4} I^{1/2}Y; Z; X; Y; Z;$$

trong đó $\frac{1}{4} X; Y$ biểu diễn phân phối chung của X và Y . Vì X , Y và Z có thể tự biểu diễn phân phối chung, nên tính chất trên có thể được sử dụng để phân tích thông tin chung thành các thành phần đơn giản hơn. Điều này làm cho thông tin chung trở thành một biện pháp tương tự hữu ích trong bối cảnh của các thuật toán phân cụm kết tụ và lựa chọn tính năng chuyển tiếp.

Với hai mảng x và y có kích thước bằng nhau, được phân rã thành một lưới đều với số phân vùng (thùng) trên mỗi chiều, [Đoạn mã 3.1](#) cho thấy cách tính entropy biên, entropy kết hợp, entropy có điều kiện và thông tin tương hỗ trong python.

3.8 Sự thay đổi của thông tin

Sự thay đổi của thông tin được định nghĩa là

$$\begin{aligned} VI^{1/2}X; Y &= \frac{1}{4} H^{1/2}X|Y - \frac{1}{4} H^{1/2}Y|X = \frac{1}{4} H^{1/2}X - \frac{1}{4} H^{1/2}Y - \frac{1}{4} I^{1/2}X; Y \\ &= \frac{1}{4} 2H^{1/2}X; Y - \frac{1}{4} H^{1/2}X - \frac{1}{4} H^{1/2}Y - \frac{1}{4} I^{1/2}X; Y; \end{aligned}$$

Biện pháp này có thể được diễn giải như là sự không chắc chắn mà chúng ta mong đợi ở một biến nếu chúng ta được cho biết giá trị của biến khác. Nó có giới hạn dưới trong $VI^{1/2}X; Y = \frac{1}{4} 0$ $X = \frac{1}{4} Y$, và giới hạn trên

ĐOẠN TRÍCH 3.1 ENTROPIE BIÊN, LIÊN KẾT, CÓ ĐIỀU KIỆN VÀ THÔNG TIN TƯƠNG NHAU

```

nhập numpy dưới dạng np, scipy.stats dưới dạng ss
từ sklearn.metrics nhập mutual_info_score
cXY=np.histogram2d(x,y,bins)[0]
hX=ss.entropy(np.histogram(x,bins)[0]) # biên
hY=ss.entropy(np.histogram(y,bins)[0]) # biên
iXY=mutual_info_score(Không có, Không có, tình huống bất ngờ=cXY)
iXYn=iXY/min(hX,hY) # thông tin tương hỗ được chuẩn hóa
hXY=hX+hY-iXY # khớp
hX_Y=hXY-hY # có điều kiện
hY_X=hXY-hX # có điều kiện

```

được liên kết trong $VI_{1/2}X; Y \leq H_{1/2}X; Y$. Sự thay đổi của thông tin là một phép đo, bởi vì nó thỏa mãn các tiên đề (1) không âm, $VI_{1/2}X; Y \geq 0$; (2) tính đối xứng,

$VI_{1/2}X; Y = 1/4 VI_{1/2}Y; X$; và (3) bất đẳng thức tam giác, $VI_{1/2}X; Z \leq VI_{1/2}X; Y + VI_{1/2}Y; Z$.

Bởi vì $H_{1/2}X; Y$ là một hàm số của kích thước SX và SY , $VI_{1/2}X; Y$ không có một giới hạn trên vững chắc. Điều này gây ra vấn đề khi chúng ta muốn so sánh sự thay đổi của thông tin trên các quy mô dân số khác nhau. Sau đây

số lượng là một số liệu giới hạn giữa không và một đối với mọi cặp $\delta \in X; Y$:

$$VI_{1/2}X; Y \leq \frac{VI_{1/2}X; Y}{H_{1/2}X; Y} \leq 1 \leq \frac{Tối_{1/2}X; Y}{H_{1/2}X; Y}.$$

Theo Kraskov et al. (2008), một phép đo giới hạn thay thế sắc nét hơn là

$$VI_{1/2}X; Y \leq \frac{\text{tối đa } H_{1/2}X_j Y; H_{1/2}Y_j X_g}{1 \text{ tối đa } H_{1/2}X; H_{1/2}Y_g} \leq \frac{Tối_{1/2}X; Y}{\text{tối đa } H_{1/2}X; H_{1/2}Y_g};$$

nơi $VI_{1/2}X; Y \leq VI_{1/2}X; Y$ cho tất cả các cặp $\delta \in X; Y$. Theo ví dụ trước, [Đoạn mã 3.2](#)

tính toán thông tin tương hỗ, sự thay đổi của thông tin,

và sự thay đổi chuẩn hóa của thông tin.⁹

Tóm lại, [Hình 3.1](#) cung cấp một hình ảnh trực quan về cách thức những điều này các khái niệm có liên quan với nhau.

3.9 Phân biệt

Trong suốt phần này, chúng tôi đã giả định rằng các biến ngẫu nhiên là rời rạc.

Đối với trường hợp liên tục, chúng ta có thể lượng tử hóa (hạt thô) các giá trị và áp dụng các khái niệm tương tự trên các quan sát được phân loại. Hãy xem xét một sự ngẫu nhiên liên tục biến X , với các hàm phân phối xác suất $f_X(x)$. Shannon đã định nghĩa nó (phân biệt) entropy như

ĐOẠN TRÍCH 3.2 THÔNG TIN LỒNG NHAU , SỰ BIẾN ĐỔI CỦA THÔNG TIN VÀ CHUẨN HÓA
SỰ THAY ĐỔI CỦA THÔNG TIN

nhập numpy dưới dạng np, scipy.stats dưới dạng ss

từ sklearn.metrics nhập mutual_info_score

#-----

```
def varInfo(x,y,bins,norm=False):
```

```
    # biến thể của thông tin
```

```
    cXY=np.histogram2d(x,y,bins)[0]
```

```
    iXY=mutual_info_score(Không có, Không có, tình huống bất ngờ=cXY)
```

```
    hX=ss.entropy(np.histogram(x,bins)[0]) # biên
```

```
    hY=ss.entropy(np.histogram(y,bins)[0]) # biên
```


```
    vXY=hX+hY-2*iXY # biến thể của thông tin
```

```
    nếu chuẩn mực:
```

```
        hXY=hX+hY-iXY # khớp vXY/=hXY
```

```
        # biến thiên chuẩn hóa của thông tin
```

```
    trả về vXY
```



Hình 3.1 Sự tương ứng giữa entropy chung, entropy biên, entropy có điều kiện, thông tin tương hỗ và biến thiên thông tin.

$$H^{1/2} X^{1/4} \int_{-\infty}^{\infty} f_X^{1/2} x \log^{1/2} f_X^{1/2} x dx :$$

Entropy của biến ngẫu nhiên Gaussian X là $H^{1/2} X^{1/4} \ln 2\pi\sigma^2$, do đó $H^{1/2} X \approx 1.42$ trong trường hợp Chuẩn mực. Một cách để ước tính $H^{1/2} X$ trên một mẫu hữu hạn các giá trị thực là chia phạm vi bao trùm các giá trị quan sát được xg thành các thùng BX có kích thước bằng nhau $\Delta X^{1/4}$ để $\max xg \min f f xg = BX$, cho chúng ta

$$H^{1/2} X \approx X \sum_{i=1}^n f_X^{1/2} x_i \log^{1/2} f_X^{1/2} x_i \Delta X ;$$

trong đó $f_X^{1/2} x_i$ biểu thị tần suất quan sát nằm trong thùng thứ i . Giả sử $p^{1/2} x_i$ là xác suất rút ra một quan sát trong đoạn ΔX

tương ứng với bin thứ i . Chúng ta có thể xấp xỉ $p^{1/2}x_i$ khi $p^{1/2}x_i \approx f_X^{1/2}x_i\Delta X$, có thể ước tính là $p^{1/2}x_i \approx \frac{1}{4} N_i/N$, trong đó N_i là số quan sát trong bin thứ i , $N \approx \frac{1}{4} \sum_{i=1}^N N_i$. Điều này dẫn đến một ước lượng rời rạc của entropy có dạng

$$H^{1/2} X \approx \sum_{i=1}^N \frac{N_i}{N} \log \frac{N_i}{N} \approx \log \frac{1}{2} \Delta X :$$

Theo cùng một lập luận, ước lượng của entropy chung là

$$H^{1/2} X; Y \approx \sum_{j=1}^N \frac{N_{i,j}}{N} \log \frac{N_{i,j}}{N} \approx \log \frac{1}{2} \Delta X \Delta Y :$$

Từ các ước lượng $H^{1/2} X$ và $H^{1/2} X; Y$, chúng ta có thể suy ra các ước lượng cho entropy có điều kiện, thông tin tương hỗ và biến thiên của thông tin. Như chúng ta có thể thấy từ các phương trình này, kết quả có thể bị sai lệch do lựa chọn BX và BY của chúng ta. Đối với trường hợp entropy biên, [Hacine-Gharbi và cộng sự \(2012\)](#) nhận thấy rằng việc phân loại sau đây là tối ưu:

$$BX \approx \frac{1}{4} \text{ tròn } \frac{\zeta}{6} \approx \frac{2}{3\zeta} \approx \frac{1}{3}$$

$$\frac{1}{4} \approx \frac{8}{324N} \approx \frac{12}{36N} \approx \frac{72}{9N^2}$$

Đối với trường hợp entropy chung, [Hacine-Gharbi và Ravier \(2018\)](#) nhận thấy rằng việc phân loại tối ưu được đưa ra bởi

$$BX \approx \frac{1}{4} \approx \frac{2}{4} \approx \frac{1}{2} \approx \frac{24N}{p^2} \approx \frac{3}{5};$$

trong đó p^2 là tương quan ước tính giữa X và Y . [Đoạn mã 3.3](#) sửa đổi hàm `varInfo` trước đó để hàm này kết hợp phân nhóm tối ưu được suy ra từ hàm `numBins`.

3.10 Khoảng cách giữa hai phân vùng

Trong các phần trước, chúng ta đã đưa ra các phương pháp để đánh giá sự giống nhau giữa các biến ngẫu nhiên. Chúng ta có thể mở rộng các khái niệm này thành bài toán so sánh hai phân vùng của cùng một tập dữ liệu, trong đó các phân vùng có thể được coi là ngẫu nhiên ở một mức độ nào đó ([Meila 2007](#)). Phân vùng P của tập dữ liệu D là một tập hợp không có thứ tự của các tập con không rỗng không giao nhau:

```
ĐOẠN TRÍCH 3.3 SỰ BIẾN ĐỔI CỦA THÔNG TIN TRÊN NGẪU NHIÊN LIÊN TỤC RỜI RỜI
BIẾN

def numBins(nObs,corr=Không có):
    # Số lượng thùng tối ưu để phân biệt
    nếu corr là None: # trường hợp đơn biến
        z=(8+324*nObs+12*(36*nObs+729*nObs**2)**.5)**(1/3.) b=vòng(z/6.+2./(3*z)+1./3)

    else: # trường hợp hai biến
        b=vòng(2**-.5*(1+(1+24*nObs/(1.-corr**2))**.5)**.5)
    trả về int(b)

#-----
def varInfo(x,y,norm=False):
    # biến thể của thông tin
    bXY=numBins(x.shape[0],corr=np.corrcoef(x,y)[0,1]) cXY=np.histogram2d(x,y,bXY)[0]
    iXY=mutual_info_score(None,None,contingency=cXY)
    hX=ss.entropy(np.histogram(x,bXY)[0]) # biến hY=ss.entropy(np.histogram(y,bXY)[0])
    # biến

    vXY=hX+hY-2*iXY # biến thể của thông tin
    nếu chuẩn mực:
        hXY=hX+hY-iXY # khớp
        vXY=hXY # biến thể chuẩn hóa của thông tin
    trả về vXY
```

$$P \frac{1}{4} fDkgk^{\frac{1}{4}}1; \dots; K;$$
$$Đk > 0;$$
$$8k; Dk \cap D1^{\frac{1}{4}}; 8k \frac{6}{4} \text{ lít};$$
$$k \quad Dk^{\frac{1}{4}} \quad D:$$
$$k^{\frac{1}{4}}1$$

Chúng ta hãy định nghĩa độ bất định liên quan đến P. Đầu tiên, chúng ta đặt xác suất chọn bất kỳ phần tử d 2 D nào là $p_{e^{\frac{1}{2}d}}^{\frac{1}{4}} 1=||D||$. Thứ hai, chúng ta định nghĩa xác suất một phần tử d 2 D được chọn ngẫu nhiên thuộc về tập hợp con Dk là $p^{\frac{1}{2}k} \frac{1}{4} ||Dk||=||D||$. Xác suất thứ hai $p^{\frac{1}{2}k}$ này liên quan đến một rời không ngẫu nhiên lấy giá trị k từ $S^{\frac{1}{4}} 1; \dots$ **độ bất**; Kgf . Thứ ba, biến định liên quan đến biến ngẫu nhiên rời rạc này có thể được biểu thị theo entropy

$$K$$
$$H^{\frac{1}{2}P^{\frac{1}{4}}X} p^{\frac{1}{2}k} \log^{\frac{1}{2}p^{\frac{1}{2}k}}:$$
$$k^{\frac{1}{4}}1$$

Từ trên, chúng ta có thể thấy rằng $H^{1/2}P$ không phụ thuộc vào $\|D\|$, mà phụ thuộc vào kích thước tương đối của các tập con. Với phân vùng thứ hai $P_0 = \{D_0, D_1, \dots, D_K\}$, chúng ta có thể định nghĩa một biến ngẫu nhiên thứ hai lấy giá trị k_0 từ $S_0 = \{1, \dots, K\}$ g.f. Xác suất chung mà một phần tử $d \in D$ được chọn ngẫu nhiên thuộc về tập hợp con D_k trong P và cũng thuộc về tập hợp con D_0 trong P_0 là

$$p^{1/2}k; k_0 = \frac{D_k \cap D_0}{\|D\|}.$$

Entropy chung được định nghĩa là

$$H^{1/2}P; P_0 = \frac{1}{K} \sum_{k=1}^K \sum_{k_0=1}^K p^{1/2}k; k_0 \log \frac{1}{p^{1/2}k; k_0};$$

và entropy có điều kiện là $H^{1/2}P_j P_0 = H^{1/2}P; P_0 = H^{1/2}P$. Thông tin lẫn nhau là

$$I^{1/2}P; P_0 = \frac{1}{K} \sum_{k=1}^K \sum_{k_0=1}^K p^{1/2}k; k_0 \log \frac{p^{1/2}k; k_0}{p^{1/2}k p^{1/2}k_0};$$

và sự thay đổi của thông tin là

$$VI^{1/2}P; P_0 = \frac{1}{K} \sum_{k=1}^K \sum_{k_0=1}^K p^{1/2}k; k_0 \log \frac{p^{1/2}k; k_0}{p^{1/2}k p^{1/2}k_0};$$

trong đó $H^{1/2}P_j P_0$ đo lượng thông tin về P mà chúng ta mất và $H^{1/2}P_0 j P$ đo lượng thông tin về P_0 mà chúng ta thu được khi đi từ phân vùng P đến P_0 . Định nghĩa về biến thiên thông tin này có một số thuộc tính, trong đó chúng ta thấy rằng (1) nó là một phép đo; (2) nó có ranh giới trên tuyệt đối tại $VI^{1/2}P; P_0 \leq \log \frac{1}{2} \|D\|$ (giống như entropy); và (3) nếu số tập hợp con thì là $VI^{1/2}P; P_0 \leq 2 \log \frac{1}{2} K$. Ba điều này bị giới hạn bởi hằng số K , với $K \leq \frac{1}{2} \|D\|$, thuộc tính rất quan trọng vì chúng cho phép chúng ta chuẩn hóa khoảng cách giữa các phân vùng và so sánh các thuật toán phân vùng trên các tập dữ liệu khác nhau. Trong bối cảnh học không giám sát, sự thay đổi của thông tin rất hữu ích để so sánh kết quả từ thuật toán phân cụm phân vùng (không phân cấp).

3.11 Kết quả thực nghiệm

Thông tin lẫn nhau định lượng lượng thông tin được chia sẻ bởi hai biến ngẫu nhiên. Thông tin lẫn nhau được chuẩn hóa có giá trị thực trong

phạm vi $[0, 1]$, giống như giá trị tuyệt đối của hệ số tương quan. Cũng giống như hệ số tương quan (hoặc giá trị tuyệt đối của nó), cả thông tin tương hỗ lẫn thông tin tương hỗ được chuẩn hóa đều không phải là số liệu thực. Thông tin tương hỗ

giữa hai biến Gaussian chuẩn hóa ngẫu nhiên X và Y có tương quan ρ được biết là $I^{1/2}X;$

$$Y = 1 - 2 \log \frac{1}{2} (1 - \rho^2).$$

Theo nghĩa này, chúng ta có thể coi thông tin tương hỗ được chuẩn hóa là tương tự về mặt lý thuyết thông tin với hệ số tương quan của đại số tuyến tính. Tiếp theo, chúng ta nghiên cứu hiệu quả của cả hai số liệu thống kê trong các tình huống khác nhau.

3.11.1 Không có mối quan hệ

Chúng ta bắt đầu bằng cách vẽ hai mảng, x và e , gồm các số ngẫu nhiên từ phân phối chuẩn Gauss. Sau đó, chúng ta tính $y = \frac{1}{4} \otimes x \oplus e = \frac{1}{4} e$, và đánh giá thông tin tương hỗ được chuẩn hóa cũng như mối tương quan giữa x và y .

Đoạn mã 3.4 trình bày chi tiết các phép tính này.

```
ĐOẠN TRÍCH 3.4 TƯƠNG QUAN VÀ THÔNG TIN TƯƠNG HỢP CHUẨN HÓA CỦA HAI
BIẾN NGẪU NHIÊN ĐỘC LẬP GAUSSIAN


def mutualInfo(x,y,nozm=False):
    # thông tin lẫn nhau
    bXY=numBins(x.shape[0],corr=np.corrcoef(x,y)[0,1]) cXY=np.histogram2d(x,y,bXY)[0]
    iXY=mutual_info_score(Không có,Không
    có,contingency=cXY)
    nếu chuẩn mực:
        hX=ss.entropy(np.histogram(x,bXY)[0]) # biên
        hY=ss.entropy(np.histogram(y,bXY)[0]) # biên
        iXY/=min(hX,hY) # thông tin tương hỗ được chuẩn hóa
    trả lại iXY

#- - - - -
kích thước, hạt giống = 5000,0
np.random.seed(hạt giống)
x=np.ngẫu nhiên.bình thường(kích thước=kích thước)
e=np.ngẫu nhiên.bình thường(kích thước=kích thước)
y=0*x+e
nmi=mutualInfo(x,y,True)
corr=np.corrcoef(x,y)[0,1]
```


Hình 3.2 biểu diễn y so với x , trông giống như một đám mây. Hệ số tương quan và thông tin tương hỗ chuẩn hóa đều gần bằng 0.

3.11.2 Mối quan hệ tuyến tính

Trong ví dụ này, chúng ta áp đặt một mối quan hệ tuyến tính mạnh giữa x và y , bằng cách đặt $y = \frac{1}{4} 100x \oplus e$. Bây giờ, mối tương quan xấp xỉ bằng 1 và thông tin tương hỗ được chuẩn hóa cũng rất cao, xấp xỉ bằng 0,9. Tuy nhiên, thông tin tương hỗ được chuẩn hóa không phải là 1, vì có một số mức độ không chắc chắn liên quan đến e . Ví dụ, nếu chúng ta áp đặt $y = \frac{1}{4} 104 \times \oplus e$, thì thông tin tương hỗ được chuẩn hóa sẽ là 0,995. Hình 3.3 biểu diễn mối quan hệ này.




Hình 3.2 Biểu đồ phân tán của hai biến ngẫu nhiên Gauss độc lập.



Hình 3.3 Biểu đồ phân tán của hai biến ngẫu nhiên Gaussian với một tuyến tính mối quan hệ.

3.11.3 Mối quan hệ phi tuyến tính

Trong ví dụ này, chúng tôi áp đặt mối quan hệ đối xứng trên trục x giữa x và y , bằng cách đặt $y = \frac{1}{4} 100x + \varepsilon$. Bây giờ tương quan xấp xỉ bằng 0 và thông tin tương hỗ được chuẩn hóa là khoảng 0,64. Như mong đợi, tương quan đã không nhận ra mối quan hệ chặt chẽ tồn tại giữa x



Hình 3.4 Biểu đồ phân tán của hai biến ngẫu nhiên Gaussian với phi tuyến tính mối quan hệ.

và y , vì mối quan hệ đó là phi tuyến tính. Ngược lại, thông tin lẫn nhau nhận ra rằng chúng ta có thể trích xuất một lượng thông tin đáng kể từ x hữu ích để dự đoán y và ngược lại. Hình 3.4 biểu diễn mối quan hệ này.

Không giống như trong trường hợp tuyến tính, việc tăng hệ số từ 102 lên 104 sẽ không tăng đáng kể thông tin tương hỗ được chuẩn hóa. Trong ví dụ này, nguồn chính của sự không chắc chắn không phải là ϵ . Thông tin tương hỗ được chuẩn hóa là cao, nhưng không phải 1, vì biết y không đủ để biết x . Trên thực tế, có hai các giá trị thay thế của x liên quan đến mỗi giá trị của y .

3.12 Kết luận

Các mối tương quan hữu ích trong việc định lượng sự phụ thuộc tuyến tính giữa ngẫu nhiên biến. Hình thức phụ thuộc lẫn nhau này chấp nhận nhiều biểu diễn khác nhau như một khoảng cách mét, như là bảng $d_{p^{1/2}X; Y^{1/4}} = \frac{1}{2} \int_0^1 p^{1/2}X; Y^{1/4}$, hoặc $d_{p^{1/2}X; Y^{1/4}} = \frac{1}{2} \int_0^1 p^{1/2}X; Y^{1/4}$. Tuy nhiên, khi các biến X và Y bị ràng buộc bởi một mối quan hệ phi tuyến tính, số liệu khoảng cách trên đánh giá sai mức độ tương đồng của các biến này. Đối với các trường hợp phi tuyến tính, chúng tôi đã lập luận rằng sự thay đổi thông tin được chuẩn hóa là một phép đo khoảng cách phù hợp hơn. Nó cho phép chúng tôi trả lời các câu hỏi liên quan đến thông tin duy nhất được đóng góp bởi một biến ngẫu nhiên, mà không cần phải đưa ra các giả định chức năng. Vì nhiều thuật toán ML không áp đặt một hình thức chức năng lên dữ liệu, nên việc sử dụng chúng trong kết hợp với các tính năng dựa trên entropy.

3.13 Bài tập

- 1 Rút ra 1.000 quan sát từ phân phối chuẩn hai biến với độ lệch chuẩn đơn vị và hệ số tương quan $\rho = 0.5$; $\mu = 0$; $\sigma = 1$. a Phân rã các mẫu, theo phương pháp được mô tả trong Mục 3.9. b Tính $H^{1/2}X$, $H^{1/2}Y$, $H^{1/2}X; Y$, $H^{1/2}XjY$, $I^{1/2}X$; Y , $VI^{1/2}X$; Y và $VI^{1/2}X; Y$. c $H^{1/2}X$ và $H^{1/2}Y$ có bị ảnh hưởng bởi ρ không? d $H^{1/2}X$; Y , $H^{1/2}XjY$, $I^{1/2}X$; Y , $VI^{1/2}X$; Y và $VI^{1/2}X; Y$ có bị ảnh hưởng bởi ρ không?
- 2 Lặp lại Bài tập 1, lần này cho 1 triệu quan sát. Các biến nào là bị ảnh hưởng bởi quy mô mẫu khác nhau?
- 3 Lặp lại Bài tập 2, lần này bạn sử dụng bước phân biệt BX từ Bài tập 1. Điều này ảnh hưởng thế nào đến kết quả?
- 4 Ưu điểm chính của sự thay đổi thông tin so với thông tin lẫn nhau là gì? Bạn có thể nghĩ ra trường hợp sử dụng nào trong tài chính mà thông tin lẫn nhau phù hợp hơn sự thay đổi thông tin không?
- 5 Hãy xem xét hai số liệu khoảng cách dựa trên tương quan mà chúng ta đã thảo luận trong Phần 3.2. Bạn có thể nghĩ ra trường hợp sử dụng nào mà các số liệu khoảng cách đó sẽ được ưu tiên hơn so với biến thể thông tin được chuẩn hóa không?
- 6 Mã trong Python là một hàm để tính độ phân kỳ KL giữa hai phân phối xác suất rời rạc.
- 7 Mã trong Python là một hàm để tính toán entropy chéo của hai số rời rạc phân phối xác suất. _____
- 8 Chứng minh rằng $d_{p2} \frac{1}{2}X; Y \frac{1}{4} \leq d_{p1} \frac{1}{2}X; Y \frac{1}{4}$ cũng là một phép đo thích hợp.

4 Phân cụm tối ưu

4.1 Động lực

Một bài toán phân cụm bao gồm một tập hợp các đối tượng và một tập hợp các đặc điểm liên quan đến các đối tượng đó. Mục tiêu là phân tách các đối tượng thành các nhóm (gọi là cụm) bằng cách sử dụng các đặc điểm, trong đó các điểm tương đồng nội nhóm được tối đa hóa và các điểm tương đồng giữa các nhóm được tối thiểu hóa. Đây là một dạng học không giám sát, vì chúng tôi không cung cấp các ví dụ để hỗ trợ thuật toán giải quyết nhiệm vụ này. Các vấn đề về cụm xuất hiện tự nhiên trong tài chính, ở mọi bước của quá trình đầu tư. Ví dụ, các nhà phân tích có thể tìm kiếm các sự kiện tương tự trong lịch sử, một nhiệm vụ liên quan đến việc phát triển phân loại số của các sự kiện.

Các nhà quản lý danh mục đầu tư thường nhóm các chứng khoán theo nhiều đặc điểm khác nhau để đưa ra giá trị tương đối giữa các công ty ngang hàng. Các nhà quản lý rủi ro muốn tránh tập trung rủi ro vào các chứng khoán có chung đặc điểm. Các nhà giao dịch muốn

hiểu các luồng ảnh hưởng đến một nhóm chứng khoán, để xác định xem đợt tăng giá hay bán tháo có phải là đặc hữu của một chứng khoán cụ thể hay không, hoặc ảnh hưởng đến một danh mục được chia sẻ bởi nhiều chứng khoán. Để giải quyết những vấn đề này, chúng tôi sử dụng các khái niệm về khoảng cách mà chúng tôi đã nghiên cứu trong [Phần 3](#). Phần này tập trung vào vấn đề tìm số lượng và thành phần tối ưu của các cụm.

4.2 Ma trận tiệm cận

Hãy xem xét một ma trận dữ liệu X , có bậc N theo F , trong đó N là số đối tượng và F là số tính năng. Chúng tôi sử dụng các tính năng F để tính độ gần giữa N đối tượng, được biểu diễn bởi một ma trận $N \times N$. Đo lường độ gần có thể biểu thị sự giống nhau (ví dụ: tương quan, thông tin tương hỗ) hoặc sự khác biệt (ví dụ: số liệu khoảng cách). Thật thuận tiện nhưng không hoàn toàn cần thiết rằng các phép đo độ khác biệt phải thỏa mãn các điều kiện của một số liệu: không âm, tính đối xứng và bất đẳng thức tam giác ([Kraskov và cộng sự, 2008](#)). Ma trận độ gần có thể được biểu diễn dưới dạng đồ thị vô hướng trong đó các trọng số là hàm của độ giống nhau (càng giống nhau thì trọng số càng lớn) hoặc độ khác biệt (càng khác biệt thì trọng số càng nhỏ).

Sau đó, vấn đề phân cụm tương đương với việc chia đồ thị thành các thành phần được kết nối (các đồ thị con được kết nối rời rạc), mỗi thành phần cho một cụm. Khi hình thành ma trận lân cận, tốt nhất là chuẩn hóa dữ liệu đầu vào để tránh trường hợp quy mô của một tính năng chiếm ưu thế hơn phần còn lại.

4.3 Các loại cụm

Có hai lớp chính của thuật toán phân cụm: phân vùng và phân cấp. Các kỹ thuật phân vùng tạo ra phân vùng một cấp (không lồng nhau) của các đối tượng (mỗi đối tượng thuộc về một cụm và chỉ thuộc về một cụm).

Các kỹ thuật phân cấp tạo ra một chuỗi phân vùng lồng nhau, với một cụm đơn lẻ, bao gồm tất cả ở trên cùng và các cụm đơn lẻ của các điểm riêng lẻ ở dưới cùng. Các thuật toán phân cụm phân cấp có thể là phân chia (từ trên xuống) hoặc kết tụ (từ dưới lên). Bằng cách hạn chế sự phát triển của một cây phân cấp, chúng ta có thể suy ra một cụm phân vùng từ bất kỳ cụm phân cấp nào. Tuy nhiên, nhìn chung, người ta không thể suy ra một cụm phân cấp từ một cụm phân vùng.

Tùy thuộc vào định nghĩa của cụm, chúng ta có thể phân biệt một số loại thuật toán phân cụm, bao gồm:

- 1 **Kết nối:** Phân cụm này dựa trên kết nối khoảng cách, giống như phân cụm phân cấp. Để biết ví dụ về tài chính, hãy xem [López de Prado \(2016\)](#).
- 2 **Tâm:** Các thuật toán này thực hiện lượng tử hóa vectơ, giống như k-means. Để biết ví dụ về tài chính, hãy xem [López de Prado và Lewis \(2018\)](#).
- 3 **Phân phối:** Các cụm được hình thành bằng cách sử dụng phân phối thống kê, ví dụ, hỗn hợp phân phối chuẩn Gauss.
- 4 **Mật độ:** Các thuật toán này tìm kiếm các vùng dày đặc được kết nối trong không gian dữ liệu. Ví dụ bao gồm DBSCAN và OPTICS.
- 5 **Không gian con:** Các cụm được mô hình hóa trên hai chiều, các đặc điểm và quan sát. Một ví dụ là biclustering (còn được gọi là coclustering). Ví dụ, chúng có thể giúp xác định điểm tương đồng trong các tập hợp con của các công cụ và khoảng thời gian cùng một lúc.¹⁰

Một số thuật toán mong đợi đầu vào là một phép đo độ tương đồng, và các thuật toán khác mong đợi đầu vào là một phép đo độ không tương đồng. Điều quan trọng là phải đảm bảo rằng bạn truyền đúng đầu vào cho một thuật toán cụ thể. Ví dụ, một thuật toán phân cụm phân cấp thường mong đợi khoảng cách là một đầu vào và nó sẽ nhóm các mục lại với nhau trong một vùng lân cận. Các tâm, phương pháp phân phối và mật độ mong đợi tọa độ không gian vectơ và chúng có thể xử lý trực tiếp khoảng cách. Tuy nhiên, biclustering trực tiếp trên ma trận khoảng cách sẽ nhóm các phần tử xa nhất lại với nhau (ngược lại với những gì k-means sẽ làm). Một giải pháp là bicluster trên nghịch đảo của khoảng cách.

Nếu số lượng các tính năng vượt quá nhiều so với số lượng quan sát, thì lời khuyên của tính đa chiều có thể khiến việc phân cụm trở nên có vấn đề: hầu hết không gian trải dài các quan sát sẽ trống, khiến việc xác định bất kỳ nhóm nào trở nên khó khăn. Một giải pháp là chiếu ma trận dữ liệu X lên không gian có chiều thấp, tương tự như cách PCA làm giảm số lượng các tính năng ([Steinbach và cộng sự 2004](#); [Ding và He 2004](#)). Một giải pháp thay thế là chiếu ma trận lân cận lên không gian có chiều thấp và sử dụng nó như một ma trận X mới. Trong cả hai trường hợp, quy trình được mô tả trong [Phần 2](#) có thể giúp xác định số chiều liên quan đến tín hiệu.

¹⁰ Để biết thêm thông tin minh họa, hãy xem <https://quantdare.com/biclustering-time-series/>.

4.4 Số lượng cụm

Thuật toán phân vùng tìm ra thành phần của các cụm không lồng nhau, trong đó nhà nghiên cứu chịu trách nhiệm cung cấp số lượng cụm chính xác. Trong thực tế, các nhà nghiên cứu thường không biết trước số lượng cụm nên là bao nhiêu.

“Phương pháp khuỷu tay” là một kỹ thuật phổ biến giúp dừng việc thêm các cụm khi phần trăm biến độ phương sai được giải thích không vượt quá ngưỡng được xác định trước. Trong bối cảnh này, phần trăm phương sai được giải thích được định nghĩa là tỷ lệ giữa phương sai giữa các nhóm với tổng phương sai (kiểm định F). Một cảnh báo của phương pháp này là ngưỡng thường được đặt tùy ý (Goutte và cộng sự, 1999).

Trong phần này, chúng tôi trình bày một thuật toán phục hồi số cụm từ ma trận tương quan khối-đường chéo được xáo trộn. López de Prado và Lewis (2018) ký hiệu thuật toán này là ONC, vì nó tìm kiếm số cụm tối ưu. ONC thuộc về lớp thuật toán rộng hơn áp dụng phương pháp silhouette (Rousseeuw 1987). Mặc dù chúng tôi thường tập trung vào việc tìm số cụm trong ma trận tương quan, thuật toán này có thể được áp dụng cho bất kỳ ma trận quan sát chung nào.

4.4.1 Ma trận quan sát

Nếu vấn đề của bạn không liên quan đến ma trận tương quan hoặc bạn đã có ma trận quan sát, bạn có thể bỏ qua phần này.¹¹ Nếu không, hãy giả sử rằng chúng ta có N biến tuân theo phân phối chuẩn đa biến được đặc trưng bởi ma trận tương quan ρ , trong đó $\rho_{i,j}$ là tương quan giữa các biến i và j . Nếu có thành phần chung mạnh, bạn nên loại bỏ thành phần này bằng cách áp dụng phương pháp nổ được giải thích trong Phần 2, vì một yếu tố phơi nhiễm được chia sẻ bởi tất cả các biến có thể che giấu sự tồn tại của các phơi nhiễm được chia sẻ một phần.

Đối với mục đích phân cụm tương quan, chúng ta có thể thực hiện ít nhất ba cách tiếp cận: (a) tránh ma trận X , bằng cách xác định trực tiếp khoảng cách

ma trận như $d_{i,j} = \frac{1}{\rho_{i,j}}$ hoặc một sự chuyển đổi tương tự (xem Phần 3); (b)

sử dụng ma trận tương quan là X ; (c) suy ra ma trận X là $X_{i,j} = \frac{1}{\rho_{i,j}}$,

hoặc một phép biến đổi tương tự (phương pháp tiếp cận khoảng cách của khoảng cách). Ưu điểm của các tùy chọn (b) và (c) là khoảng cách giữa hai biến sẽ là hàm của nhiều ước tính tương quan, chứ không chỉ một, điều này làm cho phép phân tích mạnh mẽ hơn đối với sự hiện diện của các giá trị ngoại lai. Ưu điểm của tùy chọn (c) là

¹¹ Lý tưởng nhất là ma trận quan sát của bạn sẽ dựa trên một trong các số liệu lý thuyết thông tin được giải thích trong Phần 3. Tuy nhiên, tôi phải thừa nhận rằng tương quan vẫn phổ biến hơn trong tài chính. ONC không quan tâm đến cách hình thành ma trận quan sát, vì vậy mục đích của phần này là giải thích một cách tính toán ma trận này cho những độc giả cảm thấy thoải mái hơn khi sử dụng tương quan.

rằng nó thừa nhận rằng sự thay đổi từ $\pi_{i;j} \frac{1}{4} 0:9$ thành $\pi_{i;j} \frac{1}{4} 1:0$ lớn hơn sự thay đổi từ $\pi_{i;j} \frac{1}{4} 0:1$ thành $\pi_{i;j} \frac{1}{4} 0:2$. Trong Phần này, chúng tôi tuân theo cách tiếp cận (c), do đó

chúng tôi định nghĩa ma trận quan sát là $X_{i;j} \frac{1}{4} \frac{1}{\pi_{i;j}^{1,2} x}$.

Việc nhóm các ma trận tương quan là đặc biệt theo nghĩa là các đặc điểm khớp với các quan sát: chúng ta cố gắng nhóm các quan sát trong đó chính các quan sát là các đặc điểm (do đó tính đối xứng của X). Ma trận X có vẻ là một ma trận khoảng cách, nhưng không phải vậy. Nó vẫn là một ma trận quan sát, trên đó các khoảng cách có thể được đánh giá.

Đối với các ma trận X lớn, nhìn chung, thực hành tốt là giảm chiều của nó thông qua PCA. Ý tưởng là thay thế X bằng phép chiếu trực giao chuẩn hóa của nó lên một không gian có chiều thấp hơn, trong đó số chiều được đưa ra bởi số giá trị riêng trong ma trận tương quan của X vượt quá λp (xem Phần 2). Ma trận quan sát kết quả, X_e , có kích thước $N \times F$, có tỷ lệ tín hiệu trên nhiễu cao hơn.

4.4.2 Phân cụm cơ sở

Ở giai đoạn này, chúng ta giả định rằng chúng ta có một ma trận thể hiện các quan sát của chúng ta trong một không gian số liệu. Ma trận này có thể đã được tính toán như mô tả trong phần trước hoặc áp dụng một số phương pháp khác. Ví dụ, ma trận có thể dựa trên sự thay đổi thông tin giữa các biến ngẫu nhiên, như đã giải thích trong Phần 3. Tiếp theo, chúng ta hãy thảo luận về thuật toán phân cụm cơ sở. Một khả năng là sử dụng thuật toán k-means trên ma trận quan sát của chúng ta.¹² Mặc dù k-means đơn giản và thường hiệu quả, nhưng nó có hai hạn chế đáng chú ý: thứ nhất, thuật toán yêu cầu số cụm K do người dùng đặt, không nhất thiết phải tối ưu trước; thứ hai, quá trình khởi tạo là ngẫu nhiên và do đó hiệu quả của thuật toán cũng có thể ngẫu nhiên tương tự.

Để giải quyết hai mối quan tâm này, chúng ta cần sửa đổi thuật toán k-means. Sửa đổi đầu tiên chúng ta thực hiện là đưa ra một hàm mục tiêu, để chúng ta có thể tìm ra "K tối ưu". Đối với điều này, chúng ta chọn điểm số hình bóng do Rousseeuw (1987) đưa ra. Xin nhắc lại, đối với một phần tử i nhất định và một cụm nhất định, hệ số hình bóng S_i được định nghĩa là

$$\frac{b_i - a_i}{\max\{a_i, b_i\}}; \quad \begin{matrix} b_i = \frac{1}{N} \sum_{j=1}^N |x_i - x_j| \\ a_i = \frac{1}{N} \sum_{j=1}^N |x_i - x_{(j)}| \end{matrix};$$

trong đó a_i là khoảng cách trung bình giữa i và tất cả các phần tử khác trong cùng một cụm, và b_i là khoảng cách trung bình giữa i và tất cả các phần tử trong

¹²

Một khả năng khác là sử dụng thuật toán phân cấp, trong đó cụm cơ sở xảy ra ở khoảng cách của biểu đồ phân nhánh tối đa hóa chất lượng của các phân vùng. Để biết ví dụ, hãy xem <https://ssrn.com/abstract=3512998>

cụm gần nhất mà i không phải là thành viên. Trên thực tế, đây là một phép đo so sánh khoảng cách nội cụm và khoảng cách giữa các cụm. Giá trị $S_i \frac{1}{4} 1$ có nghĩa là phần tử i được nhóm tốt, trong khi $S_i \frac{1}{4} 1$ có nghĩa là i được nhóm kém. Đối với một phân vùng nhất định, phép đo chất lượng nhóm q của chúng tôi được định nghĩa là


$$số \frac{1}{4} \frac{E \frac{1}{2} \text{ Kỳ hiệu}}{V \frac{1}{2} \text{ Sigf p}} ;$$

trong đó $E \frac{1}{2} \text{ Sigf}$ là giá trị trung bình của các hệ số hình bóng và $V \frac{1}{2} \text{ Sigf}$ là phương sai của các hệ số hình bóng. Sửa đổi thứ hai chúng ta thực hiện xử lý vấn đề khởi tạo k-mean. Ở cấp độ cơ sở, thuật toán phân cụ của chúng tôi thực hiện thao tác sau: đầu tiên, đánh giá ma trận quan sát; thứ hai, chúng tôi thực hiện vòng lặp for ... kếp. Trong vòng lặp đầu tiên, chúng tôi thử $k \frac{1}{4} 2$; ... khác nhau và đánh giá chất lượng q cho mỗi cụm. Vòng lặp thứ hai ;N trên đó để nhóm lại thông qua k-means cho một khởi tạo nhất định lặp lại vòng lặp đầu tiên nhiều lần, do đó thử các khởi tạo khác nhau. Thứ ba, trong hai vòng lặp này, chúng tôi chọn cụm có q cao nhất. [Đoạn mã 4.1](#) triển khai quy trình này và [Hình 4.1](#) tóm tắt quy trình làm việc.

ĐOẠN TRÍCH 4.1 CỤM CƠ SỞ

```
nhập numpy dưới dạng np, pandas dưới dạng
pd từ sklearn.cluster nhập KMeans từ
sklearn.metrics nhập silhouette_samples
#-----
def clusterKMeansBase(corr0,maxNumClusters=10,n_init=10):
    x,silh=((1-corr0.fillna(0))/2)**.5,pd.Series()# ma trận quan sát
    đối với init trong phạm vi (n_init):
        đối với i trong xrange(2,maxNumClusters+1):
            kmeans_=KMeans(n_clusters=i,n_jobs=1,n_init=1)
            kmeans_=kmeans_.fit(x)
            silh=silhouette_samples(x,kmeans_.labels_) stat=(silh.mean()/
            silh_std(),silh.mean()/silh_std()) nếu np.isnan(stat[1]) hoặc chỉ số [0]>chỉ
            số [1]:
                silh,kmeans=silh_,kmeans_
        newIdx=np.argsort(kmeans.labels_)
        corr1=corr0.iloc[newIdx] # sắp xếp lại các hàng

        corr1=corr1.iloc[:,newIdx] # sắp xếp lại các cột
        clstrs={i:corr0.columns[np.where(kmeans.labels_==i)[0]].tolist() \ cho i trong
            np.unique(kmeans.labels_) } # thành viên cụm
        silh=pd.Series(silh,index=x.index)
    trả về corr1,clstrs,silh
```



Hình 4.1 Cấu trúc giai đoạn phân cụm cơ sở của ONC.

4.4.3 Phân cụm cấp cao hơn

Bản sửa đổi thứ ba của chúng tôi đối với k-means xử lý các cụm có chất lượng không nhất quán. Phân cụm cơ sở có thể nắm bắt các cụm riêng biệt hơn, trong khi bỏ sót các cụm ít rõ ràng hơn. Để giải quyết vấn đề này, chúng tôi đánh giá chất lượng q_k của mỗi cụm $k = 1; \dots$ thuật toán phân ; K cho điểm chất lượng cụm được lấy từ cơ sở cụm. Sau đó, chúng tôi lấy chất lượng trung bình $\bar{q}$ và tìm tập hợp các cụm có chất lượng dưới mức trung bình, $q_k q_k < \bar{q}; k = 1; \dots; K_g$. Chúng ta hãy biểu thị K_1 là số cụm trong tập hợp đó, $K_1 < K$. Nếu số cụm cần chạy lại là $K_1 \leq 1$, thì chúng ta trả về cụm được cung cấp bởi thuật toán cơ sở. Tuy nhiên, nếu $K_1 \geq 2$, chúng tôi sẽ chạy lại việc phân cụm các mục trong các cụm K_1 đó, trong khi phần còn lại được coi là phân cụm chấp nhận được.

Chúng tôi tạo một ma trận quan sát (giảm) mới từ các phần tử tạo nên cụm K_1 và chạy lại thuật toán phân cụm cơ sở trên ma trận tương quan giảm đó. Làm như vậy sẽ trả về một phân cụm mới, có thể là mới, cho các phần tử đó trong K_1 . Để kiểm tra hiệu quả của nó, chúng tôi so sánh chất lượng cụm trung bình

trước và sau khi phân cụm lại các phần tử đó trong K1. Nếu chất lượng cụm trung bình được cải thiện, chúng tôi trả về cụm được chấp nhận từ cụm cơ sở được nối với cụm mới cho các nút được làm lại. Nếu không, chúng tôi trả về cụm được tạo thành bởi thuật toán cơ sở. [Đoạn mã 4.2](#) triển khai hoạt động này trong python và [Hình 4.2](#) tóm tắt quy trình làm việc.

ĐOẠN TRÍCH 4.2 CẤP ĐẦU CỦA CỤM

```
từ sklearn.metrics nhập silhouette_samples
#- -----
def makeNewOutputs(corr0, clstrs, clstrs2): clstrsNew={} cho
    i trong
        clstrs.keys():
            clstrsNew[len(clstrsNew.keys())]=danh sách(clstrs[i])
    đổi với i trong clstrs2.keys():
        clstrsNew[len(clstrsNew.keys())]=danh sách(clstrs2[i])
    newIdx=[j cho i trong clstrsNew cho j trong clstrsNew[i]]
    corrNew=corr0.loc[newIdx, newIdx]
    x=((1-corr0.fillna(0))/2.0)**.5
    kmeans_labels=np.zeros(len(x.columns)) cho i trong
        clstrsNew.keys():
            idxs=[x.index.get_loc(k) cho k trong clstrsNew[i]]
            kmeans_labels[idxs]=i
    silhNew=pd.Series(mẫu_hình_bóng(x, kmeans_labels),
        chỉ số = x.chỉ số)
    trả về corrNew, clstrsNew, silhNew
#- -----
def clusterKMeansTop(corr0, maxNumClusters=None, n_init=10):
    nếu maxNumClusters==None: maxNumClusters=corr0.shape[1]-1
    corr1, clstrs, silh=clusterKMeansBase(corr0, maxNumClusters= \
        min(maxNumClusters, corr0.shape[1]-1), n_init=n_init)
    clusterTstats={i: np.mean(silh[clstrs[i]])/ \
        np.std(silh[clstrs[i]]) cho i trong clstrs.keys()}
    tStatMean=tổng(clusterTstats.values())/len(clusterTstats) redoClusters=[i cho i trong
        clusterTstats.keys() nếu \
            cụmTstats[i]<tStatMean]
    nếu len(redoClusters)<=1:
        trả về corr1, clstrs, silh
    khác:
        keysRedo=[j cho i trong redoClusters cho j trong clstrs[i]]
        corrTmp=corr0.loc[keysRedo, keysRedo]
        tStatMean=np.mean([clusterTstats[i] cho i trong redoClusters])
        corr2, clstrs2, silh2=clusterKMeansTop(corrTmp, \
            maxNumClusters=min(maxNumClusters, \
                corrTmp.shape[1]-1), n_init=n_init)
```



```
# Tạo đầu ra mới nếu cần thiết
corrNew, clstrsNew, silhNew = makeNewOutputs(corr0, \
    {i: clstrs[i] cho i trong clstrs.keys() nếu i không có trong redoClusters}, \
    nhóm 2)

newTstatMean = np.mean([np.mean(silhNew[clstrsNew[i]]) / \
    np.std(silhNew[clstrsNew[i]]) cho i trong clstrsNew.keys()])
nếu newTstatMean <= tStatMean:
    trả về corr1, clstrs, silh
khác:
    trả về corrNew, clstrsNew, silhNew
```

4.5 Kết quả thực nghiệm


Bây giờ chúng tôi thiết kế một thí nghiệm Monte Carlo để xác minh độ chính xác của ONC thuật toán được giới thiệu trước đó: đầu tiên, chúng ta tạo một ma trận tương quan $N \times N$ từ rút thăm ngẫu nhiên với số khối K được xác định trước, trong đó tương quan nội khối cao và tương quan giữa các khối thấp; thứ hai, chúng tôi xáo trộn ma trận tương quan đó. Thứ ba, chúng tôi áp dụng ONC và xác minh rằng thuật toán ONC phục hồi các khối chúng tôi đã tiêm.¹³

4.5.1 Tạo Ma trận Tương quan Khối Ngẫu nhiên

Cho bộ $\{p, N, M, K\}$ cấu hình $N \times N$, chúng tôi muốn tạo một ma trận tương quan khối ngẫu nhiên được tạo thành từ K khối, mỗi khối có kích thước lớn hơn hoặc bằng M . Chúng ta hãy mô tả quy trình phân chia ngẫu nhiên N mục thành K nhóm rời rạc, mỗi kích thước ít nhất là M . Lưu ý rằng điều này tương đương với phân vùng ngẫu nhiên $N \sim \frac{1}{4} NK$ mục thành K nhóm, mỗi nhóm có kích thước ít nhất là 1, do đó chúng ta giảm phân tích của chúng tôi về điều đó. Hãy xem xét việc chọn ngẫu nhiên K 1 mục riêng biệt, được biểu thị như tập hợp B , từ tập hợp $A \sim \frac{1}{4} N$; $N \sim \frac{1}{4} 1 iK$, trong đó, sau đó thêm $N \sim \frac{1}{4} 0$ vào B , do đó B có kích thước K . Do đó, B chứa $i1; \dots; iK$; đó $1 \leq i1 < i2 < \dots < iK \sim \frac{1}{4} N \sim \frac{1}{4} 0$. Cho B , xét tập phân vùng K $C1 \sim \frac{1}{4} 0; \dots; Ck \sim \frac{1}{4} 1; \dots; i2 \sim \frac{1}{4} 1; \dots$; và $CK \sim \frac{1}{4} iK1; \dots; iK \sim \frac{1}{4} 1$. Với điều kiện ij là khác nhau, mỗi phân vùng chứa ít nhất một phần tử như mong muốn và hơn nữa phân vùng hoàn toàn tập hợp $N \sim \frac{1}{4} 0$. Khi làm như vậy, mỗi tập Cj chứa ij phần tử cho $j \sim \frac{1}{4} 1; \dots; K$, cho $i0 \sim \frac{1}{4} 0$. Chúng ta có thể khái quát lại bằng cách thêm M 1 phần tử cho mỗi khối.

Cho mỗi khối $k \sim \frac{1}{4} 1; \dots; K$ có kích thước $xk \sim \frac{1}{4} xk$, trong đó $xk \geq M$, do đó ngụ ý $x1 \sim \frac{1}{4} \dots \sim \frac{1}{4} xK \sim \frac{1}{4} N \geq MK$. Đầu tiên, đối với mỗi khối k , chúng ta tạo một chuỗi thời gian chiều dài T được rút ra từ độc lập và phân phối giống hệt nhau (IID)

¹³ Tôi cảm ơn Michael J. Lewis đã giúp đỡ tôi thực hiện thí nghiệm này.



Hình 4.2 Cấu trúc giai đoạn cấp cao hơn của ONC.

Nguồn: López de Prado và Lewis (2018)

Gauss chuẩn, sau đó tạo các bản sao của nó cho mỗi cột của ma trận X có kích thước $\delta \times P \times T$; x_k . Thứ hai, chúng ta thêm vào mỗi $X_{i,j}$ một nhiễu Gauss ngẫu nhiên với độ lệch chuẩn $\sigma > 0$. Theo thiết kế, các cột của X sẽ có tương quan cao đối với σ nhỏ và ít tương quan hơn đối với σ lớn. Thứ ba, chúng ta đánh giá ma trận hiệp phương sai ΣX cho các cột của X và thêm ΣX dưới dạng một khối vào Σ . Thứ tư, chúng ta thêm vào Σ một ma trận hiệp phương sai khác có một khối nhưng σ lớn hơn. Cuối cùng, chúng ta suy ra ma trận tương quan p liên kết với Σ .

Theo cấu trúc, p có K khối với tương quan cao bên trong mỗi khối và tương quan thấp bên ngoài. **Hình 4.3** là ví dụ về ma trận tương quan được xây dựng theo cách này. **Đoạn mã 4.3** triển khai hoạt động này trong python.

```

Snippet 4.3 TẠO MA TRẬN TƯƠNG QUAN KHỐI NGẪU NHIÊN

nhập numpy dưới dạng np, pandas dưới dạng
pd từ scipy.linalg nhập block_diag từ sklearn.utils
nhập check_random_state
#- - - - -
def getCovSub(nObs,nCols,sigma,random_state=None):
    # Ma trận tương quan phụ

    rng=check_random_state(random_state) nếu nCols==1:
    trả về np.ones((1,1)) ar0=rng.normal(kích
    thước=(nObs,1)) ar0=np.repeat(ar0,nCols,trục=1)
    ar0+=rng.normal(tỷ lệ=sigma,kích
    thước=ar0.shape) ar0=np.cov(ar0,rowvar=False)

    trả về ar0
#- - - - -
def getRndBlockCov(nCols,nBlocks,minBlockSize=1,sigma=1.,
    random_state=Không có):
    # Tạo ma trận tương quan ngẫu nhiên khối

    rng=kiểm_tra_trạng_thái_ngẫu_nhiên(trạng_thái_ngẫu_nhiên)
    các_phần=rng.lựa_chọn(phạm_vi(1,nCols-(minBlockSize-1)*nBlocks), \
        nBlocks-1,thay_thế=Sai)
    parts.sort()
    parts=np.append(parts,nCols-(minBlockSize-1)*nBlocks)
    parts=np.append(parts[0],np.diff(parts))-1+minBlockSize
    cov=Không có

    cho nCols_ theo từng phần:
        cov=getCovSub(int(max(nCols_*(nCols_+1)/2.,100)), \
            nCols_,sigma,trạng_thái_ngẫu_nhiên=rng)
        nếu cov là None:cov=cov_.copy()
        else:cov=block_diag(cov,cov_)
    trả về cov
#- - - - -
def randomBlockCorr(nCols,nBlocks,random_state=None,
    Kích_thước_khối_tối_thiểu = 1):
    # Khối biểu mẫu corr

    rng=kiểm_tra_trạng_thái_ngẫu_nhiên(trạng_thái_ngẫu_nhiên)


    cov0=getRndBlockCov(nCols,nBlock,
        minBlockSize=minBlockSize,sigma=.5,random_state=rng)
    cov1=getRndBlockCov(nCols,1,minBlockSize=minBlockSize,
        sigma=1.,random_state=rng) # thêm nhiễu

```

```

cov0+=cov1
cor0=cov2corr(cov0)
corr0=pd.DataFrame(corr0)
trả về cor0

```



Hình 4.3 Ví dụ về ma trận tương quan khối ngẫu nhiên trước khi xáo trộn.

Nguồn: López de Prado và Lewis (2018)


4.5.2 Số lượng cụm

Sử dụng quy trình được mô tả ở trên, chúng tôi tạo các ma trận tương quan $N \times N$ ngẫu nhiên với K khối có kích thước ít nhất là M . Chúng tôi xáo trộn các hàng và cột của

mỗi ma trận tương quan, do đó các khối không còn có thể nhận dạng được nữa. Sau đó, chúng tôi kiểm tra hiệu quả của thuật toán ONC trong việc khôi phục số lượng và thành phần của các khối đó. Đối với các mô phỏng của mình, chúng tôi đã chọn $N = 20; 40; 80; 160$. Vì chúng tôi mong đợi các cụm được hình thành từ ít nhất hai đối tượng, chúng tôi đặt $M \geq 2$ và do đó cần thiết $K = N \leq 1 = 2$. Đối với mỗi N , chúng tôi kiểm tra $K = 3; 6; \dots$, lên đến $N = 2$. Cuối cùng, chúng tôi kiểm tra 1.000 thể hệ ngẫu nhiên cho mỗi bộ tham số này.

Hình 4.4 hiển thị nhiều biểu đồ hộp cho các mô phỏng này. Đặc biệt, đối với $K=N$ trong một thùng nhất định, chúng tôi hiển thị biểu đồ hộp của tỷ lệ K được dự đoán bởi cụm (ký hiệu là $E_{K|P}$) so với K thực tế được thử nghiệm. Lý tưởng nhất là tỷ lệ này phải gần bằng 1. Kết quả cho thấy ONC thường khôi phục đúng số cụm, với một số lỗi nhỏ.

Để nhắc lại, trong biểu đồ hộp, hộp trung tâm có đáy được đặt thành phần trăm thứ 25 của dữ liệu ($Q1$), trong khi đỉnh được đặt thành phần trăm thứ 75 ($Q3$).



Hình 4.4 Biểu đồ hộp của K ước tính/K thực tế cho K/N được phân nhóm.

Nguồn: [López de Prado và Lewis \(2018\)](#)

khoảng liên tứ phân vị (IQR) được đặt thành $Q3-Q1$. Trung vị được hiển thị dưới dạng một đường thẳng bên trong hộp. “Râu ria” mở rộng đến dữ liệu lớn nhất nhỏ hơn $Q3 + 1.5 \times IQR$ và dữ liệu nhỏ nhất lớn hơn $Q1 - 1.5 \times IQR$. Các điểm nằm ngoài phạm vi đó được coi là ngoại lệ.

4.6 Kết luận

Trong phần này, chúng tôi đã nghiên cứu vấn đề xác định thành phần và số lượng cụm tối ưu bằng thuật toán phân vùng. Chúng tôi đã thực hiện ba sửa đổi đối với thuật toán k-means: (1) chúng tôi đã định nghĩa một hàm mục tiêu đo lường chất lượng của các cụm; (2) chúng tôi đã giải quyết vấn đề khởi tạo k-mean bằng cách chạy lại thuật toán với các hạt giống thay thế; và (3) một cụm cấp cao hơn tìm kiếm các phân vùng tốt hơn trong số các cụm có chất lượng dưới mức trung bình. Kết quả thử nghiệm cho thấy thuật toán khôi phục hiệu quả số lượng và thành phần của các cụm được đưa vào ma trận khối chéo.

Chúng tôi đã áp dụng giải pháp đề xuất cho các ma trận tương quan ngẫu nhiên, tuy nhiên không có gì trong phương pháp này ngăn cản việc áp dụng cho các loại ma trận khác. Điểm khởi đầu của thuật toán là một ma trận quan sát, có thể được định nghĩa theo các số liệu dựa trên tương quan, sự thay đổi của thông tin hoặc một số hàm khác.

4.7 Bài tập

- 1 Sự khác biệt chính giữa đầu ra từ thuật toán phân cụm phân cấp và phân vùng là gì? Tại sao đầu ra từ thuật toán sau không thể được chuyển đổi thành đầu ra của thuật toán trước?
- 2 Hệ thống phân loại GICS của MSCI có phải là ví dụ về phân cụm phân cấp hay phân vùng không? Sử dụng thuật toán thích hợp trên ma trận tương quan, hãy thử sao chép phân loại MSCI. Để so sánh đầu ra phân cụm với MSCI, hãy sử dụng khoảng cách phân cụm được giới thiệu trong [Phần 3](#).
- 3 Sửa đổi [đoạn mã 4.1](#) và [4.2](#) để sử dụng thuật toán phân cụm phổ.
Bạn có nhận được kết quả khác biệt cơ bản không? Gợi ý: Hãy nhớ rằng, giống như ma trận lân cận, thuật toán biclustering mong đợi một ma trận tương tự, không phải ma trận khoảng cách.
- 4 Lập lại phân tích thử nghiệm, trong đó lần này thuật toán cơ sở của ONC chọn số cụm bằng “phương pháp khuỷu tay”. Bạn có khôi phục được số cụm thực sự một cách nhất quán không? Tại sao?
- 5 Trong [Phần 2](#), chúng tôi đã sử dụng một phương pháp khác để xây dựng ma trận tương quan khối-đường chéo. Trong phương pháp đó, tất cả các khối đều có cùng kích thước. Lập lại phân tích thử nghiệm trên các ma trận tương quan khối-đường chéo thông thường. Bạn có kết quả tốt hơn hay tệ hơn? Tại sao?

5 Nhãn tài chính

5.1 Động lực

Phần 4 thảo luận về phân cụm, một kỹ thuật tìm kiếm điểm tương đồng trong một tập dữ liệu các tính năng (ma trận X). Phân cụm là một phương pháp học không giám sát, theo nghĩa là thuật toán không học thông qua các ví dụ. Ngược lại, thuật toán học có giám sát giải quyết một nhiệm vụ với sự trợ giúp của các ví dụ (mảng y). Có hai loại chính của các vấn đề học có giám sát: hồi quy và phân loại. Trong các vấn đề hồi quy, các ví dụ được rút ra từ một quần thể vô hạn, có thể đếm được (như số nguyên) hoặc không đếm được (như giá trị thực). Trong các vấn đề phân loại, các ví dụ được rút ra từ một tập hợp hữu hạn các nhãn (có thể là phân loại hoặc thứ tự). Khi không có thứ tự nội tại giữa các giá trị, các nhãn biểu diễn các quan sát từ một biến phân loại, như nam so với nữ. Khi có thứ tự nội tại giữa các giá trị, các nhãn biểu diễn các quan sát từ một biến thứ tự, như xếp hạng tín dụng. Các biến thực có thể được phân rã thành các nhãn phân loại hoặc thứ tự.

Các nhà nghiên cứu cần cân nhắc rất cẩn thận về cách họ định nghĩa nhãn, vì nhãn xác định nhiệm vụ mà thuật toán sẽ học. Ví dụ, chúng ta có thể đào tạo một thuật toán để dự đoán dấu hiệu của lợi nhuận ngày hôm nay cho cổ phiếu XYZ hoặc liệu động thái 5% tiếp theo của cổ phiếu đó có phải là dương (một đợt kéo dài trong một số ngày thay đổi hay không). Các tính năng cần thiết để giải quyết cả hai nhiệm vụ có thể rất khác nhau, vì nhãn đầu tiên liên quan đến dự báo điểm trong khi nhãn thứ hai liên quan đến sự kiện phụ thuộc vào đường dẫn. Ví dụ, dấu hiệu của lợi nhuận hàng ngày của cổ phiếu có thể không thể đoán trước, trong khi xác suất tăng giá của cổ phiếu (không phụ thuộc vào khung thời gian) có thể đánh giá được. Việc một số tính năng không dự đoán được một loại nhãn cho một cổ phiếu cụ thể không có nghĩa là chúng sẽ không dự đoán được tất cả các loại nhãn cho cùng một cổ phiếu đó. Vì các nhà đầu tư thường không ngại kiếm tiền theo cách này hay cách khác, nên việc thử các cách khác nhau để định nghĩa nhãn là điều đáng giá. Trong phần này, chúng tôi thảo luận về bốn chiến lược dán nhãn quan trọng.

5.2 Phương pháp chân trời cố định

Hầu như tất cả các nghiên cứu học thuật về ML tài chính đều sử dụng phương pháp dán nhãn chân trời cố định (xem phần tài liệu tham khảo). Hãy xem xét một ma trận đặc điểm X có I hàng, $fX_{i1}^{1/4}; \dots; I$, được lấy mẫu từ một loạt các thanh có chỉ số $t = 1; \dots; T$, ở đâu $I \leq T$. Chúng tôi tính toán giá lợi nhuận trong một khoảng thời gian h như sau

$$r_{ti;0;ti;1}^{1/4} = \frac{p_{ti;1} - p_{ti;0}}{p_{ti;0}} \quad 1;$$

trong đó $t_{i;0}$ là chỉ số thanh liên quan đến các đặc điểm quan sát thứ i và $t_{i;1}$ $\frac{1}{4} t_{i;0}$ p h là chỉ số thanh sau khi đường chân trời cố định của h thanh đã trôi qua. Phương pháp này gán nhãn $y_i \frac{1}{4} 1; 0; 1$ gf cho một quan sát X_i , với

$$\begin{aligned} &8 && 1 \text{ nếu } r_{ti;0};t_{i;1} < \tau; 0 \\ \text{CÓ } \frac{1}{4} &< && \text{ nếu } j_{rti;0};t_{i;1} j \leq \\ &: && \tau; 1 \text{ nếu } r_{ti;0};t_{i;1} > \tau; \end{aligned}$$

trong đó τ là ngưỡng hằng số được xác định trước. Khi các thanh được lấy mẫu ở tần suất thời gian theo trình tự thời gian đều đặn, chúng được gọi là thanh thời gian. Thanh thời gian cũng rất phổ biến trong tài liệu tài chính. Sự kết hợp của các thanh thời gian với nhãn thời gian cố định tạo ra các đường chân trời thời gian cố định. Mặc dù phổ biến, có một số lý do để tránh phương pháp này. Đầu tiên, lợi nhuận được tính toán trên các thanh thời gian thể hiện tính không đồng nhất đáng kể, là hậu quả của các mô hình hoạt động theo mùa trong ngày. Áp dụng ngưỡng hằng số τ kết hợp với lợi nhuận không đồng nhất $f_{rti;0};t_{i;1}$ $gi \frac{1}{4} 1; \dots$; Tôi sẽ chuyển tính theo mùa đó sang các nhãn, do đó phân phối nhãn sẽ không dừng. Ví dụ, việc lấy nhãn 0 khi mở cửa hoặc đóng cửa sẽ cung cấp nhiều thông tin hơn (theo nghĩa là không mong đợi) so với việc lấy nhãn 0 vào khoảng trưa hoặc trong đêm. Một giải pháp là áp dụng phương pháp đường chân trời cố định trên các thanh tích tắc, khối lượng hoặc đô la (xem [López de Prado 2018a](#)). Một giải pháp khác là dán nhãn dựa trên lợi nhuận chuẩn hóa $z_{ti;0};t_{i;1}$, được điều chỉnh cho sự biến động được dự đoán trong khoảng thời gian của các thanh $\frac{1}{2}t_{i;0}; t_{i;1}$,

$$\begin{aligned} &8 && 1 \text{ nếu } z_{ti;0};t_{i;1} < \tau; 0 \\ \text{CÓ } \frac{1}{4} &< && \text{ nếu } j_{zti;0};t_{i;1} j \leq \\ &: && \tau; 1 \text{ nếu } z_{ti;0};t_{i;1} > \tau; \end{aligned}$$

Mối quan tâm thứ hai của phương pháp đường chân trời cố định là nó loại bỏ tất cả thông tin liên quan đến lợi nhuận trung gian trong khoảng $\frac{1}{2}t_{i;0}; t_{i;1}$. Điều này có vấn đề, vì các vị thế thường được quản lý theo mức chốt lời và mức dừng lỗ. Trong trường hợp dừng lỗ cụ thể, các mức đó có thể do người quản lý danh mục đầu tư tự áp đặt hoặc do bộ phận rủi ro thực thi. Theo đó, các nhãn đường chân trời cố định có thể không đại diện cho kết quả của một khoản đầu tư thực tế.

Mối quan tâm thứ ba của phương pháp đường chân trời cố định là các nhà đầu tư hiếm khi quan tâm đến việc dự báo liệu lợi nhuận có vượt ngưỡng τ tại một thời điểm chính xác $t_{i;0}$ p h hay không. Sẽ thực tế hơn nếu dự đoán phía của lợi nhuận tuyệt đối tiếp theo vượt ngưỡng τ trong đường chân trời tối đa h .

phương pháp sau đây giải quyết ba mối quan tâm này.

5.3 Phương pháp rào cản ba

Trong các ứng dụng tài chính, một phương pháp thực tế hơn là tạo nhãn phản ánh sự thành công hay thất bại của một vị thế. Một quy tắc giao dịch điển hình được danh mục đầu tư áp dụng

người quản lý phải giữ một vị thế cho đến khi kết quả đầu tiên trong ba kết quả có thể xảy ra: (1) mục tiêu lợi nhuận chưa thực hiện được đạt được và vị thế được đóng thành công; (2) giới hạn lỗ chưa thực hiện được đạt đến và vị thế được đóng thất bại; (3) vị thế được giữ vượt quá số lượng thanh tối đa và vị thế được đóng mà không có thất bại cũng như thành công. Trong biểu đồ thời gian về hiệu suất vị thế, hai điều kiện đầu tiên xác định hai rào cản ngang và điều kiện thứ ba xác định một rào cản dọc. Chỉ số của thanh liên quan

với rào cản đầu tiên được chạm vào được ghi là t_1 ; 1. Khi rào cản chốt lời được chạm vào đầu tiên, chúng ta dán nhãn quan sát là $y_1 = \frac{1}{4} \cdot 1$. Khi rào cản dừng lỗ được chạm vào đầu tiên, chúng ta dán nhãn quan sát là $y_1 = \frac{1}{4} \cdot 1$. Khi rào cản thắng đứng được chạm vào đầu tiên, chúng ta có hai lựa chọn: chúng ta có thể dán nhãn là $y_1 = \frac{1}{4} \cdot 0$ hoặc chúng ta có thể dán nhãn là $y_1 = \frac{1}{4} \cdot \text{sgn}(\frac{1}{2}r_{t_1}; 0; t_1; 1)$. Xem López de Prado (2018a) để biết các đoạn mã triển khai phương pháp rào cản ba trong python.

Thiết lập các rào cản chốt lời và dừng lỗ đòi hỏi phải biết về phía vị thế liên quan đến quan sát thứ i . Khi phía vị thế không được biết, chúng ta vẫn có thể thiết lập các rào cản ngang theo hàm của độ biến động được dự đoán trong khoảng thời gian của các thanh $\frac{1}{2}t_i; 0; t_i; 0$ p h, trong đó h là số thanh cho đến khi chạm đến rào cản dọc. Trong trường hợp này, các rào cản sẽ đối xứng, vì nếu không có thông tin về phía, chúng ta không thể biết rào cản nào có nghĩa là lợi nhuận và rào cản nào có nghĩa là thua lỗ.

Một lợi thế chính của phương pháp rào cản ba so với phương pháp đường chân trời cố định là phương pháp trước kết hợp thông tin về đường đi kéo dài khoảng thời gian của các thanh $\frac{1}{2}t_i; 0; t_i; 0$ p h. Trong thực tế, thời gian nắm giữ tối đa của một cơ hội đầu tư có thể được xác định một cách tự nhiên và giá trị của h không phải là chủ quan. Một bất lợi là việc chạm đến rào cản là một sự kiện rời rạc, có thể xảy ra hoặc không xảy ra với biên độ mỏng. Cảnh báo này được giải quyết bằng phương pháp sau.

5.4 Phương pháp quét xu hướng

Trong phần này, chúng tôi giới thiệu một phương pháp dán nhãn mới không yêu cầu xác định các rào cản h hoặc chốt lời hoặc dừng lỗ. Ý tưởng chung là xác định các xu hướng và để chúng chạy trong thời gian dài nhất có thể mà không cần đặt ra bất kỳ rào cản nào.¹⁴ Để thực hiện được điều đó, trước tiên chúng ta cần xác định những gì tạo nên một xu hướng.

Hãy xem xét một loạt các quan sát $\{x_t\}_{t=1}^T$, trong đó x_t có thể biểu diễn giá của một chứng khoán mà chúng ta muốn dự đoán. Chúng ta muốn gán một nhãn $y_t \in \{-1, 0, 1\}$ cho mọi quan sát trong x_t , dựa trên việc x_t có phải là một phần của xu hướng giảm, không có xu hướng hay xu hướng tăng. Một khả năng là tính giá trị t ($\wedge^1$) liên quan đến hệ số hồi quy ước tính ($\wedge^1$) trong mô hình xu hướng thời gian tuyến tính,

¹⁴ Ý tưởng quét xu hướng là thành quả của quá trình hợp tác chung với các đồng nghiệp Lee Cohn, Michael Lock và Yaxiong Zeng.

$$xt_{\beta 1} = \frac{1}{4} \beta_0 + \beta_1 + \epsilon_{t\beta 1}$$
$$\epsilon_{t\beta 1} = \frac{1}{4} \frac{\sigma^2 \beta_1}{\sigma^2 \beta_1};$$

trong đó $\sigma^2 \beta_1$ là sai số chuẩn của β_1 và $1/4 \neq 0; \dots$; $L = 1$, và L thiết lập giao diện giai đoạn chuyển tiếp. [Đoạn mã 5.1](#) tính toán giá trị t này trên mẫu được xác định bởi L .

```
ĐOẠN TRÍCH 5.1 GIÁ TRỊ T CỦA XU HƯỚNG TUYẾN TÍNH

nhập statsmodels.api như sm1
#-----
def tVallinR(đóng):
    # tValue từ xu hướng tuyến tính
    x=np.ones((close.shape[0],2))
    x[:,1]=np.arange(close.shape[0])
    ols=sm1.OLS(đóng,x).fit()
    trả về ols.tvalues[1]
```

Các giá trị khác nhau của L dẫn đến các giá trị t khác nhau. Để giải quyết sự bất định này, chúng ta có thể thử một tập hợp các giá trị thay thế cho L và chọn giá trị của L để tối đa hóa $j^2 t_{\beta 1}$ j . Theo cách này, chúng ta dán nhãn xt theo xu hướng có ý nghĩa thống kê nhất được quan sát thấy trong tương lai, trong số nhiều giai đoạn hướng tới tương lai có thể. [Đoạn mã 5.2](#) triển khai quy trình này trong python. Các đối số là molecular, là chỉ số của các quan sát mà chúng ta muốn dán nhãn; close, là chuỗi thời gian của $xt_{\beta 1}$; và span, là tập hợp các giá trị của L mà thuật toán sẽ

```
ĐOẠN TRÍCH 5.2 TRIỂN KHAI PHƯƠNG PHÁP QUÉT XU HƯỚNG

def getBinsFromTrend(phần tử,đóng,khoảng):
    '''
    Lấy nhãn từ đầu của giá trị t của xu hướng tuyến tính
    Đầu ra bao gồm:
    - t1: Thời gian kết thúc cho xu hướng đã xác định
    - tval: giá trị t liên quan đến hệ số xu hướng ước tính
    - bin: Dấu hiệu của xu hướng
    '''

    ra=pd.DataFrame(index=phần tử,cột=['t1','tVal','bin']) hrzns=xrange(*span)

    đối với dt0 trong phần tử:
        df0=pd.Series()
        iloc0=close.index.get_loc(dt0) nếu
        iloc0+max(hrzns)>close.shape[0]:continue
```

```

đối với hrzn trong hrzn:
    dt1=đóng.index[iloc0+hrzn-1]
    df1=đóng.loc[dt0:dt1]
    df0.loc[dt1]=tValInR(df1.giá trị)
    dt1=df0.replace([-np.inf,np.inf,np.nan],0).abs().idxmax()
    ra.loc[dt0,['t1','tVal','bin']]=df0.index[-1],df0[dt1],
    np.sign(df0[dt1]) # ngăn chặn rò rỉ
out['t1']=pd.to_datetime(out['t1'])
out['bin']=pd.to_numeric(out['bin'],downcast='signed') trả về
out.dropna(subset=['bin'])

```

đánh giá, trong quá trình tìm kiếm giá trị t tuyệt đối lớn nhất. Đầu ra là một khung dữ liệu trong đó chỉ số là dấu thời gian của xt , cột $t1$ báo cáo dấu thời gian của quan sát xa nhất được sử dụng để tìm xu hướng quan trọng nhất, cột $tVal$ báo cáo giá trị t liên quan đến xu hướng tuyến tính quan trọng nhất trong tập hợp các khoảng thời gian hướng tới được đánh giá và cột bin là nhãn (yt).

Nhãn quét xu hướng thường trực quan và có thể được sử dụng trong các vấn đề phân loại cũng như hồi quy. Chúng tôi trình bày một ví dụ trong phần kết quả thử nghiệm.

5.5 Siêu nhãn

Một hiện tượng phổ biến trong tài chính là chúng ta biết liệu chúng ta muốn mua hay bán một loại chứng khoán cụ thể, tuy nhiên chúng ta không chắc chắn về số tiền chúng ta nên đặt cược. Một mô hình xác định một bên của vị thế có thể không phải là mô hình tốt nhất để xác định quy mô của vị thế đó. Có lẽ quy mô nên là một hàm số của hiệu suất gần đây của mô hình, trong khi hiệu suất gần đây đó không liên quan đến việc dự báo bên của vị thế đó.

Có một mô hình định cỡ cược tốt là cực kỳ quan trọng. Hãy xem xét một chiến lược đầu tư có độ chính xác là 60% và độ thu hồi là 90%. Độ thu hồi 90% có nghĩa là chiến lược dự đoán chín mươi trong số một trăm cơ hội đầu tư thực sự. Độ chính xác 60% có nghĩa là trong số một trăm cơ hội dự đoán, sáu mươi là đúng. Chiến lược như vậy sẽ mất tiền nếu định cỡ cược nhỏ đối với sáu mươi kết quả dương tính thực và lớn đối với bốn mươi kết quả dương tính giả. Là nhà đầu tư, chúng ta không có quyền kiểm soát (hợp pháp) nào đối với giá cả và quyết định quan trọng mà chúng ta có thể và phải đưa ra là định cỡ cược hợp lý.

Meta-labeling hữu ích để tránh hoặc ít nhất là giảm thiểu rủi ro của nhà đầu tư đối với các kết quả dương tính giả. Nó đạt được điều đó bằng cách từ bỏ một số khả năng thu hồi để đổi lấy độ chính xác cao hơn. Trong ví dụ trên, việc thêm một lớp meta-labeling có thể dẫn đến khả năng thu hồi là 70% và độ chính xác là 70%, do đó cải thiện điểm F1 của mô hình (trung bình hài hòa của độ chính xác và khả năng thu hồi). Xem [López de Prado \(2018a\)](#) để biết cách triển khai meta-labeling bằng python.

Mục tiêu của việc gắn nhãn siêu dữ liệu là đào tạo một mô hình thứ cấp về dự đoán kết quả của một mô hình chính, trong đó tồn tại được dán nhãn là "0" và lợi nhuận được được gắn nhãn là "1." Do đó, mô hình thứ cấp không dự đoán được phía.

Thay vào đó, mô hình thứ cấp dự đoán liệu mô hình chính có thành công hay không hoặc thất bại trong một dự đoán cụ thể (một siêu dự đoán). Xác suất liên quan đến dự đoán "1" sau đó có thể được sử dụng để định cỡ vị trí, như đã giải thích tiếp.

5.5.1 Quy mô cược theo Tỷ lệ Sharpe dự kiến

Giả sử p là xác suất mong đợi rằng cơ hội đó mang lại lợi nhuận π và $1-p$ xác suất dự kiến rằng cơ hội mang lại lợi nhuận $-\pi$ (tức là thua lỗ), đối với một số phần thưởng đối xứng có độ lớn $\pi > 0$. Lợi nhuận dự kiến từ cơ hội là $\mu = p\pi - (1-p)\pi = 2p - 1$. Phương sai dự kiến từ cơ hội là $\sigma^2 = 4\pi^2 p(1-p)$. Tỷ lệ Sharpe liên quan đến do đó cơ hội có thể được ước tính là

$$z = \frac{\mu}{\sigma} = \frac{p - \frac{1}{2}}{\sqrt{p(1-p)}};$$

với $z \rightarrow \pm\infty$. Giả sử rằng tỷ lệ Sharpe của các cơ hội tuân theo phân phối chuẩn Gaussian, chúng ta có thể suy ra kích thước cược là $m = \frac{1}{2} z \sqrt{1 - z^2}$, trong đó Z^2 : là hàm phân phối tích lũy của chuẩn Gaussian, và $m \in [-\frac{1}{2}, \frac{1}{2}]$ tuân theo sự phân bố đồng đều.

5.5.2 Kích thước cược tổng hợp

Hãy xem xét n bộ phân loại nhãn siêu dữ liệu đưa ra dự đoán nhị phân về việc liệu một cơ hội sẽ có lợi nhuận hay không, $y_i \in \{0, 1\}$; $i = 1, \dots, n$. Vấn đề thực sự-năng có lợi nhuận là p , và dự đoán y_i được rút ra từ Bernoulli

phân phối, vì vậy $P(y_i = 1) = p$; trong đó $B^{\frac{1}{2}n}$; p là phân phối nhị thức của n p , thử nghiệm với xác suất p . Giả sử rằng các dự đoán là độc lập và phân phối giống hệt nhau, định lý de Moivre-Laplace phát biểu rằng sự phân phối của P_n

$\frac{1}{\sqrt{n}}(P_n - np)$ hội tụ thành một Gaussian với giá trị trung bình np và phương sai $np(1-p)$ khi $n \rightarrow \infty$. Theo đó, $\lim_{n \rightarrow \infty} \frac{1}{\sqrt{n}} P_n = N(p, p(1-p))$; đây là một trường hợp cụ thể của định lý Lindeberg-Lévy.

Chúng ta hãy biểu thị $\hat{p}$ là dự đoán trung bình trên n bộ phân loại siêu nhãn, $\hat{p} = \frac{1}{n} \sum_{i=1}^n y_i$. Độ lệch chuẩn liên quan đến $\hat{p}$ là

$\sigma_{\hat{p}} = \sqrt{\frac{p(1-p)}{n}}$ theo giả thuyết không $H_0: p = \frac{1}{2}$, thống kê

$\hat{p} = \frac{1}{n} \sum_{i=1}^n y_i$ không, với $t \rightarrow \pm\infty$, theo một học sinh t

phân phối với $n - 1$ bậc tự do. Chúng ta có thể suy ra kích thước cỡ mẫu là $m = \frac{1}{2} \sqrt{2(n-1)} t$, trong đó $t_{n-1, \frac{\alpha}{2}}$ là hàm phân phối tích lũy của t-student với $n - 1$ bậc tự do, và $m = \frac{1}{2} \sqrt{2(n-1)}$ tuân theo phân phối đều.


5.6 Kết quả thực nghiệm

Trong phần này, chúng tôi trình bày cách tạo nhãn bằng phương pháp quét xu hướng. Đoạn mã 5.3 tạo ra một bước ngẫu nhiên Gaussian, trong đó chúng tôi thêm một xu hướng sin, để buộc một số điểm uốn. Theo cách đó, chúng tôi tạo ra các phân đoạn lồi và lõm, giúp việc xác định xu hướng trở nên khó khăn hơn. Sau đó, chúng tôi gọi hàm `getBinsFromTrend` để lấy các đường chân trời xu hướng, giá trị t và nhãn.


```
ĐOẠN TRÍCH 5.3 KIỂM TRA THUẬT TOÁN GHI NHÃN QUÉT XU HƯỚNG

df0=pd.Series(np.random.normal(0, .1,100)).cumsum()
df0+=np.sin(np.linspace(0,10,df0.shape[0]))
df1=getBinsFromTrend(df0.index,df0,[3,10,1])
mpl.scatter(df1.index,df0.loc[df1.index].values,
            c=df1['bin'].giá trị, cmap='viridis')
mpl.savefig('fig 5.1.png');mpl.clf();mpl.close()
mpl.scatter(df1.index,df0.loc[df1.index].values,c=c,cmap='viridis')
```

Hình 5.1 vẽ một đường đi ngẫu nhiên theo Gauss với xu hướng, trong đó các màu sắc khác nhau theo bốn xu hướng rõ ràng riêng biệt, với 1 nhãn được vẽ màu vàng và 1 nhãn



Hình 5.1 Ví dụ về nhãn quét xu hướng.



Hình 5.2 Ví dụ về giá trị t quét xu hướng.

được vẽ bằng màu tím. Các nhãn nhị phân này, mặc dù phù hợp với các vấn đề phân loại, nhưng lại bỏ sót thông tin về cường độ của xu hướng.

Để sửa lỗi thiếu sót đó, Hình 5.2 vẽ cùng một đường đi ngẫu nhiên Gaussian với xu hướng, trong đó các màu biểu thị độ lớn của giá trị t . Các giá trị t cực kỳ dương được vẽ bằng màu vàng, và các giá trị t cực kỳ âm được vẽ bằng màu tím. Các giá trị dương gần bằng không được vẽ bằng màu xanh lá cây, và các giá trị âm gần bằng không được vẽ bằng màu xanh lam. Thông tin này có thể được sử dụng trong các mô hình hồi quy hoặc làm trọng số mẫu trong các bài toán phân loại.

5.7 Kết luận

Trong phần này, chúng tôi đã trình bày bốn phương pháp dán nhãn thay thế có thể hữu ích trong các ứng dụng tài chính. Phương pháp chân trời cố định, mặc dù được triển khai trong hầu hết các nghiên cứu tài chính, nhưng lại gặp phải nhiều hạn chế. Trong số những hạn chế này, chúng tôi đã liệt kê rằng phân phối nhãn chân trời cố định có thể không đúng, rằng các nhãn này loại bỏ thông tin đường dẫn và rằng sẽ thực tế hơn khi dự đoán phía của lợi nhuận tuyệt đối tiếp theo vượt quá ngưỡng nhất định.

Phương pháp ba rào cản trả lời những mối quan tâm này bằng cách mô phỏng kết quả của một quy tắc giao dịch. Một bất lợi là việc chạm vào rào cản là một sự kiện rời rạc, có thể xảy ra hoặc không xảy ra với biên độ mỏng. Để giải quyết vấn đề đó, phương pháp quét xu hướng xác định phía của xu hướng tuyến tính mạnh nhất trong số các giai đoạn hướng tới thay thế, với giá trị p liên quan. Các nhãn quét xu hướng thường trực quan và có thể được sử dụng trong các vấn đề phân loại cũng như hồi quy. Cuối cùng, phương pháp siêu nhãn hữu ích trong các ứng dụng mà phía của một vị thế được xác định trước và chúng ta chỉ quan tâm đến việc tìm hiểu

kích thước. Một phương pháp định cỡ phù hợp có thể giúp cải thiện hiệu suất của chiến lược, bằng cách từ bỏ một số khả năng thu hồi để đổi lấy độ chính xác cao hơn.

5.8 Bài tập

1 Với chuỗi thời gian của hợp đồng tương lai E-mini S&P 500, hãy tính nhân trên thanh thời gian một phút bằng phương pháp đường chân trời cố định, trong đó τ được đặt ở hai độ lệch chuẩn của lợi nhuận một phút.

a Tính toán phân phối chung của các nhân. b Tính toán phân

phối của các nhân trong tất cả các ngày, cho mỗi giờ của phiên giao dịch. c Phân phối trong (b)

khác biệt như thế

nào so với phân phối trong (a)?

Tại sao?

2 Lặp lại Bài tập 1, lần này bạn dán nhãn lợi nhuận chuẩn hóa (thay vì lợi nhuận thô), trong đó chuẩn hóa dựa trên ước tính trung bình và phương sai từ việc xem xét lại một giờ. Bạn có đi đến kết luận khác không?

3 Lặp lại Bài tập 1, lần này bạn áp dụng phương pháp rào cản ba lần trên các thanh khối lượng.

Khoảng thời gian nắm giữ tối đa là số thanh trung bình mỗi ngày và các rào cản ngang được đặt ở hai độ lệch chuẩn của lợi nhuận thanh. Kết quả so sánh như thế nào với các giải pháp từ Bài tập 1 và 2?

4 Lặp lại Bài tập 1, lần này bạn áp dụng phương pháp quét xu hướng, với khoảng thời gian nhìn về phía trước lên đến một ngày. Kết quả so sánh như thế nào với các giải pháp từ Bài tập 1, 2 và 3?

5 Sử dụng các nhân được tạo ra trong Bài tập 3 (phương pháp ba rào cản):

a Phù hợp với một bộ phân loại rừng ngẫu nhiên trên các nhân đó. Sử dụng như các ước tính tính năng của lợi nhuận trung bình, độ biến động, độ lệch, độ nhọn và nhiều sự khác biệt khác trong các đường trung bình động.

b Kiểm tra lại các dự đoán đó bằng cách sử dụng quy tắc giao dịch giống như quy tắc được sử dụng để tạo nhân. c Áp dụng nhãn

siêu dữ liệu vào kết quả kiểm tra ngược. d Lặp lại rừng

ngẫu nhiên trên nhãn siêu dữ liệu, thêm nhân được dự đoán trong (a) làm tính năng. e Định cỡ cuộc (a) theo dự

đoán trong (d) và tính toán lại kiểm tra ngược.

6 Phân tích tầm quan trọng của tính năng

6.1 Động lực

Hãy tưởng tượng rằng bạn được đưa cho mười câu đố, mỗi câu đố có một nghìn mảnh, trong đó tất cả các mảnh đã được xáo trộn vào cùng một hộp. Bạn được yêu cầu giải một câu đố cụ thể trong số mười câu đố. Một cách hợp lý để tiến hành là chia nhiệm vụ của bạn thành hai bước. Ở bước đầu tiên, bạn cố gắng cô lập một nghìn mảnh quan trọng đối với vấn đề của mình và loại bỏ chín nghìn mảnh không liên quan. Ví dụ, bạn có thể nhận thấy rằng khoảng một phần mười các mảnh được làm bằng nhựa và phần còn lại được làm bằng giấy. Bất kể mẫu nào được hiển thị trên các mảnh, bạn biết rằng việc loại bỏ tất cả các mảnh giấy sẽ cô lập một câu đố duy nhất. Ở bước thứ hai, bạn cố gắng lắp một cấu trúc vào một nghìn mảnh mà bạn đã cô lập. Bây giờ bạn có thể đoán mẫu đó là gì và sắp xếp các mảnh xung quanh mẫu đó.

Bây giờ hãy xem xét một nhà nghiên cứu quan tâm đến việc mô hình hóa một hệ thống động như một hàm của nhiều biến giải thích ứng viên khác nhau. Chỉ một tập hợp con nhỏ trong số các biến ứng viên đó được kỳ vọng là có liên quan, tuy nhiên nhà nghiên cứu không biết trước là những biến nào. Cách tiếp cận thường được áp dụng trong tài liệu tài chính là cố gắng phù hợp với một hàm đại số được đoán trên một tập hợp con các biến được đoán và xem biến nào có vẻ có ý nghĩa thống kê (tùy thuộc vào việc hàm đại số được đoán đó có đúng không, bao gồm tất cả các hiệu ứng tương tác giữa các biến). Một cách tiếp cận như vậy là phản trực giác và có khả năng bỏ sót các biến quan trọng mà các thông số kỹ thuật chưa được khám phá sẽ tiết lộ.

Thay vào đó, các nhà nghiên cứu có thể làm theo các bước tương tự mà họ áp dụng cho vấn đề giải câu đố: đầu tiên, cô lập các biến quan trọng, bất kể dạng hàm nào, và chỉ sau đó mới cố gắng khớp các biến đó với một thông số kỹ thuật cụ thể phù hợp với các biến bị cô lập đó. Các kỹ thuật ML cho phép chúng ta tách biệt tìm kiếm thông số kỹ thuật khỏi tìm kiếm biến.

Trong phần này, chúng tôi chứng minh rằng ML cung cấp các công cụ trực quan và hiệu quả cho các nhà nghiên cứu làm việc về phát triển các lý thuyết. Bài trình bày của chúng tôi trái ngược với huyền thoại phổ biến rằng các mô hình ML có giám sát là hộp đen. Theo quan điểm đó, các thuật toán ML có giám sát tìm ra các mẫu dự đoán, tuy nhiên các nhà nghiên cứu không hiểu những phát hiện đó. Nói cách khác, thuật toán đã học được điều gì đó, chứ không phải nhà nghiên cứu. Lời chỉ trích này là không có cơ sở.

Ngay cả khi một thuật toán ML có giám sát không đưa ra một giải pháp đại số dạng đóng (ví dụ như phương pháp hồi quy sẽ làm được), thì việc phân tích các dự báo của nó có thể cho chúng ta biết những biến nào có liên quan quan trọng đến một hiện tượng cụ thể, những biến nào là thừa, những biến nào là vô dụng và các biến có liên quan tương tác với nhau như thế nào. Loại phân tích này được gọi là "tầm quan trọng của tính năng" và việc khai thác sức mạnh của nó sẽ đòi hỏi chúng ta phải sử dụng mọi thứ chúng ta đã học được trong các phần trước.

6.2 Giá trị p

Khung hồi quy cổ điển đưa ra một số giả định liên quan đến mô hình được lắp, chẳng hạn như thông số mô hình chính xác, các hồi quy không tương quan lẫn nhau hoặc phần dư nhiễu trắng. Với điều kiện là các giả định đó là đúng, các nhà nghiên cứu đặt mục tiêu xác định tầm quan trọng của một biến giải thích thông qua kiểm định giả thuyết.¹⁵ Một cách phổ biến để thể hiện ý nghĩa của một biến là thông qua giá trị p của nó, một khái niệm có từ những năm 1700 (Brian và Jaisson 2007). Giá trị p định lượng xác suất rằng, nếu hệ số thực liên quan đến biến đó bằng không, chúng ta có thể thu được kết quả bằng hoặc cực đoan hơn kết quả chúng ta đã ước tính. Nó chỉ ra mức độ không tương thích của dữ liệu với một mô hình thống kê đã chỉ định. Tuy nhiên, giá trị p không đo được xác suất mà cả giả thuyết không và giả thuyết thay thế đều không đúng hoặc dữ liệu là ngẫu nhiên. Và giá trị p không đo lường được quy mô của một hiệu ứng hoặc ý nghĩa của một kết quả.¹⁶ Việc sử dụng sai giá trị p rất phổ biến đến mức Hiệp hội Thống kê Hoa Kỳ đã không khuyến khích việc áp dụng chúng trong tương lai như một thước đo ý nghĩa thống kê (Wasserstein và cộng sự, 2019). Điều này đặt ra nghi ngờ trong nhiều thập kỷ nghiên cứu thực nghiệm về Tài chính. Để tìm kiếm các giải pháp thay thế cho giá trị p, trước tiên chúng ta phải hiểu được những cạm bẫy của nó.

6.2.1 Một số lưu ý về giá trị p

Lưu ý đầu tiên về giá trị p là chúng dựa trên những giả định vững chắc đã nêu ở trên. Khi những giả định đó không chính xác, giá trị p có thể thấp mặc dù giá trị thực của hệ số là 0 (kết quả dương tính giả) và giá trị p có thể cao mặc dù giá trị thực của hệ số không phải là 0 (kết quả âm tính giả).

Một cảnh báo thứ hai về giá trị p là đối với các biến giải thích có đa cộng tuyến (tương quan lẫn nhau) cao, giá trị p không thể được ước tính một cách chắc chắn. Trong các hệ thống đa cộng tuyến, các phương pháp hồi quy truyền thống không thể phân biệt giữa các biến giải thích trùng lặp, dẫn đến hiệu ứng thay thế giữa các giá trị p có liên quan.

Một cảnh báo thứ ba về giá trị p là chúng đánh giá một xác suất không hoàn toàn liên quan. Với giả thuyết vô hiệu H_0 và hệ số ước tính $\hat{\beta}$, giá trị p ước tính xác suất thu được kết quả bằng hoặc cực đoan hơn $\hat{\beta}$, tùy thuộc vào việc H_0 là đúng. Tuy nhiên, các nhà nghiên cứu thường quan tâm nhiều hơn đến một xác suất khác, cụ thể là xác suất H_0 là đúng, tùy thuộc vào việc đã quan sát $\hat{\beta}$. Xác suất này có thể được tính toán bằng định lý Bayes, than ôi, với cái giá phải trả là đưa ra các giả định bổ sung (các tiên nghiệm Bayesian).¹⁷

¹⁵ Một số thử nghiệm ý nghĩa cũng yêu cầu phần dư phải tuân theo phân phối chuẩn Gauss.

¹⁶ Để biết thêm thông tin chi tiết, hãy đọc "Tuyên bố về ý nghĩa thống kê và giá trị P" của Hiệp hội thống kê Hoa Kỳ (2016) và Wasserstein và Lazar (2016).

¹⁷ Chúng tôi xem xét lại lập luận này trong Phần 8.2.

Một cảnh báo thứ tư của giá trị p là nó đánh giá ý nghĩa trong mẫu. Toàn bộ mẫu được sử dụng để giải quyết hai nhiệm vụ: ước tính các hệ số và xác định ý nghĩa của chúng. Theo đó, giá trị p có thể thấp (tức là có ý nghĩa) đối với các biến không có giá trị giải thích ngoài mẫu (tức là dự báo).

Việc chạy nhiều thử nghiệm trong mẫu trên cùng một tập dữ liệu có thể dẫn đến phát hiện sai, một hành vi được gọi là p -hacking.

Tóm lại, các giá trị p đòi hỏi chúng ta phải đưa ra nhiều giả định (cảnh báo số 1) để tạo ra ước tính nhiều (cảnh báo số 2) về một xác suất mà chúng ta thực sự không cần (cảnh báo số 3) và có thể không thể khái quát hóa ngoài mẫu (cảnh báo số 4). Đây không phải là những mối quan tâm thừa thãi. Về mặt lý thuyết, một lợi thế chính của các phương pháp cổ điển là chúng cung cấp một sự quy kết rõ ràng về ý nghĩa giữa các biến giải thích. Nhưng vì sự quy kết cổ điển đó có quá nhiều cảnh báo trong thực tế, có lẽ các phương pháp cổ điển có thể sử dụng một số trợ giúp từ các kỹ thuật tính toán hiện đại để khắc phục những cảnh báo đó.

6.2.2 Một ví dụ về số

Hãy xem xét một bài toán phân loại ngẫu nhiên nhị phân bao gồm bốn mươi đặc điểm, trong đó năm đặc điểm mang tính thông tin, ba mươi đặc điểm là trùng lặp và năm đặc điểm là nhiễu. [Đoạn mã 6.1](#) triển khai hàm `getTestData`, hàm này tạo ra các đặc điểm mang tính thông tin, trùng lặp và nhiễu. Các đặc điểm mang tính thông tin (được đánh dấu bằng tiền tố "I_") là các đặc điểm được sử dụng để tạo nhãn. Các đặc điểm trùng lặp (được đánh dấu bằng tiền tố "R_") là các đặc điểm được hình thành bằng cách thêm nhiễu Gauss vào một đặc điểm mang tính thông tin được chọn ngẫu nhiên (giá trị `sigmaStd` càng thấp thì hiệu ứng thay thế càng lớn). Các đặc điểm nhiễu (được đánh dấu bằng tiền tố "N_") là các đặc điểm không được sử dụng để tạo nhãn.

[Hình 6.1](#) biểu diễn các giá trị p thu được từ hồi quy logit trên các đặc điểm đó. Các thanh ngang báo cáo các giá trị p và đường thẳng đứng đứt nét đánh dấu mức ý nghĩa 5%. Chỉ có bốn trong số ba mươi lăm đặc điểm không nhiễu được coi là có ý nghĩa thống kê: `I_1`, `R_29`, `R_27`, `I_3`. Các đặc điểm nhiễu được xếp hạng là tương đối quan trọng (với vị trí 9, 11, 14, 18 và 26). Mười bốn đặc điểm được xếp hạng là ít quan trọng nhất không phải là nhiễu. Tóm lại, các giá trị p này không phản ánh đúng sự thật cơ bản vì những lý do đã giải thích trước đó.

Thật không may, các tập dữ liệu tài chính có xu hướng đa cộng tuyến cao, do các yếu tố rủi ro chung được chia sẻ bởi phần lớn vũ trụ đầu tư: thị trường, lĩnh vực, xếp hạng, giá trị, động lực, chất lượng, thời hạn, v.v. Trong những trường hợp này, các nhà nghiên cứu tài chính nên ngừng chỉ dựa vào các giá trị p . Điều quan trọng là các nhà nghiên cứu tài chính phải làm quen với các phương pháp bổ sung để xác định biến nào chứa thông tin trong một hiện tượng cụ thể.

ĐOẠN TRÍCH 6.1 TẠO RA MỘT TẬP HỢP GIẢI THÍCH CÓ THÔNG TIN, THỪA VÀ TIẾNG ỒN BIẾN

```
def getTestData(n_features=100,n_informative=25,n_redundant=25,
               n_samples=10000,random_state=0,sigmaStd=.0): # tạo một tập dữ
               liệu ngẫu nhiên cho một vấn đề phân loại từ sklearn.datasets import
               make_classification np.random.seed(random_state)

X,y=make_classification(n_mẫu=n_mẫu, n_features=n_features-
               n_redundant, n_informative=n_informative,
               n_redundant=0,shuffle=False, random_state=random_state)

cols=['I_'+str(i) cho i trong xrange(n_informative)] cols+=['N_'+str(i)
               cho i trong xrange(n_features-n_informative- \ n_redundant)]

X,y=pd.DataFrame(X,columns=cols),pd.Series(y)

i=np.random.choice(xrange(n_informative),size=n_redundant) cho k,j trong enumerate(i):

               X['R_'+str(k)]=X['I_'+str(j)]+np.random.normal(kích thước= \
               X.hình dạng[0])*sigmaStd


               trả về X,y
#- - - - -
nhập numpy dưới dạng np, pandas dưới dạng pd, seaborn dưới
dạng sns nhập statsmodels.discrete.discrete_model dưới dạng sm
X,y=getTestData(40,5,30,10000,sigmaStd=.1) ols=sm.Logit(y,X).fit()
```

6.3 Tính năng quan trọng

Trong phần này, chúng tôi nghiên cứu cách hai phương pháp tính mức độ quan trọng của tính năng ML giải quyết các cảnh báo về giá trị p , với các giả định tối thiểu, bằng cách sử dụng các kỹ thuật tính toán. Các ví dụ khác về phương pháp diễn giải ML là hiệu ứng cục bộ tích lũy (Apley 2016) và giá trị Shapley (Štrumbelj 2014).

6.3.1 Tập chất giảm trung bình

Giả sử bạn có một mẫu học có kích thước N , bao gồm các đặc điểm F , fXf gf $\frac{1}{41}; \dots; F$ và một nhãn cho mỗi quan sát. Thuật toán phân loại (hoặc hồi quy) dựa trên cây chia tại mỗi nút t nhãn của nó thành hai mẫu: đối với một đặc điểm Xf cho trước, các nhãn trong nút t liên kết với Xf dưới ngưỡng τ được đặt trong mẫu bên trái và phần còn lại được đặt trong mẫu bên phải. Đối với mỗi mẫu này, chúng ta có thể đánh giá độ tạp chất của chúng là entropy của phân phối nhãn, là chỉ số Gini hoặc theo một số tiêu chí khác. Theo trực giác, một mẫu là tinh khiết nhất khi nó chỉ chứa các nhãn cùng loại và nó là không tinh khiết nhất



Hình 6.1 Giá trị p được tính toán trên một tập hợp các biến giải thích.

khi nhân của nó tuân theo một phân phối đồng đều. Mức tăng thông tin thu được từ việc chia tách được đo bằng mức giảm tạp chất thu được,

$$\Delta g_{1/2}; f \frac{1}{4} i_{1/2} t \frac{N_0 p_0}{\text{Không}} \frac{N_0 p_1}{\text{Không}} i_{1/2} t \frac{1}{2} p_1$$

trong đó $i_{1/2}$ là tạp chất của nhân tại nút t (trước khi chia tách), $i_{1/2} t \frac{1}{2} p_0$ là tạp chất của nhân trong mẫu bên trái và $i_{1/2} t \frac{1}{2} p_1$ là tạp chất của nhân trong mẫu bên phải. Tại mỗi nút t , thuật toán phân loại đánh giá $\Delta g_{1/2}; f$ cho các tính năng khác nhau trong $f x f g f \frac{1}{4} 1; \dots; F$, xác định ngưỡng tối ưu t tối đa hóa $\Delta g_{1/2}; f$ cho mỗi tính năng trong số chúng và chọn tính năng f liên quan đến $\Delta g_{1/2}; f$ lớn nhất. Thuật toán phân loại tiếp tục chia tách các mẫu thêm cho đến khi không thể tạo ra thêm thông tin nào nữa hoặc một số điều kiện dừng sớm được đáp ứng, chẳng hạn như đạt được tạp chất dưới giới hạn tối đa có thể chấp nhận được.

Tầm quan trọng của một tính năng có thể được tính toán như là mức tăng thông tin có trọng số ($\Delta g_{1/2}; f$) trên tất cả các nút mà tính năng đó được chọn. Khái niệm tầm quan trọng của tính năng dựa trên cây này, được giới thiệu bởi Breiman (2001), được gọi là tạp chất giảm trung bình (MDI). Theo cấu trúc, giá trị MDI liên quan đến mỗi tính năng được giới hạn giữa 0 và 1 và tất cả kết hợp lại bằng 1. Trong

sự hiện diện của các đặc điểm F trong đó tất cả đều không cung cấp thông tin (hoặc cung cấp thông tin như nhau), mỗi giá trị MDI được kỳ vọng là $1=F$. Đối với các thuật toán kết hợp các nhóm cây, như rừng ngẫu nhiên, chúng ta có thể ước tính thêm giá trị trung bình và phương sai của các giá trị MDI cho từng đặc điểm trên tất cả các cây. Các ước tính giá trị trung bình và phương sai này, cùng với định lý giới hạn trung tâm, rất hữu ích trong việc kiểm tra ý nghĩa của một đặc điểm so với giả thuyết vô hiệu do người dùng xác định. [Đoạn mã 6.2](#) triển khai một quy trình MDI tổng hợp. Xem [López de Prado \(2018a\)](#) để biết lời khuyên thực tế về cách sử dụng MDI.

```

DOAN TRÍCH 6.2 TRIỂN KHAI PHƯƠNG PHÁP MDI TỔNG THỂ

def featImpMDI(fit,featNames): # tầm quan
    trọng của feat dựa trên việc giảm độ tạp chất trung bình IS
    df0={i:tree.feature_importances_ cho i,tree trong \
        liệt kê(fit.estimators_)}
    df0=pd.DataFrame.from_dict(df0,orient='index')
    df0.columns=tên đặc trưng

    df0=df0.replace(0,np.nan) # vì max_features=1
    imp=pd.concat({'mean':df0.mean(),
        'std':df0.std()*df0.shape[0]**-.5},axis=1) # CLT
    imp/=imp['mean'].sum() trả về
    imp


#- - - - -
từ sklearn.tree nhập DecisionTreeClassifier từ sklearn.ensemble
nhập BaggingClassifier X,y=getTestData(40,5,30,10000,sigmaStd=.1)
clf=DecisionTreeClassifier(criterion='entropy',max_features=1,
    class_weight='balanced',min_weight_fraction_leaf=0)

clf=BaggingClassifier(base_estimator=clf,n_estimators=1000,
    max_features=1.,max_samples=1.,oob_score=False) fit=clf.fit(X,y)

imp=featImpMDI(fit,featNames=X.columns)

```

[Hình 6.2](#) biểu diễn kết quả của việc áp dụng MDI cho cùng một vấn đề phân loại ngẫu nhiên được thảo luận trong [Hình 6.1](#). Các thanh ngang biểu thị giá trị trung bình của các giá trị MDI trên 1.000 cây trong một khu rừng ngẫu nhiên và các đường biểu thị độ lệch chuẩn xung quanh giá trị trung bình đó. Càng thêm nhiều cây vào khu rừng, độ lệch chuẩn xung quanh giá trị trung bình càng nhỏ. MDI thực hiện tốt nhiệm vụ của mình, theo nghĩa là tất cả các tính năng không nhiễu (có thông tin hoặc dư thừa) đều được xếp hạng cao hơn các tính năng nhiễu. Tuy nhiên, một số ít tính năng không nhiễu có vẻ quan trọng hơn nhiễu so với các tính năng tương tự. Đây là loại hiệu ứng thay thế mà chúng tôi dự đoán sẽ tìm thấy khi có các tính năng dư thừa. [Phần 6.5](#) đề xuất một giải pháp cho mối quan tâm cụ thể này.



Hình 6.2 Ví dụ về kết quả MDI.

Trong bốn cảnh báo về giá trị p , phương pháp MDI xử lý ba cảnh báo: (1) Bản chất tính toán của MDI tránh được nhu cầu về các giả định phân phối mạnh có thể sai (cảnh báo số 1) - chúng tôi không áp đặt một cấu trúc cây hoặc thông số đại số cụ thể, hoặc dựa vào các đặc điểm ngẫu nhiên hoặc phân phối của phần dư. (2) Trong khi beta được ước tính trên một mẫu duy nhất, thì MDI tổng hợp được bắt nguồn từ một bootstrap của các cây. Theo đó, phương sai của các ước tính MDI có thể được giảm bằng cách tăng số lượng cây trong các phương pháp tổng hợp nói chung hoặc trong một khu rừng ngẫu nhiên nói riêng (cảnh báo số 2). Điều này làm giảm khả năng xảy ra các kết quả dương tính giả do quá khớp. Ngoài ra, không giống như các giá trị p , ước tính của MDI không yêu cầu đảo ngược một ma trận có thể có điều kiện kém. (3) Mục tiêu của các bộ phân loại dựa trên cây không phải là ước tính các hệ số của một phương trình đại số nhất định, do đó, ước tính xác suất của một giả thuyết vô hiệu cụ thể là không liên quan. Nói cách khác, MDI hiệu chỉnh cảnh báo số 3 bằng cách tìm các tính năng quan trọng nói chung, bất kể bất kỳ thông số tham số cụ thể nào.

Ước tính tổng thể của MDI sẽ cho thấy phương sai thấp khi có đủ số lượng cây, do đó làm giảm mối lo ngại về p -hacking. Nhưng bản thân quy trình này không liên quan đến việc xác thực chéo. Do đó, một cảnh báo về giá trị p mà MDI không giải quyết được hoàn toàn là MDI cũng được tính toán trong mẫu (cảnh báo số 4). Để đối mặt với cảnh báo cuối cùng này, chúng ta cần giới thiệu khái niệm về độ chính xác giảm trung bình.

6.3.2 Độ chính xác giảm trung bình

Một nhược điểm của cả giá trị p và MDI là một biến có vẻ quan trọng đối với mục đích giải thích (trong mẫu) có thể không liên quan đến mục đích dự báo (ngoài mẫu). Để giải quyết vấn đề này (cảnh báo số 4), [Breiman \(2001\)](#) đã giới thiệu phương pháp độ chính xác giảm trung bình (MDA).¹⁸ MDA hoạt động như sau: đầu tiên, nó phù hợp với một mô hình và tính toán hiệu suất đã xác thực chéo của nó; thứ hai, nó tính toán hiệu suất đã xác thực chéo của cùng một mô hình đã được lắp, với sự khác biệt duy nhất là nó xáo trộn các quan sát liên quan đến một trong các tính năng. Điều đó

cung cấp cho chúng ta một hiệu suất xác thực chéo đã sửa đổi cho mỗi tính năng. Thứ ba, nó suy ra MDA liên quan đến một tính năng cụ thể bằng cách so sánh hiệu suất xác thực chéo trước và sau khi xáo trộn. Nếu tính năng này quan trọng, sẽ có sự suy giảm đáng kể về hiệu suất do xáo trộn, miễn là các tính năng là độc lập. Một thuộc tính quan trọng của MDA là, giống như ensembleMDI, nó không phải là kết quả của một ước tính duy nhất, mà là giá trị trung bình của nhiều ước tính (một cho mỗi tập kiểm tra trong xác thực chéo k lần).

Khi các tính năng không độc lập, MDA có thể đánh giá thấp tầm quan trọng của các tính năng có liên quan. Ở mức cực đoan, với hai tính năng cực kỳ quan trọng nhưng giống hệt nhau, MDA có thể kết luận rằng cả hai tính năng đều tương đối không quan trọng, vì hiệu ứng của việc xáo trộn một tính năng có thể được bù đắp một phần bằng cách không xáo trộn tính năng kia. Chúng tôi giải quyết mối quan tâm này trong [Phần 6.5](#).

Giá trị MDA không bị giới hạn và việc xáo trộn một tính năng có khả năng cải thiện hiệu suất xác thực chéo khi tính năng đó không cung cấp thông tin đến mức gây bất lợi. Vì MDA liên quan đến bước xác thực chéo nên phương pháp này có thể tốn kém về mặt tính toán. [Đoạn mã 6.3](#) triển khai MDA. Xem [López de Prado \(2018a\)](#) để biết lời khuyên thực tế về cách sử dụng MDA.

[Hình 6.3](#) biểu diễn kết quả của việc áp dụng MDA cho cùng một bài toán phân loại ngẫu nhiên mà chúng ta đã thảo luận trong [Hình 6.2](#). Chúng ta có thể rút ra những kết luận tương tự như chúng ta đã làm trong ví dụ MDI. Đầu tiên, MDA thực hiện tốt nhiệm vụ tổng thể trong việc tách các đặc điểm nhiễu khỏi phần còn lại. Các đặc điểm nhiễu được xếp hạng cuối cùng. Thứ hai, các đặc điểm nhiễu cũng được coi là không quan trọng về mặt độ lớn, với các giá trị MDA về cơ bản là bằng không. Thứ ba, mặc dù các hiệu ứng thay thế góp phần làm tăng mức độ quan trọng của MDA, nhưng không có hiệu ứng nào đủ cao để đặt câu hỏi về tầm quan trọng của các tính năng không gây nhiễu.

Mặc dù có tên như vậy, MDA không nhất thiết phải dựa vào độ chính xác để đánh giá hiệu suất được xác thực chéo. MDA có thể được tính toán dựa trên các điểm hiệu suất khác. Trên thực tế, trong trường hợp cụ thể của tài chính, tính chính xác không phải là lựa chọn tốt. Lý do là, độ chính xác đánh giá một bộ phân loại theo tỷ lệ dự đoán đúng của nó. Điều này có nhược điểm là xác suất không được tính đến.

¹⁸ Đôi khi điều này còn được gọi là tầm quan trọng của hoán vị.

```

DOẠN TRÍCH 6.3 TRIỂN KHAI MDA

def featImpMDA(clf,X,y,n_splits=10):
    # tầm quan trọng của thành tích dựa trên việc giảm điểm OOS từ
    sklearn.metrics nhập log_loss từ
    sklearn.model_selection._split nhập KFold cvGen=KFold(n_splits=n_splits)

    scr0,scr1=pd.Series(),pd.DataFrame(cột=X.cột)
    đối với i,(train,test) trong enumerate(cvGen.split(X=X)):
        X0,y0=X.iloc[tàu,:],y.iloc[tàu]
        X1,y1=X.iloc[test,:],y.iloc[test]
        fit=clf.fit(X=X0,y=y0) # sự phù hợp xảy ra ở đây
        prob=fit.predict_proba(X1) # dự đoán trước khi xáo trộn scr0.loc[i]=
        log_loss(y1,prob,labels=clf.classes_) cho j trong X.columns:

        X1=X1.copy(deep=True)
        np.random.shuffle(X1[j].values) # xáo trộn một cột
        prob=fit.predict_proba(X1_) # dự đoán sau khi xáo trộn scr1.loc[i,j]=
        log_loss(y1,prob,labels=clf.classes_)
    imp=(-1*scr1).add(scr0,axis=0) imp=imp/
    (-1*scr1)
    imp=pd.concat({'mean':imp.mean(),
        'std':imp.std()*imp.shape[0]**-.5},axis=1) # CLT trả về imp


#- - - - -
X,y=getTestData(40,5,30,10000,sigmaStd=.1)
clf=DecisionTreeClassifier(tiêu chí='entropy',max_features=1,
    class_weight='balanced',min_weight_fraction_leaf=0)
clf=BaggingClassifier(base_estimator=clf,n_estimators=1000,
    max_features=1.,max_samples=1.,oob_score=Sai)
imp=featImpMDA(clf,X,y,10)

```

Ví dụ, một bộ phân loại có thể đạt được độ chính xác cao ngay cả khi nó đưa ra dự đoán tốt với độ tin cậy thấp và dự đoán xấu với độ tin cậy cao. Trong phần sau, chúng tôi giới thiệu một hàm chấm điểm giải quyết mối quan tâm này.

6.4 Độ chính xác có trọng số xác suất

Trong các ứng dụng tài chính, một giải pháp thay thế tốt cho độ chính xác là log-loss (còn được gọi là cross-entropy loss). Log-loss chấm điểm cho một bộ phân loại theo log-likelihood trung bình của các nhãn thực (để biết định nghĩa chính thức, hãy xem phần 9.4 của [López de Prado 2018a](#)). Tuy nhiên, một nhược điểm là điểm log-loss không dễ diễn giải và so sánh. Một giải pháp khả thi là tính toán khả năng trung bình âm của các nhãn thực (NegAL),



Hình 6.3 Ví dụ về kết quả MDA.

$$N1 \quad K1$$
$$\hat{A}m \quad \frac{1}{4} \quad N1X \quad X \quad y_n; k p_n; k;$$

số ¼0 k ¼0

trong đó $p_n; k$ là xác suất liên quan đến dự đoán n của nhãn k và $y_n; k$ là hàm chỉ báo, $y_n; k \geq 0$; $1g f$, trong đó $y_n; k \leq 1$ khi quan sát n được gán nhãn k và $y_n; k \leq 0$ nếu không. Điều này rất giống với log-loss, với sự khác biệt là nó tính trung bình các khả năng xảy ra chứ không phải log-likelihood, do đó NegAL vẫn nằm trong khoảng từ 0 đến 1.

Ngoài ra, chúng ta có thể định nghĩa độ chính xác có trọng số xác suất (PWA) là

$$N1$$
$$PWA \quad \frac{1}{4} \quad X \quad \text{trong } p_n \quad v.v. \quad K1$$

số ¼0 K1, XN1 số ¼0

trong đó $p_n \leq \max p_n; k$ và y_n là một hàm chỉ báo, $y_n \geq 0$; $1g f$, trong đó $y_n \leq 1$ khi dự đoán là đúng và $y_n \leq 0$ trong trường hợp ngược lại.¹⁹ Điều này tương đương với độ chính xác tiêu chuẩn khi bộ phân loại có niềm tin tuyệt đối vào mọi dự đoán ($p_n \leq 1$ cho mọi n). PWA trừng phạt các dự đoán xấu được thực hiện với độ tin cậy cao nghiêm khắc hơn độ chính xác, nhưng ít nghiêm trọng hơn log-loss.

¹⁹ Ý tưởng về PWA là thành quả của quá trình hợp tác chung với các đồng nghiệp Lee Cohn, Michael Lock và Yaxiong Zeng.

6.5 Hiệu ứng thay thế

Hiệu ứng thay thế phát sinh khi hai tính năng chia sẻ thông tin dự đoán.

Hiệu ứng thay thế có thể làm sai lệch kết quả từ các phương pháp tính mức độ quan trọng của đặc điểm. Trong trường hợp MDI, mức độ quan trọng của hai đặc điểm giống hệt nhau sẽ giảm đi một nửa vì chúng được chọn ngẫu nhiên với xác suất bằng nhau. Trong trường hợp MDA, hai đặc điểm giống hệt nhau có thể được coi là tương đối không quan trọng, ngay cả khi chúng là quan trọng, vì hiệu ứng của việc xáo trộn một đặc điểm có thể được bù đắp bởi đặc điểm kia.

6.5.1 Trực giao hóa

Khi các tính năng phụ thuộc lẫn nhau cao, tầm quan trọng của chúng không thể được đánh giá theo cách chắc chắn. Những thay đổi nhỏ trong các quan sát có thể có tác động đáng kể đến tầm quan trọng ước tính của chúng. Tuy nhiên, tác động này không phải là ngẫu nhiên: với hai tính năng phụ thuộc lẫn nhau cao, sự giảm tầm quan trọng của một tính năng được bù đắp bằng sự gia tăng tầm quan trọng của tính năng kia. Nói cách khác, sự phụ thuộc lẫn nhau gây ra hiệu ứng thay thế khi đánh giá tầm quan trọng của các tính năng.

Một giải pháp cho đa cộng tuyến là áp dụng PCA trên các đặc điểm, suy ra các thành phần chính trực giao của chúng, sau đó chạy MDI hoặc MDA trên các thành phần chính đó (để biết thêm chi tiết, hãy xem chương 8 của [López de Prado 2018a](#)). Các đặc điểm được trực giao theo cách này có thể phục hồi tốt hơn trước các hiệu ứng thay thế, với ba cảnh báo: (1) các đặc điểm trùng lặp phát sinh từ các kết hợp phi tuyến tính của các đặc điểm thông tin vẫn sẽ gây ra các hiệu ứng thay thế; (2) các thành phần chính có thể không có lời giải thích trực quan; (3) các thành phần chính được xác định bởi các vectơ riêng không nhất thiết phải tối đa hóa hiệu suất ngoài mẫu của mô hình ([Witten et al. 2013](#)).

6.5.2 Tầm quan trọng của tính năng cụm

Một cách tiếp cận tốt hơn, không yêu cầu thay đổi cơ sở, là nhóm các đặc điểm tương tự và áp dụng phân tích tầm quan trọng của đặc điểm ở cấp độ cụm. Theo cấu trúc, các cụm không giống nhau, do đó chế ngự được các hiệu ứng thay thế. Vì phân tích được thực hiện trên một phân vùng các đặc điểm, không thay đổi cơ sở, nên kết quả thường trực quan.

Chúng tôi xin giới thiệu một thuật toán thực hiện ý tưởng này. Thuật toán tầm quan trọng của tính năng theo cụm (CFI) bao gồm hai bước: (1) tìm số lượng và thành phần của cụm tính năng; (2) áp dụng phân tích tầm quan trọng của tính năng trên các nhóm tính năng tương tự thay vì trên các tính năng riêng lẻ.

Một số điểm hình bóng có thể thấp do một đặc điểm là sự kết hợp của nhiều tính năng trên các cụm. Đây là một vấn đề, vì ONC không thể chỉ định một tính năng thành nhiều cụm. Trong trường hợp này, phép biến đổi sau có thể giúp giảm đa cộng tuyến của hệ thống. Đối với mỗi cụm $k = 1; \dots$ thay thế các tính năng K , có trong cụm đó bằng các tính năng còn lại, trong đó các tính năng còn lại không chứa thông tin từ các tính năng bên ngoài cụm k . Để nói một cách chính xác, hãy để D_k là tập con của các đặc điểm chỉ mục $D = \frac{1}{4} \text{Hgf}$. bao gồm trong cụm k , trong đó $D_k \cap D_l = \emptyset$; $k \neq l$; $D_k \cap D_l = \frac{1}{4} : 8k - \frac{1}{4} 1$; Anh $k \neq l D_k = \frac{1}{4} D$. Sau đó, đối với một tính năng X_i nhất định trong đó $i \in D_k$, chúng tôi tính toán tính năng còn lại $X_i \wedge i$ bằng phù hợp

$$X_{n,i} = \sum_{j=1}^n \beta_{i,j} X_{n,j} + \epsilon_{n,i}$$

trong đó $n = \frac{1}{4}, 1; \dots; N$ là chỉ số quan sát trên mỗi tính năng. Nếu mức độ tự do trong hồi quy trên quá thấp, một lựa chọn là sử dụng hồi quy tuyến tính sự kết hợp của các tính năng trong mỗi cụm (ví dụ, theo một sơ đồ trọng số phương sai tối thiểu), do đó chỉ cần ước tính $K + 1$ beta. Một trong những tính chất của phần dư OLS là chúng trực giao với các hồi quy. Vì vậy, bằng cách thay thế mỗi tính năng X_i bằng giá trị tương đương còn lại của nó $\hat{\epsilon}_i$, chúng ta loại bỏ từ thông tin cụm k đã được bao gồm trong các cụm khác, trong khi bảo tồn thông tin chỉ thuộc về cụm k . Một lần nữa, điều này có nghĩa là sự biến đổi không cần thiết nếu điểm số hình bóng chỉ ra rõ ràng rằng các tính năng thuộc về nhóm tương ứng của chúng.

²⁰ Để biết ví dụ về tính năng nhóm với số liệu khoảng cách lý thuyết thông tin, hãy xem <https://ssrn.com/tóm tắt=3517595>

Bước 2: Tầm quan trọng của cụm

Bước 1 đã xác định số lượng và thành phần của các cụm tính năng. Chúng ta có thể sử dụng thông tin này để áp dụng MDI và MDA vào các nhóm tính năng tương tự, thay vì vào các tính năng riêng lẻ. Trong phần sau, chúng ta giả định rằng một thuật toán phân vùng đã nhóm các tính năng, tuy nhiên khái niệm về tầm quan trọng của tính năng nhóm này cũng có thể được áp dụng cho các cụm phân cấp.

MDI cụm

Như chúng ta đã thấy trong [Phần 6.3.1](#), MDI của một tính năng là sự giảm tạp chất có trọng số trên tất cả các nút mà tính năng đó được chọn. Chúng tôi tính toán MDI cụm là tổng các giá trị MDI của các tính năng cấu thành nên tính năng đó

cụm. Nếu có một tính năng cho mỗi cụm, thì MDI và MDI cụm là giống nhau. Trong trường hợp của một tập hợp các cây, có một MDI cụm cho mỗi cây, cho phép chúng ta tính toán MDI cụm trung bình và độ lệch chuẩn xung quanh MDI cụm trung bình, tương tự như cách chúng ta đã làm đối với MDI tính năng.

[Đoạn mã 6.4](#) triển khai quy trình ước tính MDI theo cụm.

ĐOẠN TRÍCH 6.4 MDI NHÓM

```

định nghĩa nhómMeanStd(df0,clstrs):
    out=pd.DataFrame(cột=['trung bình','tiêu chuẩn'])
    đối với i,j trong clstrs.iteritems():
        df1=df0[j].tổng(trục=1)
        out.loc['C_'+str(i),'mean']=df1.mean()
        out.loc['C_'+str(i),'std']=df1.std()*df1.shape[0]**-.5
    trở về
#- - - - -

def featImpMDI_Clustered(fit,featNames,clstrs):
    df0={i:tree.feature_importances_ cho i,tree trong \
        liệt kê(fit.estimators_)}
    df0=pd.DataFrame.from_dict(df0,orient='index')
    df0.columns=tên đặc trưng

    df0=df0.replace(0,np.nan) # vì max_features=1 imp=groupMeanStd(df0,clstrs)
    imp=imp['mean'].sum() trả về imp

```

MDA cụm

MDA của một tính năng được tính bằng cách so sánh hiệu suất của một thuật toán trước và sau khi xáo trộn tính năng đó. Khi tính toán MDA theo cụm, thay vì xáo trộn từng tính năng một, chúng tôi xáo trộn tất cả các tính năng tạo nên một cụm nhất định. Nếu có một cụm cho mỗi tính năng, thì MDA và MDA theo cụm là

ĐOẠN TRÍCH 6.5 MDA NHÓM

```
def featImpMDA_Clustered(clf,X,y,clstrs,n_splits=10):
    từ sklearn.metrics nhập log_loss từ
    sklearn.model_selection._split nhập KFold cvGen=KFold(n_splits=n_splits)

    scr0,scr1=pd.Series(),pd.DataFrame(columns=clstrs.keys())
    đối với i,(train,test) trong enumerate(cvGen.split(X=X)):
        X0,y0=X.iloc[tàu,:],y.iloc[tàu]
        X1,y1=X.iloc[test,:],y.iloc[test]

        phù hợp = clf.phù hợp (X = X0, y = y0)
        prob=fit.predict_proba(X1)
        scr0.loc[i]=-log_loss(y1,prob,labels=clf.classes_) cho j trong scr1.columns:

        X1=X1.copy(deep=True) cho k
        trong clstrs[j]:
            np.random.shuffle(X1[k].values) # xáo trộn cụm
            prob=fit.predict_proba(X1_)
            scr1.loc[i,j]=-log_loss(y1,prob,labels=clf.classes_)
    imp=(-1*scr1).add(scr0,axis=0) imp=imp/
    (-1*scr1)
    imp=pd.concat({'mean':imp.mean(),
        'std':imp.std()*imp.shape[0]**-.5},axis=1)
    imp.index=['C_'+str(i) cho i trong imp.index] trả về imp
```

tương tự. [Đoạn mã 6.5](#) triển khai quy trình ước tính MDA theo cụm.

6.6 Kết quả thực nghiệm

Trong thí nghiệm này, chúng tôi sẽ kiểm tra các quy trình MDI và MDA theo cụm trên cùng một tập dữ liệu mà chúng tôi đã sử dụng trên các phiên bản MDI và MDA không theo cụm.

(xem [Mục 6.3.1](#) và [6.3.2](#)). Bộ dữ liệu đó bao gồm bốn mươi tính năng, trong đó năm tính năng mang tính thông tin, ba mươi tính năng trùng lặp và năm tính năng nhiễu. Đầu tiên, chúng tôi áp dụng thuật toán ONC vào ma trận tương quan của các tính năng đó.²¹ Trong bối cảnh không phải thực nghiệm, nhà nghiên cứu nên khử nhiễu và khử âm ma trận tương quan trước khi phân cụm, như đã giải thích trong [Mục 2](#). Chúng tôi không làm như vậy trong thí nghiệm này vì mục đích kiểm tra tính mạnh mẽ của phương pháp (dự kiến kết quả sẽ tốt hơn trên ma trận tương quan đã khử nhiễu và khử âm).


²¹ Để thực hành, chúng tôi yêu cầu người đọc áp dụng ONC vào phép chiếu số liệu của các tính năng được tính toán bằng cách sử dụng biến thể thông tin chuẩn hóa.

Hình 6.4 cho thấy ONC nhận dạng đúng rằng có sáu cụm có liên quan (một cụm cho mỗi đặc điểm thông tin, cộng với một cụm các đặc điểm nhiễu) và nó gán các đặc điểm trùng lặp cho cụm chứa đặc điểm thông tin mà các đặc điểm trùng lặp được lấy ra. Với mối tương quan thấp

trên các cụm, không cần phải thay thế các tính năng bằng phần dư của chúng (như đã đề xuất trong Phần 6.5.2.1). [Đoạn mã 6.6](#) triển khai ví dụ này.

SNIPPET 6.6 CÁC TÍNH NĂNG NHÓM BƯỚC

```
X,y=getTestData(40,5,30,10000,sigmaStd=.1)
corr0,clstrs,silh=clusterKMeansBase(X.corr(),maxNumClusters=10,
    n_init=10)
sns.heatmap(corr0,cmap='viridis')
```




Hình 6.4 Các cụm ONC cùng với các tính năng thông tin và dự phòng.

Tiếp theo, chúng tôi áp dụng phương pháp MDI theo cụm của mình trên tập dữ liệu đó. [Hình 6.5](#) hiển thị đầu ra MDI theo cụm, mà chúng ta có thể so sánh với đầu ra không theo cụm được báo cáo trong [Hình 6.2](#). Tiền tố “C_” biểu thị cụm và “C_5” là cụm được liên kết với các đặc điểm nhiễu. Các đặc điểm theo cụm “C_1” là đặc điểm ít quan trọng thứ hai, tuy nhiên tầm quan trọng của nó gấp đôi tầm quan trọng của “C_5”. Điều này trái ngược với những gì chúng ta thấy trong [Hình 6.2](#), trong đó có một sự khác biệt nhỏ về tầm quan trọng giữa các đặc điểm nhiễu và một số đặc điểm không nhiễu. Do đó, phương pháp MDI theo cụm dường như hoạt động tốt hơn phương pháp MDI tiêu chuẩn. [Đoạn mã 6.7](#) cho thấy cách tính toán các kết quả này.

SNIPPET 6.7 GỌI CÁC HÀM CHO MDI NHÓM

```
clf=DecisionTreeClassifier(tieu_chi='entropy',max_features=1,
    class_weight='cân bằng',min_weight_fraction_leaf=0)
clf=BaggingClassifier(base_estimator=clf,n_estimators=1000,
    max_features=1.,max_samples=1.,oob_score=Sai)
phù_hợp = clf.fit(X,y)
imp=featImpMDI_Clustered(phù_hợp,X.cột,clstrs)
```



Hình 6.5 MDI cụm.


Cuối cùng, chúng tôi áp dụng phương pháp MDA nhóm của mình trên tập dữ liệu đó. Hình 6.6 cho thấy đầu ra MDA được nhóm lại, mà chúng ta có thể so sánh với đầu ra không được nhóm lại được báo cáo trong Hình 6.3. Một lần nữa, “C_5” là cụm liên quan đến tiếng ồn các tính năng và tất cả các cụm khác đều có liên quan đến thông tin và dự phòng tính năng. Phân tích này đã đưa ra hai kết luận đúng: (1) “C_5” có vẻ cơ bản là không quan trọng và nên bị loại bỏ vì không liên quan; và (2) tất cả các cụm khác có tầm quan trọng rất giống nhau. Điều này trái ngược với những gì chúng ta đã thấy trong Hình 6.3, trong đó một số tính năng không nhiều dường như quan trọng hơn nhiều hơn những người khác, thậm chí sau khi xem xét đến sự suy diễn chuẩn mực xung quanh giá trị trung bình. Đoạn mã 6.8 cho thấy cách tính toán những kết quả này.

6.7 Kết luận

Hầu hết các nhà nghiên cứu sử dụng giá trị p để đánh giá ý nghĩa của các biến giải thích. Tuy nhiên, như chúng ta đã thấy trong phần này, giá trị p có bốn lỗi chính. ML cung cấp các phương pháp đánh giá tầm quan trọng của tính năng giúp khắc phục hầu hết hoặc toàn bộ những nhược điểm đó.

ĐOẠN TRÍCH 6.8 GỌI CÁC HÀM CHO MDA NHÓM

```
clf=DecisionTreeClassifier(tiêu chí='entropy',max_features=1,
    class_weight='cân bằng',min_weight_fraction_leaf=0)
clf=BaggingClassifier(base_estimator=clf,n_estimators=1000,
    max_features=1,max_samples=1.,oob_score=Sai)
imp=featImpMDA_Clustered(clf,X,y,clstrs,10)
```



Hình 6.6 MDA cụm.

Các phương pháp MDI và MDA đánh giá tầm quan trọng của các tính năng một cách mạnh mẽ và mà không đưa ra những giả định mạnh mẽ về sự phân bố và cấu trúc của dữ liệu. Không giống như các giá trị p, MDA đánh giá tầm quan trọng của tính năng trong xác thực chéo thí nghiệm. Hơn nữa, không giống như các giá trị p, MDI cụm và MDA cụm ước tính kiểm soát hiệu quả các hiệu ứng thay thế. Nhưng có lẽ Ưu điểm nổi bật của MDI và MDA là, không giống như các phân tích ý nghĩa cổ điển, các kỹ thuật ML này đánh giá tầm quan trọng của một tính năng bất kể bất kỳ thông số kỹ thuật cụ thể nào. Khi làm như vậy, họ cung cấp thông tin cực kỳ hữu ích cho việc phát triển một lý thuyết. Một khi nhà nghiên cứu biết các biến số liên quan đến một hiện tượng, cô ấy có thể tập trung sự chú ý của mình vào việc tìm kiếm cơ chế hoặc thông số kỹ thuật liên kết chúng lại với nhau.

Ý nghĩa là các phương pháp thống kê cổ điển, chẳng hạn như hồi quy phân tích, không nhất thiết phải minh bạch hơn hoặc sâu sắc hơn ML của họ các đối tác. Nhận thức rằng các công cụ ML là hộp đen và các công cụ cổ điển là hộp trắng là sai. Không chỉ các phương pháp tầm quan trọng của tính năng ML có thể là hữu ích như giá trị p, nhưng trong một số trường hợp, chúng có thể sâu sắc và chính xác hơn.

Lời khuyên cuối cùng là hãy cân nhắc cẩn thận những gì chúng ta muốn giải thích hoặc dự đoán. Trong [Phần 5](#), chúng tôi đã xem xét các phương pháp dán nhãn khác nhau. Các đặc điểm giống nhau có thể mang lại nhiều mức độ quan trọng khác nhau trong việc giải thích hoặc dự đoán các loại nhãn khác nhau. Bất cứ khi nào có thể, việc áp dụng các phương pháp quan trọng của đặc điểm này cho tất cả các phương pháp dán nhãn đã thảo luận trước đó là hợp lý và xem sự kết hợp nào giữa các đặc điểm và nhãn dẫn đến lý thuyết mạnh nhất. Ví dụ, bạn có thể không quan tâm đến việc dự đoán dấu hiệu của xu hướng tiếp theo hay dự đoán dấu hiệu của lợi nhuận 5% tiếp theo, vì bạn có thể xây dựng các chiến lược có lợi nhuận dựa trên cả hai loại dự đoán (miễn là phân tích về tầm quan trọng của đặc điểm cho thấy sự tồn tại của một kết nối lý thuyết mạnh mẽ).

6.8 Bài tập

- Hãy xem xét một xét nghiệm y khoa có tỷ lệ dương tính giả $\alpha = 1/4$, $P_{1/2}^x > \tau_{H0}$, trong đó H_0 là giả thuyết vô hiệu (bệnh nhân khỏe mạnh), x là phép đo quan sát được và τ là ngưỡng có ý nghĩa. Một xét nghiệm được tiến hành trên một bệnh nhân ngẫu nhiên và cho kết quả dương tính (giả thuyết vô hiệu bị bác bỏ). Xác suất bệnh nhân thực sự mắc tình trạng này là bao nhiêu? a Có phải là $1 - \alpha = 3/4$, $P_{1/2}^x \leq \tau_{H0}$ (độ tin cậy của xét nghiệm)? b Có phải là $1 - \beta = 3/4$, $P_{1/2}^x > \tau_{H1}$ (độ mạnh hoặc độ thu hồi của xét nghiệm)? c Hay là $P_{1/2}^{H1|x} > \tau$ (độ chính xác của xét nghiệm)? d Trong các giá trị trên, giá trị p đo lường cái gì? e Trong tài chính, tình huống tương tự là kiểm tra xem một biến có liên quan đến một hiện tượng hay không. Giá trị p có cho chúng ta biết bất cứ điều gì về xác suất biến đó có liên quan hay không, với bằng chứng quan sát được?
- Hãy xem xét một xét nghiệm y khoa trong đó $\alpha = 1/4$, $\beta = 1/4$ và xác suất của tình trạng này là $P_{1/2}^{H1} = 1/4$. Xét nghiệm có khả năng thu hồi đầy đủ và độ tin cậy rất cao. Xác suất một bệnh nhân xét nghiệm dương tính thực sự bị bệnh là bao nhiêu? Tại sao nó thấp hơn nhiều so với $1 - \alpha$ và $1 - \beta$? Xác suất một bệnh nhân thực sự bị bệnh sau khi xét nghiệm dương tính hai lần trong các xét nghiệm độc lập là bao nhiêu?
- Chạy lại các ví dụ trong [Mục 6.3.1](#) và [6.3.2](#), lần này bạn truyền tham số $\sigma_{std}=0$ vào hàm `getTestData`. [Hình 6.2](#) và [6.3](#) trông như thế nào bây giờ? Nguyên nhân nào gây ra sự khác biệt, nếu có?
- Chạy lại phân tích MDA trong [Phần 6.3.2](#), lần này bạn sử dụng độ chính xác có trọng số xác suất ([Phần 6.4](#)) làm hàm tính điểm. Kết quả có khác biệt đáng kể không? Chúng trực quan hơn hay dễ giải thích hơn không? Bạn có thể nghĩ ra những cách khác để biểu diễn đầu ra MDA bằng độ chính xác có trọng số xác suất không?
- Chạy lại thí nghiệm trong [Phần 6.6](#), trong đó lần này số liệu đo khoảng cách được sử dụng để nhóm các tính năng là sự thay đổi của thông tin ([Phần 3](#)).

7 Xây dựng danh mục đầu tư

7.1 Động lực

Việc phân bổ tài sản đòi hỏi phải đưa ra quyết định trong điều kiện không chắc chắn. Markowitz (1952) đã đề xuất một trong những ý tưởng có ảnh hưởng nhất trong lịch sử tài chính hiện đại, cụ thể là, biểu diễn vấn đề đầu tư như một chương trình tối ưu hóa lồi. Thuật toán đường tới hạn (CLA) của Markowitz ước tính một “biên giới hiệu quả” của các danh mục đầu tư tối đa hóa lợi nhuận kỳ vọng theo một mức rủi ro nhất định, trong đó rủi ro danh mục đầu tư được đo lường theo độ lệch chuẩn của lợi nhuận. Trong thực tế, các giải pháp tối ưu trung bình-phương sai có xu hướng tập trung và không ổn định (De Miguel và cộng sự, 2009).

Có ba cách tiếp cận phổ biến để giảm sự bất ổn trong danh mục đầu tư tối ưu. Đầu tiên, một số tác giả đã cố gắng điều chỉnh giải pháp bằng cách đưa thêm thông tin liên quan đến giá trị trung bình hoặc phương sai dưới dạng các giá trị trước (Black và Litterman 1992). Thứ hai, các tác giả khác đề xuất giảm vùng khả thi của giải pháp bằng cách kết hợp các ràng buộc bổ sung (Clarke và cộng sự 2002). Thứ ba, các tác giả khác đề xuất cải thiện tính ổn định về mặt số của ma trận nghịch đảo hiệp phương sai (Ledoit và Wolf 2004).

Trong Phần 2, chúng ta đã thảo luận về cách xử lý sự bất ổn định do nhiễu chứa trong ma trận hiệp phương sai gây ra. Thực tế là, tín hiệu chứa trong ma trận hiệp phương sai cũng có thể là nguồn gây bất ổn định, đòi hỏi phải có cách xử lý chuyên biệt. Trong phần này, chúng tôi giải thích lý do tại sao một số cấu trúc dữ liệu (hoặc loại tín hiệu) khiến các giải pháp trung bình-phương sai không ổn định và chúng ta có thể làm gì để giải quyết nguồn bất ổn định thứ hai này.

7.2 Tối ưu hóa danh mục đầu tư lồi

Hãy xem xét một danh mục đầu tư gồm N cổ phiếu, trong đó lợi nhuận của nó vượt quá tỷ lệ không rủi ro có giá trị kỳ vọng μ và hiệp phương sai kỳ vọng V . Nhận định của Markowitz là xây dựng bài toán phân bổ tài sản cổ điển dưới dạng bậc hai chương trình,

$$\begin{aligned} \text{phút } \frac{1}{\omega} V \omega \\ \text{s.t: } \omega^T a \geq 1; \end{aligned}$$

trong đó a đặc trưng cho các ràng buộc của danh mục đầu tư. Vấn đề này có thể được thể hiện dưới dạng Lagrangian như

$$L = \frac{1}{2} \omega^T V \omega - \lambda (\omega^T a - 1)$$

với điều kiện bậc nhất

$$\frac{L^{1/2}\omega}{\lambda} = \frac{1}{4} V\omega \lambda a$$

$$\frac{L^{1/2}\omega; \lambda}{\lambda} = \frac{1}{4} \omega \text{ trên } 1:$$

Đặt các điều kiện bậc nhất (cần thiết) thành không, ta thu được rằng

$$V\omega \lambda a = \frac{1}{4} 0 \Rightarrow \omega = \frac{1}{4} \lambda V1a \text{ và } \omega = \frac{1}{4} a \Rightarrow \omega = \frac{1}{4} 1 \Rightarrow \lambda a = V1a = \frac{1}{4} 1 \Rightarrow \lambda = \frac{1}{4} 1 = a \Rightarrow V1a$$

, do đó

$$\omega = \frac{1}{4} \frac{V1a}{\text{và } V1a}$$

Điều kiện bậc hai (đủ) xác nhận rằng nghiệm này là nghiệm tối thiểu của Lagrangian:

$$\begin{array}{ccc} \frac{L^{1/2}\omega}{\omega^2} & \frac{L^{1/2}\omega}{\omega \lambda} & V0 a0 a \\ & & 0 \end{array} \quad \frac{1}{4} a0 a \geq 0:$$

$$\frac{L^{1/2}\omega}{\lambda \omega} \quad \frac{L^{1/2}\omega; \lambda}{\lambda^2}$$

Bây giờ chúng ta hãy chuyển sự chú ý của mình sang một vài công thức đặc trưng vectơ, a :

1 Đối với $\frac{1}{4} 1N$ và $V = \frac{1}{4} \sigma 1N$, trong đó $\sigma \in \mathbb{R}^p$, $1N$ là vectơ số một có kích thước N và $1N$ là ma trận đơn vị có kích thước N , thì giải pháp là danh mục đầu tư có trọng số bằng nhau (được gọi là danh mục đầu tư "1/N" hoặc danh mục đầu tư "ngây thơ"), vì $\omega = \frac{1}{4} 1N \Rightarrow \omega = \frac{1}{4} 1N = \frac{1}{4} 1N$.

2 Với $a = \frac{1}{4} 1N$ và V là ma trận đường chéo có các mục không bằng nhau ($V_{i,j} = \frac{1}{4} 0$, với mọi $i \neq j$), thì giải pháp là danh mục nghịch đảo phương sai, vì $g = \frac{1}{4} 1; \dots; N$:

$$\omega = \frac{1}{4} \frac{1}{N} \frac{1}{\frac{1}{N} V_{11} + \dots + \frac{1}{N} V_{NN}} = \frac{1}{4} \frac{1}{V_{11} + \dots + V_{NN}}$$

3 Đối với $a = \frac{1}{4} 1N$, giải pháp là danh mục đầu tư có phương sai tối

với $a = \frac{1}{4} \mu$, giải pháp tối đa hóa tỷ lệ Sharpe của danh mục đầu tư, $\frac{\mu - r_f}{\sigma} = \frac{\mu - r_f}{\sigma} = \frac{\mu - r_f}{\sigma} = \frac{\mu - r_f}{\sigma}$ (Grinold và Kahn 1999).

7.3 Số điều kiện

Một số cấu trúc hiệp phương sai có thể khiến giải pháp tối ưu hóa phương sai trung bình trở nên không ổn định. Để hiểu lý do tại sao, chúng ta cần giới thiệu khái niệm về số điều kiện của ma trận hiệp phương sai. Hãy xem xét ma trận tương quan giữa hai chứng khoán,

Vết tích của C istr $C\delta$ $\rho^{1/4}$ $\Lambda_1;1$ ρ $\Lambda_2;2$ $\rho^{1/4}$ 2 , do đó ρ thiết lập độ lớn của một giá trị riêng khi lấy giá trị riêng kia. Định thức của C được $\rho^{1/4}$ $\Lambda_1;1$ $\rho^{1/4}$ $\Lambda_2;2$ $\rho^{1/4}$ đưa bởi 1 ρ $\rho^{1/4}$ 1 ρ 1 ρ^2 . Định thức đạt $\max -jCj$ imum tại $\Lambda_1;1$ $\rho^{1/4}$ $\Lambda_2;2$ $\rho^{1/4}$ 1 , tương ứng với trường hợp không tương quan, ρ $\rho^{1/4}$ 0 . Định thức đạt giá trị nhỏ nhất tại $\Lambda_1;1$ $\rho^{1/4}$ 0 hoặc $\Lambda_2;2$ $\rho^{1/4}$ 0 , tương ứng với trường hợp có tương quan hoàn hảo, $j\rho j$ $\rho^{1/4}$ 1 . Nghịch đảo của C là

$$C1 = \frac{1}{p} \sum_{j=1}^p W_{1j} W_{0j} \quad \text{với } p \rightarrow \infty$$

Điều này ngụ ý rằng p càng lệch khỏi 0 thì một giá trị riêng càng lớn so với giá trị riêng kia, khiến jC_j tiến tới 0, khiến các giá trị của $C1$ tăng đột biến.

Nói chung, sự bất ổn do cấu trúc hiệp phương sai gây ra có thể được đo lường theo độ lớn giữa hai giá trị riêng cực trị.

Theo đó, số điều kiện của ma trận hiệp phương sai hoặc tương quan (hoặc chuẩn, do đó có thể chéo hóa) được định nghĩa là giá trị tuyệt đối của tỷ lệ giữa các giá trị riêng cực đại và cực tiểu (theo moduli). Trong ví dụ trên,

$$\lim_{p \rightarrow \infty} \frac{\lambda_{1;1}}{\lambda_{p;2}} = 2$$

$$\lim_{p \rightarrow \infty} \frac{\lambda_{2;2}}{\lambda_{1;1}} = \frac{1}{2}$$

7.4 Lời nguyên của Markowitz

Ma trận C chỉ là phiên bản chuẩn hóa của V , và các kết luận chúng ta rút ra trên $C1$ áp dụng cho $V1$ được sử dụng để tính toán w . Khi các chứng khoán trong danh mục đầu tư có mối tương quan cao ($1 < \rho \leq 1$ hoặc $0 \leq \rho < 1$), C có số điều kiện cao và các giá trị của $V1$ bùng nổ. Điều này gây ra vấn đề trong bối cảnh tối ưu hóa danh mục đầu tư, vì w phụ thuộc vào $V1$ và trừ khi $\rho \approx 0$, chúng ta phải mong đợi một giải pháp không ổn định cho chương trình tối ưu hóa lỗi. Nói cách khác, giải pháp của Markowitz được đảm bảo là ổn định về mặt số chỉ khi $\rho \approx 0$, đây chính xác là trường hợp chúng ta không cần đến nó! Lý do chúng ta cần Markowitz là để xử lý trường hợp $\rho \approx 0$, nhưng chúng ta càng cần Markowitz thì ước tính w càng không ổn định về mặt số. Đây chính là lời nguyên của Markowitz.

López de Prado (2016) đã giới thiệu một phương pháp phân bổ tài sản dựa trên ML được gọi là phân bổ rủi ro phân cấp (HRP). HRP vượt trội hơn Markowitz và phân bổ ngẫu nhiên trong các thí nghiệm Monte Carlo ngoài mẫu. Mục đích của HRP không phải là cung cấp phân bổ tối ưu, mà chỉ đơn thuần là để chứng minh tiềm năng của các phương pháp ML. Trên thực tế, HRP vượt trội hơn Markowitz ngoài mẫu mặc dù HRP về mặt xây dựng là không tối ưu trong mẫu. Trong phần tiếp theo, chúng tôi phân tích thêm lý do tại sao tối ưu hóa phương sai trung bình tiêu chuẩn lại tương đối dễ bị đánh bại.

7.5 Tín hiệu như một nguồn bất ổn định hiệp phương sai

Trong [Phần 2](#), chúng ta đã thấy rằng sự bất ổn định hiệp phương sai liên quan đến nhiều được điều chỉnh bởi tỷ lệ N/T , vì giới hạn dưới của phân phối Marcenko-Pastur, λ , trở nên nhỏ hơn khi N/T tăng,²² trong khi giới hạn trên, λ_p , tăng khi N/T tăng. Trong phần này, chúng ta đang giải quyết một nguồn bất ổn định hiệp phương sai khác, do cấu trúc của dữ liệu (tín hiệu) gây ra. Như chúng ta đã thấy trong ví dụ ma trận 2×2 , p điều chỉnh số điều kiện của ma trận, bất kể và độc lập với N/T . Sự bất ổn do tín hiệu gây ra là có cấu trúc và không thể giảm bằng cách lấy mẫu nhiều quan sát hơn.

Có một lời giải thích trực quan về cách tín hiệu làm cho tối ưu hóa phương sai trung bình không ổn định. Khi ma trận tương quan là ma trận đơn vị, hàm giá trị riêng là một đường ngang và số điều kiện là 1.

Bên ngoài trường hợp lý tưởng đó, số điều kiện bị ảnh hưởng bởi các cấu trúc tương quan bất thường. Trong trường hợp tài chính cụ thể, khi một tập hợp con các chứng khoán thể hiện mối tương quan lớn hơn giữa chúng so với phần còn lại của vũ trụ đầu tư, tập hợp con đó tạo thành một cụm trong ma trận tương quan. Các cụm xuất hiện một cách tự nhiên, như một hệ quả của các mối quan hệ phân cấp. Khi K chứng khoán tạo thành một cụm, chúng tiếp xúc nhiều hơn với một vectơ riêng chung, ngụ ý rằng giá trị riêng liên quan giải thích một lượng phương sai lớn hơn. Nhưng vì dấu vết của ma trận tương quan chính xác là N , điều đó có nghĩa là một giá trị riêng chỉ có thể tăng lên khi phải trả giá bằng $K-1$ giá trị riêng khác trong cụm đó, dẫn đến số điều kiện lớn hơn 1.

Do đó, tương quan nội cụm càng lớn thì số điều kiện càng cao. Nguồn bất ổn này là riêng biệt và không liên quan đến $N=T$.


Hãy minh họa trực giác này bằng một ví dụ số. [Đoạn mã 7.1](#) cho thấy cách tạo ma trận tương quan khối-đường chéo của các số khối, kích thước khối và tương quan nội khối khác nhau. [Hình 7.1](#) vẽ đồ thị khối-đường chéo

ĐOẠN TRÍCH 7.1 THÀNH PHẦN CỦA MA TRẬN TƯƠNG QUAN KHỐI-CHÉO

```
nhập matplotlib.pyplot dưới dạng mpl, seaborn dưới dạng sns
nhập numpy dưới dạng np

#-----
corr0=formBlockMatrix(2,2,.5)
eVal,eVec=np.linalg.eigh(corr0) in
max(eVal)/min(eVal)
sns.heatmap(corr0,cmap='viridis')
```

²² Để nhắc lại, trong [Phần 2](#), biến N biểu thị số cột trong ma trận hiệp phương sai và biến T biểu thị số quan sát độc lập được sử dụng để tính toán ma trận hiệp phương sai.



Hình 7.1 Bản đồ nhiệt của ma trận tương quan khối-đường chéo.

ma trận có kích thước 4x4, bao gồm hai khối có kích thước bằng nhau, trong đó tương quan nội khối là 0,5 và tương quan ngoại khối là 0. Bởi vì khối này

cấu trúc, số điều kiện không phải là 1 mà là 3. Số điều kiện tăng nếu (1) chúng ta làm cho một khối lớn hơn hoặc (2) chúng ta tăng tương quan trong khối. Lý do là, trong cả hai trường hợp, một vectơ riêng giải thích nhiều phương sai hơn phần còn lại. Ví dụ, nếu chúng ta tăng kích thước của một khối lên ba và giảm kích thước của khối kia xuống 1, số điều kiện trở thành 4. Thay vào đó, nếu chúng ta tăng tương quan trong khối lên 0,75, số điều kiện trở thành 7. Ma trận tương quan đường chéo khối có kích thước 500x500 với hai khối có kích thước bằng nhau, trong đó tương quan trong khối là 0,5 có số điều kiện là 251, một lần nữa là kết quả của việc có 500 vectơ riêng trong đó hầu hết phương sai chỉ được giải thích bởi 2.

Đoạn mã 7.2 chứng minh rằng việc giảm tương quan nội khối chỉ trong một trong hai khối không làm giảm số điều kiện. Lý do là, các giá trị riêng cực đại là do khối chiếm ưu thế gây ra. Vì vậy, mặc dù số điều kiện cao có thể chỉ do một cụm gây ra, nhưng nó tác động đến toàn bộ ma trận tương quan. Quan sát này có một hàm ý quan trọng: sự bất ổn định của giải pháp Markowitz có thể bắt nguồn từ một số ít chiếm ưu thế

ĐOẠN TRÍCH 7.2 MA TRẬN TƯƠNG QUAN CHÉO KHỐI VỚI KHỐI CHIẾM CHỦ

```
corr0=block_diag(formBlockMatrix(1,2,.5))
corr1=formBlockMatrix(1,2,.0)
corr0=khối_diag(corr0,corr1)
eVal,eVec=np.linalg.eigh(corr0)
in max(eVal)/min(eVal)
```

các cụm trong ma trận tương quan. Chúng ta có thể hạn chế sự bất ổn đó bằng cách tối ưu hóa các cụm thống trị riêng biệt, do đó ngăn chặn sự bất ổn lan rộng trong toàn bộ danh mục đầu tư.

7.6 Thuật toán tối ưu hóa cụm lồng nhau

Phần còn lại của phần này dành riêng để giới thiệu một phương pháp mới dựa trên ML, được gọi là tối ưu hóa cụm lồng nhau (NCO), giải quyết nguồn gốc của lời nguyên Markowitz. NCO thuộc về một lớp thuật toán được gọi là "wrapper": nó không phụ thuộc vào thành viên nào của biên giới hiệu quả được tính toán hoặc tập hợp các ràng buộc nào được áp dụng. NCO cung cấp một chiến lược để giải quyết tác động của lời nguyên Markowitz đối với phương pháp phân bổ phương sai trung bình hiện có.

7.6.1 Phân cụm tương quan

Bước đầu tiên của thuật toán NCO là phân cụm ma trận tương quan. Hoạt động này liên quan đến việc tìm số lượng cụm tối ưu. Một khả năng là áp dụng thuật toán ONC (Phần 4), tuy nhiên NCO không quan tâm đến thuật toán cụ thể nào được sử dụng để xác định số lượng cụm. Đối với các ma trận lớn, trong đó $T = N$ tương đối thấp, nên khử nhiễu ma trận tương quan trước khi phân cụm, theo phương pháp được mô tả trong Phần 2. Đoạn mã 7.3 triển khai quy trình này. Chúng tôi tính toán ma trận hiệp phương sai đã khử nhiễu, `cov1`, bằng cách sử dụng hàm `deNoiseCov` được giới thiệu trong Phần 2. Để nhắc lại, đối số `q` thông báo tỷ lệ giữa số hàng và số cột trong ma trận quan sát. Khi `bwidth = 0`, ma trận hiệp phương sai không được khử nhiễu. Chúng tôi chuẩn hóa ma trận hiệp phương sai kết quả thành ma trận tương quan bằng cách sử dụng hàm `cov2corr`. Sau đó, chúng tôi nhóm ma trận tương quan đã được làm sạch bằng hàm `clusterKMeansBase` mà chúng tôi đã giới thiệu trong Phần 4. Đối số `maxNumClusters` được đặt thành một nửa số cột trong ma trận tương quan. Lý do là, các cụm mục đơn không gây ra sự gia tăng số điều kiện của ma trận, vì vậy chúng tôi

ĐOẠN TRÍCH 7.3 BƯỚC PHÂN CỤM TƯƠNG QUAN

```
nhập pandas dưới dạng pd
cols=cov0.columns

cov1=deNoiseCov(cov0,q,bwidth=.01) # khử nhiễu cov
cov1=pd.DataFrame(cov1,index=cols,columns=cols)
corr1=cov2corr(cov1)
corr1,clstrs,silh=clusterKMeansBase(corr1,
    maxNumClusters=corr0.shape[0]/2,n_init=10)
```


chỉ cần xem xét các cụm có kích thước tối thiểu là hai. Nếu chúng ta mong đợi ít cụm hơn, có thể sử dụng `maxNumClusters` thấp hơn để tăng tốc tính toán.

Một câu hỏi thường gặp là liệu chúng ta nên nhóm `corr1` hay `corr1.abs()`. Khi tất cả các tương quan đều không âm, việc nhóm `corr1` và `corr1.abs()` sẽ cho ra cùng một kết quả. Khi một số tương quan là âm, câu trả lời sẽ phức tạp hơn và phụ thuộc vào các thuộc tính số của các đầu vào quan sát được. Tôi khuyên bạn nên thử cả hai và xem nhóm nào hoạt động tốt hơn cho `corr1` cụ thể của bạn trong các thí nghiệm Monte Carlo.²³

7.6.2 Trọng số nội cụm

Bước thứ hai của thuật toán NCO là tính toán phân bổ nội cụm tối ưu, sử dụng ma trận hiệp phương sai khởi nhiễu, `cov1`. Đoạn mã 7.4 triển khai quy trình này. Vì mục đích đơn giản, chúng tôi đã mặc định phân bổ phương sai tối thiểu, như được triển khai trong hàm `minVarPort`.

Tuy nhiên, không có gì trong quy trình ngăn cản việc sử dụng các phương pháp phân bổ thay thế. Sử dụng các trọng số nội cụm ước tính, chúng ta có thể suy ra ma trận hiệp phương sai giảm, `cov2`, báo cáo các mối tương quan giữa các cụm.

ĐOẠN TRÍCH 7.4 PHÂN BỐ TỐI ƯU TRONG CỤM

```
wIntra=pd.DataFrame(0,index=cov1.index,columns=clstrs.keys())
đối với i trong các nhóm:
    wIntra.loc[clstrs[i],i]=minVarPort(cov1.loc[clstrs[i],
        clstrs[i]]).làm phẳng()
cov2=wIntra.T.dot(np.dot(cov1,wIntra)) # ma trận hiệp phương sai giảm
```

7.6.3 Trọng số liên cụm

Bước thứ ba của thuật toán NCO là tính toán các phân bổ liên cụm tối ưu, sử dụng ma trận hiệp phương sai giảm, `cov2`. Theo cấu trúc, ma trận hiệp phương sai này gần với ma trận đường chéo và bài toán tối ưu hóa gần với trường hợp Markowitz lý tưởng. Nói cách khác, các bước tối ưu hóa cụm và nội cụm đã cho phép chúng ta biến đổi một bài toán “bị Markowitz nguyên rủa” (`jpj 0`) thành một bài toán có hành vi tốt ($\rho \approx 0$).

²³ Theo nguyên tắc chung, `corr1.abs()` có xu hướng hoạt động tốt hơn trong các bài toán tối ưu hóa danh mục đầu tư dài-ngắn khi một số tương quan là âm. Theo trực giác, khả năng có trọng số âm tương đương với việc đảo ngược dấu của tương quan, điều này có thể gây ra sự bất ổn đáng kể. Vì các biến có tương quan âm sẽ tương tác thông qua trọng số nên việc nhóm các biến đó lại với nhau là hợp lý, do đó chứa đựng nguồn bất ổn trong mỗi nhóm.

Code Snippet 7.5 triển khai quy trình này. Nó áp dụng cùng quy trình phân bổ đã được sử dụng trong bước phân bổ nội cụm (tức là, trong trường hợp **Code Snippet 7.4**, hàm `minVarPort`). Phân bổ cuối cùng cho mỗi bảo mật được báo cáo bởi khung dữ liệu `wAll0`, kết quả từ việc nhân trọng số nội cụm với trọng số liên cụm.

Snippet 7.5 PHÂN BỐ TỐI ƯU GIỮA CÁC CỤM

```
wInter=pd.Series(minVarPort(cov2).flatten(),index=cov2.index)
wAll0=wIntra.mul(wInter,axis=1).sum(axis=1).sort_index()
```

7.7 Kết quả thực nghiệm

Trong phần này, chúng tôi đưa thuật toán NCO vào các thí nghiệm được kiểm soát và so sánh hiệu suất của nó với phương pháp của Markowitz. Giống như trong **Phần 2**, chúng tôi thảo luận về hai danh mục đầu tư đặc trưng của biên giới hiệu quả, cụ thể là các giải pháp phương sai tối thiểu và tỷ lệ Sharpe tối đa, vì bất kỳ thành viên nào của biên giới hiệu quả không bị ràng buộc đều có thể được suy ra như một tổ hợp lồi của

hai (một kết quả đôi khi được gọi là “định lý tách biệt”).

Đoạn mã 7.6 triển khai thuật toán NCO đã giới thiệu trước đó trong phần này. Khi đối số `mu` là `None`, hàm `optPort_nco` trả về danh mục phương sai tối thiểu, trong khi khi `mu` không phải là `None`, hàm `optPort_nco` trả về danh mục tỷ lệ Sharpe tối đa.

Snippet 7.6 CHỨC NĂNG TRIỂN KHAI THUẬT TOÁN NCO

```
def optPort_nco(cov,mu=None,maxNumClusters=None):
    cov=pd.DataFrame(cov)
    nếu mu không phải là None:mu=pd.Series(mu[:,0])
    corr1=cov2corr(cov)

    corr1,clstrs,_=clusterKMeansBase(corr1,maxNumClusters,
        n_init=10)
    wIntra=pd.DataFrame(0,index=cov.index,columns=clstrs.keys())
    đối với i trong các nhóm:
        cov_=cov.loc[clstrs[i],clstrs[i]].values nếu mu là
        None:mu_=None
        else:mu_=mu.loc[clstrs[i]].values.reshape(-1,1)
        wIntra.loc[clstrs[i],i]=optPort(cov_,mu_).flatten()
    cov_=wIntra.T.dot(np.dot(cov,wIntra)) # giảm ma trận hiệp phương sai mu_=(Không có nếu mu
    là Không có khác wIntra.T.dot(mu))
    wInter=pd.Series(optPort(cov_,mu_).flatten(),index=cov_.index)
    nco=wIntra.mul(wInter,axis=1).sum(axis=1).values.reshape(-1,1)
    trả lại nco
```

7.7.1 Danh mục đầu tư có phương sai tối thiểu

Đoạn mã 7.7 tạo ra một vectơ ngẫu nhiên của các giá trị trung bình và một ma trận hiệp phương sai ngẫu nhiên biểu diễn phiên bản cách điệu của danh mục năm mươi chứng khoán, được nhóm thành mười khối với các tương quan nội cụm là 0,5. Vectơ và ma trận này đặc trưng

acterize quá trình “thực” tạo ra các quan sát.²⁴ Chúng tôi đặt một hạt giống cho mục đích tái tạo và so sánh kết quả giữa các lần chạy với các tham số khác nhau. Hàm `formTrueMatrix` đã được khai báo trong Phần 2.

Snippet 7.7 Quy trình tạo dữ liệu

```
nBlock, bKích thước, bCorr = 10, 50, .5
np.random.seed(0)
mu0, cov0 = formTrueMatrix(nBlock, bKích thước, bCorr)
```

Đoạn mã 7.8 sử dụng hàm `simCovMu` để mô phỏng một vectơ kinh nghiệm ngẫu nhiên của các giá trị trung bình và một ma trận hiệp phương sai kinh nghiệm ngẫu nhiên dựa trên 1.000 quan sát được rút ra từ quy trình thực (được khai báo trong Phần 2). Khi `shrink=True`, ma trận hiệp phương sai kinh nghiệm chịu sự co lại của Ledoit-Wolf. Sử dụng ma trận hiệp phương sai kinh nghiệm đó, hàm `optPort` (cũng được khai báo trong Phần 2) ước tính danh mục phương sai tối thiểu theo Markowitz và hàm `optPort_nco` ước tính danh mục phương sai tối thiểu bằng cách áp dụng thuật toán NCO. Quy trình này được lặp lại trên 1.000 ma trận hiệp phương sai kinh nghiệm ngẫu nhiên khác nhau. Lưu ý rằng, vì `minVarPortf=True`, các vectơ kinh nghiệm ngẫu nhiên của các giá trị trung bình bị loại bỏ.

ĐOẠN TRÍCH 7.8 VỀ MA TRẬN VECTOR TRUNG BÌNH VÀ PHƯƠNG PHÁP KINH NGHIỆM

```
nObs, nSims, thu nhỏ, minVarPortf = 1000, 1000, Sai, Đúng
np.random.seed(0) cho i
trong phạm vi(nSims):
    mu1, cov1 = simCovMu(mu0, cov0, nObs, shrink=thu nhỏ)
    nếu minVarPortf: mu1=None

    w1.loc[i] = optPort(cov1, mu1).flatten()
    w1_d.loc[i] = optPort_nco(cov1, mu1, int(cov1.shape[0]/
        2)).flatten()
```

²⁴

Trong các ứng dụng thực tế, chúng ta không cần phải mô phỏng μ ; Vgf, vì các đầu vào này được ước tính từ dữ liệu quan sát. Người đọc có thể lặp lại thí nghiệm này trên một cặp μ ; Vgf quan sát được và đánh giá thông qua Monte Carlo lỗi ước tính của các phương pháp tối ưu hóa thay thế trên các đầu vào cụ thể đó, do đó tìm ra phương pháp nào mang lại ước tính mạnh mẽ nhất cho một đầu vào cụ thể.

Code Snippet 7.9 tính toán danh mục phương sai tối thiểu thực, được lấy từ ma trận hiệp phương sai thực. Sử dụng các phân bố đó làm chuẩn, sau đó tính toán các lỗi bình phương trung bình (RMSE) trên tất cả các trọng số. Chúng ta có thể chạy **Code Snippet 7.9** có và không có sự co lại, do đó thu được bốn kết hợp được hiển thị trong **Hình 7.2**.

ĐOẠN TRÍCH 7.9 ƯỚC TÍNH LỖI PHÂN BỐ

```
w0=optPort(cov0,None nếu minVarPortf else mu0)
w0=np.repeat(w0.T,w1.shape[0],axis=0) # phân bố đúng rmsd=np.mean((w1-
w0).values.flatten())**2)**.5 # RMSE rmsd_d=np.mean((w1_d-
w0).values.flatten())**2)**.5 # RMSE
```

	Markowitz	Hệ số quan
Thô	7.95E-03	4.21E-03
Thu nhỏ	8.89E-03	6.74E-03

Hình 7.2 RMSE cho danh mục đầu tư có phương sai tối thiểu.

NCO tính toán danh mục phương sai tối thiểu với 52,98% RMSE của Markowitz, tức là giảm 47,02% trong RMSE. Trong khi sự co lại của Ledoit-Wolf giúp giảm RMSE, thì mức giảm đó tương đối nhỏ, khoảng 11,81%. Kết hợp độ co góc và NCO mang lại mức giảm RMSE là 15,30%, tốt hơn độ co góc nhưng kém hơn so với chỉ dùng NCO.

Điều này ngụ ý rằng NCO cung cấp RMSE thấp hơn đáng kể so với giải pháp của Markowitz, ngay cả đối với danh mục đầu tư nhỏ chỉ có năm mươi chứng khoán và sự co lại không mang lại giá trị nào. Có thể dễ dàng kiểm tra rằng lợi thế của NCO mở rộng đối với danh mục đầu tư lớn hơn (chúng tôi để nó như một bài tập).

7.7.2 Danh mục đầu tư tỷ lệ Sharpe tối đa

Bằng cách đặt minVarPortf=False, chúng ta có thể chạy lại **Code Snippets 7.8** và **7.9** để lấy RMSE liên quan đến danh mục đầu tư tỷ lệ Sharpe tối đa. **Hình 7.3** báo cáo kết quả từ thử nghiệm này.

NCO tính toán danh mục tỷ lệ Sharpe tối đa với 45,17% RMSE của Markowitz, tức là giảm 54,83% trong RMSE. Sự kết hợp của sự co lại và NCO tạo ra sự giảm 18,52% trong RMSE của danh mục tỷ lệ Sharpe tối đa, tốt hơn sự co lại nhưng tệ hơn NCO. Một lần nữa, NCO cung cấp RMSE thấp hơn đáng kể so với giải pháp của Markowitz và sự co lại không mang lại giá trị nào.

	Markowitz	Hệ số quan
Thô	7.02E-02	3.17E-02
Thu nhỏ	6.54E-02	5.72E-02

Hình 7.3 RMSE cho danh mục đầu tư có tỷ lệ Sharpe tối đa.

7.8 Kết luận

Khung tối ưu hóa danh mục đầu tư của Markowitz về mặt toán học là chính xác, tuy nhiên ứng dụng thực tế của nó lại gặp phải các vấn đề về số. Đặc biệt, ma trận hiệp phương sai tài chính thể hiện số điều kiện cao do nhiễu và tín hiệu. Nghịch đảo của các ma trận hiệp phương sai đó phóng đại các lỗi ước tính, dẫn đến các giải pháp không ổn định: thay đổi một vài hàng trong các quan sát ma trận có thể tạo ra các phân bổ hoàn toàn khác nhau. Ngay cả khi các phân bổ ước lượng không thiên vị, phương sai liên quan đến các giải pháp không ổn định này chắc chắn sẽ dẫn đến chi phí giao dịch lớn có thể xóa bỏ phần lớn lợi nhuận của các chiến lược này.

Trong phần này, chúng tôi đã lần ngược lại nguồn gốc của sự bất ổn của Markowitz các vấn đề về hình dạng của hàm giá trị riêng của ma trận tương quan. Các hàm giá trị riêng theo chiều ngang là lý tưởng cho khuôn khổ của Markowitz. Trong tài chính, nơi các nhóm chứng khoán thể hiện mối tương quan lớn hơn giữa chúng so với phần còn lại của vũ trụ đầu tư, các hàm giá trị riêng không ngang, mà đến lượt nó lại là nguyên nhân gây ra số lượng tình trạng cao. Tín hiệu là nguyên nhân của loại bất ổn hiệp phương sai này, không phải là nhiễu.

Chúng tôi đã giới thiệu thuật toán NCO để giải quyết nguồn bất ổn này, bằng cách chia nhỏ bài toán tối ưu hóa thành nhiều bài toán: tính toán một tối ưu hóa cho mỗi cụm và tính toán một tối ưu hóa cuối cùng trên tất cả các cụm. Bởi vì mỗi bảo mật thuộc về một cụm và chỉ một cụm, nên tối ưu hóa cuối cùng phân bổ là tích của trọng số nội cụm và liên cụm. Kết quả thử nghiệm chứng minh rằng phương pháp phân cụm kép này có thể làm giảm đáng kể lỗi ước tính của Markowitz. Thuật toán NCO linh hoạt và có thể được sử dụng kết hợp với bất kỳ khuôn khổ nào khác, chẳng hạn như Black-Litterman, co rút, tối ưu hóa đảo ngược hoặc tối ưu hóa bị ràng buộc cách tiếp cận. Chúng ta có thể nghĩ về NCO như một chiến lược để chia tách chung vấn đề tối ưu hóa thành các vấn đề con, sau đó có thể được giải quyết bằng cách sử dụng phương pháp được nhà nghiên cứu ưa thích.

Giống như nhiều thuật toán ML khác, NCO linh hoạt và có tính mô-đun. Ví dụ, khi ma trận tương quan thể hiện một cấu trúc phân cấp mạnh mẽ, với

cụm trong cụm, chúng ta có thể áp dụng thuật toán NCO trong mỗi cụm và cụm con, mô phỏng cấu trúc giống cây của ma trận. Mục tiêu là hạn chế sự bất ổn về số ở mỗi cấp độ của cây, sao cho sự bất ổn trong cụm con không mở rộng đến cụm cha hoặc phần còn lại của ma trận tương quan.

Chúng ta có thể làm theo phương pháp Monte Carlo được nêu trong phần này để ước tính lỗi phân bổ do nhiều phương pháp tối ưu hóa khác nhau tạo ra trên một tập hợp các biến đầu vào cụ thể. Kết quả là xác định chính xác phương pháp nào là mạnh mẽ nhất đối với một trường hợp cụ thể. Do đó, thay vì luôn dựa vào một phương pháp cụ thể, chúng ta có thể áp dụng một cách có cơ hội bất kỳ phương pháp tối ưu hóa nào phù hợp nhất trong một bối cảnh cụ thể.

7.9 Bài tập

- 1 Thêm vào [Đoạn mã 7.3](#) một bước nổi và lặp lại phân tích thử nghiệm được thực hiện trong [Phần 7.7](#). Bạn có thấy hiệu suất của NCO được cải thiện thêm không? Tại sao?
- 2 Lặp lại [Mục 7.7](#), lần này bạn tạo ma trận hiệp phương sai mà không có cấu trúc cụm, sử dụng hàm `getRndCov` được liệt kê trong [Mục 2](#). Bạn có đi đến kết luận khác về mặt định tính không? Tại sao?
- 3 Lặp lại [Phần 7.7](#), trong đó lần này bạn thay thế hàm `minVarPort` bằng lớp CLA được liệt kê trong [Bailey và López de Prado \(2013\)](#).
- 4 Lặp lại [Mục 7.7](#) cho ma trận hiệp phương sai có kích thước mười và cho ma trận hiệp phương sai có kích thước một trăm. Kết quả của NCO so sánh với kết quả của Markowitz như thế nào khi xét đến kích thước của bài toán?
- 5 Lặp lại [Mục 7.7](#), trong đó bạn cố tình đánh lừa thuật toán `clusterKMeansBase` bằng cách đặt đối số `maxNumClusters` của nó thành một giá trị rất nhỏ, như 2. Giải pháp của NCO tệ hơn bao nhiêu? Làm sao có thể, ngay cả với chỉ hai cụm (thay vì mười), NCO vẫn hoạt động tốt hơn đáng kể so với giải pháp của Markowitz?

8 Kiểm tra tập hợp quá mức

8.1 Động lực

Trong suốt Element này, chúng tôi đã nghiên cứu các tính chất của các giải pháp ML thông qua các thí nghiệm Monte Carlo. Mô phỏng Monte Carlo đóng vai trò tương tự trong toán học với một thí nghiệm được kiểm soát trong khoa học vật lý. Chúng cho phép chúng ta đưa ra kết luận liên quan đến các tính chất toán học của nhiều ước lượng và quy trình khác nhau trong các điều kiện được kiểm soát. Có khả năng kiểm soát các điều kiện của một thí nghiệm là điều cần thiết để có thể đưa ra các tuyên bố suy luận nhân quả.

Backtest là mô phỏng lịch sử về cách một chiến lược đầu tư sẽ hoạt động trong quá khứ. Đây không phải là một thí nghiệm được kiểm soát, vì chúng ta không thể thay đổi các biến môi trường để có được một chuỗi thời gian lịch sử mới để thực hiện một backtest độc lập. Do đó, backtest không thể giúp chúng ta có được các cơ chế nhân quả chính xác giúp một chiến lược thành công.

Sự bất lực chung này trong việc tiến hành các thí nghiệm có kiểm soát đối với các chiến lược đầu tư không chỉ là một sự bất tiện về mặt kỹ thuật. Trong bối cảnh phát triển chiến lược, tất cả những gì chúng ta có là một vài chuỗi thời gian lịch sử (tương đối ngắn, có tương quan nối tiếp, đa cộng tuyến và có thể không dừng). Một nhà nghiên cứu có thể dễ dàng điều chỉnh quá mức một phép kiểm tra ngược bằng cách tiến hành nhiều mô phỏng lịch sử và chọn chiến lược có hiệu suất tốt nhất (Bailey và cộng sự, 2014). Khi một nhà nghiên cứu trình bày một phép kiểm tra ngược quá mức như là kết quả của một thử nghiệm duy nhất, hiệu suất mô phỏng sẽ bị thổi phồng. Dạng lạm phát thống kê này được gọi là sai lệch lựa chọn trong nhiều thử nghiệm (SBuMT). SBuMT dẫn đến các khám phá sai: các chiến lược có thể lặp lại trong các phép kiểm tra ngược, nhưng lại thất bại khi triển khai.

Tệ hơn nữa, SBuMT được kết hợp ở nhiều nhà quản lý tài sản, như là hậu quả của SBuMT tuân thủ ở hai cấp độ: (1) mỗi nhà nghiên cứu chạy hàng triệu mô phỏng và trình bày những mô phỏng tốt nhất (quá phù hợp) cho sếp của mình; (2) công ty tiếp tục chọn một vài backtest trong số các backtest (đã quá phù hợp) do các nhà nghiên cứu gửi. Chúng ta có thể gọi đây là siêu phù hợp backtest, để phân biệt với quá phù hợp backtest (xảy ra ở cấp độ nhà nghiên cứu).

Có thể mất nhiều thập kỷ để thu thập thông tin trong tương lai (ngoài mẫu) cần thiết để vạch trần một khám phá sai lầm xuất phát từ SBuMT. Trong phần này, chúng tôi nghiên cứu cách các nhà nghiên cứu có thể ước tính tác động của SBuMT lên các phát hiện của họ.

8.2 Độ chính xác và khả năng thu hồi

Hãy xem xét các chiến lược đầu tư. Một số chiến lược này là những khám phá sai lầm, theo nghĩa là lợi nhuận kỳ vọng của chúng không phải là dương. Chúng ta có thể phân tích các chiến lược này thành đúng (sT) và sai (sF), trong đó s $\frac{1}{4}$ sT p sF . Giả sử θ là tỷ lệ cược

tỷ lệ giữa các chiến lược đúng so với các chiến lược sai, $\theta \approx sT = sF$. Trong một lĩnh vực như tài chính kinh tế, nơi mà tỷ lệ tín hiệu trên nhiễu thấp, các chiến lược sai lầm tràn lan, do đó θ dự kiến sẽ thấp. Số lượng các chiến lược đầu tư thực sự là

$$sT \approx s \frac{sT}{sT + sF} \approx \frac{1}{2} \text{ giấy } \frac{\frac{sT}{sF}}{\frac{sT}{sF} + 1} \approx \frac{1}{2} \frac{s}{1 + \theta}.$$

Tương tự như vậy, số lượng các chiến lược đầu tư sai lầm là

$$sF \approx \frac{1}{2} \text{ giấy } sT \approx \frac{1}{2} \text{ giấy } 1 \frac{s}{1 + \theta} \approx \frac{1}{2} \text{ giấy } \frac{1}{1 + \theta}.$$

Với tỷ lệ dương tính giả α (lỗi loại I), chúng ta sẽ thu được một số kết quả sai dương tính, $FP \approx \alpha F$, và một số âm tính thực, $TN \approx 1 - \alpha F$. Chúng ta hãy biểu thị là β tỷ lệ âm tính giả (lỗi loại II) liên quan đến α đó. Chúng tôi sẽ thu được một số kết quả âm tính giả, $FN \approx \beta T$ và một số kết quả dương tính thật, $TP \approx 1 - \beta T$. Độ chính xác và khả năng thu hồi của bài kiểm tra của chúng tôi là

$$\begin{aligned} \text{độ chính xác} &\approx \frac{TP}{TP + FP} \approx \frac{1 - \beta}{1 - \beta + \alpha} \\ &\approx \frac{1 - \beta}{1 - \beta + \alpha} \frac{s}{1 + \theta} \approx \frac{1 - \beta}{1 + \theta} \frac{s}{1 + \theta} \\ \text{nhớ lại} &\approx \frac{TP}{TP + FN} \approx \frac{1 - \beta}{1 - \beta + \beta} \approx 1 - \beta \end{aligned}$$

Trước khi chạy thử nghiệm ngược trên một chiến lược, các nhà nghiên cứu nên thu thập bằng chứng rằng một chiến lược thực sự có thể tồn tại. Lý do là, độ chính xác của bài kiểm tra là một hàm của tỷ lệ cược, θ . Nếu tỷ lệ cược thấp, độ chính xác sẽ thấp, ngay cả khi chúng ta nhận được kết quả dương tính với độ tin cậy cao (giá trị p thấp).²⁵ Đặc biệt, chiến lược có nhiều khả năng sai hơn là đúng nếu $1 - \beta > \alpha$.

Ví dụ, giả sử rằng xác suất của một chiến lược được kiểm tra ngược là có lợi nhuận là 0,01, nghĩa là một trong một trăm chiến lược là đúng, do đó $\theta \approx 1/99$. Sau đó, ở ngưỡng chuẩn của $\alpha \approx 0:05$ và $\beta \approx 0:2$, các nhà nghiên cứu dự kiến sẽ có khoảng năm mươi tám kết quả dương tính trong một nghìn lần thử nghiệm, trong đó có khoảng tám là kết quả dương tính thật và khoảng năm mươi là kết quả dương tính giả tích cực. Trong những trường hợp này, giá trị p là 0,05 ngụ ý tỷ lệ phát hiện sai là 86,09% (khoảng 50/58). Chỉ vì lý do này, chúng ta nên mong đợi rằng hầu hết các khám phá trong kinh tế lượng tài chính có thể là sai.

²⁵ Lập luận này dẫn đến cùng một kết luận mà chúng ta đã đạt được trong Phần 6: giá trị p báo cáo một xác suất không cung cấp thông tin. Có thể một bài kiểm tra thống kê có độ tin cậy cao (giá trị p thấp) và độ chính xác thấp.

8.3 Độ chính xác và khả năng thu hồi trong thử nghiệm nhiều lần

Sau một lần thử, xác suất mắc lỗi loại I là α . Giả sử rằng chúng ta lặp lại lần thử hai một thử nghiệm với xác suất dương tính giả α . Tại mỗi lần thử nghiệm, xác suất không mắc lỗi loại I là $1 - \alpha$. Nếu hai lần thử nghiệm là độc lập, xác suất không mắc lỗi loại I ở lần thử nhất và lần thử hai kiểm tra là $(1 - \alpha)^2$. Xác suất mắc ít nhất một lỗi loại I là bổ sung, $1 - (1 - \alpha)^2$. Nếu chúng ta tiến hành K thử nghiệm độc lập, xác suất chung-năng không mắc một lỗi loại I nào là $(1 - \alpha)^K$. Do đó, xác suất của một lỗi loại I là bổ sung, $1 - (1 - \alpha)^K$ còn được gọi là tỷ lệ lỗi theo nhóm (FWER).

Sau một lần thử, xác suất mắc lỗi loại II là β . Sau K các thử nghiệm độc lập, xác suất mắc lỗi loại II trong tất cả các thử nghiệm đó là β^K . Lưu ý sự khác biệt với FWER. Trong trường hợp dương tính giả, chúng ta là quan tâm đến khả năng mắc ít nhất một lỗi. Điều này là do một lỗi duy nhất báo động giả là một thất bại. Tuy nhiên, trong trường hợp âm tính giả, chúng tôi quan tâm đến xác suất mà tất cả các giá trị dương đều bị bỏ sót. Khi K tăng, α^K tăng và β^K co lại.

Độ chính xác và khả năng thu hồi được điều chỉnh cho nhiều lần thử nghiệm là

$$\text{độ chính xác} = \frac{1 - \beta^K}{1 - \beta^K} \quad \text{và} \quad \frac{1 - \beta^K}{1 - \beta^K} = \frac{1 - \beta^K}{1 - \beta^K}$$

nhớ lại $1 - \beta^K = 1 - \beta^K$:

8.4 Tỷ lệ Sharpe

Các nhà phân tích tài chính thường không đánh giá hiệu suất của một chiến lược theo các điều khoản của độ chính xác và khả năng thu hồi. Biện pháp phổ biến nhất của hiệu suất chiến lược là tỷ lệ Sharpe. Trong phần sau, chúng tôi sẽ phát triển một khuôn khổ để đánh giá xác suất một chiến lược là sai. Các đầu vào là ước tính tỷ lệ Sharpe, như cũng như siêu dữ liệu được thu thập trong quá trình khám phá.²⁶

Hãy xem xét một chiến lược đầu tư với lợi nhuận vượt trội (hoặc phí bảo hiểm rủi ro) r_{tgf} , $t = 1; \dots; T$, là độc lập và phân phối giống hệt nhau (IID) Chuẩn,

$$r_t \sim N(\mu; \sigma^2)$$

²⁶ Có lẽ các nhà phân tích nên sử dụng độ chính xác và độ thu hồi thay vì tỷ lệ Sharpe, nhưng điều đó vượt quá khả năng. điểm. Các nhà toán học tài chính hiếm khi có đủ khả năng để định hình các vấn đề mà họ đang giải quyết, không giống như các nhà topology, nhà lý thuyết tập hợp, nhà hình học đại số, v.v.

trong đó $N^{1/2}\mu$; σ^2 biểu thị phân phối chuẩn với trung bình μ và phương sai σ^2 . Theo [Sharpe \(1966, 1975, 1994\)](#), Tỷ lệ Sharpe (không tính theo năm) của chiến lược được định nghĩa là

$$SR = \frac{\mu}{\sigma}$$

Vì các tham số μ và σ không được biết, SR được ước tính là

$$SRC = \frac{E^{1/2} \text{rtgf}}{V^{1/2} \text{rtgf } p}$$

Theo giả định rằng lợi nhuận là IID bình thường, [Lo \(2002\)](#) đã đưa ra phân phối tiệm cận của SR như

$$SRC \sim SR \sim \text{Số } 0; \frac{1 - \frac{1}{2} SR^2}{\frac{1}{2}} \quad \#:$$

Tuy nhiên, bằng chứng thực nghiệm cho thấy lợi nhuận của quỹ đầu cơ thể hiện độ lệch âm đáng kể và độ nhọn dư thừa dương (trong số những yếu tố khác, hãy xem [Brooks và Kat 2002](#); [Ingersoll et al. 2007](#)). Giả định sai lầm rằng lợi nhuận là IID Bình thường có thể dẫn đến việc đánh giá thấp đáng kể xác suất dương tính giả.

Theo giả định rằng lợi nhuận được rút ra từ phân phối không chuẩn của IID tions, [Mertens \(2002\)](#) đã đưa ra phân phối tiệm cận của SR như

$$SRC \sim SR \sim \text{Số } 0; \frac{1 - \frac{1}{2} SR^2 - \gamma_3 SR^3 - \frac{\gamma_4}{4} SR^4}{\frac{1}{2}} \quad \#;$$

trong đó γ_3 là độ lệch của rtgf và γ_4 là độ nhọn của rtgf ($\gamma_3 \neq 0$ và $\gamma_4 \neq 3$ khi lợi nhuận tuân theo phân phối chuẩn). Ngay sau đó, [Christie \(2005\)](#) và [Opdyke \(2007\)](#) đã phát hiện ra rằng, trên thực tế, phương trình của Mertens cũng có giá trị theo giả định chung hơn rằng lợi nhuận là dừng và ergodic (không nhất thiết là IID). Ý nghĩa chính là SR^2 vẫn tuân theo một Chuẩn phân phối ngay cả khi lợi nhuận không bình thường, tuy nhiên với phương sai một phần phụ thuộc vào độ lệch và độ nhọn của lợi nhuận.

8.5 Định lý “Chiến lược sai”

Một nhà nghiên cứu có thể thực hiện một số lượng lớn các mô phỏng lịch sử (thử nghiệm) và chỉ báo cáo kết quả tốt nhất (tỷ lệ Sharpe tối đa). Sự phân bố của tỷ lệ Sharpe tối đa không giống với sự phân bố của tỷ lệ Sharpe được chọn ngẫu nhiên trong số các lần thử nghiệm, do đó dẫn đến đến SBuMT. Khi có nhiều hơn một lần thử nghiệm diễn ra, giá trị mong đợi của

Tỷ lệ Sharpe tối đa lớn hơn giá trị kỳ vọng của tỷ lệ Sharpe từ một thử nghiệm ngẫu nhiên. Đặc biệt, với một chiến lược đầu tư có tỷ lệ Sharpe kỳ vọng bằng không và phương sai không null, giá trị kỳ vọng của tỷ lệ Sharpe tối đa là dương nghiêm ngặt và là hàm của số lần thử nghiệm.

Với những điều trên, độ lớn của SBuMT có thể được biểu thị theo sự khác biệt giữa tỷ lệ Sharpe tối đa mong đợi và tỷ lệ Sharpe mong đợi từ một thử nghiệm ngẫu nhiên (bằng không, trong trường hợp chiến lược sai). Thực tế là, SBuMT là một hàm của hai biến: số lần thử nghiệm và phương sai của tỷ lệ Sharpe trong các lần thử nghiệm. Định lý sau đây nêu chính thức mối quan hệ đó. Có thể tìm thấy bằng chứng trong Phụ lục B.

Định lý: Cho một mẫu thống kê hiệu suất ước tính fSR_{ckg} , $k \geq 1$; ...

; K , được rút ra từ các Gaussian độc lập và phân phối giống hệt nhau,

$SR_{ck} \in N^{1/2}0$; $V^{1/2}SR_{ck}$, sau đó

$$E \text{ tối đa } k \text{ } fSR_{ckg} \text{ iV } h \text{ } fSR_{ckg} \text{ i1 } 2 \text{ } \frac{1}{\sigma^2} \text{ } 1 \text{ } \gamma \text{ } Z1 \text{ } 1 \approx \frac{1}{K} \text{ } \text{ } \gamma Z1 \text{ } 1 \text{ } \frac{1}{\sigma^2} \text{ } \text{ } ;$$

trong đó $Z1^{1/2}$: là nghịch đảo của CDF Gaussian chuẩn, $E^{1/2}$: là giá trị kỳ vọng, $V^{1/2}$: là phương sai, e là số Euler và γ là Euler-Mascheroni

không thay đổi.

8.6 Kết quả thực nghiệm

Định lý False Strategy cung cấp cho chúng ta một phép xấp xỉ tỷ lệ Sharpe tối đa mong đợi. Một phân tích thực nghiệm về định lý này có thể hữu ích ở hai cấp độ. Đầu tiên, nó có thể giúp chúng ta tìm ra bằng chứng cho thấy định lý không đúng và trên thực tế, bằng chứng có sai sót. Tất nhiên, điều ngược lại cũng không đúng: bằng chứng thực nghiệm không bao giờ có thể thay thế vai trò của một bằng chứng toán học. Tuy nhiên, bằng chứng thực nghiệm có thể chỉ ra các vấn đề với bằng chứng và giúp chúng ta hiểu rõ hơn về việc bằng chứng nên trông như thế nào. Thứ hai, định lý không cung cấp ranh giới cho phép xấp xỉ. Một phân tích thực nghiệm có thể giúp chúng ta ước tính phân phối của lỗi xấp xỉ.

Thí nghiệm Monte Carlo sau đây đánh giá độ chính xác của định lý False Strategy. Đầu tiên, với một cặp giá trị σK ; $V^{1/2}fSR_{ckg}$, chúng ta tạo ra một mảng ngẫu nhiên có kích thước $\sigma^2 \times K$. Các giá trị, trong đó S là số thí nghiệm Monte Carlo. giá trị chứa trong mảng ngẫu nhiên này được rút ra từ một phân phối chuẩn chuẩn. Thứ hai, các hàng trong mảng này được căn giữa và chia tỷ lệ để khớp với giá trị trung bình bằng không và phương sai $V^{1/2}fSR_{ckg}$. Thứ ba, giá trị lớn nhất trên mỗi hàng là

được tính toán, $\max_k fSR_{ckg}$, dẫn đến một số S của các giá trị cực đại như vậy. Thứ tư, chúng tôi tính toán giá trị trung bình trên S giá trị cực đại, $E^{1/2} \max_k fSR_{ckg}$. Thứ năm, ước tính kinh nghiệm (Monte Carlo) này về SR cực đại mong đợi sau đó có thể được so sánh với giải pháp phân tích do định lý Chiến lược Sai cung cấp, $E^{1/2} \max_k fSR_{ckg}$. Thứ sáu, lỗi ước tính được định nghĩa theo các điều khoản tương đối với giá trị dự đoán, như

$$\epsilon = \frac{E^{1/2} \text{ tối đa } k fSR_{ckg}}{E^{1/2} \max_k fSR_{ckg}} \quad 1:$$

Thứ bảy, chúng tôi lặp lại các bước trước R lần, dẫn đến lỗi ước tính $\epsilon_{\text{gr}1/41; \dots; R}$, cho phép chúng tôi tính toán giá trị trung bình và độ lệch chuẩn của lỗi ước tính liên quan đến K lần thử. [Đoạn mã 8.1](#) triển khai thử nghiệm Monte Carlo này trong python.

```

ĐOẠN TRÍCH 8.1 KIỂM TRA THỰC NGHIỆM ĐỊNH LÝ CHIẾN LƯỢC SAI

nhập numpy dưới dạng np, pandas dưới dạng pd
từ scipy.stats nhập norm,percentileofscore
#- - - - -

def getExpectedMaxSR(nTrials,meanSR,stdSR):
    # SR tối đa dự kiến, kiểm soát SBUt
    emc=0.577215664901532860606512090082402431042159336

    sr0=(1-emc)*norm.ppf(1-1./nThử nghiệm)+ /
        emc*norm.ppf(1-(nThử nghiệm*np.e)**-1)
    sr0=trung bìnhSR+stdSR*sr0
    trả về sr0
#- - - - -

def getDistMaxSR(nSims,nTrials,stdSR,meanSR):
    # Monte Carlo của max{SR} trên nTrials, từ mô phỏng nSims rng=np.random.RandomState()
    out=pd.DataFrame() cho nTrials_ trong
    nTrials:

    #1) Tỷ lệ Sharpe mô phỏng
    sr=pd.DataFrame(rng.randn(nSims,nTrials_))
    sr=sr.sub(sr.mean(trục=1),trục=0) # tâm
    sr=sr.div(sr.std(trục=1),trục=0) # tỷ lệ
    sr=trung bìnhSR+sr*stdSR

    #2) Lưu trữ đầu ra
    out=sr.max(axis=1).to_frame('max{SR}') out_['nTrials']=nTrials_
    out=out.append(out_,ignore_index=True)


    trở về
#- - - - -

```

```

nếu __name__=='__main__':
    nTrials=list(set(np.logspace(1,6,1000).astype(int)));nTrials.sort()
    sr0=pd.Series({i:getExpectedMaxSR(i,meanSR=0,stdSR=1) \
        đối với i trong nTrials})
    sr1=getDistMaxSR(nSims=1E3,nThử nghiệm=nThử nghiệm,Trung bìnhSR=0,
        stdSR=1)

```



Hình 8.1 So sánh kết quả thực nghiệm và lý thuyết từ định lý Chiến lược sai.

Hình 8.1 giúp chúng ta hình dung kết quả từ thí nghiệm này, cho nhiều lần thử nghiệm (trong sơ đồ, từ 2 đến 1 triệu). Đối với $V^{1/2}fSR_{ckg} \approx 1$ và bất kỳ số lần thử nghiệm K nào, chúng tôi mô phỏng tỷ lệ Sharpe tối đa 10.000 lần, để chúng tôi có thể suy ra phân phối của tỷ lệ Sharpe tối đa. Trục y cho thấy phân phối của tỷ lệ Sharpe tối đa ($\max\{fSR_{ckg}\}$) cho mỗi số lần thử nghiệm K (trục x), khi tỷ lệ Sharpe thực bằng 0. Kết quả có xác suất cao hơn sẽ nhận được màu sáng hơn. Ví dụ, nếu chúng tôi tiến hành 1.000 lần thử nghiệm, tỷ lệ Sharpe tối đa dự kiến ($E^{1/2} \max\{fSR_{ckg}\}$) là 3,26, mặc dù tỷ lệ Sharpe thực của chiến lược là không. Như dự kiến, có một rào cản tăng dần mà nhà nghiên cứu phải vượt qua khi tiến hành nhiều lần kiểm tra ngược hơn. Chúng ta có thể so sánh các kết quả thử nghiệm này với các kết quả được dự đoán bởi định lý Chiến lược sai, được biểu diễn bằng đường đứt nét. So sánh hai kết quả này

(thí nghiệm và lý thuyết) dường như chỉ ra rằng định lý Chiến lược Sai ước tính chính xác SR tối đa dự kiến cho phạm vi thử nghiệm được nghiên cứu.

Bây giờ chúng ta chuyển sự chú ý của mình sang việc đánh giá độ chính xác của phép xấp xỉ định lý. Chúng tôi định nghĩa lỗi xấp xỉ là sự khác biệt giữa dự đoán thực nghiệm (dựa trên 1.000 mô phỏng) và dự đoán của định lý, chia cho dự đoán của định lý. Sau đó, chúng ta có thể đánh giá lại các lỗi ước tính này một trăm lần cho mỗi số lần thử K và rút ra

giá trị trung bình và độ lệch chuẩn của các lỗi. [Đoạn mã 8.2](#) triển khai một thí nghiệm Monte Carlo thứ hai để đánh giá độ chính xác của định lý.

```

ĐOẠN TRÍCH 8.2 ĐỘ LỆCH TRUNG BÌNH VÀ ĐỘ LỆCH CHUẨN CỦA CÁC LỖI DỰ ĐOÁN


def getMeanStdError(nSims0,nSims1,nTrials,stdSR=1,meanSR=0):
    # Tính độ lệch chuẩn của lỗi trên nTrial
    # nTrials: [số SR được sử dụng để tính max{SR}] # nSims0: số
    max{SR} được sử dụng để ước tính E[max{SR}]
    # nSims1: số lỗi mà std được tính toán
    sr0=pd.Series({i:getExpectedMaxSR(i,meanSR,stdSR) \
                    đối với i trong nThử nghiệm})
    sr0=sr0.to_frame('E[max{SR}]') sr0.index.name='nThử
    nghiệm'
    err=pd.DataFrame() cho i
    trong xrange(int(nSims1)):
        sr1=getDistDSR(nSims=1E3,nTrials=nTrials,meanSR=0,
            stdSR=1)
        sr1=sr1.groupby('nThử nghiệm').mean()
        err_=sr0.join(sr1).reset_index()
        err_['err']=err_['max{SR}']/err_['E[max{SR}]']-1. err=err.append(err_)
        out={'meanErr':err.groupby('nThử
    nghiệm')['err'].mean()} out['stdErr']=err.groupby('nThử nghiệm')['err'].std()
    out=pd.DataFrame.from_dict(out,orient='columns')

    trở về

#- - - - -
nếu __name__=='__main__':
    nTrials=danh sách(bộ(np.logspace(1,6,1000).astype(int)));nTrials.sort()
    số liệu thống kê=getMeanStdError(nSims0=1E3,nSims1=1E2,
        nThử nghiệm=nThử nghiệm,stdSR=1)

```

[Hình 8.2](#) biểu diễn kết quả từ thí nghiệm thứ hai này. Các vòng tròn biểu diễn các lỗi trung bình so với các giá trị dự đoán (trục y), được tính toán cho các số lần thử thay thế (trục x). Từ kết quả này, có vẻ như định lý False Strategy tạo ra các ước tính không thiên vị tiệm cận. Chỉ tại $K \approx 50$, ước tính của định lý vượt quá giá trị thực nghiệm khoảng 0,7%.



Hình 8.2 Thống kê các lỗi xấp xỉ như một hàm số của số lượng thử nghiệm.

Các dấu chéo biểu thị độ lệch chuẩn của các lỗi (trục y), được suy ra đối với số lượng thử nghiệm khác nhau (trục x). Từ thí nghiệm này, chúng ta có thể suy ra rằng độ lệch chuẩn tương đối nhỏ, dưới 0,5% giá trị được dự báo bởi định lý, và chúng trở nên nhỏ hơn khi số lần thử nghiệm tăng lên.

8.7 Tỷ lệ Sharpe xẹp

Kết luận chính từ định lý Chiến lược Sai lầm là, trừ khi $\max_{k \in K} \text{SR}_{\text{ckg}} \geq \frac{1}{2} \max_{k \in K} \text{SR}_{\text{ckg}}$, chiến lược được phát hiện có khả năng là sai tích cực. Nếu chúng ta có thể tính toán $\frac{1}{2} \max_{k \in K} \text{SR}_{\text{ckg}}$, chúng ta có thể sử dụng giá trị đó để đặt giá trị null giả thuyết phải bị bác bỏ để kết luận rằng hiệu suất của chiến lược có ý nghĩa thống kê, $H_0: \frac{1}{4} \max_{k \in K} \text{SR}_{\text{ckg}}$. Sau đó, tỷ lệ Sharpe giảm phát (Bailey và López de Prado 2014) có thể được suy ra là

$$\text{DSR} = \frac{1}{4} Z \sqrt{\frac{2}{n}} \frac{\text{SRC} \cdot E \max_{k \in K} \text{SR}_{\text{ckg}} \cdot \text{hiq}}{1 - \gamma \text{SRC} \cdot p} \cdot \frac{\sqrt{\gamma 41}}{4} \text{SRC}^2 \cdot \frac{T - 1}{5} \text{trang}_3$$

DSR có thể được hiểu là xác suất quan sát tỷ lệ Sharpe lớn hơn hoặc bằng SR theo giả thuyết không rằng tỷ lệ Sharpe thực sự là 0, trong khi điều chỉnh độ lệch, độ nhọn, độ dài mẫu và thử nghiệm nhiều lần.

tính toán DSR đòi hỏi phải ước tính E

$\frac{1}{2} \max_{k \in K} \text{SR}_{\text{ckg}}$, mà lần lượt

yêu cầu ước tính K và $V^{1/2}fSRckg$. Đây là nơi ML đến giải cứu chúng ta, như được giải thích tiếp theo.

8.7.1 Số lượng thử nghiệm có hiệu lực

Định lý Chiến lược Sai đòi hỏi phải biết số lượng thử nghiệm độc lập trong một họ các thử nghiệm. Tuy nhiên, các nhà nghiên cứu tài chính không thường chạy các thử nghiệm độc lập. Một tình huống điển hình hơn là các nhà nghiên cứu thử các chiến lược khác nhau, trong đó nhiều thử nghiệm được chạy cho mỗi chiến lược. Các thử nghiệm liên quan đến một chiến lược được cho là có mối tương quan cao hơn với nhau so với các chiến lược khác. Mối quan hệ này có thể được hình dung như một ma trận tương quan khối. Ví dụ, [Hình 8.3](#) vẽ một ví dụ thực tế về ma trận tương quan giữa 6.385 chuỗi lợi nhuận được kiểm tra ngược cho cùng một vũ trụ đầu tư, trước và sau khi phân cụm (để biết mô tả chi tiết về ví dụ này, hãy xem [López de Prado 2019a](#)). Thuật toán ONC ([Phần 4](#)) phát hiện ra sự tồn tại của bốn chiến lược khác biệt. Do đó, trong ví dụ này, chúng tôi sẽ ước tính rằng $E^{1/2}K \approx 4$. Đây là một ước tính thận trọng, vì số lượng K thực sự của các chiến lược độc lập phải nhỏ hơn số lượng các chiến lược có mối tương quan thấp.


8.7.2 Phương sai giữa các lần thử nghiệm

Trong phần này, chúng tôi theo sát [López de Prado và Lewis \(2018\)](#). Sau khi hoàn thành việc phân cụm ở trên, ONC đã phân chia thành công N chiến lược của chúng tôi thành K nhóm, mỗi nhóm được xây dựng từ các chiến lược có tương quan cao. Chúng tôi có thể sử dụng thêm phân cụm này để giảm N chiến lược thành K chiến lược cấp cụm. Sau khi tạo ra các "chiến lược cụm" này, chúng tôi đưa ra ước tính của mình về $V^{1/2}fSRckg$, trong đó $k = 1, \dots, K$.

Đối với một cụm k nhất định, mục tiêu là tạo thành một chuỗi thời gian trả về cụm tổng hợp $S_k; t$. Điều này đòi hỏi phải chọn một lược đồ trọng số cho phép tổng hợp. Một ứng cử viên tốt là phân bố phương sai tối thiểu, vì nó ngăn chặn các thử nghiệm riêng lẻ có phương sai cao chi phối lợi nhuận của cụm. Giả sử C_k biểu thị tập hợp các chiến lược trong cụm k , Σ_k là ma trận hiệp phương sai giới hạn cho các chiến lược trong C_k , $r_i; t$ là chuỗi lợi nhuận cho chiến lược $i \in C_k$ và $w_k; i$ là trọng số liên quan đến chiến lược $i \in C_k$. Sau đó, chúng ta tính toán

$$fwk; i; t = \frac{\sum_{i \in C_k} w_k; i r_i; t}{\sum_{i \in C_k} w_k; i}$$

$$S_k; t = \frac{1}{|C_k|} \sum_{i \in C_k} w_k; i r_i; t$$



Hình 8.3 Phân cụm 6.385 thử nghiệm, diễn hình của việc thử nghiệm nhiều nhóm chiến lược, trước và sau khi phân cụm.

Nguồn: [López de Prado \(2019a\)](#)

Tần số $\frac{1}{4}$ $\frac{Tk}{\text{Năm}}$;

$$\frac{1}{4} \frac{\text{Tần số } E^{1/2} f_{Sk}; t_g \text{ aSRdk}}{\text{Tần số } V^{1/2} f_{Sk}; t_g p} \quad \text{Tần số: } p$$

$$E^{1/2} V^{1/2} fSRckg^{-1/4} \frac{V^{1/2} faSRdkg}{\text{Tần số}} ;$$

8.8 Tỷ lệ lỗi theo gia đình

Theo khuôn khổ kiểm định giả thuyết Neyman-Pearson chuẩn, chúng ta bác bỏ giả thuyết không H_0 với độ tin cậy $1 - \alpha$ khi chúng ta quan sát một sự kiện mà nếu giả thuyết không đúng thì chỉ có thể xảy ra với xác suất α . Khi đó, xác suất bác bỏ sai giả thuyết không (lỗi loại I) là α . Điều này cũng được gọi là xác suất dương tính giả.

Khi **Neyman và Pearson (1933)** đề xuất khuôn khổ này, họ đã làm không xem xét khả năng tiến hành nhiều thử nghiệm và lựa chọn thử nghiệm tốt nhất kết quả. Như chúng ta đã thấy trong **Phần 8.3**, khi một bài kiểm tra được lặp lại nhiều lần, xác suất dương tính giả kết hợp tăng lên. Sau một "gia đình" K các thử nghiệm độc lập, chúng tôi sẽ bác bỏ H_0 với độ tin cậy $1 - \alpha$ K, do đó xác suất dương tính giả "gia đình" (hoặc tỷ lệ lỗi theo gia đình, FWER) là $1 - (1 - \alpha)^K$. Đây là xác suất mà ít nhất một trong những kết quả dương tính là sai, là phần bù cho xác suất không có kết quả dương tính nào là sai, là $(1 - \alpha)^K$.

8.8.1 Bản sửa lỗi của Šidák

Giả sử rằng chúng ta đặt một FWER trên K bài kiểm tra độc lập tại α . Sau đó, xác suất dương tính giả cá nhân có thể được suy ra từ phương trình trên $1 - (1 - \alpha)^{1/K}$ ở α như $\alpha = 1 - (1 - \alpha)^{1/K}$. Điều này được gọi là hiệu chỉnh Šidák cho nhiều thử nghiệm (**Šidák 1967**), và nó có thể được xấp xỉ như là số hạng đầu tiên của Taylor mở rộng, $\alpha \approx \alpha^* = K$ (được gọi là phép xấp xỉ Bonferroni).

Như chúng ta đã làm trước đó, chúng ta có thể áp dụng thuật toán ONC để ước tính $E_{1/2}K$. Trong khi nó đúng là các thử nghiệm $E_{1/2}K$ không hoàn toàn không tương quan, chúng cung cấp ước tính thận trọng về số lượng cụm tối thiểu mà thuật toán không thể giảm thêm nữa. Với ước tính $E_{1/2}K$ này, chúng ta có thể áp dụng phép hiệu chỉnh của Šidák và tính toán xác suất lỗi loại I trong quá trình thử nghiệm nhiều lần, α_K .

8.8.2 Lỗi loại I trong thử nghiệm nhiều

Hãy xem xét một chiến lược đầu tư với chuỗi thời gian lợi nhuận có quy mô T . Chúng tôi ước tính tỷ lệ Sharpe, SR , và đưa ước tính đó vào thử nghiệm giả thuyết, trong đó $H_0 : SR \leq 0$ và $H_1 : SR > 0$. Chúng tôi muốn xác định xác suất của một sai dương tính khi thử nghiệm này được thực hiện nhiều lần.

Bailey và López de Prado (2012) đã đưa ra xác suất rằng Sharpe thực sự tỷ lệ vượt quá ngưỡng SR nhất định, theo giả định chung là lợi nhuận là tĩnh và ergodic (không nhất thiết là IID Normal). Nếu tỷ lệ Sharpe thực bằng SR , thống kê $\sqrt{T}SR$ được phân phối tiệm cận như một Chuẩn Bình thường,

$$\sqrt{T}SR \xrightarrow{d} N\left(\frac{\sqrt{41}}{4} SR, \frac{1}{4}\right);$$

trong đó SR là tỷ lệ Sharpe ước tính (không theo năm), T là số lượng quan sát, $\sqrt{41}$ là độ lệch của lợi nhuận và $1/4$ là độ nhọn của trả về. Lỗi loại I theo gia đình xảy ra với xác suất

$$P^{1/2} \text{ tối đa } f^{1/2} \text{ kgk}^{1/4} 1; \dots; K > \alpha_j H_0^{1/4} 1 \quad \text{đ } P \text{ } 1 \text{ } \alpha^{1/4} \text{ } \alpha_K:$$

Đối với FWER α_K , phép hiệu chỉnh của Šidák cung cấp cho chúng ta mức ý nghĩa thử nghiệm đơn lẻ $\alpha^{1/4} 1 \quad \text{đ } 1 \text{ } \alpha_K \quad 1=K$. Sau đó, giả thuyết không bị bác bỏ với độ tin cậy

P_{α_K} hầu hết $\max_k f^{1/2} \text{ kgk}^{1/4} 1; \dots; K > \alpha$, trong đó α là giá trị tới hạn của Phân phối chuẩn chuẩn để lại xác suất α ở bên phải,

za $1/4 \quad Z^{1/2} 1 \text{ } \alpha^{1/4} \quad Z^{1/2}$ ở Phân $1 \text{ } \alpha_K \quad 1=K$ và $Z^{1/2}$: là CDF của chuẩn phối chuẩn.

Ngược lại, chúng ta có thể suy ra lỗi loại I trong thử nghiệm nhiều lần (α_K) như sau sau đây: đầu tiên, áp dụng quy trình phân cụm trên ma trận tương quan thử nghiệm, để ước tính chuỗi lợi nhuận của cụm và $E^{1/2} K$; thứ hai, ước tính

$\wedge^{1/2} \text{ } 1/4 \quad \max_k f^{1/2} \text{ kgk}^{1/4} 1; \dots; K$ trên lợi nhuận của cụm được chọn; thứ ba, tính toán lỗi loại I cho một bài kiểm tra duy nhất, $\alpha^{1/4} 1 \quad Z^{1/2} \wedge^{1/2} \text{ } 1/4$; thứ tư, đúng cho nhiều nghiệm, $\alpha_K^{1/4} 1 \quad \text{đ } \text{ } \alpha_K$, dẫn đến

$$\alpha_K^{1/4} 1 \quad Z^{1/2} \wedge^{1/2} \text{ } 1/4 \text{ } E^{1/2} K :$$

Chúng ta hãy minh họa các phép tính trên bằng một ví dụ số.

Giả sử sau khi tiến hành 1.000 lần thử nghiệm, chúng ta xác định được một khoản đầu tư chiến lược với tỷ lệ Sharpe là 0,0791 (không theo năm), độ lệch của

3, độ nhọn của 10, được tính toán trên 1.250 quan sát hàng ngày (năm năm, tại 250 quan sát hàng năm). Các mức độ lệch và độ nhọn này là

điển hình của lợi nhuận quỹ đầu cơ được lấy mẫu với tần suất hàng ngày. Từ những

đầu vào chúng ta suy ra $\wedge^{1/2} \text{ } 1/4 \approx 2.4978$ và $\alpha \approx 0.0062$. Ở xác suất lỗi loại I này,

hầu hết các nhà nghiên cứu sẽ bác bỏ giả thuyết không và tuyên bố rằng một cái mới

chiến lược đầu tư đã được tìm thấy. Tuy nhiên, α này không được điều chỉnh cho

$E^{1/2} K$ thử nghiệm đã mất để tìm ra chiến lược này. Chúng tôi áp dụng thuật toán ONC của mình và

kết luận rằng trong số 1.000 thử nghiệm (có tương quan), có $E^{1/2} K^{1/4} 10$ thực sự

các thử nghiệm độc lập (một lần nữa, với “thực sự” độc lập, chúng tôi không khẳng định rằng mười cụm hoàn toàn độc lập, nhưng thuật toán không thể tìm thấy

nhiều nhóm không tương quan hơn). Sau đó, FWER đã hiệu chỉnh là $\alpha_K \approx 0.0608$. Thậm chí

mặc dù tỷ lệ Sharpe hàng năm là khoảng 1,25, khả năng này

chiến lược là một khám phá sai lầm tương đối cao, vì hai lý do: (1) số lượng

thử nghiệm, vì $\alpha_K^{1/4} \alpha \approx 0.0062$ nếu $E^{1/2} K^{1/4} 1$; (2) tính không bình thường của lợi nhuận,

vì $\alpha_K \approx 0.0261$ nên lợi nhuận phải là Bình thường. Như mong đợi, sai

giả sử lợi nhuận bình thường dẫn đến việc đánh giá thấp nghiêm trọng lỗi loại I

xác suất. [Đoạn mã 8.3](#) cung cấp mã python sao chép những

kết quả.

ĐOẠN TRÍCH 8.3 LỖI LOẠI I, CỎ VÍ DỤ SỐ

```

nhập scipy.stats như ss
#- - - - -
def getZStat(sr,t,sr_=0,skew=0,kurt=3):
    z=(sr-sr_)*(t-1)**.5 z/=(1-độ
    lệch*sr+(kurt-1)/4.*sr**2)**.5
    trả về z
#- - - - -
def nghĩa typeIErr(z,k=1):
    # tỷ lệ dương tính giả
    alpha=ss.norm.cdf(-z)
    alpha_k=1-(1-alpha)**k # trả về hiệu chỉnh nhiều lần thử nghiệm alpha_k
#- - - - -
def nghĩa main0():
    # Ví dụ số t, skew, kurt,
    k, freq=1250,-3,10,10,250 sr=1.25/freq**.5;sr_=1./
    freq**.5 z=getZStat(sr,t,0, skew, kurt)
    alpha_k=typeIErr(z,k=k) print alpha_k

    trở lại
#- - - - -
nếu __name__=='__main__':main0()

```

8.8.3 Lỗi loại II trong thử nghiệm nhiều

Giả sử rằng giả thuyết thay thế ($H_1 : SR > 0$) cho chiến lược tốt nhất là đúng và $SR \sim \frac{1}{4} SR$. Sau đó, sức mạnh của phép thử liên quan đến FWER α là

$$\begin{aligned}
 & P^{1/2} \max_{\text{...}} f^{\wedge 1/2} \text{kgk}^{1/4} 1; \dots; K > \text{zajSR} \sim \frac{1}{4} SR \\
 & \frac{1}{4} \text{Đ} \cdot \frac{2}{4} \frac{\text{SRC} \text{ p SR SR}}{\text{q} \text{ 1 } \wedge \gamma \text{3SRC} \text{ p}} \frac{\text{T 1 p}}{\frac{\wedge \gamma \text{41}}{4} \text{SRC2}} > \text{zajSR} \sim \frac{1}{4} SR \quad \frac{3}{5} \\
 & \frac{1}{4} \text{P} \wedge \text{z}^{1/2} \text{SR} > \text{z} \alpha \quad \frac{\text{SR} \text{ T 1 trang}}{\text{q} \text{ 1 } \wedge \gamma \text{3SRC} \text{ p}} \frac{\wedge \gamma \text{41}}{4} \text{SRC2} \text{ jSR} \sim \frac{1}{4} SR \quad \frac{3}{5} \\
 & \frac{1}{4} \text{1 P} \wedge \text{z}^{1/2} \text{SR} < \text{z} \alpha \quad \frac{\text{SR} \text{ T 1 trang}}{\text{q} \text{ 1 } \wedge \gamma \text{3SRC} \text{ p}} \frac{\wedge \gamma \text{41}}{4} \text{SRC2} \text{ jSR} \sim \frac{1}{4} SR \quad \frac{3}{5}
 \end{aligned}$$

Chúng ta hãy áp dụng các phương trình trên vào ví dụ số ở [phần trước](#). Ở đó, chúng tôi ước tính rằng FWER là $\alpha_K \approx 0.0608$, điều này ngụ ý một giá trị quan trọng $z_{\alpha} \approx 2.4978$. Sau đó, xác suất bỏ lỡ một chiến lược với một Tỷ lệ Sharpe $SR \approx 0.0632$ (không theo năm) là $\beta \approx 0.6913$, trong đó $\theta \approx 1.9982$. Xác suất lỗi loại II cá nhân cao này có thể hiểu được, bởi vì thử nghiệm không đủ mạnh để phát hiện ra tín hiệu yếu như vậy (một Sharpe hàng năm tỷ lệ chỉ 1.0) sau một lần thử nghiệm duy nhất. Nhưng vì chúng tôi đã tiến hành mười lần thử nghiệm, $\beta_K \approx 0.0249$. Bài kiểm tra phát hiện hơn 97,5% các chiến lược có giá trị thực Tỷ lệ Sharpe $SR \geq 0.0632$. [Đoạn mã 8.4](#) cung cấp mã python sao chép các kết quả này (xem [Đoạn mã 8.3](#) cho các hàm `getZStat` và `loại 1Err`).

ĐOẠN TRÍCH 8.4 LỖI LOẠI II , CÓ VÍ DỤ SỐ

```

def getTheta(sr,t,sr_=0,skew=0,kurt=3):
    theta=sr_*(t-1)**.5 theta/
    =(1-độ lệch*sr_+(kurt-1)/4.*sr**2)**.5
    trả về theta

#- - - - -

định nghĩa type2Err(alpha_k,k,theta):
    # tỷ lệ âm tính giả
    z=ss.norm.ppf((1-alpha_k)**(1./k)) # Sửa lỗi của Sidak
    beta=ss.norm.cdf(z-theta)
    trả lại beta

#- - - - -

định nghĩa main0():
    # Ví dụ số
    t, độ lệch, kurt, k, tần số = 1250, -3, 10, 10, 250
    sr=1.25/freq**.5;sr_=1./freq**.5
    z=getZStat(sr,t,0,skew,kurt)
    alpha_k=type1Err(z,k=k)
    theta=getTheta(sr,t,sr_,skew,kurt)
    beta=type2Err(alpha_k,k,theta)
    beta_k=beta**k in
    beta_k
    trả lại

#- - - - -

nếu __name__=='__main__':main0()


```

8.8.4 Sự tương tác giữa lỗi loại I và lỗi loại II


Hình 8.4 minh họa mối quan hệ giữa α và β . Phân phối trên cùng mô hình hóa xác suất ước tính SR theo giả định rằng H_0 là đúng. Phân phối dưới cùng (được vẽ ngược, để dễ hiển thị) mô hình hóa xác suất ước tính SR theo giả định rằng H_1 là đúng và đặc biệt là theo kịch bản mà $SR \approx 1$. Chiều dài mẫu, độ lệch và độ nhọn ảnh hưởng đến phương sai của hai phân phối này. Với một

ước tính SR, các biến đó xác định xác suất α và β , trong đó việc giảm một biến ngụ ý việc tăng biến kia. Trong hầu hết các bài báo, tác giả tập trung vào phân phối "trên cùng" và bỏ qua phân phối "dưới cùng".


Giải pháp phân tích mà chúng tôi đưa ra cho lỗi Loại II cho thấy rõ ràng rằng sự đánh đổi này cũng tồn tại giữa αK và βK , mặc dù theo cách không đơn giản như trong trường hợp $K \approx 1$. Hình 8.5 cho thấy, đối với αK cố định, khi K tăng, α giảm, β tăng, do đó β tăng.



Hình 8.4 Minh họa mối quan hệ giữa α và β .



Hình 8.5 Sự tương tác giữa α và β .



Hình 8.6 β_K khi K tăng đối với $\theta \approx 1.9982$ và $\alpha \in \{0.01; 0.025; 0.005\}$.

Hình 8.6 vẽ đồ thị β_K khi K tăng đối với các mức α_K khác nhau. Mặc dù β tăng theo K , hiệu ứng tổng thể là làm giảm β_K . Đối với α_K cố định, phương trình xác định β_K theo hàm số của K và θ là

$$\beta_K = \frac{1}{2} \left(1 + \frac{1}{2} \left(1 - \frac{1}{2} \right)^{1/2} \right) \approx 1 - \alpha_K \quad 1 = K \text{ i } \theta \beta_K:$$

8.9 Kết luận

Tỷ lệ Sharpe của một chiến lược đầu tư trong một lần thử nghiệm duy nhất tuân theo phân phối Gauss, ngay cả khi lợi nhuận của chiến lược không phải là chuẩn (vẫn vậy, lợi nhuận phải là dừng và ergodic). Các nhà nghiên cứu thường tiến hành nhiều lần thử nghiệm và việc chọn ra chiến lược có hiệu suất tốt nhất trong số đó sẽ làm tăng khả năng chọn ra một chiến lược sai. Trong phần này, chúng tôi đã nghiên cứu hai quy trình thay thế để đánh giá mức độ mà việc kiểm tra quá mức bộ làm mất hiệu lực một chiến lược đầu tư đã phát hiện.

Cách tiếp cận đầu tiên dựa trên định lý False Strategy. Định lý này suy ra giá trị kỳ vọng của tỷ lệ Sharpe tối đa, $E^{1/2} \max_k fSR_{ckg}$, như một hàm của số lần thử, K , và phương sai của tỷ lệ Sharpe trong các lần thử, $V^{1/2} fSR_{ckg}$. Các phương pháp ML cho phép chúng ta ước tính hai biến này. Với ước tính này của $E^{1/2} \max_k fSR_{ckg}$, chúng ta có thể kiểm tra xem $\max_k fSR_{ckg}$ có ý nghĩa thống kê hay không, bằng cách sử dụng tỷ lệ Sharpe giảm phát (Bailey và López de Prado 2014).

Cách tiếp cận thứ hai ước tính số lần thử, K , và áp dụng hiệu chỉnh của Šidák để suy ra tỷ lệ lỗi theo gia đình (FWER). FWER cung cấp ngưỡng từ chối đã điều chỉnh mà chúng ta có thể kiểm tra xem maxkFSRckg có ý nghĩa thống kê hay không, bằng cách sử dụng các phân phối do Lo (2002) và Mertens (2002) đề xuất. Các nhà nghiên cứu có thể sử dụng các ước tính phân tích này về xác suất dương tính giả theo gia đình và xác suất âm tính giả theo gia đình khi họ thiết kế các bài kiểm tra thống kê của mình.

8.10 Bài tập

- 1 Theo cách tiếp cận được mô tả trong Phần 8.2, hãy vẽ độ chính xác và khả năng thu hồi liên quan đến một bài kiểm tra dưới dạng hàm của $\theta \in [0, 1]$, trong đó $\alpha = 0.05$ và $K = 1$. Điều này có phù hợp với trực giác của bạn không?
- 2 Lặp lại Bài tập 1, vẽ bề mặt theo hàm số $K = 1$; ... tác động tổng thể của α . 25. Cái gì là nhiều lần thử nghiệm đối với độ chính xác và khả năng thu hồi?
- 3 Hãy xem xét một chiến lược với năm năm lợi nhuận IID Normal hàng ngày. Thử nghiệm tốt nhất trong mười lần cho tỷ lệ Sharpe hàng năm là 2, trong đó phương sai giữa các tỷ lệ Sharpe hàng năm là 1. a Tỷ lệ Sharpe tối đa dự kiến là bao nhiêu? Gợi ý: Áp dụng định lý Chiến lược Sai.
- b Sau một lần thử, xác suất quan sát thấy tỷ lệ Sharpe tối đa bằng hoặc cao hơn 2 là bao nhiêu? Gợi ý: Đây là tỷ lệ Sharpe xác suất. c Sau mười lần thử, xác suất quan sát thấy tỷ lệ Sharpe tối đa bằng hoặc cao hơn 2 là bao nhiêu? Gợi ý: Đây là tỷ lệ Sharpe giảm phát.
- 4 Hãy xem xét một chiến lược đầu tư mua hợp đồng tương lai S&P 500 khi giá trung bình động có thời gian hồi tưởng ngắn vượt quá giá trung bình động có thời gian hồi tưởng dài hơn. a Tạo ra chuỗi lợi nhuận chiến lược gấp 1.000 lần bằng cách áp dụng các kết hợp khác nhau của
- i Nhìn lại ngắn gọn
- ii Nhìn lại dài hạn
- iii Dừng lỗ iv Chốt lời v Thời gian nắm giữ tối đa b Tính tỷ lệ Sharpe tối đa trong số 1.000 lần thử nghiệm. c Đạo hàm $E^{1/2}$ maxkFSRckg, như đã giải thích trong Phần 8.7. d Tính xác suất quan sát thấy tỷ lệ Sharpe bằng hoặc cao hơn 4(b).
- 5 Lặp lại Bài tập 4, lần này bạn tính lỗi Loại I và Loại II theo gia đình, trong đó SR là trung vị trên 1.000 tỷ lệ Sharpe.


Phụ lục A: Kiểm tra trên dữ liệu tổng hợp

Bộ dữ liệu tổng hợp cho phép các nhà nghiên cứu thử nghiệm các chiến lược đầu tư trên chuỗi tương đương với hàng ngàn năm lịch sử và ngăn chặn việc lấp quá mức vào một tập dữ liệu quan sát cụ thể. Nói chung, các tập dữ liệu tổng hợp này có thể được tạo ra thông qua hai phương pháp: lấy mẫu lại và Monte Carlo. Hình A.1 tóm tắt cách các phương pháp này phân nhánh và liên quan đến nhau.

Lấy mẫu lại bao gồm việc tạo ra các tập dữ liệu mới (chưa được quan sát) bằng cách lấy mẫu lặp lại trên tập dữ liệu quan sát được. Lấy mẫu lại có thể là xác định hoặc ngẫu nhiên. Các trường hợp lấy mẫu lại xác định bao gồm jackknife (bỏ qua một), xác thực chéo (một lần ra), và xác thực chéo kết hợp (kiểm tra hoán vị). Ví dụ, người ta có thể chia các quan sát lịch sử thành N lần và tính toán tất cả các tập kiểm tra kết quả từ việc bỏ qua k lần gộp. Xác thực chéo kết hợp này tạo ra các đường dẫn lịch sử N chính, đó là

khó phù hợp hơn so với kiểm tra ngược lịch sử đường dẫn đơn (xem AFML, chương 12, cho một triển khai). Các trường hợp lấy mẫu lại ngẫu nhiên bao gồm lấy mẫu phụ (lấy mẫu ngẫu nhiên không thay thế) và bootstrap (lấy mẫu ngẫu nhiên với thay thế). Lấy mẫu phụ dựa trên các giả định yếu hơn, tuy nhiên nó không thực tế khi tập dữ liệu quan sát có kích thước hạn chế. Bootstrap có thể tạo ra mẫu lớn bằng tập dữ liệu quan sát được, bằng cách rút ra các quan sát riêng lẻ hoặc các khối của chúng (do đó bảo toàn sự phụ thuộc nối tiếp của các quan sát). Hiệu quả của bootstrap phụ thuộc vào tính độc lập của ngẫu nhiên mẫu, một yêu cầu được thừa hưởng từ định lý giới hạn trung tâm. Để thực hiện rút thăm ngẫu nhiên càng độc lập càng tốt, bootstrap tuần tự điều chỉnh trực tuyến khả năng rút ra các quan sát tương tự như những quan sát đã lấy mẫu (xem AFML, chương 4, để biết cách thực hiện).

Cách tiếp cận thứ hai để tạo ra các tập dữ liệu tổng hợp là Monte Carlo. Monte Carlo lấy mẫu ngẫu nhiên các tập dữ liệu mới (chưa được quan sát) từ một ước tính dân số hoặc quá trình tạo dữ liệu, thay vì từ một tập dữ liệu được quan sát (giống như bootstrap sẽ làm). Các thí nghiệm Monte Carlo có thể là tham số hoặc không tham số. Một ví dụ về Monte Carlo tham số là chế độ chuyển đổi mô hình chuỗi thời gian (Hamilton 1994), trong đó các mẫu được lấy từ các phương án thay thế quá trình, $n = 1; \dots; N$, và trong đó xác suất $p_{t,n}$ của việc rút ra từ quá trình n tại thời điểm t là một hàm của quá trình mà quan sát trước đó là được rút ra (một chuỗi Markov). Các thuật toán tối đa hóa kỳ vọng có thể được sử dụng để ước tính xác suất chuyển đổi từ quá trình này sang quá trình khác tại thời điểm t (ma trận xác suất chuyển đổi). Phương pháp tiếp cận tham số này cho phép các nhà nghiên cứu dễ phù hợp với các thuộc tính thống kê của tập dữ liệu quan sát, sau đó



Hình A.1 Tạo bộ dữ liệu tổng hợp.

được sao chép trong tập dữ liệu không quan sát được. Một cảnh báo của Monte Carlo tham số là rằng quá trình tạo dữ liệu có thể phức tạp hơn một tập hợp hữu hạn các hàm đại số có thể sao chép. Khi đó là trường hợp, Monte không tham số Các thí nghiệm Carlo có thể hữu ích, chẳng hạn như bộ mã hóa tự động biến thiên, bản đồ tự tổ chức hoặc mạng đối nghịch tạo sinh. Các phương pháp này có thể được hiểu là các ước lượng phi tham số, phi tuyến tính của các biến tiềm ẩn (tương tự như một PCA phi tuyến tính). Một bộ mã hóa tự động là một mạng nơ-ron học cách biểu diễn quan sát chiều cao trong không gian chiều thấp. Bộ mã hóa tự động biến thiên có một thuộc tính bổ sung làm cho không gian tiềm ẩn của chúng liên tục. Điều này cho phép lấy mẫu ngẫu nhiên và nội suy thành công và, đến lượt nó, việc sử dụng chúng như một mô hình sinh sản. Khi một bộ mã hóa tự động biến thiên đã học được cấu trúc cơ bản của dữ liệu, nó có thể tạo ra những quan sát mới giống với các đặc tính thống kê của mẫu ban đầu, trong một độ phân tán nhất định (do đó có khái niệm "biến thể"). Một bản đồ tự tổ chức khác với bộ mã hóa tự động ở chỗ nó áp dụng học tập cạnh tranh (thay vì sửa lỗi), và nó sử dụng một hàm lân cận để bảo toàn các đặc tính tô pô của không gian đầu vào. Các mạng đối nghịch tạo ra đào tạo hai mạng nơ-ron cạnh tranh, trong đó một mạng (gọi là máy phát) được giao nhiệm vụ tạo ra quan sát mô phỏng từ một hàm phân phối và mạng lưới khác (được gọi là bộ phân biệt) có nhiệm vụ dự đoán xác suất các quan sát mô phỏng là sai dựa trên dữ liệu quan sát thực tế. Hai mạng thần kinh các mạng lưới cạnh tranh với nhau cho đến khi chúng hội tụ đến trạng thái cân bằng. mẫu gốc mà Monte Carlo phi tham số được đào tạo phải là đủ đại diện để tìm hiểu các đặc điểm chung của dữ liệu tạo ra quá trình, nếu không thì nên ưu tiên phương pháp Monte Carlo tham số (xem AFML, chương 13, là một ví dụ).

Phụ lục B: Bằng chứng của “Chiến lược sai lầm” Định lý

Người ta biết rằng giá trị lớn nhất trong một mẫu ngẫu nhiên độc lập các biến theo phân phối mũ hội tụ tiệm cận đến một Phân phối Gumbel. Để biết bằng chứng, hãy xem [Embrechts et al. \(2003, 138-47\)](#). Là một trường hợp cụ thể, phân phối Gumbel bao phủ Miền cực đại của Sự hấp dẫn của phân phối Gaussian, và do đó nó có thể được sử dụng để ước tính giá trị mong đợi của giá trị cực đại của một số Gaussian ngẫu nhiên độc lập biến số.

Để xem cách thực hiện, hãy giả sử một mẫu độc lập và phân phối giống hệt nhau Biến ngẫu nhiên Gauss, $y_k \in N(0, 1)$, $k = 1, 2, \dots, K$. Nếu chúng ta áp dụng Fisher-Định lý Tippet-Gnedenko đối với phân phối Gauss, chúng ta suy ra một xấp xỉ cho mẫu tối đa, $\max y_k$, dẫn đến

$$\lim_{K \rightarrow \infty} \text{C\o l\i} \frac{\max y_k - \alpha}{\beta} \leq x \quad G^{1/2}(x); \quad (1)$$

trong đó $G^{1/2}(x)$ là CDF cho phân phối Gumbel Chuẩn, $\alpha = 1/2$, $\beta = 1/2$, và Z_1 tương ứng với nghịch đảo của CDF Chuẩn mực. Xem [Resnick \(1987\)](#) và [Embrechts et al. \(2003\)](#) để tìm ra hằng số chuẩn hóa α và β .

Giới hạn của kỳ vọng của cực đại chuẩn hóa từ một phân phối trong Miền hấp dẫn cực đại của Gumbel (xem Đề xuất 2.1(iii) trong [Resnick 1987](#)) là

$$\lim_{K \rightarrow \infty} E \frac{\max y_k - \alpha}{\beta} = \gamma; \quad (2)$$

trong đó γ là hằng số Euler-Mascheroni, $\gamma \approx 0.5772 \dots$. Đối với một lượng đủ lớn K , giá trị trung bình của mẫu cực đại của phân phối chuẩn ngẫu nhiên các biến có thể được xấp xỉ bằng

$$E \frac{\max y_k}{\beta} \approx \alpha + \gamma \beta \quad G^{1/2}(1) \quad \frac{1}{K} \quad \frac{1}{K} e^1; \quad (3)$$

trong đó $K \beta$:

Bây giờ hãy xem xét một tập hợp các thống kê hiệu suất ước tính fSR_{ck} , $k = 1, 2, \dots, K$, với $SR_{ck} \in N(0, 1)$ Gaussian độc lập và phân phối giống hệt nhau; $V^{1/2} fSR_{ck}$.

Chúng tôi sử dụng tính tuyến tính của toán tử kỳ vọng để suy ra sự biểu lộ

$$E^{1/2} \text{ tối đa } fSRckg \ V^{1/2} fSRckg \ i p \ 1^{=2} \approx \delta \ 1 \ \gamma \ Z1 \ 1 \ p \ \frac{1}{K} \ p \ \gamma Z1 \ 1 \ \frac{1}{C6} \ .$$

(4)

Như vậy là kết thúc phần chứng minh định lý.

Tài liệu tham khảo

- Aggarwal, C., và C. Reddy (2014): Phân cụm dữ liệu - Thuật toán và ứng dụng. Ấn bản lần thứ 1. CRC Press.
- Ahmed, N., A. Atiya, N. Gayar và H. El-Shishiny (2010): "So sánh thực nghiệm các mô hình học máy để dự báo chuỗi thời gian." Tạp chí Kinh tế lượng, Tập 29, Số 5-6, trang 594-621.
- Anderson, G., A. Guionnet và O. Zeitouni (2009): Giới thiệu về Lý thuyết Ma trận Ngẫu nhiên. Ấn bản lần thứ 1. Cambridge Studies in Advanced Mathematics. Nhà xuất bản Đại học Cambridge.
- Ballings, M., D. van den Poel, N. Hespels và R. Gryp (2015): "Đánh giá nhiều bộ phân loại để dự đoán hướng giá cổ phiếu." Hệ thống chuyên gia có ứng dụng, Tập 42, Số 20, trang 7046-56.
- Bansal, N., A. Blum và S. Chawla (2004): "Phân cụm tương quan". Học máy, Tập 56, Số 1, trang 89-113.
- Benjamini, Y., và D. Yekutieli (2001): "Kiểm soát tỷ lệ phát hiện sai trong thử nghiệm nhiều lần dưới sự phụ thuộc." Biên niên sử thống kê, Tập 29, trang 1165-88.
- Benjamini, Y. và W. Liu (1999): "Quy trình kiểm tra nhiều giả thuyết theo từng bước kiểm soát tỷ lệ phát hiện sai trong điều kiện độc lập". Tạp chí Kế hoạch và Suy luận Thống kê, Tập 82, trang 163-70.
- Benjamini, Y., và Y. Hochberg (1995): "Kiểm soát tỷ lệ phát hiện sai: Một cách tiếp cận thực tế và mạnh mẽ đối với thử nghiệm nhiều lần." Tạp chí của Hiệp hội thống kê Hoàng gia, Loạt B, Tập 57, trang 289-300.
- Bontempi, G., S. Taieb và Y. Le Borgne (2012): "Chiến lược học máy để dự báo chuỗi thời gian." Ghi chú bài giảng về Xử lý thông tin kinh doanh, Tập 138, Số 1, trang 62-77.
- Booth, A., E. Gerding và F. McGroarty (2014): "Giao dịch tự động với Rừng ngẫu nhiên có trọng số hiệu suất và tính theo mùa." Hệ thống chuyên gia có ứng dụng, Tập 41, Số 8, trang 3651-61.
- Cao, L., và F. Tay (2001): "Dự báo tài chính bằng cách sử dụng máy vectơ hỗ trợ." Neural Computing and Applications, Tập 10, Số 2, trang 184-92.
- Cao, L., F. Tay và F. Hock (2003): "Máy vectơ hỗ trợ với các tham số thích ứng trong dự báo chuỗi thời gian tài chính." IEEE Transactions on Neural Networks, Tập 14, Số 6, trang 1506-18.
- Cervello-Royo, R., F. Guijarro và K. Michniuk (2015): "Quy tắc giao dịch chứng khoán dựa trên nhận dạng mẫu và phân tích kỹ thuật: Dự báo

- Chỉ số DJIA với Dữ liệu trong ngày." Hệ thống chuyên gia với Ứng dụng, Tập 42, Số 14, trang 5963-75.
- Chang, P., C. Fan và J. Lin (2011): "Khám phá xu hướng trong dữ liệu chuỗi thời gian tài chính bằng cách sử dụng cây quyết định mờ dựa trên trường hợp." Hệ thống chuyên gia có ứng dụng, Tập 38, Số 5, trang 6070-80.
- Chen, B., và J. Pearl (2013): "Hồi quy và nguyên nhân: Một đánh giá quan trọng về sáu sách giáo khoa kinh tế lượng." Real-World Economics Review, Tập 65, trang 2-20.
- Creamer, G., và Y. Freund (2007): "Một cách tiếp cận thúc đẩy cho giao dịch tự động." Tạp chí giao dịch, Tập 2, Số 3, trang 84-96.
- Creamer, G., và Y. Freund (2010): "Giao dịch tự động với Boosting và Expert Weighting." Tài chính định lượng, Tập 10, Số 4, trang 401-20.
- Creamer, G., Y. Ren, Y. Sakamoto và J. Nickerson (2016): "Thuật toán phân tích văn bản cho thị trường vốn chủ sở hữu: Trường hợp châu Âu." Tạp chí đầu tư, Tập 25, Số 3, trang 105-16.
- Dixon, M., D. Klabjan và J. Bang (2017): "Dự đoán thị trường tài chính dựa trên phân loại bằng cách sử dụng mạng nơ-ron sâu." Tài chính thuật toán, Tập 6, Số 3, trang 67-77.
- Dunis, C. và M. Williams (2002): "Lập mô hình và giao dịch tỷ giá hối đoái Euro/Đô la Mỹ: Các mô hình mạng nơ-ron có hoạt động tốt hơn không?" Tạp chí phái sinh và quỹ đầu cơ, Tập 8, Số 3, trang 211-39.
- Easley, D. và J. Kleinberg (2010): Mạng lưới, Đám đông và Thị trường: Lý luận về một Thế giới Kết nối Cao. Ấn bản lần thứ 1. Nhà xuất bản Đại học Cambridge.
- Easley, D., M. López de Prado, M. O'Hara và Z. Zhang (2011): "Cấu trúc vi mô trong thời đại máy móc." Bài báo nghiên cứu.
- Efroymsen, M. (1960): "Phân tích hồi quy bội." Trong A. Ralston và H. Wilf (biên tập), Phương pháp toán học cho máy tính số. Ấn bản lần thứ 1. Wiley.
- Einav, L., và J. Levin (2014): "Kinh tế học trong thời đại dữ liệu lớn." Science, Tập 346, Số 6210. Có tại <http://science.sciencemag.org/content/346/6210/1243089>
- Feuerriegel, S. và H. Prendinger (2016): "Chiến lược giao dịch dựa trên tin tức". Hệ thống hỗ trợ quyết định, Tập 90, trang 65-74.
- Greene, W. (2012): Phân tích kinh tế lượng. Ấn bản lần thứ 7. Pearson Education.
- Harvey, C., và Y. Liu (2015): "Kiểm tra ngược". Tạp chí danh mục đầu tư Quản lý, Tập 42, Số 1, trang 13-28.
- Harvey, C., và Y. Liu (2018): "Những khám phá sai lầm (và bị bỏ lỡ) trong kinh tế tài chính." Bài báo làm việc. Có tại <https://ssrn.com/abstract=3073799> Harvey, C., và Y. Liu (2018): "Yếu tố may mắn." Bài báo làm việc. Có tại <https://ssrn.com/abstract=2528780>
- Hastie, T., R. Tibshirani và J. Friedman (2016): Các yếu tố của học thống kê: Khai thác dữ liệu, suy luận và dự đoán. Ấn bản lần 2. Springer.

- Hayashi, F. (2000): Kinh tế lượng. Ấn bản lần thứ 1. Nhà xuất bản Đại học Princeton.
- Holm, S. (1979): "Một quy trình kiểm tra đa bội tuần tự từ chối đơn giản." Tạp chí Thống kê Scandinavia, Tập 6, trang 65-70.
- Hsu, S., J. Hsieh, T. Chih và K. Hsu (2009): "Kiến trúc hai giai đoạn để dự báo giá cổ phiếu bằng cách tích hợp bản đồ tự tổ chức và hồi quy vectơ hỗ trợ." Hệ thống chuyên gia có ứng dụng, Tập 36, Số 4, trang 7947-51.
- Huang, W., Y. Nakamori và S. Wang (2005): "Dự báo hướng chuyển động của thị trường chứng khoán bằng máy vectơ hỗ trợ." Máy tính và nghiên cứu hoạt động, Tập 32, Số 10, trang 2513-22.
- Ioannidis, J. (2005): "Tại sao hầu hết các phát hiện nghiên cứu được công bố đều sai." PLoS Medicine, Tập 2, Số 8. Có tại <https://doi.org/10.1371/journal.pmed.0020124>
- James, G., D. Witten, T. Hastie và R. Tibshirani (2013): Giới thiệu về học thống kê. Ấn bản lần thứ 1. Springer.
- Kahn, R. (2018): Tương lai của Quản lý đầu tư. Ấn bản đầu tiên. Viện CFA Quỹ nghiên cứu.
- Kara, Y., M. Boyacioglu, và O. Baykan (2011): "Dự đoán hướng biến động của chỉ số giá cổ phiếu bằng mạng nơ-ron nhân tạo và máy vectơ hỗ trợ: Mẫu của Sở giao dịch chứng khoán Istanbul." Hệ thống chuyên gia có ứng dụng, Tập 38, Số 5, trang 5311-19.
- Kim, K. (2003): "Dự báo chuỗi thời gian tài chính bằng cách sử dụng máy vectơ hỗ trợ." Neurocomputing, Tập 55, Số 1, trang 307-19.
- Kolanovic, M. và R. Krishnamachari (2017): "Chiến lược dữ liệu lớn và AI: Phương pháp tiếp cận dữ liệu thay thế và học máy để đầu tư." Chiến lược định lượng và phái sinh của JP Morgan, tháng 5.
- Kolm, P., R. Tutuncu và F. Fabozzi (2010): "60 năm tối ưu hóa danh mục đầu tư." Tạp chí nghiên cứu hoạt động châu Âu, Tập 234, Số 2, trang 356-71.
- Krauss, C., X. Do, và N. Huck (2017): "Mạng nơ-ron sâu, cây tăng cường gradient, rừng ngẫu nhiên: Trọng tài thống kê trên S&P 500." Tạp chí nghiên cứu hoạt động châu Âu, Tập 259, Số 2, trang 689-702.
- Kuan, C., và L. Tung (1995): "Dự báo tỷ giá hối đoái bằng cách sử dụng mạng nơ-ron hồi quy và truyền thẳng." Tạp chí Kinh tế lượng ứng dụng, Tập 10, Số 4, trang 347-64.
- Kuhn, HW, và AW Tucker (1952): "Lập trình phi tuyến tính." Trong Biên bản báo cáo của Hội thảo Berkeley lần thứ 2. Nhà xuất bản Đại học California, trang 481-92.
- Laborda, R., và J. Laborda (2017): "Liệu các bộ phân loại có cấu trúc cây có thể mang lại giá trị cho nhà đầu tư không?" Finance Research Letters, Tập 22, trang 211-26.

- López de Prado, M. (2018): "Một giải pháp thực tế cho cuộc khủng hoảng kiểm tra nhiều lần trong nghiên cứu tài chính." Tạp chí khoa học dữ liệu tài chính, Tập 1, Số 1. Có sẵn tại <https://ssrn.com/abstract=3177057>
- López de Prado, M., và M. Lewis (2018): "Sự tự tin và sức mạnh của Tỷ lệ Sharpe trong Kiểm tra nhiều lần." Bài báo làm việc. Có tại <https://ssrn.com/abstract=3193697>
- MacKay, D. (2003): Lý thuyết thông tin, suy luận và thuật toán học tập. Ấn bản lần thứ 1. Nhà xuất bản Đại học Cambridge.
- Marcenko, V., và L. Pastur (1967): "Phân phối các giá trị riêng cho một số tập hợp ma trận ngẫu nhiên." Matematicheskii Sbornik, Tập 72, Số 4, trang 507-36.
- Michaud, R. (1998): Phân bổ tài sản hiệu quả: Hướng dẫn thực tế về tối ưu hóa danh mục đầu tư cổ phiếu và phân bổ tài sản. Boston: Nhà xuất bản Trường Kinh doanh Harvard.
- Nakamura, E. (2005): "Dự báo lạm phát bằng mạng nơ-ron nhân tạo." Thư kinh tế, Tập 86, Số 3, trang 373-78.
- Olson, D., và C. Mossman (2003): "Dự báo mạng nơ-ron về lợi nhuận cổ phiếu Canada bằng cách sử dụng tỷ lệ kế toán." Tạp chí dự báo quốc tế, Tập 19, Số 3, trang 453-65.
- Otto, M. (2016): Hóa học: Thống kê và ứng dụng máy tính trong hóa học phân tích. Ấn bản lần thứ 3. Wiley.
- Patel, J., S. Sha, P. Thakkar và K. Kotecha (2015): "Dự đoán biến động của cổ phiếu và chỉ số giá cổ phiếu bằng cách sử dụng kỹ thuật chuẩn bị dữ liệu xác định xu hướng và học máy." Hệ thống chuyên gia có ứng dụng, Tập 42, Số 1, trang 259-68.
- Pearl, J. (2009): "Suy luận nhân quả trong thống kê: Tổng quan." Thống kê Khảo sát, Tập 3, trang 96-146.
- Plerou, V., P. Gopikrishnan, B. Rosenow, L. Nunes Amaral, và H. Stanley (1999): "Các tính chất phổ biến và không phổ biến của tương quan chéo trong chuỗi thời gian tài chính." Physical Review Letters, Tập 83, Số 7, trang 1471-74.
- Porter, K. (2017): "Ước tính sức mạnh thống kê khi sử dụng nhiều quy trình thử nghiệm." Có tại www.mdrc.org/sites/default/files/PowerMultiplicity-IssueFocus.pdf
- Potter, M., JP Bouchaud và L. Laloux (2005): "Ứng dụng tài chính của lý thuyết ma trận ngẫu nhiên: Dây giầy cũ và mảnh mới." Acta Physica Polonica B, Tập 36, Số 9, trang 2767-84.
- Qin, Q., Q. Wang, J. Li và S. Shuzhi (2013): "Các mô hình giao dịch tuyến tính và phi tuyến tính với rừng ngẫu nhiên tăng cường gradient và ứng dụng vào thị trường chứng khoán Singapore." Tạp chí Hệ thống học tập thông minh và ứng dụng, Tập 5, Số 1, trang 1-10.

- Robert, C. (2014): "Về nghịch lý Jeffreys-Lindley." *Triết học khoa học*, Tập 81, Số 2, trang 216-32.
- Shafer, G. (1982): "Nghịch lý của Lindley." *Tạp chí Thống kê Hoa Kỳ Hiệp hội*, Tập 77, Số 378, trang 325-34.
- Simon, H. (1962): "Kiến trúc của sự phức tạp." *Biên bản của Hội Triết học Hoa Kỳ*, Tập 106, Số 6, trang 467-82.
- SINTEF (2013): "Dữ liệu lớn, dù tốt hay xấu: 90% dữ liệu của thế giới được tạo ra trong hai năm qua." *Science Daily*, ngày 22 tháng 5. Có tại www.sciencedaily.com/releases/2013/05/130522085217.htm
- Sorensen, E., K. Miller và C. Ooi (2000): "Phương pháp tiếp cận cây quyết định để lựa chọn cổ phiếu." *Tạp chí quản lý danh mục đầu tư*, Tập 27, Số 1, trang 42-52.
- Theofilatos, K., S. Likothanassis và A. Karathanasopoulos (2012): "Mô hình hóa và giao dịch tỷ giá hối đoái EUR/USD bằng các kỹ thuật học máy." *Nghiên cứu khoa học ứng dụng, công nghệ và kỹ thuật*, Tập 2, Số 5, trang 269-72.
- Trafalis, T., và H. Ince (2000): "Máy vectơ hỗ trợ cho hồi quy và ứng dụng trong dự báo tài chính." *Mạng nơ-ron*, Tập 6, Số 1, trang 348-53.
- Trippi, R., và D. DeSieno (1992): "Giao dịch hợp đồng tương lai chỉ số cổ phiếu bằng mạng nơ-ron." *Tạp chí quản lý danh mục đầu tư*, Tập 19, Số 1, trang 27-33.
- Tsai, C., và S. Wang (2009): "Dự báo giá cổ phiếu bằng các kỹ thuật học máy lai." *Biên bản báo cáo của Hội nghị quốc tế đa ngành của các kỹ sư và nhà khoa học máy tính*, Tập 1, Số 1, trang 755-60.
- Tsai, C., Y. Lin, D. Yen, và Y. Chen (2011): "Dự đoán lợi nhuận cổ phiếu theo nhóm phân loại." *Applied Soft Computing*, Tập 11, Số 2, trang 2452-59.
- Tsay, R. (2013): *Phân tích chuỗi thời gian đa biến: Với R và tài chính ứng dụng*. Ấn bản lần thứ 1. Wiley.
- Wang, J., và S. Chan (2006): "Khám phá quy tắc giao dịch trên thị trường chứng khoán bằng cách sử dụng cây quyết định thiên vị hai lớp." *Hệ thống chuyên gia có ứng dụng*, Tập 30, Số 4, trang 605-11.
- Wang, Q., J. Li, Q. Qin và S. Ge (2011): "Các mô hình giao dịch tuyến tính, thích ứng và phi tuyến tính cho thị trường chứng khoán Singapore với rừng ngẫu nhiên." *Trong Biên bản báo cáo Hội nghị quốc tế lần thứ 9 của IEEE về kiểm soát và tự động hóa*, trang 726-31.
- Wei, P., và N. Wang (2016): "Wikipedia và lợi nhuận cổ phiếu: Mẫu hình sử dụng Wikipedia giúp dự đoán biến động cổ phiếu riêng lẻ." *Trong Biên bản báo cáo Hội nghị quốc tế lần thứ 25 về World Wide Web*, Tập 1, trang 591-94.

Wooldridge, J. (2010): Phân tích kinh tế lượng của dữ liệu cắt ngang và dữ liệu bảng. Ấn bản lần 2. Nhà xuất bản MIT.

Wright, S. (1921): "Tương quan và nguyên nhân." Tạp chí Nông nghiệp Nghiên cứu, Tập 20, trang 557-85.

Żbikowski, K. (2015): "Sử dụng máy vectơ hỗ trợ có trọng số khối lượng với thử nghiệm Walk Forward và lựa chọn tính năng nhằm mục đích tạo ra chiến lược giao dịch chứng khoán." Hệ thống chuyên gia có ứng dụng, Tập 42, Số 4, trang 1797-1805.

Zhang, G., B. Patuwo và M. Hu (1998): "Dự báo bằng mạng nơ-ron nhân tạo: Tình trạng nghệ thuật." Tạp chí dự báo quốc tế, Tập. 14, số 1, trang 35-62.

Zhu, M., D. Philpotts và M. Stevenson (2012): "Những lợi ích của mô hình dựa trên cây để lựa chọn cổ phiếu." Tạp chí quản lý tài sản, Tập 13, Số 6, trang 437-48.

Zhu, M., D. Philpotts, R. Sparks và J. Stevenson (2011): "Một phương pháp tiếp cận kết hợp giữa CART và hồi quy logistic để xếp hạng cổ phiếu." Tạp chí quản lý danh mục đầu tư, Tập 38, Số 1, trang 100-109.

Tài liệu tham khảo

- Hiệp hội Thống kê Hoa Kỳ (2016): "Tuyên bố về Ý nghĩa Thống kê và Giá trị P." Có tại [www.amstat.org/asa/files/pdfs/P-ValueStatement .pdf](http://www.amstat.org/asa/files/pdfs/P-ValueStatement.pdf)
- Apley, D. (2016): "Hình dung các hiệu ứng của các biến dự báo trong các mô hình học có giám sát hộp đen." Có tại <https://arxiv.org/abs/1612.08468>
- Athey, Susan (2015): "Học máy và suy luận nhân quả để đánh giá chính sách." Trong Biên bản Hội nghị quốc tế lần thứ 21 của ACM SIGKDD về khám phá kiến thức và khai thác dữ liệu, trang 5-6. ACM.
- Bailey, D., và M. López de Prado (2012): "Tỷ lệ Sharpe hiệu quả Biên giới." Tạp chí Rủi ro, Tập 15, Số 2, trang 3-44.
- Bailey, D., và M. López de Prado (2013): "Một triển khai mã nguồn mở của thuật toán Critical-Line cho tối ưu hóa danh mục đầu tư." Algorithms, Tập 6, Số 1, trang 169-96. Có tại <http://ssrn.com/abstract=2197616> Bailey, D. và M.
- López de Prado (2014): "Tỷ lệ Sharpe giảm phát: Điều chỉnh độ lệch lựa chọn, quá trình kiểm tra ngược quá mức và không bình thường". Tạp chí Quản lý danh mục đầu tư, Tập 40, Số 5, trang 94-107.
- Bailey, D., J. Borwein, M. López de Prado và J. Zhu (2014): "Giả toán học và Lừa đảo tài chính: Tác động của Backtest Overfitting trên hiệu suất ngoài mẫu." Notices of the American Mathematical Society, Tập 61, Số 5, trang 458-71. Có tại [http://ssrn .com/abstract=2308659](http://ssrn.com/abstract=2308659)
- Black, F., và R. Litterman (1991): "Phân bổ tài sản kết hợp quan điểm của nhà đầu tư với cân bằng thị trường." Tạp chí thu nhập cố định, Tập 1, Số 2, trang 7-18.
- Black, F., và R. Litterman (1992): "Tối ưu hóa danh mục đầu tư toàn cầu." Tài chính Tạp chí phân tích, Tập 48, Số 5, trang 28-43.
- Breiman, L. (2001): "Rừng ngẫu nhiên." Học máy, Tập 45, Số 1, trang 5-32.
- Brian, E., và M. Jaisson (2007): "Physico-theology and Mathematics (1710-1794)." Trong The Descent of Human Sex Ratio at Birth. Springer Science & Business Media, trang 1-25.
- Brooks, C., và H. Kat (2002): "Các thuộc tính thống kê của lợi nhuận chỉ số quỹ đầu cơ và ý nghĩa của chúng đối với nhà đầu tư." Tạp chí đầu tư thay thế, Tập 5, Số 2, trang 26-44.

- Cavallo, A. và R. Rigobon (2016): "Dự án Tỷ giá: Sử dụng Giá trực tuyến để Đo lường và Nghiên cứu." NBER Working Paper 22111, tháng 3.
- CFTC (2010): "Những phát hiện liên quan đến các sự kiện thị trường ngày 6 tháng 5 năm 2010." Báo cáo của các nhân viên CFTC và SEC gửi đến Ủy ban cố vấn chung về các vấn đề quản lý môi nổi, ngày 30 tháng 9.
- Christie, S. (2005): "Tỷ lệ Sharpe có hữu ích trong phân bổ tài sản không?" Bài nghiên cứu MAFC 31. Trung tâm tài chính ứng dụng, Đại học Macquarie.
- Clarke, Kevin A. (2005): "Mối đe dọa ma quái: Sai lệch biến số bị bỏ sót trong nghiên cứu kinh tế lượng." Quản lý xung đột và khoa học hòa bình, Tập 22, Số 1, trang 341-52.
- Clarke, R., H. De Silva và S. Thorley (2002): "Những ràng buộc về danh mục đầu tư và Luật cơ bản của Quản lý chủ động." Tạp chí Phân tích tài chính, Tập 58, trang 48-66.
- Cohen, L. và A. Frazzini (2008): "Liên kết kinh tế và lợi nhuận có thể dự đoán được". Tạp chí Tài chính, Tập 63, Số 4, trang 1977-2011.
- De Miguel, V., L. Garlappi và R. Uppal (2009): "Sự đa dạng hóa tối ưu so với sự đa dạng hóa ngẫu nhiên: Chiến lược danh mục đầu tư 1/N kém hiệu quả đến mức nào?" Tạp chí Nghiên cứu Tài chính, Tập 22, trang 1915-53.
- Ding, C., và X. He (2004): "Phân cụm K-Means thông qua Phân tích thành phần chính." Trong Biên bản báo cáo của Hội nghị quốc tế lần thứ 21 về Học máy. Có tại [http://ranger.uta.edu/~chqding/papers/KmeansPCA1 .pdf](http://ranger.uta.edu/~chqding/papers/KmeansPCA1.pdf)
- Easley, D., M. López de Prado và M. O'Hara (2011a): "Độc tính của dòng chảy và tính thanh khoản trong thế giới tần số cao." Tạp chí nghiên cứu tài chính, Tập 25, Số 5, trang 1457-93.
- Easley, D., M. López de Prado và M. O'Hara (2011b): "Cấu trúc vi mô của 'Sự sụp đổ chớp nhoáng': Độc tính dòng chảy, Sự sụp đổ thanh khoản và Xác suất giao dịch có thông tin." Tạp chí Quản lý danh mục đầu tư, Tập 37, Số 2, trang 118-28.
- Efron, B. và T. Hastie (2016): Suy luận thống kê thời đại máy tính: Thuật toán, bằng chứng và khoa học dữ liệu. Ấn bản lần thứ 1. Nhà xuất bản Đại học Cambridge.
- Embrechts, P., C. Klueppelberg và T. Mikosch (2003): Mô hình hóa các sự kiện cực đoan. Ấn bản lần thứ 1. Springer.
- Goutte, C., P. Toft, E. Rostrup, F. Nielsen và L. Hansen (1999): "Về chuỗi thời gian fMRI phân cụm." Hình ảnh thần kinh, Tập. 9, số 3, trang 298-310.
- Grinold, R. và R. Kahn (1999): Quản lý danh mục đầu tư chủ động. Ấn bản lần thứ 2. Đồi McGraw.

- Gryak, J., R. Haralick và D. Kahrobaei (Sắp xuất bản): "Giải quyết vấn đề quyết định liên hợp thông qua học máy." Toán học thực nghiệm. Có tại <https://doi.org/10.1080/10586458.2018.1434704>
- Hacine-Gharbi, A. và P. Ravier (2018): "Công thức phân loại của Bi-histogram để ước tính entropy chung bằng cách giảm thiểu lỗi bình phương trung bình". Thư nhận dạng mẫu, Tập 101, trang 21-28.
- Hacine-Gharbi, A., P. Ravier, R. Harba và T. Mohamadi (2012): "Ước tính thông tin tương hỗ dựa trên biểu đồ histogram có độ lệch thấp để lựa chọn tính năng." Thư nhận dạng mẫu, Tập 33, trang 1302-8.
- Hamilton, J. (1994): Phân tích chuỗi thời gian. Ấn bản lần thứ 1. Nhà xuất bản Đại học Princeton.
- Harvey, C., Y. Liu, và C. Zhu (2016): "... và Mặt cắt ngang của Lợi nhuận kỳ vọng." Review of Financial Studies, Tập 29, Số 1, trang 5-68. Có tại <https://ssrn.com/abstract=2249314>
- Hodge, V., và J. Austin (2004): "Một cuộc khảo sát về các phương pháp phát hiện ngoại lệ." Artificial Intelligence Review, Tập 22, Số 2, trang 85-126.
- IDC (2014): "Vũ trụ số của các cơ hội: Dữ liệu phong phú và giá trị ngày càng tăng của Internet vạn vật." EMC Digital Universe với Nghiên cứu và Phân tích. Tháng 4. Có tại www.emc.com/leadership/digital-universe/2014view/index.htm
- Ingersoll, J., M. Spiegel, W. Goetzmann và I. Welch (2007): "Thao túng hiệu suất danh mục đầu tư và các biện pháp đo lường hiệu suất chống thao túng". Tạp chí Nghiên cứu Tài chính, Tập 20, Số 5, trang 1504-46.
- Jaynes, E. (2003): Lý thuyết xác suất: Logic của khoa học. Ấn bản lần thứ 1. Nhà xuất bản Đại học Cambridge.
- Jolliffe, I. (2002): Phân tích thành phần chính. Ấn bản lần 2. Springer.
- Kraskov, A., H. Stoeckbauer, và P. Grassberger (2008): "Ước tính thông tin tương hỗ." Bài báo làm việc. Có tại <https://arxiv.org/abs/cond-mat/0305641v1>
- Laloux, L., P. Cizeau, JP Bouchaud và M. Potters (2000): "Lý thuyết ma trận ngẫu nhiên và tương quan tài chính." Tạp chí quốc tế về tài chính lý thuyết và ứng dụng, Tập 3, Số 3, trang 391-97.
- Ledoit, O., và M. Wolf (2004): "Một ước lượng có điều kiện tốt cho các ma trận hiệp phương sai chiều lớn." Tạp chí phân tích đa biến, Tập 88, Số 2, trang 365-411.
- Lewandowski, D., D. Kurowicka và H. Joe (2009): "Tạo ma trận tương quan ngẫu nhiên dựa trên phương pháp Vines và Extended Onion." Tạp chí Phân tích Đa biến, Tập 100, trang 1989-2001.
- Liu, Y. (2004): "Một nghiên cứu so sánh về các phương pháp lựa chọn tính năng để khám phá thuốc." Tạp chí thông tin và mô hình hóa hóa học, Tập 44, Số 5, trang 1823-28. Có tại <https://pubs.acs.org/doi/abs/10.1021/ci049875d>

- Lo, A. (2002): "Thống kê tỷ lệ Sharpe." Tạp chí phân tích tài chính, tháng 7, trang 36-52.
- Lochner, M., J. McEwen, H. Peiris, O. Lahav, và M. Winter (2016): "Phân loại siêu tân tinh quang trắc với máy học." Tạp chí Astrophysical Journal, Tập 225, Số 2. Có tại <http://iopscience.iop.org/article/10.3847/0067-0049/225/2/31/meta>
- López de Prado, M. (2016): "Xây dựng danh mục đầu tư đa dạng vượt trội so với danh mục đầu tư ngoài mẫu." Tạp chí quản lý danh mục đầu tư, Tập 42, Số 4, trang 59-69.
- López de Prado, M. (2018a): Những tiến bộ trong học máy tài chính. Ấn bản lần thứ 1. Wiley.
- López de Prado, M. (2018b): "10 lý do khiến hầu hết các quỹ học máy thất bại." Tạp chí quản lý danh mục đầu tư, Tập 44, Số 6, trang 120-33.
- López de Prado, M. (2019a): "Giải pháp khoa học dữ liệu cho cuộc khủng hoảng kiểm tra nhiều lần trong nghiên cứu tài chính." Tạp chí khoa học dữ liệu tài chính, Tập 1, Số 1, trang 99-110.
- López de Prado, M. (2019b): "Beyond Econometrics: A Roadmap toward Financial Machine Learning." Bài báo làm việc. Có tại <https://ssrn.com/abstract=3365282>
- López de Prado, M. (2019c): "Mười ứng dụng của Financial Machine Learning." Bài báo làm việc. Có tại <https://ssrn.com/abstract=3365271>
- López de Prado, M. và M. Lewis (2018): "Phát hiện các chiến lược đầu tư sai lầm bằng phương pháp học không giám sát." Bài báo nghiên cứu. Có sẵn tại <https://ssrn.com/abstract=3167017>
- Louppe, G., L. Wehenkel, A. Suter và P. Geurts (2013): "Hiểu tầm quan trọng của biến đổi trong rừng cây ngẫu nhiên." Trong Biên bản báo cáo Hội nghị quốc tế lần thứ 26 về Hệ thống xử lý thông tin thần kinh, trang 431-39.
- Markowitz, H. (1952): "Lựa chọn danh mục đầu tư." Tạp chí Tài chính, Tập 7, trang 77-91.
- Meila, M. (2007): "So sánh các cụm - Khoảng cách dựa trên thông tin." Tạp chí Phân tích Đa biến, Tập 98, trang 873-95.
- Mertens, E. (2002): "Phương sai của ước lượng IID trong Lo (2002)." Làm việc bài báo, Đại học Basel.
- Molnar, C. (2019): "Interpretable Machine Learning: Hướng dẫn để làm cho các mô hình hộp đen có thể giải thích được." Có tại <https://christophm.github.io/interpretable-ml-book/>
- Mullainathan, S., và J. Spiess (2017): "Học máy: Một phương pháp tiếp cận kinh tế lượng ứng dụng." Tạp chí triển vọng kinh tế, Tập 31, Số 2, trang 87-106.

- Neyman, J., và E. Pearson (1933): "IX. Về vấn đề kiểm tra hiệu quả nhất các giả thuyết thống kê." *Philosophical Transactions of the Royal Society, Series A*, Tập 231, Số 694-706, trang 289-337.
- Opdyke, J. (2007): "So sánh tỷ lệ Sharpe: Vậy giá trị p ở đâu?"
 Tạp chí Quản lý Tài sản, Tập 8, Số 5, trang 308-36.
- Parzen, E. (1962): "Về ước tính hàm mật độ xác suất và chế độ." *Biên niên sử thống kê toán học*, Tập 33, Số 3, trang 1065-76.
- Resnick, S. (1987): *Giá trị cực đại, Biến thể thường xuyên và Quá trình điểm*. 1st biên tập. Springer.
- Romer, P. (2016): "Rắc rối với Kinh tế vĩ mô." *Tạp chí American Nhà kinh tế học*, ngày 14 tháng 9.
- Rosenblatt, M. (1956): "Nhận xét về một số ước tính phi tham số của hàm mật độ." *Biên niên sử thống kê toán học*, Tập 27, Số 3, trang 832-37.
- Rousseeuw, P. (1987): "Hình bóng: Một công cụ hỗ trợ đồ họa cho việc diễn giải và xác thực Phân tích cụm." *Toán học tính toán và ứng dụng*, Tập 20, trang 53-65.
- Schlecht, J., M. Kaplan, K. Barnard, T. Karafet, M. Hammer và N. Merchant (2008): "Các phương pháp tiếp cận học máy để phân loại nhóm đơn bội từ dữ liệu STR nhiễm sắc thể Y." *PLOS Computational Biology*, Tập 4, Số 6.
 Có sẵn tại <https://doi.org/10.1371/journal.pcbi.1000093>
- Sharpe, W. (1966): "Hiệu suất quỹ tương hỗ." *Tạp chí kinh doanh*, Tập 39, Số 1, trang 119-38.
- Sharpe, W. (1975): "Điều chỉnh rủi ro trong đo lường hiệu suất danh mục đầu tư." *Tạp chí quản lý danh mục đầu tư*, Tập 1, Số 2, trang 29-34.
- Sharpe, W. (1994): "Tỷ lệ Sharpe." *Tạp chí Quản lý danh mục đầu tư*, Tập 21, Số 1, trang 49-58.
- Šidák, Z. (1967): "Các vùng tin cậy hình chữ nhật cho các giá trị trung bình của phân phối chuẩn đa biến." *Tạp chí của Hiệp hội thống kê Hoa Kỳ*, Tập 62, Số 318, trang 626-33.
- Solow, R. (2010): "Xây dựng khoa học kinh tế cho thế giới thực."
 Bản tuyên bố được chuẩn bị của Robert Solow, Giáo sư danh dự, MIT, trước Ủy ban Khoa học và Công nghệ Hạ viện, Tiểu ban Điều tra và Giám sát, ngày 20 tháng 7.
- Steinbach, M., E. Levent, và V. Kumar (2004): "Những thách thức của việc nhóm dữ liệu chiều cao." Trong L. Wille (biên tập), *New Directions in Statistical Physics*. Ấn bản lần thứ 1. Springer, trang 273-309.
- Štrumbelj, E., và I. Kononenko (2014): "Giải thích các mô hình dự đoán và dự đoán cá nhân với các đóng góp đặc điểm." *Hệ thống kiến thức và thông tin*, Tập 41, Số 3, trang 647-65.

- Varian, H. (2014): "Dữ liệu lớn: Những thủ thuật mới cho Kinh tế lượng." Tạp chí Triển vọng Kinh tế, Tập 28, Số 2, trang 3-28.
- Wasserstein, R., A. Schirm và N. Lazar (2019): "Chuyển đến một thế giới vượt ra ngoài $p < 0,05$." Tạp chí Thống kê Hoa Kỳ, Tập 73, Số 1, trang 1-19.
- Wasserstein, R. và N. Lazar (2016): "Tuyên bố của ASA về giá trị p: Bối cảnh, quy trình và mục đích." The American Statistician, Tập 70, trang 129-33.
- Witten, D., A. Shojaie và F. Zhang (2013): "Mạng đàn hồi cụm cho hồi quy chiều cao với nhóm biến không xác định." Technometrics, Tập 56, Số 1, trang 112-22.

Lời cảm ơn

Giáo sư Riccardo Rebonato đã vui lòng mời tôi xuất bản Element này trong loạt bài mà ông biên tập cho Cambridge Elements in Quantitative Finance. Giáo sư Frank Fabozzi đã đưa ra những gợi ý quan trọng về nội dung và phạm vi của Element. Nhiều kỹ thuật được giới thiệu trong Element này đã được thử nghiệm trong quá trình làm việc của tôi tại Phòng thí nghiệm quốc gia Lawrence Berkeley, mà tôi đặc biệt biết ơn Giáo sư Horst Simon và Tiến sĩ Kesheng Wu. Cuối cùng, tôi muốn ghi nhận khoảng ba mươi đồng tác giả của mình trong hai mươi năm qua, vì sự ủng hộ và nguồn cảm hứng bền bỉ của họ.

Về tác giả

Marcos M. López de Prado là giáo sư thực hành tại Khoa Kỹ thuật của Đại học Cornell và là CIO của True Positive Technologies (TPT). Tiến sĩ López de Prado có hơn 20 năm kinh nghiệm trong việc phát triển các chiến lược đầu tư với sự trợ giúp của các thuật toán học máy và siêu máy tính. Năm 2019, ông đã nhận được giải thưởng 'Quant of the Year Award' từ Tạp chí Quản lý danh mục đầu tư. Để biết thêm thông tin, hãy truy cập www.QuantResearch.org

Tài chính định lượng

Riccardo Rebonato

Trưởng Kinh doanh EDHEC

Biên tập viên Riccardo Rebonato là Giáo sư Tài chính tại Trưởng Kinh doanh EDHEC và giữ chức Chủ tịch Nghiên cứu PIMCO cho Viện Rủi ro EDHEC. Trước đây, ông đã giữ các vị trí học thuật tại Imperial College, London và Đại học Oxford và là Trưởng phòng Thu nhập cố định và Phân tích FX toàn cầu tại PIMCO, và Trưởng phòng Nghiên cứu, Quản lý Rủi ro và Giao dịch phái sinh tại một số ngân hàng quốc tế lớn. Trước đây, ông đã từng là thành viên Hội đồng quản trị của ISDA và GARP, và hiện đang là thành viên Hội đồng quản trị của Giải thưởng Nine Dot. Ông là tác giả của một số cuốn sách và bài báo về tài chính và quản lý rủi ro, bao gồm Định giá trái phiếu và Mô hình đường cong lợi suất (2017, Nhà xuất bản Đại học Cambridge).

Về Series Cambridge

Elements in Quantitative Finance hướng đến phạm vi bao quát rộng rãi về tất cả các chủ đề chính trong lĩnh vực này. Được viết ở cấp độ phù hợp với sinh viên đại học hoặc sau đại học và các học viên nâng cao, Elements kết hợp các báo cáo về nghiên cứu gốc bao gồm lĩnh vực chuyên môn cá nhân của tác giả, hướng dẫn và lớp học nâng cao về các phương pháp luận mới nổi và đánh giá các tài liệu quan trọng nhất.

Cambridge Elements[≡]

Tài chính định lượng

Các yếu tố trong Series

Học máy cho các nhà quản lý tài
sản Marcos M. López de Prado

Danh sách đầy đủ các series có tại: www.cambridge.org/EQF